

---

---

# 机器学习的统计力学

## STATISTICAL-MECHANICS OF MACHINE LEARNING

---

---

作者: YUXUAN ZENG 

[florian@whu.edu.cn](mailto:florian@whu.edu.cn)

WUHAN UNIVERSITY  
No. 8, S. DONGHU RD., WUCHANG DIST., WUHAN 430072, HUBEI PROV., PR. CHINA.

# 目录

|                      |           |
|----------------------|-----------|
| 目录                   | I         |
| 插图                   | V         |
| 表格                   | IX        |
| <b>第一章 入门</b>        | <b>1</b>  |
| 1.1 人工神经网络           | 1         |
| 1.2 一个简单例子           | 3         |
| 1.3 一般设定             | 6         |
| 1.4 习题               | 8         |
| <b>第二章 感知机学习：基础</b>  | <b>10</b> |
| 2.1 Gibbs 学习         | 10        |
| 2.2 退火近似             | 13        |
| 2.3 Gardner 分析       | 15        |
| 2.4 小结               | 17        |
| 2.5 习题               | 19        |
| <b>第三章 学习规则的选择</b>   | <b>21</b> |
| 3.1 Hebb 规则          | 21        |
| 3.2 感知机规则            | 23        |
| 3.3 伪逆规则             | 23        |
| 3.4 Adaline 规则       | 24        |
| 3.5 最大稳定性            | 25        |
| 3.6 Bayes 规则         | 26        |
| 3.7 小结               | 29        |
| 3.8 习题               | 29        |
| <b>第四章 扩展的统计力学表述</b> | <b>31</b> |
| 4.1 最大稳定性            | 31        |
| 4.2 非零温度下的 Gibbs 学习  | 33        |
| 4.3 一般统计力学表述         | 36        |
| 4.4 重新审视学习规则         | 37        |
| 4.5 最优势              | 40        |
| 4.6 小结               | 41        |
| 4.7 习题               | 41        |

|                            |           |
|----------------------------|-----------|
| <b>第五章 含噪教师</b>            | <b>44</b> |
| 5.1 噪声来源                   | 44        |
| 5.2 尝试完美学习                 | 46        |
| 5.3 带错误学习                  | 50        |
| 5.4 改进                     | 51        |
| 5.5 小结                     | 52        |
| 5.6 习题                     | 53        |
| <b>第六章 存储问题</b>            | <b>55</b> |
| 6.1 存储容量                   | 55        |
| 6.2 二分法计数: Cover 分析        | 57        |
| 6.3 Galileo 式拼贴: Ising 感知机 | 60        |
| 6.4 稳定性分布                  | 64        |
| 6.5 超过存储容量之后               | 66        |
| 6.6 习题                     | 68        |
| <b>第七章 不连续学习</b>           | <b>71</b> |
| 7.1 光滑网络                   | 71        |
| 7.2 Ising 感知机              | 72        |
| 7.3 反楔形感知机                 | 74        |
| 7.4 不连续学习的动力学              | 76        |
| 7.5 小结                     | 79        |
| 7.6 习题                     | 79        |
| <b>第八章 无监督学习</b>           | <b>81</b> |
| 8.1 有监督学习与无监督学习            | 81        |
| 8.2 随机性的欺骗                 | 84        |
| 8.3 学习对称性破缺方向              | 86        |
| 8.4 通过竞争学习聚类               | 89        |
| 8.5 通过调节温度聚类               | 92        |
| 8.6 讨论                     | 94        |
| 8.7 习题                     | 95        |
| <b>第九章 在线学习</b>            | <b>97</b> |
| 9.1 随机梯度下降                 | 97        |
| 9.2 具体例子                   | 99        |
| 9.3 最优在线学习                 | 101       |
| 9.4 具有光滑传递函数的感知机           | 103       |
| 9.5 查询                     | 104       |
| 9.6 无监督在线学习                | 107       |
| 9.7 自然梯度                   | 109       |
| 9.8 讨论                     | 110       |

|                             |            |
|-----------------------------|------------|
| 9.9 习题                      | 111        |
| <b>第十章 与统计学建立联系</b>         | <b>114</b> |
| 10.1 频率到概率的收敛               | 114        |
| 10.2 Sauer 引理               | 115        |
| 10.3 Vapnik–Chervonenkis 定理 | 116        |
| 10.4 与统计力学的比较               | 117        |
| 10.5 Cramer–Rao 不等式         | 120        |
| 10.6 讨论                     | 121        |
| 10.7 习题                     | 122        |
| <b>第十一章 鸟瞰：多重分形</b>         | <b>124</b> |
| 11.1 破碎的耦合空间                | 124        |
| 11.2 感知机的多重分形谱              | 125        |
| 11.3 内部表示的多重分形组织            | 130        |
| 11.4 讨论                     | 132        |
| 11.5 习题                     | 133        |
| <b>第十二章 多层网络</b>            | <b>135</b> |
| 12.1 基本结构                   | 135        |
| 12.2 界                      | 138        |
| 12.3 存储问题                   | 140        |
| 12.4 奇偶树的泛化                 | 143        |
| 12.5 委员会树的泛化                | 144        |
| 12.6 全连接委员会机                | 147        |
| 12.7 小结                     | 148        |
| 12.8 习题                     | 149        |
| <b>第十三章 多层网络中的在线学习</b>      | <b>152</b> |
| 13.1 委员会树                   | 152        |
| 13.2 奇偶树                    | 155        |
| 13.3 软委员会机                  | 157        |
| 13.4 反向传播                   | 160        |
| 13.5 贝叶斯在线学习                | 162        |
| 13.6 讨论                     | 163        |
| 13.7 习题                     | 163        |
| <b>第十四章 还有什么？</b>           | <b>165</b> |
| 14.1 支持向量机                  | 165        |
| 14.2 复杂优化                   | 167        |
| 14.3 纠错码                    | 169        |
| 14.4 博弈论                    | 171        |

|                                           |     |
|-------------------------------------------|-----|
| 附录 A 基础数学                                 | 174 |
| A1.1 Gaussian 积分 . . . . .                | 174 |
| A1.2 Jensen 不等式 . . . . .                 | 175 |
| A1.3 $\delta$ -函数与 $\theta$ -函数 . . . . . | 175 |
| A1.4 鞍点法 . . . . .                        | 177 |
| 附录 B Gardner 分析                           | 179 |
| 附录 C 感知机规则的收敛性                            | 185 |
| 附录 D 复本对称鞍点的稳定性                           | 186 |
| 附录 E 一步复本对称破缺                             | 193 |
| 附录 F 空腔方法                                 | 196 |
| 附录 G VC 定理                                | 200 |
| 参考文献                                      | 202 |
| 索引                                        | 215 |

# 插图

|     |                                                                                                                                                                                               |    |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1.1 | 形式神经网络的不同类型。a: 一般结构; b: 全连接吸引子神经网络; c: 具有一个隐藏层的前馈网络; d: 单层感知机。 . . . . .                                                                                                                      | 2  |
| 1.2 | 用于给二进制数排序的简单感知机。 . . . . .                                                                                                                                                                    | 3  |
| 1.3 | 用于给二进制数排序的感知机的完美耦合图示, 如式 (1.4) 所给。 $J_1, \dots, J_{10}$ (白色) 为正, $J_{11}, \dots, J_{20}$ (黑色) 为负。 . . . . .                                                                                   | 4  |
| 1.4 | 用于给二进制数排序的感知机从样例学习时, 泛化误差的模拟结果 (圆点)。结果对训练集的 1000 次实现取平均, 统计误差小于符号尺寸。实线给出淬火计算的解析结果, 虚线给出退火近似的结果。二者将在第二章详细讨论。 . . . . .                                                                         | 5  |
| 1.5 | 学习 50 个样例 (左) 和 200 个样例 (右) 后, 感知机耦合的图示。柱子的符号表示相应耦合是否与图 1.3 中的完美耦合同号。 . . . . .                                                                                                               | 5  |
| 2.1 | 输入空间在教师和学生耦合向量张成平面上的投影。投影落在阴影区域中的输入会被学生错误分类。 . . . . .                                                                                                                                        | 11 |
| 2.2 | 式 (2.6) 方括号中的表达式作为 $\varepsilon$ 的函数; $\alpha = 0, 1, 2, 3, 4, 5$ , 曲线从上到下排列。 . . . . .                                                                                                       | 12 |
| 2.3 | 教师-学生重叠 $R$ (虚线) 和泛化误差 $\varepsilon$ (实线) 随训练集大小 $\alpha$ 的变化。插图显示每个耦合的淬火熵随 $\alpha$ 增加而下降。点线给出习题 2.9 中要确定的信息增益 $\Delta I$ 的行为。 . . . . .                                                     | 18 |
| 3.1 | 版本空间的示意图。呈现一个新样例时, 版本空间被分成相对大小为 $P$ 和 $1 - P$ 的两个区域。 . . . . .                                                                                                                                | 28 |
| 3.2 | 把表示版本空间的多边形二等分的直线集合并不经过同一点。因此, 不存在一个单一点, 使得对所有可能直线而言它都位于较大区域中。 . . . . .                                                                                                                      | 28 |
| 4.1 | 保证稳定性大于 $\kappa$ 的那部分版本空间的示意图。随着 $\kappa$ 增大, 该区域越来越小, 最终收缩到由黑点表示的点 $\mathbf{J}_{MS}$ , 这意味着在 $\kappa = \kappa_{opt}$ 时 $q = 1$ 。注意, 如第 3.5 节所讨论的, 图中只有一部分直线是主动约束。 . . . . .                  | 31 |
| 4.2 | 非零温度 Gibbs 学习中, 泛化误差 (实线) 和训练误差 (虚线) 作为训练集大小 $\alpha$ 的函数; 温度取 $T = 0.2, 0.5, 0.8$ (从下到上)。作为比较, 点线给出 $T = 0$ 时的泛化误差。 . . . . .                                                                | 35 |
| 4.3 | 泛化误差 $\varepsilon$ 作为训练集大小 $\alpha$ 的函数: Hebb 规则 (虚线)、零温 Gibbs 学习 (点划线)、adaline/伪逆规则 (长虚线)、由 adatron 规则等得到的最大稳定向量 (点线) 以及 Bayes 规则 (实线)。 $\alpha \rightarrow \infty$ 时的渐近行为列于表 4.1。 . . . . . | 39 |
| 5.1 | 临界训练集大小 $\alpha_c$ : 当训练集大于它时, 不再能找到完全重现所有样例的学生。实线为强度由 (5.9) 定义的输入噪声或权重噪声结果; 虚线为由参数 $a$ 刻画的输出噪声结果, 见 (5.4)。 . . . . .                                                                         | 47 |

|     |                                                                                                                                                                                                                               |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.2 | 在强度 $\gamma = 0.8$ 的输入噪声或权重噪声存在时，零温 $T = 0$ Gibbs 学习的泛化误差、训练误差以及序参量随训练集大小 $\alpha$ 的变化。实线表示泛化误差，长虚线表示训练误差，点划线表示 $R$ ，虚线表示 $q$ 。竖直点线标出临界训练集大小 $\alpha_c$ 。插图放大了 $\alpha_c$ 附近的 $\epsilon(\alpha)$ 曲线，显示临界性之前的过拟合。 . . . . .    | 48 |
| 5.3 | 在强度 $a = 0.8$ 的输出噪声存在时，零温 $T = 0$ Gibbs 学习的泛化误差、训练误差以及序参量随训练集大小 $\alpha$ 的变化。实线表示泛化误差，长虚线表示训练误差，点划线表示 $R$ ，虚线表示 $q$ 。竖直点线标出临界训练集大小 $\alpha_c$ 。插图放大了 $\alpha_c$ 附近的 $\epsilon(\alpha)$ 曲线，显示临界性之前的过拟合。 . . . . .              | 49 |
| 5.4 | 在参数 $a = 0.8$ 的输出噪声存在时，温度 $T = 0.2$ 的 Gibbs 学习中，泛化误差、训练误差以及序参量随训练集大小 $\alpha$ 的变化。实线表示泛化误差，长虚线表示训练误差，点划线表示 $R$ ，虚线表示 $q$ 。 . . . . .                                                                                          | 51 |
| 5.5 | 在参数 $a = 0.8$ 的输出噪声存在时， $T = 0$ Gibbs 学习（虚线）与 $T = 0.2$ Gibbs 学习（实线）的泛化误差和训练误差随训练集大小 $\alpha$ 的变化。 . . . . .                                                                                                                  | 52 |
| 6.1 | 不同 $\alpha$ 下解体积 $\Omega$ （阴影区域）的示意图。图中还画出了两个可能的耦合向量 $J^1$ 和 $J^2$ ，它们的典型重叠由 $q$ 描述。当 $\alpha$ 接近存储容量 $\alpha_c$ 时，有 $q \rightarrow 1$ 且 $\Omega \rightarrow 0$ 。 . . . . .                                                   | 57 |
| 6.2 | 感知机的存储容量 $\alpha_c$ 作为 (6.4) 中定义的稳定性参数 $\kappa$ 的函数。 . . . . .                                                                                                                                                                | 58 |
| 6.3 | 二维中三个点的两种不同着色。左图给出一个二分法，并画出一个可能的分离超平面。右图中，不存在过原点且能把黑点与白点分开的直线。 . . . . .                                                                                                                                                      | 58 |
| 6.4 | 加入一个新点（方块）时，二分法数 $C(p, N)$ 的变化。(a) 新点必须染为白色，二分法数不增加。(b) 存在一个经过新点、同时分开旧点的超平面。因此，只需稍微旋转这个超平面（点线），新点的两种着色就都线性可分，二分法数因此增加 1。 . . . .                                                                                              | 59 |
| 6.5 | 随机着色 $N$ 维中 $p$ 个点成为二分法的概率，作为 $p/N$ 的函数；这里 $N = 5$ （大点）、 $N = 50$ （小点）以及 $N = 500$ （线），均由 (6.18) 确定。 . . . . .                                                                                                                | 60 |
| 6.6 | Gardner 球面一部分的示意图，它包含 $N$ 维超立方体的四个角，对应于 Ising 感知机可能的耦合向量。灰色区域表示球形感知机的解空间。它总是凸的，因此也是连通的。(a) 一般解体积中所含的两个 Ising 感知机解由超立方体的一条边连接。(b) 沿超立方体的边从一个 Ising 解走到另一个 Ising 解时，无法不离开解体积。因此，Ising 感知机的解空间未必连通，这可能使复本对称鞍点不稳定。 . . . . .      | 62 |
| 6.7 | 由 (6.39) 给出的稳定性分布 $P(\Delta)$ ，其中 $\alpha = 1.0$ 、 $\kappa = 0.3$ 。初始 Gaussian 分布 (6.32) 中对应于稳定性大于 $\kappa$ 的部分不受学习过程改变，而所有小于 $\kappa$ 的稳定性都被移动到 $\Delta = \kappa$ 处的 $\delta$ 峰上。图中该峰的高度等于 (6.39) 中 $\delta$ 函数的前因子。 . . . . | 66 |
| 6.8 | 过饱和感知机的稳定性分布 $P(\Delta)$ ，其中 $\alpha = 1.0$ 、 $\kappa = 0.7$ 。点线给出复本对称表达式 (6.43)，实线是一阶复本对称破缺结果 [62]。分布中的间隙是只计数错误的代价函数的典型特征；间隙左边界处的跳跃会使复本对称性不稳定 [75, 83]。 . . . . .                                                            | 67 |
| 6.9 | 带随机着色的 200 维空间中 250 个随机点，在两个不同二维平面上的投影。 . . . .                                                                                                                                                                               | 68 |
| 7.1 | Ising 感知机学习中的泛化误差与淬火熵 . . . . .                                                                                                                                                                                               | 73 |
| 7.2 | 反楔形感知机的非单调激活函数 . . . . .                                                                                                                                                                                                      | 74 |
| 7.3 | 反楔形感知机的泛化误差 . . . . .                                                                                                                                                                                                         | 76 |
| 7.4 | Ising 反楔形感知机的退火熵 . . . . .                                                                                                                                                                                                    | 77 |
| 8.1 | 有监督问题对应的非均匀分布示例 . . . . .                                                                                                                                                                                                     | 83 |

|                                                                                                                                                                                                                                                    |     |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 8.2 随机样例的对齐场分布 . . . . .                                                                                                                                                                                                                           | 84  |
| 8.3 竞争学习聚类示意图 . . . . .                                                                                                                                                                                                                            | 90  |
| 8.4 竞争学习的对齐场分布等高线 . . . . .                                                                                                                                                                                                                        | 91  |
| 8.5 温度调节聚类中的簇中心解 . . . . .                                                                                                                                                                                                                         | 94  |
| 9.1 不同在线情景中的泛化误差 . . . . .                                                                                                                                                                                                                         | 100 |
| 9.2 最优对齐幅度 . . . . .                                                                                                                                                                                                                               | 103 |
| 10.1 左：学生空间的三维示意图。图中画出了与教师 $\mathbf{T}$ 的重叠固定为 $R > 0$ 与 $R < 0$ 的两个环。若将一个模式 $\xi$ 加入训练集，与它垂直的平面会切去这些环中与教师分类不相容的部分。右：若 $R < 0$ ，两个模式总会留下环中的一个连通部分；而对于 $R > 0$ ，属于版本空间的环部分可能不连通。这会导致 $R > 0$ 时的复本对称性破缺。 . . . . .                                   | 118 |
| 10.2 版本空间中最差学生的重叠 $R_{\min}$ 随训练集大小 $\alpha$ 的变化：实线为复本对称结果，虚线为一步复本对称性破缺结果。修正始终很小。插图显示版本空间中最差学生的泛化误差（实线）、典型学生的泛化误差（点线），以及由 VC 定理得到的上界 $\epsilon^{\text{VC}}$ （虚线）。 . . . . .                                                                        | 119 |
| 11.1 由 $p = 4$ 个样例对具有 $N = 3$ 个输入的球形感知机耦合空间作出的随机划分。注意这里只生成了 $14 < 2^4$ 个胞元。阴影部分是一对镜像胞元，对应于变换 $(\mathbf{J}, \sigma) \mapsto (-\mathbf{J}, -\sigma)$ 。 . . . . .                                                                                     | 124 |
| 11.2 球形感知机的胞元大小分布所对应的多重分形谱 $c(k)$ 。图中 $\alpha = 0.2, 0.35, 0.5, 1.0, 2.0$ （从左到右），结果来自复本对称 ansatz。圆点标出各曲线的最大值；菱形左侧的结果对复本对称性破缺不稳定。点线部分对应于自由能 (11.11) 奇异的区域，见正文。 . . . . .                                                                            | 127 |
| 11.3 Ising 感知机的胞元大小分布所对应的多重分形谱 $c(k)$ 。图中 $\alpha = 0.2, 0.4, 0.833, 1.245, 1.4$ （从左到右），结果来自复本对称 ansatz。圆点标出各曲线的最大值；菱形左侧的结果对复本对称性破缺不稳定。点线部分对应于自由能 (11.11) 奇异的区域，见正文。对 $\alpha = 1.4$ ，谱的连续部分在三角形处终止，并由正方形标出的孤立点 $(\ln 2, \ln 2)$ 补全。 . . . . .     | 129 |
| 11.4 反楔形感知机的 Gardner 体积分解为不同内部表示所对应胞元时的多重分形谱。这里 $\gamma = 1$ ， $\alpha = 0.1, 0.5, 1.0, 2.0$ ，以及 $\alpha = \alpha_{\text{disc}} \sim 3.0$ 和 $\alpha = \alpha_c \sim 4.6$ （从左到右）。负斜率部分以点线表示；虚线对应于 $c$ 的负值。圆圈标出主导总 Gardner 体积的胞元大小 $k_1$ 。 . . . . . | 132 |
| 12.1 具有一个隐层的多层网络的全连接结构（左）与树结构（右）。 . . . . .                                                                                                                                                                                                        | 136 |
| 12.2 输入空间按照奇偶机（左）和委员会机（右）输出所作的划分；两者都有 $K = 3$ 个隐单元且各自阈值非零。 . . . . .                                                                                                                                                                               | 138 |
| 12.3 $N = 2$ 维中两组 $p = 6$ 个输入。白圈（黑圈）表示正（负）输出。左图所示标记无法由 $K = 2$ 奇偶机实现；但若输入的相对取向如右图，则所有标记都能由这样的机器实现。 . . . . .                                                                                                                                       | 138 |
| 12.4 树结构奇偶机的泛化误差随训练集大小的变化；隐单元数 $K = 2, 3, 4, 5, 6, 7$ （从左到右）。结果来自 annealed 近似 (12.13)。 . . . . .                                                                                                                                                   | 140 |
| 12.5 树结构奇偶机的泛化误差随训练集大小的变化；隐单元数 $K = 2, 3, 4, 5, 6, 7$ （从左到右）。结果来自对 (12.35) 的数值极值化。 . . . . .                                                                                                                                                       | 144 |



|                                                                                                                                                                                        |     |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----|
| 12.6 奇偶树中非平凡泛化不连续转变发生的训练集大小 $\alpha_d$ , 作为隐单元数 $K$ 的函数。圆点来自 quenched 理论 (12.35), 三角形来自 annealed 近似 (12.13)。直线描述存储容量的渐近行为 (12.15)。                                                     | 145 |
| 12.7 树结构委员会机的泛化误差随训练集大小的变化, 取无限多隐单元极限 $K \rightarrow \infty$ (实线)。图中还给出 annealed 近似在 $K \rightarrow \infty$ 时的结果 (长虚线)、 $K = 3$ 时的结果 (虚线), 以及对应于 $K = 1$ 的感知机结果 (点划线)。细线是渐近结果 (12.41)。 | 147 |
| 13.1 树结构委员会机的泛化误差                                                                                                                                                                      | 154 |
| 13.2 最优学习幅度的缩放形式                                                                                                                                                                       | 155 |
| 13.3 软委员会机的泛化误差                                                                                                                                                                        | 159 |

# 表格

|     |                                                                                                    |    |
|-----|----------------------------------------------------------------------------------------------------|----|
| 4.1 | 各种学习规则对应的代价函数势以及训练集大小 $\alpha$ 很大时泛化误差 $\varepsilon$ 的渐近行为。<br>较小 $\alpha$ 下的泛化表现见图 4.3。 . . . . . | 40 |
|-----|----------------------------------------------------------------------------------------------------|----|

# 第一章 入门

本章介绍在统计力学框架内研究学习问题所需的基本概念。我们还将通过一个非常简单情形的数值分析，展示从样例学习的效率。由这个例子作推广，我们将给出学习问题在统计力学中的基本设定；在后续各章中，这一设定会以多种变体反复出现。

## 1.1 人工神经网络

学习的统计力学主要是为所谓形式神经元组成的网络发展起来的。这些网络的目标，是在具有相似结构的人工系统中，对生物神经网络的一些基本信息处理能力建模。形式神经元是这些人工神经网络的微观构件，50 多年前由 McCulloch 和 Pitts 引入，作为生物神经元的极端简化模型 [1]。它们是双稳态的线性阈值元件，或者处于活动状态，或者处于静息状态；下文用二值变量  $S = \pm 1$  表示。给定神经元  $i$  的状态  $S_i$  会随时间改变，因为它通过突触耦合  $J_{ij}$  接收来自“外部世界”或其他神经元  $j$  的信号。

更确切地说，神经元  $i$  将所有其他神经元传入的活动按相应突触耦合强度加权求和，得到突触后电位  $\sum_j J_{ij} S_j$ ，并将结果与该神经元特有的阈值  $\theta_i$  比较。如果突触后电位超过阈值，该神经元在下一时间步处于活动状态；否则处于静息状态：

$$S_i(t+1) = \text{sgn} \left( \sum_j J_{ij} S_j(t) - \theta_i \right), \quad (1.1)$$

其中符号函数定义为：当  $x > 0$  时  $\text{sgn}(x) = 1$ ，否则  $\text{sgn}(x) = -1$ 。

McCulloch-Pitts 神经元显然是对其生物原型的极端过度简化。事实上，对它提出的每一个反对意见，都很容易再找到一个补充反对意见。然而，神经网络统计力学所强调的问题与神经生理学的问题是互补的。它并不聚焦于单个神经元，而是关注大量神经元集合中涌现出的集体性质。以往关于磁体、液晶和超流体等复杂物理系统的经验表明，这些集体性质往往出人意料地不敏感于许多微观细节；因此，用极端简化的组分模型描述系统的宏观性质常常是适当的。学习统计力学中的一个核心假设便是：从样例中学习正是这样一种涌现的集体性质，并且可以在大型 McCulloch-Pitts 神经元网络中加以研究。

将形式神经元连接成网络有多种方式，这些方式由突触矩阵  $J_{ij}$  的连接图刻画。图 1.1 展示了小系统中的几种简单可能。

不过，数学分析通常只可能针对若干极端结构展开。有两类连接方式尤其重要。第一类中，每个神经元都与其他每个神经元相连，见图 1.1b。此时动力学 (1.1) 具有高度递归性，一般会导致神经元活动模式的混沌序列。然而，对于一组适当选择的耦合  $J_{ij}$ ，情况可以简单得多。例如考虑对称耦合  $J_{ij} = J_{ji}$  的情形。此时容易证明，函数

$$H(\mathbf{S}) = - \sum_{i,j} J_{ij} S_i S_j \quad (1.2)$$

在动力学 (1.1) 下永远不会增加，其中  $\mathbf{S} = \{S_i\}$  表示神经元活动的完整向量。由于  $H(\mathbf{S})$  不能任

意变小，系统最终会接近使  $H$  最小的构型，并停留在这些吸引子状态中。事实上，通过适当选择耦合  $J_{ij}$ ，可以把这些吸引子预设为某些期望的神经元构型

$$\xi^\mu = \{\xi_1^\mu, \dots, \xi_N^\mu\}, \quad \xi_i^\mu = \pm 1.$$

指标  $\mu$  标记不同的共存吸引子状态，取值从 1 到  $p$ 。如果现在把网络初始化为某个与嵌入模式之一（例如  $\xi^1$ ）相似的构型  $\mathbf{S}$ ，那么动力学在多数情况下会趋向这一吸引子，从而恢复出完整模式  $\xi^1$ 。在这个意义上，吸引子神经网络可以作为联想记忆：如果先用某个存储模式  $\xi^1$  的含噪或不完整变体  $\mathbf{S}$  刺激它，它便能取回该存储模式。这样一种记忆的并行和分布式特征颇似人脑，而与今天的电子存储装置非常不同。吸引子神经网络统计力学中的核心问题包括：可以存储的模式  $\xi^\mu$  的最大可能数目  $p_c$ ；不同学习规则在把突触耦合值确定为存储模式函数时的性质；吸引盆的典型大小，即刺激与期望模式之间最大允许差异的定量刻画；以及不同模式在取回过程中的相互干扰。已有若干教材讨论这类系统的统计力学分析 [2, 3, 4, 5]。




图 1.1: 形式神经网络的不同类型。a: 一般结构；b: 全连接吸引子神经网络；c: 具有一个隐藏层的前馈网络；d: 单层感知机。

另一种极端结构称为前馈神经网络，如图 1.1c 所示。在这种网络中，神经元可以排列成层  $l = 1, \dots, L$ ，使得第  $l$  层中的每个神经元只接收来自第  $(l-1)$  层神经元的输入，并且只馈送到第  $(l+1)$  层神经元。第一层  $l=1$  称为输入层；最后一层  $l=L$  称为输出层；所有满足  $1 < l < L$  的层称为隐藏层。

由于不存在反馈环，动力学非常简单。输入按照 (1.1) 经由连续时间步映射为输出。因此，网络把输入串分类到由输出层不同构型标记的类别中。这种结构非常适合从样例中学习。特别是最简单的前馈神经网络，即完全没有隐藏层的感知机，如图 1.1d 所示，可以被非常详细地分析。Rosenblatt

于 1962 年引入感知机 [6]，开启了人工神经网络的第一段热潮。感知机作为人脑某些基本认知能力的简单模型，其有吸引力的特征也激发了一些大大高估其重要性的推测。因此，当感知机的一些相当明显的局限性在 1969 年被清楚指出时 [7]，这一时期出人意料地突然结束了。

尽管如此，感知机仍是一个非常有趣且有价值的模型系统。在学习的统计力学中，它已经成为该领域的一种“氢原子”，因此本书经常会把它作为关注焦点。在后续各章中，我们将讨论如何把为感知机发展出的技术应用于更强大的多层网络，即具有一个或多个隐藏层的网络。

## 1.2 一个简单例子

用一个简单例子来引入从样例学习当然是合适的。考虑图 1.2 所示的感知机。它有  $N = 20$  个输入单元  $S_i$ ，每个输入单元都通过实值耦合  $J_i$  直接连接到唯一输出  $\sigma$ 。




图 1.2: 用于给二进制数排序的简单感知机。

对任意输入向量  $\mathbf{S}$ ，输出由下式确定：

$$\sigma = \text{sgn} \left( \sum_i J_i S_i \right), \quad (1.3)$$

这是 (1.1) 的一个特例。

我们希望用这个网络给 10 位二进制数排序。<sup>1</sup> 为此，我们要求：如果左边十个输入位表示的二进制数大于（小于）右边十个输入位给出的数，则输出为 +1（-1）。为简单起见，我们暂时忽略两个数相等的可能性。

构造一组能够完美完成该任务的耦合并不困难。考虑如下耦合值：

$$\begin{aligned} J_i^{\text{perf}} &= 2^{10-i}, & \text{若 } i = 1, \dots, 10, \\ J_i^{\text{perf}} &= -J_{i-10}^{\text{perf}}, & \text{若 } i = 11, \dots, 20. \end{aligned} \quad (1.4)$$

它们也显示在图 1.3 中。正如所需，这一选择使输入两个子域中最左端的比特在叠加式 (1.3) 中具有更大的权重。另一方面，它也保证了当两个数的前几位相同时，较低有效位仍能打破平衡。上述问题足够简单，因此我们能够猜出合适的耦合值。这样做就是显式编程的一个例子，而几乎所有今天的计算机都采用这种方式。

<sup>1</sup>一个三位二进制数，其二进制编码为  $(-1, 1, -1)$ ，等于  $0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0$ 。




图 1.3: 用于给二进制数排序的感知机的完美耦合图示, 如式 (1.4) 所给。  $J_1, \dots, J_{10}$  (白色) 为正,  $J_{11}, \dots, J_{20}$  (黑色) 为负。

然而, 我们还可以用另一种更有意思的过程来解决这个问题, 即从样例中学习。首先将耦合  $J_i$  随机初始化。然后, 从总数为  $2^{20} \simeq 10^6$  的不同输入串中随机选取给定数目  $p$  个输入向量  $\xi^\mu$ ,  $\mu = 1, \dots, p$ , 并为每个情形给出正确输出, 记为  $\sigma_T^\mu$ 。接着, 用集合  $\{\xi^\mu, \sigma_T^\mu\}$  训练网络。为此, 我们依次把每个输入向量呈现给网络, 并检查由 (1.3) 给出的网络输出  $\sigma^\mu$  是否正确, 即是否与  $\sigma_T^\mu$  一致。若一致, 初始时约有一半情形如此, 我们就直接进入下一个样例。若  $\sigma^\mu \neq \sigma_T^\mu$ , 则修改耦合, 使得所考察样例在下次呈现时不那么容易被错误分类。第三章将介绍实现这一目标的多种规则。<sup>1</sup> 我们反复执行这一过程, 直到训练集中的所有样例都能被正确再现。这个过程是否收敛事先并不显然, 但对当前问题它确实会收敛: 数的排序对于感知机而言是一个可学习问题。

不过, 训练集上的成功并不能告诉我们网络是否真的学到了样例背后的规则。要回答这一问题, 必须考察它在此前未见过的输入上的表现。<sup>2</sup> 从样例到规则的泛化程度可以通过一个定量指标来度量: 遍历全部  $2^{20}$  个不同输入时, 错误输出所占的比例。这个比例称为泛化误差  $\varepsilon$ , 是学习问题分析中的核心量之一。

图 1.4 展示了按上述模拟得到的  $\varepsilon$  随训练集大小  $p$  的变化。注意,  $\varepsilon$  是一个随机变量, 依赖于训练集的具体选择。在图 1.4 中, 我们给出的是对训练集 1000 次随机实现取平均后的结果。

总体行为与预期一致。当  $p = 0$  时, 网络对目标规则没有任何信息。由于偶然性, 一半样例会被正确分类,  $\varepsilon = 0.5$ , 这正是纯随机猜测的已知成功率。随着  $p$  增加, 泛化误差单调下降; 当  $p \rightarrow \infty$  时, 它当然必须消失。然而, 令人惊讶的是, 当  $p$  只有几百量级时, 泛化误差已经变得相当小, 这远远少于所有不同输入向量的总数! 换句话说, 网络能够相当好地泛化: 它可以基于非常有限的一组样例来逼近期望规则。

<sup>1</sup>在下文展示的模拟中, 我们使用第 3.2 节讨论的随机化感知机学习规则。

<sup>2</sup>这也是本书多数章节末尾都设置习题的原因。




图 1.4: 用于给二进制数排序的感知机从样例学习时, 泛化误差的模拟结果 (圆点)。结果对训练集的 1000 次实现取平均, 统计误差小于符号尺寸。实线给出淬火计算的解析结果, 虚线给出退火近似的结果。二者将在第 2 章详细讨论。

类似地, 可以证明由布尔门组成的稍复杂网络能够从样例中学习数的加法 [8]。人工神经网络从样例中学习的另一个引人注目的展示, 是一个多层神经网络能够把英文文本读出声来 [9]; 还有更多例子已有记录 [10]。

乍看之下, 一个像感知机这样简单的系统竟然“足够聪明”到可以破解样例背后的规则, 似乎有些神秘。不过解释其实很简单: 感知机只能实现输入与输出之间极为有限的一组映射, 而数的排序恰好是其中之一。在这种限制下, 基于样例选择正确映射就相对容易。后续各章将把这些相当粗略的说法变得更加精确。

为了更具体地理解感知机在上述问题中的运行方式, 考察耦合  $J_i$  随训练集大小  $p$  的演化是有帮助的。图 1.5 给出了  $p = 50$  和  $p = 200$  时的耦合。为便于同 (1.4) 和图 1.3 中的目标值比较, 两种情形下都把耦合归一化为  $J_1 = 2^9$ 。可以容易看到, 最重要的耦合  $J_1, J_2, J_3, J_{11}, J_{12}, J_{13}$  之间的关系最先被固定下来。这是因为无论在训练集中还是在完整集合中, 它们决定了绝大多数输入模式的输出。考虑到  $J_1, J_2, J_3, J_{11}, J_{12}$  和  $J_{13}$  取正确值已经能使全部模式中的 15/16 得到正确输出, 我们便能理解学习过程最初的高效率。基于同样道理, 可以预期, 能够提供关于  $J_9, J_{10}, J_{19}$  和  $J_{20}$  信息的输入是稀少的, 其结果是泛化误差向零的渐近衰减相当缓慢。




图 1.5: 学习 50 个样例 (左) 和 200 个样例 (右) 后, 感知机耦合的图示。柱子的符号表示相应耦合是否与图 1.3 中的完美耦合同号。

图 1.4 中还包括了在统计力学框架下对该学习问题进行两种解析处理所得的泛化误差：一种是称为“退火”的近似处理，另一种是称为“淬火”的精确处理。产生这类曲线所需的概念和技术，正是本书的主要内容。

### 1.3 一般设定

现在我们可以表述人工神经网络统计力学中学习问题的基本场景。为此，考虑一个由形式神经元组成的前馈网络，它有  $N$  个输入单元，记为  $S_i$ ,  $i = 1, \dots, N$ ，以及一个输出  $\sigma$ 。我们把讨论限制在只有一个输出单元的网络上，仅仅是为了简单。由于同一层中的神经元之间没有耦合，具有多个输出的网络并不比只有一个输出的网络显著更复杂。

网络实现的输入-输出映射由突触耦合向量

$$\mathbf{J} = \{J_1, \dots, J_N\}$$

指定。网络需要调整这些耦合，以完成某个目标映射；下文通常把这个目标映射称为规则。把目标映射想象为由另一个前馈神经网络表示，常常是方便的；该网络由突触向量

$$\mathbf{T} = \{T_1, \dots, T_N\}$$

表征。教师网络  $\mathbf{T}$  与学生网络  $\mathbf{J}$  当然必须具有相同数目  $N$  的输入和一个输出，但一般而言二者的结构可以不同。

在逼近教师的任务中，学生既不知道教师的详细结构，也不知道教师向量  $\mathbf{T}$  的各个分量。关于目标规则唯一可获得的信息包含在训练集中：它由  $p$  个输入  $\xi^\mu$ ,  $\mu = 1, \dots, p$  组成，其中

$$\xi^\mu = \{\xi_i^\mu = \pm 1, i = 1, \dots, N\},$$

并附有教师给出的相应输出  $\sigma_T^\mu = \pm 1$ ,  $\mu = 1, \dots, p$ 。根据训练集指定一个合适学生耦合向量  $\mathbf{J}$  的处方

$$\{\xi^\mu, \sigma_T^\mu\} \mapsto \mathbf{J}$$

称为学习规则。对学习规则最明显的要求，是生成一个尽可能好地逼近教师的学生向量。不过，还有其他重要特征，例如确定  $\mathbf{J}$  所需的时间，以及在把新的输入加入训练集时的灵活性。

一个关键问题是训练集中的样例如何被选择。这一点很重要，因为相同大小的不同训练集完全可能携带关于目标规则的不同信息量。在许多实际情形中，人们无法任意设计训练集，因为其元素由某种实验过程决定。为了模拟这些情形，因此假设训练集中的样例是在输入空间上按某个概率分布  $P_S(\mathbf{S})$  独立随机选取的。在本书中，我们将使用一些简单分布，例如

$$P_S(\mathbf{S}) = \prod_i \left[ \frac{1}{2} \delta(S_i + 1) + \frac{1}{2} \delta(S_i - 1) \right], \quad (1.5)$$

这意味着输入的各个分量  $S_i$  以相等概率且彼此独立地取值  $\pm 1$ 。 $\delta$  函数的一些性质汇总在附录 A 中。

类似于考虑随机编制的训练集，人们往往也不专注于某个特定目标规则  $\mathbf{T}$ ，而是假设目标也是按照某个概率分布  $P_T(\mathbf{T})$  从规则空间中随机选出的。这样，分析结果就刻画一整类学习问题，而不是只描述某一特定任务上的表现。



最后，许多学习规则包含随机因素，以便促进收敛。于是，训练集并不导向唯一的  $\mathbf{J}$  向量，而是导向整个分布  $P_J(\mathbf{J})$ 。此时，学习过程可以方便地描述为：基于从样例中获得的信息，对这一概率分布进行重塑 [11, 12]。

总之，一般学习问题中存在若干随机性来源；处理这种概率性质的不同方式，将导致学习数学分析中的不同进路。

为了量化学生逼近教师的成功程度，我们首先需要度量两个网络相似或不相似的量。把同一输入向量  $\mathbf{S}$  呈现给两个网络，分别记教师和学生的相应输出为  $\sigma_T$  和  $\sigma$ 。对于二值输出，量

$$d(\mathbf{J}; \mathbf{S}, \mathbf{T}) = \Theta(-\sigma_T \sigma) \quad (1.6)$$

是合适的距离度量；这里  $\Theta$  函数定义为：当  $x > 0$  时  $\Theta(x) = 1$ ，否则  $\Theta(x) = 0$ （参见 (A1.17)）。因此，若出现错误（输出不同于目标输出），它为 1；否则为 0。<sup>1</sup> 于是，可以通过计算所谓训练误差来量化学生在训练集上的表现：

$$\varepsilon_t(\mathbf{J}; \{\xi^\mu\}, \mathbf{T}) = \frac{1}{p} \sum_{\mu=1}^p d(\mathbf{J}; \xi^\mu, \mathbf{T}), \quad (1.7)$$

它正是训练集中被错误分类模式所占的比例。训练误差是大多数学习规则中的重要成分；在后续章节中我们会看到，选择训练误差小的学生向量常常（但并非总是）是一个好主意。

另一方面，训练误差显然并不适合判断学生是否真正很好地逼近了目标规则。真正度量这一点的是泛化误差  $\varepsilon(\mathbf{J}; \mathbf{T})$ ，定义为  $d$  在所有可能输入  $\mathbf{S}$  上的平均：

$$\varepsilon(\mathbf{J}; \mathbf{T}) = \sum_{\{\mathbf{S}\}} P_S(\mathbf{S}) d(\mathbf{J}; \mathbf{S}, \mathbf{T}). \quad (1.8)$$

等价地，我们可以把  $\varepsilon$  理解为：随机抽取一个输入时，学生与教师给出不同分类的概率。它有时也称为“犯错概率”或“期望 0-1 损失”。注意，从与训练样例相同的概率分布  $P_S$  中抽取测试输入是自然的。

由  $\varepsilon_t$  和  $\varepsilon$  的定义可见，从样例学习的问题与数理统计中的一个标准问题有共同之处，即频率向概率的收敛。事实上，训练误差  $\varepsilon_t$  可以解释为在样例测试集  $\xi^\mu$  上对泛化误差  $\varepsilon$  的估计。因此，随着该集合大小  $p$  的增加，它必须收敛到泛化误差。由于我们可以通过适当选择  $\mathbf{J}$  来控制训练误差（在可学习情形中可保证  $\varepsilon_t = 0$ ），这种收敛的细节将给出大训练集大小  $p$  下泛化误差渐近行为的信息。

具体而言，概率

$$P = \text{Prob}(|\varepsilon_t - \varepsilon| > \delta) \quad (1.9)$$

随训练集大小减小的方式，可以用来刻画所考察系统从样例中学习的能力。注意，描述这种能力需要两个参数：一个容差  $\delta$ ，因为在有限  $p$  下通常只能实现目标规则的近似；以及一个置信度  $P$ ，用来防范训练集的不幸实现。这就是“可能近似正确”（probably almost correct, PAC）学习的概念 [13]，它是数理统计和计算机科学中许多学习问题研究的中心。这个进路中的一个微妙之处，是要正确处理由学习规则引入的输入  $\xi^\mu$  与学生耦合  $\mathbf{J}$  之间的相关性。由于这些相关性，训练集并不只是一个简单的独立测试集；要确定  $P$  作为  $p$  的函数的行为，需要数理统计中更高级的技术。

第十章将阐明 PAC 方法的一些方面。这里我们只指出，通过研究最坏情形，它允许人们推导学习场景表现的非常一般的界。这些最坏情形通常包括：给定训练误差时学生向量的最坏可能选

<sup>1</sup>对于连续输出， $d(\mathbf{J}; \mathbf{S}, \mathbf{T}) = (\sigma_T - \sigma)^2/4$  是一个合适的推广。

择、目标规则的最坏选择，以及训练集的最坏实现。因此，所得结果完全可能过于悲观，并不一定刻画平均行为或最可能行为。

本书概述的从样例学习的理论描述，基于不同于 PAC 学习的概念。与数理统计不同，统计力学试图精确描述典型行为，而不是给最坏情形加界。在统计力学中，所谓典型不仅意味着最可能；此外还要求，与典型情形不同的情况的概率可以变得任意小。这一显著性质通过所谓热力学极限实现。在这一极限中，自由度数目  $N$  趋于无穷；统计力学之所以成功，依赖于这样一个事实：在这一极限下，相关量的概率分布会围绕其最大值变得尖锐。

在学习的统计力学中，自由度是学生网络的耦合  $J_i$ 。在本书研究的大多数情形中，它们的数目等于输入空间维数  $N$ 。无论在生物神经网络还是许多技术实现的神经网络中，这个数目确实很大，因此我们可以期待通过考虑极限  $N \rightarrow \infty$  来描述相关情形。后面我们会看到，即使对于中等大小的  $N$ ，其行为往往也已经接近渐近结果（参见图 1.4）。

由于在热力学极限中可调参数的数目变大，人们预期只有当训练样例数  $p$  也增长时，从样例学习才仍然可能。事实上，训练集大小的适当标度为

$$p = \alpha N, \quad (1.10)$$

因此在热力学极限中， $N$  和  $p$  都发散，而二者之比  $\alpha$  保持为  $O(1)$ 。

为了把统计力学机器用于学习问题分析，人们必须确定有趣量（例如泛化误差）的典型值。不过，一般而言最可能值很难计算，因为这或多或少要求计算完整概率分布。幸运的是，对于某些量，最可能值与平均值一致，而平均值在解析上更容易得到。如果概率分布的方差还会在热力学极限中趋于零，那么这样的量称为自平均量，因为在热力学极限中，它取不同于其平均值的概率趋于零。然而必须始终牢记，并非所有有趣量都会自动自平均。<sup>1</sup> 因此我们会发现，识别问题中的自平均量，是学习问题统计力学分析中的第一步，也是相当关键的一步。

概括而言，从样例学习的数学分析要求恰当地处理这类问题中固有的多种概率因素。统计力学主要考虑教师神经网络和学生神经网络这一特殊场景，并旨在给出典型学习行为的精确结果。通过考虑热力学极限，这一点成为可能；在该极限中，学生网络的可调耦合数和训练集中的样例数都发散。识别出问题的自平均量之后，典型表现便可通过计算它们在相关概率分布上的平均来刻画。

## 1.4 习题

- 1.1 证明：对于对称耦合  $J_{ij} = J_{ji}$ ，式 (1.2) 中定义的函数  $H(\mathbf{S})$  在动力学 (1.1) 下只能减小，或至多保持不变。为什么对称耦合这一限制很重要？试构造一个非对称耦合矩阵  $J_{ij}$ ，使网络动力学产生循环。
- 1.2 验证：如果第 1.2 节讨论的排序机器中， $J_1, J_2, J_3, J_{11}, J_{12}$  和  $J_{13}$  已经取到了式 (1.4) 给出的完美值，而其他耦合仍为随机值，那么如正文所述，所有输入中的 15/16 已经能被正确分类。一个输入携带关于  $J_{10}$  和  $J_{20}$  取值的信息的概率是多少？
- 1.3 除式 (1.5) 中定义在输入空间上的概率分布  $P_S(\mathbf{S})$  外，考虑另外两种分布：一种中  $\mathbf{S}$  的各分量是均值为零、方差为一的高斯随机变量；另一种中， $N$  维向量  $\mathbf{S}$  的端点以常密度分布在半

<sup>1</sup>一个常见反例是收入分布。典型收入显著低于平均收入。文献 [14] 中有一个很好的讨论。

径为  $\sqrt{N}$  的  $N$  维球面上。证明这三种分布具有相同的一阶矩和二阶矩：

$$\langle\langle S \rangle\rangle = 0, \quad \langle\langle S^2 \rangle\rangle = N.$$

- 1.4 考虑一个只有单个参数  $\theta_T$  的系统，它把实数  $S \in (0, 1)$  分类为：若  $S > \theta_T$  则为 +1，否则为 -1。这个所谓高-低游戏可看作一个极端简化的感知机 ( $N = 1$ )，其动力学为 (1.1)。由  $\theta_J$  表征的学生，需要根据教师对一组随机样例  $\xi^\mu$  给出的分类来猜测教师阈值  $\theta_T$ 。假设阈值  $\theta_T$  从区间  $(0, 1)$  上的均匀分布随机抽取。证明：如果学生从训练误差为零的数  $\theta_J$  的集合中等概率随机选取，则泛化误差为

$$\varepsilon = \frac{\xi_{\max} - \xi_{\min}}{3},$$

其中  $\xi_{\max}$  是训练集中被教师分类为 +1 的最小元素， $\xi_{\min}$  是被教师分类为 -1 的最大元素。

## 第二章 感知机学习：基础

本章将逐步分析从样例学习的一个典型范式：学生感知机学习由教师感知机给出的一组  $p$  个训练样例。Gibbs 学习是一个简单场景，非常适合作为入门讨论。我们先给出对学习过程的直观但近似的描述；随后逐步引入统计力学中的适当概念和技术，使这一描述得到修正和精化。

### 2.1 Gibbs 学习

首先，引入一个简单的几何解释：感知机  $\mathbf{J}$  对输入  $\mathbf{S}$  的分类  $\text{sgn}(\mathbf{J}\mathbf{S})$ ，取  $+1$  或  $-1$ ，取决于  $\mathbf{S}$  与  $\mathbf{J}$  之间的夹角小于还是大于  $\pi/2$ 。因此，分类从  $+1$  切换到  $-1$  的点集，也就是所谓决策边界，正是经过原点且与  $\mathbf{J}$  正交的超平面。由于这个原因，感知机能够实现的分类称为线性可分分类。

显然， $\mathbf{J}$  和  $\mathbf{S}$  的长度并不影响分类。因此，通常把耦合和输入都按如下方式归一化：

$$\mathbf{J}^2 = \sum_{i=1}^N J_i^2 = N, \quad \mathbf{S}^2 = \sum_{i=1}^N S_i^2 = N. \quad (2.1)$$

于是，这两类向量都位于半径为  $\sqrt{N}$  的  $N$  维球面上，下文称为  $N$  球面。选择这个半径与输入分量为  $\pm 1$  的情形相容（参见式 (1.5)），同时该球面的面积随  $N$  指数增长（参见习题 2.1），这也为下面引入的量提供了方便的标度。

为了比较教师感知机  $\mathbf{T}$  和学生感知机  $\mathbf{J}$  所实现的分类，我们把输入样例投影到由教师和学生的耦合向量张成的平面上，如图 2.1 所示。容易看出，投影落在阴影区域中的输入，正是被教师和学生作出不同分类的输入。如果输入是随机选取的，那么发生不一致的概率，也就是泛化误差  $\varepsilon$ ，正是投影落入这一阴影区域的概率。由于决策直线分别与向量  $\mathbf{T}$  和  $\mathbf{J}$  正交，我们得到  $\varepsilon = \theta/\pi$ ，其中  $\theta$  是  $\mathbf{T}$  和  $\mathbf{J}$  之间的夹角。因此，泛化误差正比于  $N$  球面上分别对应教师和学生感知机的两点之间的测地距离。为此，引入所谓教师-学生重叠：

$$R = \frac{\mathbf{J}\mathbf{T}}{N} = \frac{1}{N} \sum_i T_i J_i. \quad (2.2)$$

由于两个向量的长度都固定为  $\sqrt{N}$ ， $R$  就是  $\mathbf{J}$  和  $\mathbf{T}$  之间夹角  $\theta$  的余弦，泛化误差可写为

$$\varepsilon = \frac{1}{\pi} \arccos R. \quad (2.3)$$

现在考虑学习过程中确定学生耦合的一种简单策略。考虑所有在样例上与教师得分完全相同的耦合向量  $\mathbf{J}$ 。这些相容学生的集合称为版本空间。我们关心从版本空间中随机抽取的向量  $\mathbf{J}$  的泛化误差。这一简单处方称为 Gibbs 学习。<sup>1</sup> 它很有意义，因为对这一学习规则得到的结果刻画了一个相容学生的典型表现。

在 Gibbs 学习中，随着训练集大小增加，越来越多与样例不相容的耦合  $\mathbf{J}$  被排除，版本空间不断收缩，泛化误差随之下降。如果能够定量描述一个耦合在呈现新样例时的“存活概率”，就可以

<sup>1</sup>更确切地说，这是零温 Gibbs 学习，见第 4.2 节。




图 2.1: 输入空间在教师和学生耦合向量张成平面上的投影。投影落在阴影区域中的输入会被学生错误分类。

推断训练过程中泛化误差的平均行为。若按耦合与教师的重叠对耦合分类，这一点确实可行。对于所有重叠为式 (2.2) 中  $R$  的耦合  $\mathbf{J}$ ，在随机输入上给出与教师相同输出的概率，由泛化误差定义可知为  $1 - (\arccos R)/\pi = 1 - \varepsilon$ 。令  $\Omega_0(\varepsilon)$  表示训练前与教师重叠为  $R = \cos(\pi\varepsilon)$  的耦合向量体积。由于样例相互独立，每个样例平均会把这一数目乘以因子  $1 - \varepsilon$ ，于是呈现  $p$  个训练样例后，泛化误差为  $\varepsilon$  的相容学生的平均体积为

$$\Omega_p(\varepsilon) = \Omega_0(\varepsilon)(1 - \varepsilon)^p. \quad (2.4)$$

如前一章所述，我们感兴趣的是可用热力学极限  $N \rightarrow \infty$  描述的大网络。在这一极限中，一个简单计算（参见习题 2.2）给出  $N$  的主导阶：

$$\Omega_0(\varepsilon) = \int d\mathbf{J} \delta(\mathbf{J}^2 - N) \delta\left(\frac{\mathbf{J}\mathbf{T}}{N} - \cos(\pi\varepsilon)\right) \sim \exp\left\{\frac{N}{2} [1 + \ln(2\pi) + \ln \sin^2(\pi\varepsilon)]\right\}. \quad (2.5)$$

结合式 (2.4) 和 (2.5)，并使用式 (1.10) 假设的训练集大小标度  $p = \alpha N$ ，得到

$$\Omega_p(\varepsilon) \sim \exp\left\{N \left[\frac{1}{2}(1 + \ln 2\pi) + \frac{1}{2} \ln \sin^2(\pi\varepsilon) + \alpha \ln(1 - \varepsilon)\right]\right\}. \quad (2.6)$$

方括号中的表达式作为  $\varepsilon$  的函数，在图 2.2 中给出了若干  $\alpha$  取值下的曲线。注意，虽然它是  $\varepsilon$  的光滑函数，但  $\Omega_p(\varepsilon)$  的相应差异会被式 (2.6) 中大的前因子  $N$  指数放大。因此，在大  $N$  下从版本空间中随机选取学生向量时，将以压倒性概率选中使图 2.2 所示函数取最大值的  $\varepsilon$ 。其他  $\varepsilon$  值对应的耦合向量在指数意义上是稀有的。于是我们预期，在大  $N$  极限中，泛化误差由

$$\varepsilon(\alpha) = \operatorname{argmax}_{\varepsilon} \left[ \frac{1}{2} \ln \sin^2(\pi\varepsilon) + \alpha \ln(1 - \varepsilon) \right] \quad (2.7)$$

给出。

当  $\alpha = 0$  时， $\Omega_p$  的最大值出现在  $\varepsilon = 0.5$ ，对应于与教师“正交”的学生。显然，在没有任何其他信息时，所有  $\mathbf{J}$  的选择等概率，而执行随机猜测的学生在数目上以指数优势压倒其他学生。




图 2.2: 式 (2.6) 方括号中的表达式作为  $\varepsilon$  的函数;  $\alpha = 0, 1, 2, 3, 4, 5$ , 曲线从上到下排列。

在学习过程中, 来自训练集的信息项抵消了这一效应。在当前 Gibbs 学习情形中, 这一项就是式 (2.6) 中的  $\alpha \ln(1 - \varepsilon)$ ; 当  $\alpha = O(1)$  时, 它正好具有所需阶数, 从而验证了标度假设 (1.10)。对于大训练集, 泛化误差变小, 并且如预期那样在  $\alpha \rightarrow \infty$  时  $\varepsilon \rightarrow 0$ 。

上述结果还为神经网络如何从样例学习提供了一些定性理解。首先, 网络的具体结构给可实现映射引入了一种先验层级。“容易”的输入-输出关系可由许多不同耦合向量实现; “困难”的关系则要求相当精细的微观构型。可以把这种层级称为系统的偏见。其次, 与训练集不相容的分类被剔除。因此, 这类学习意味着速度与灵活性之间的权衡。一个对所有映射具有同等实现能力的系统原则上能学习任意问题, 但其泛化特性对所有问题都会同样差。相反, 一个高度专门化的系统只能学习非常受限的一类问题, 但学习会很快。事实上, 在这样的系统中可能出现类似“顿悟”的、通向完美泛化的突变 (参见第 七 章)。

为了检验这个简单 Gibbs 学习分析的精确性, 我们已把式 (2.7) 的结果作为虚线加入图 1.4。与模拟结果比较可见, 尽管定性行为描述正确, 但存在明显偏差。特别地, 对大  $\alpha$ , 由式 (2.7) 得到

$$\varepsilon \sim \frac{1}{\alpha}, \quad (2.8)$$

这给出了正确标度, 但由于前因子错误, 定量上很差。

问题出在哪里? 主要缺陷在于我们没有正确处理学习样例  $\xi^\mu$  和教师耦合  $\mathbf{T}$  中的随机性。记  $\Omega(\varepsilon; \xi^\mu, \mathbf{T})$  为那些与教师向量  $\mathbf{T}$  夹角为  $\pi\varepsilon$ 、并且在学习  $p$  个样例  $\xi^\mu$  后仍留在版本空间中的学生耦合向量体积。由于  $\mathbf{T}$  和  $\xi^\mu$  都是随机选择的,  $\Omega(\varepsilon; \xi^\mu, \mathbf{T})$  本身也是随机量。然而, 式 (2.4) 中定义的  $\Omega_p$  只描述其平均值。第 1.3 节中已经讨论过, 在许多随机系统中, 平均值也能合理估计随机量的典型值, 即最可能值。但这并非总是成立, 尤其对  $\Omega(\varepsilon; \xi^\mu, \mathbf{T})$  不成立。结果是, 在大  $N$  下, 以压倒性概率出现的  $\Omega(\varepsilon; \xi^\mu, \mathbf{T})$  值不同于式 (2.6) 所描述的平均值。

为了说明  $\Omega(\varepsilon; \xi^\mu, \mathbf{T})$  的分布在大  $N$  下确实不能由其平均值很好刻画, 更重要的是为了找到描述  $\varepsilon(\alpha)$  典型行为的正确方法, 先在统计力学框架内重新表述上述方法是有益的。在此基础上, 我们将发展学习问题定量分析所需的核心统计力学技术。



## 2.2 退火近似

从统计力学角度重新表述上述学习场景。微观变量是学生向量的分量  $J_i$ ，它们张成所谓相空间。泛化误差  $\varepsilon$  是相关宏观变量。同一个  $\varepsilon$  值可以由许多不同微观变量  $\mathbf{J}$  实现。重要量  $\Omega(\varepsilon; \boldsymbol{\xi}^\mu, \mathbf{T})$  表示在给定  $\boldsymbol{\xi}^\mu$  和  $\mathbf{T}$  时，实现由  $\varepsilon$  指定的宏观状态的所有微观状态在相空间中占据的体积。在统计力学中，它由熵  $S$  定量刻画，而熵不过是该体积的对数：

$$S(\varepsilon; \boldsymbol{\xi}^\mu, \mathbf{T}) = \ln \Omega(\varepsilon; \boldsymbol{\xi}^\mu, \mathbf{T}). \quad (2.9)$$

由式 (2.5)，在学习前并且  $N$  很大时有

$$S_0(\varepsilon) \sim \frac{N}{2} [1 + \ln(2\pi) + \ln \sin^2(\pi\varepsilon)]. \quad (2.10)$$

熵具有一个吸引人的性质：它是广延量，<sup>1</sup> 即与自由度数目  $N$  成正比。

式 (2.10) 的前两项与  $\varepsilon$  无关，只对应于  $N$  球面的面积（参见习题 2.1）。用这个值对  $\Omega(\varepsilon; \boldsymbol{\xi}^\mu, \mathbf{T})$  归一化是方便的。为此，下文采用积分测度

$$d\mu(\mathbf{J}) := \frac{dJ \delta(\mathbf{J}^2 - N)}{\int dJ \delta(\mathbf{J}^2 - N)} \quad (2.11)$$

以保证  $\int d\mu(\mathbf{J}) = 1$ 。归一化熵于是简化为

$$S_0(\varepsilon) \sim \frac{N}{2} \ln \sin^2(\pi\varepsilon). \quad (2.12)$$

随着学习进行，越来越多的耦合  $\mathbf{J}$  因为与训练样例  $\boldsymbol{\xi}^\mu$  不相容而被拒绝。函数

$$\chi(\mathbf{J}) = \prod_{\mu=1}^p \Theta \left[ \left( \frac{1}{\sqrt{N}} \mathbf{T} \boldsymbol{\xi}^\mu \right) \left( \frac{1}{\sqrt{N}} \mathbf{J} \boldsymbol{\xi}^\mu \right) \right] \quad (2.13)$$

在  $\mathbf{J}$  对所有样例的分类都与教师完全一致时为 1，否则为 0。因此它可以作为版本空间中剩余耦合的指示函数。 $\Theta$  函数的自变量经过归一化，使它们在  $N \rightarrow \infty$  时保持  $O(1)$ 。虽然这并非绝对必要，因为 Heaviside 函数只关心自变量的符号，但它有助于追踪热力学极限中不同项的阶数，也便于与光滑神经元特性中的表达式比较。

利用指示函数  $\chi(\mathbf{J})$ ，学习  $p$  个样例后整个版本空间的归一化体积可写为

$$\Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) = \int d\mu(\mathbf{J}) \prod_{\mu=1}^p \Theta \left[ \left( \frac{1}{\sqrt{N}} \mathbf{T} \boldsymbol{\xi}^\mu \right) \left( \frac{1}{\sqrt{N}} \mathbf{J} \boldsymbol{\xi}^\mu \right) \right]. \quad (2.14)$$

它依赖于教师向量  $\mathbf{T}$  和构成训练集的具体样例  $\boldsymbol{\xi}^\mu$ ；二者都是随机变量。现在计算版本空间体积的平均值

$$\Omega_p = \langle \langle \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle \rangle.$$

这里及下文中双尖括号  $\langle \langle \dots \rangle \rangle$  表示对训练样例和教师耦合取平均。 $\Omega_p$  的对数称为退火熵：

$$S_p^{\text{ann}} = \ln \langle \langle \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle \rangle. \quad (2.15)$$

显式计算平均时，输入采用分布 (1.5)。教师耦合向量  $\mathbf{T}$  假设以均匀概率从  $N$  球面选取，即

$$P_T(\mathbf{T}) = (2\pi e)^{-N/2} \delta(\mathbf{T}^2 - N). \quad (2.16)$$

<sup>1</sup>保持熵的这一性质，是式 (2.1) 中选择  $\mathbf{J}$  归一化的原因。

不过，稍后会看到，在完成  $\xi^\mu$  平均后，对教师的平均是平凡的，因为几乎所有  $\mathbf{T}$  的选择都给出相同的泛化误差结果。

随机变量以乘积形式出现在式 (2.14) 中，而且位于函数内部。引入辅助变量

$$\lambda_\mu = \frac{1}{\sqrt{N}} \mathbf{J} \xi^\mu, \quad u_\mu = \frac{1}{\sqrt{N}} \mathbf{T} \xi^\mu, \quad (2.17)$$

可将式 (2.14) 改写为（参见 (A1.11)）

$$\begin{aligned} \Omega_p = & \int d\mu(\mathbf{J}) \int \prod_\mu d\lambda_\mu du_\mu \prod_\mu \Theta(\lambda_\mu u_\mu) \\ & \times \left\langle \left\langle \prod_\mu \delta\left(\lambda_\mu - \frac{1}{\sqrt{N}} \mathbf{J} \xi^\mu\right) \delta\left(u_\mu - \frac{1}{\sqrt{N}} \mathbf{T} \xi^\mu\right) \right\rangle \right\rangle. \end{aligned} \quad (2.18)$$

此时可以形式上用 Fourier 表示 delta 函数，使关于样例分量  $\xi_i^\mu$  的因子分解（见附录 A）。这里采用一个捷径。对于固定的  $\mathbf{J}$  和  $\mathbf{T}$ ， $\lambda_\mu$  与  $u_\mu$  都是  $N$  个独立项之和，按中心极限定理服从高斯分布。利用式 (2.1)、(2.2) 和 (1.5)，容易得到（参见习题 2.3）

$$\langle\langle \lambda_\mu \rangle\rangle = \langle\langle u_\mu \rangle\rangle = 0, \quad \langle\langle \lambda_\mu^2 \rangle\rangle = \langle\langle u_\mu^2 \rangle\rangle = 1, \quad \langle\langle \lambda_\mu u_\mu \rangle\rangle = \frac{\mathbf{J} \mathbf{T}}{N} = R. \quad (2.19)$$

用这些矩确定的二维高斯分布计算式 (2.18)，得到

$$\begin{aligned} \Omega_p = & \int d\mu(\mathbf{J}) \int \prod_\mu \frac{d\lambda_\mu du_\mu}{2\pi\sqrt{1-R^2}} \prod_\mu \Theta(\lambda_\mu u_\mu) \\ & \times \exp \left[ -\frac{1}{2(1-R^2)} \sum_\mu (\lambda_\mu^2 + u_\mu^2 - 2R\lambda_\mu u_\mu) \right], \end{aligned} \quad (2.20)$$

其中  $R$  是  $\mathbf{J} \mathbf{T}/N$  的简写。进一步引入 delta 函数  $\delta(\mathbf{J} \mathbf{T}/N - R)$ ，也就是把  $\mathbf{J}$  积分分解为固定  $R$  的切片，可得

$$\begin{aligned} \Omega_p = & \int_{-1}^1 dR \int d\mu(\mathbf{J}) \delta\left(\frac{\mathbf{J} \mathbf{T}}{N} - R\right) \int \prod_\mu \frac{d\lambda_\mu du_\mu}{2\pi\sqrt{1-R^2}} \prod_\mu \Theta(\lambda_\mu u_\mu) \\ & \times \exp \left[ -\frac{1}{2(1-R^2)} \sum_\mu (\lambda_\mu^2 + u_\mu^2 - 2R\lambda_\mu u_\mu) \right]. \end{aligned} \quad (2.21)$$

此时  $\lambda_\mu, u_\mu$  积分按  $\mu$  因子分解，并且

$$2\sqrt{1-R^2} \int_0^\infty \frac{d\lambda}{\sqrt{2\pi}} \int_0^\infty \frac{du}{\sqrt{2\pi}} \exp \left[ -\frac{\lambda^2 + u^2 - 2R\lambda u}{2(1-R^2)} \right] = 1 - \frac{1}{\pi} \arccos R. \quad (2.22)$$

由式 (2.3) 和 (2.5)，得到

$$\Omega_p = \int_{-1}^1 dR \exp \left\{ N \left[ \frac{1}{2} \ln(1-R^2) + \alpha \ln \left( 1 - \frac{1}{\pi} \arccos R \right) \right] \right\}. \quad (2.23)$$

与式 (2.6) 类似，该式表明，把耦合向量限制到版本空间中，会引入一个额外项来抵消纯熵部分 (2.12)。由于训练集大小满足  $p = \alpha N$ ，这个新贡献同样是广延的。由于稍后会说明的原因，它称为能量部分。

热力学极限  $N \rightarrow \infty$  下，式 (2.23) 中剩余  $R$  积分的渐近行为可由附录 A 中解释的鞍点法确定，最终得到

$$S_p^{\text{ann}} = N \max_R \left[ \frac{1}{2} \ln(1-R^2) + \alpha \ln \left( 1 - \frac{1}{\pi} \arccos R \right) \right]. \quad (2.24)$$



这特别意味着，平均相空间体积  $\Omega_p$  由具有如下重叠的耦合支配：

$$R = \operatorname{argmax}_R \left[ \frac{1}{2} \ln(1 - R^2) + \alpha \ln \left( 1 - \frac{1}{\pi} \arccos R \right) \right]. \quad (2.25)$$

式 (2.23) 和 (2.25) 分别重现了式 (2.6) 与 (2.7)。这是合理的，因为两种情况下我们分析的都是相空间体积  $\Omega(\boldsymbol{\xi}^\mu, \mathbf{T})$  的平均值。然而，由式 (2.14) 可见， $\Omega(\boldsymbol{\xi}^\mu, \mathbf{T})$  包含许多随机贡献的乘积。独立随机数的乘积分布常带长尾，使平均值与最可能值显著不同（见习题 2.5）。另一方面，这类量的对数是大量独立项之和，因此趋于高斯分布，其平均值和最可能值渐近一致。因此，大  $N$  下  $\Omega(\boldsymbol{\xi}^\mu, \mathbf{T})$  的典型值为<sup>1</sup>

$$\Omega^{\text{typ}}(\boldsymbol{\xi}^\mu, \mathbf{T}) \sim \exp(\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle). \quad (2.26)$$

这符合无序系统统计力学中的一般信条：熵和能量这样的广延量是自平均的 [16, 17]。因此，对典型泛化行为的可靠分析，必须计算  $\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle$ ，而不是  $\langle \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle$ 。下一节将看到，这确实给出正确结果。

## 2.3 Gardner 分析

上一节末尾已经表明，退火熵  $S^{\text{ann}} = \ln \langle \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle$  不能描述典型泛化行为。正确理论必须建立在所谓淬火熵上：

$$S = \langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle. \quad (2.27)$$

这要求计算

$$\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle = \left\langle \left\langle \ln \int d\mu(\mathbf{J}) \prod_{\mu=1}^p \Theta \left[ \left( \frac{1}{\sqrt{N}} \mathbf{T} \boldsymbol{\xi}^\mu \right) \left( \frac{1}{\sqrt{N}} \mathbf{J} \boldsymbol{\xi}^\mu \right) \right] \right\rangle \right\rangle, \quad (2.28)$$

其中平均对训练集的随机样例和随机教师向量进行。这个淬火平均在技术上远不如退火平均 (2.18) 直接。主要困难在于，对于样例的每个单独实现， $\mathbf{J}$  上的积分无法解析完成。只有在对样例取平均之后，系统才在平移意义上不变：所有神经元  $i$  彼此等价，使得  $\mathbf{J}$  上的积分可以化为对  $\mathbf{J}$  的单个分量的积分。因此，必须以某种方式交换式 (2.28) 中的平均和对数。幸运的是，淬火平均自 20 世纪 70 年代以来一直是无序固体理论中的中心问题，我们可以借用该领域发展出的技术。一个虽非严格数学证明、但在许多情形中成功的方法是复本技巧 [18, 19, 20]，它依赖简单恒等式

$$\ln x = \lim_{n \rightarrow 0} \frac{d}{dn} x^n = \lim_{n \rightarrow 0} \frac{x^n - 1}{n}. \quad (2.29)$$

用于当前问题时，它给出

$$\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle = \lim_{n \rightarrow 0} \frac{\langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle - 1}{n}. \quad (2.30)$$

于是， $\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle$  的计算被转化为  $\langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle$  的计算。对一般实数  $n$ ，这当然与原平均一样复杂。然而，对自然数  $n = 1, 2, 3, \dots$ ，该平均可以写成

$$\begin{aligned} \langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle &= \left\langle \left\langle \int d\mu(\mathbf{J}) \prod_{\mu=1}^p \Theta \left[ \left( \frac{1}{\sqrt{N}} \mathbf{T} \boldsymbol{\xi}^\mu \right) \left( \frac{1}{\sqrt{N}} \mathbf{J} \boldsymbol{\xi}^\mu \right) \right] \right\rangle^n \right\rangle \\ &= \left\langle \left\langle \int \prod_{a=1}^n d\mu(\mathbf{J}^a) \prod_{\mu=1}^p \prod_{a=1}^n \Theta \left[ \left( \frac{1}{\sqrt{N}} \mathbf{T} \boldsymbol{\xi}^\mu \right) \left( \frac{1}{\sqrt{N}} \mathbf{J}^a \boldsymbol{\xi}^\mu \right) \right] \right\rangle \right\rangle. \end{aligned} \quad (2.31)$$

<sup>1</sup> 尽管  $\Omega(\boldsymbol{\xi}^\mu, \mathbf{T})$  中的不同项弱相关，这一说法仍成立；严格证明见 [15]。

这看起来像是对原系统的  $n$  个不同复本 (replicas) 作联合平均，而且这些复本面对的是同一个随机样例实现。稍后可以看到，该平均只比上一节的退火平均略复杂。剩下的主要问题，是如何找到适当解析延拓，使得由自然数  $n$  得到的结果能够确定  $n \rightarrow 0$  的极限。这个问题可能很困难。<sup>1</sup> 幸运的是，对于本书考察的大多数系统，一个相对直接的步骤是成功的。

为了对样例和教师取  $\Omega^n(\xi^\mu, \mathbf{T})$  的平均，引入类似 (2.17) 的辅助变量：

$$\lambda_\mu^a = \frac{1}{\sqrt{N}} \mathbf{J}^a \xi^\mu, \quad u_\mu = \frac{1}{\sqrt{N}} \mathbf{T} \xi^\mu. \quad (2.32)$$

给定  $\mathbf{J}^a$  和  $\mathbf{T}$  时，它们在大  $N$  下再次是正态分布随机变量，其矩为

$$\begin{aligned} \langle\langle \lambda_\mu^a \rangle\rangle &= \langle\langle u_\mu \rangle\rangle = 0, & \langle\langle (\lambda_\mu^a)^2 \rangle\rangle &= \langle\langle u_\mu^2 \rangle\rangle = 1, \\ \langle\langle \lambda_\mu^a \lambda_\mu^b \rangle\rangle &= q^{ab}, & \langle\langle \lambda_\mu^a u_\mu \rangle\rangle &= R^a, \end{aligned} \quad (2.33)$$

其中

$$R^a = \frac{\mathbf{J}^a \mathbf{T}}{N}, \quad q^{ab} = \frac{\mathbf{J}^a \mathbf{J}^b}{N}. \quad (2.34)$$

这里  $R^a$  表示不同学生与教师之间的重叠，仍然直接关联到泛化误差。新的参数  $q^{ab}$  刻画两个不同学生向量之间的相互重叠，因此描述版本空间中仍然可能存在的变动性。

如附录 B 详细说明的那样，与退火计算类似， $\langle\langle \ln \Omega(\xi^\mu, \mathbf{T}) \rangle\rangle$  由具有特定  $R^a$  和  $q^{ab}$  值的  $\mathbf{J}^a$  构型支配。由于所有复本变量扮演完全对称的角色，自然假设这些典型值不依赖于复本指标，即  $R^a = R$  且  $q^{ab} = q$ 。这是复本对称的关键假设（参见 (A2.28)），它会大幅简化下面的分析。它意味着从版本空间中随机选出的成员  $\mathbf{J}^a$  与教师之间的重叠，总是以概率 1 取同一值  $R$ ；而版本空间中随机选取的任意一对向量  $\mathbf{J}^a$  和  $\mathbf{J}^b$  的典型相互重叠也几乎总是取同一值  $q$ 。第 6 章将讨论如何检验复本对称假设是否确实有效。这里先说明，它对当前学习问题是合理的。

事实上，我们的特殊学习情形还具有额外对称性。教师  $\mathbf{T}$  从整个球面上的均匀分布随机选出（参见 (2.16)），并且按定义属于版本空间。另一方面，当前学习场景是以相等概率从版本空间中随机抽取学生向量。因此，典型教师-学生重叠  $R$  应当与典型学生-学生重叠  $q$  一致。详细计算验证了这一假设（见 (A2.36)）。

利用与矩 (2.33) 对应的高斯概率分布，并使用  $q^{ab} = R^a = R$ ，可由 (2.31) 经过与上一节类似的变形得到

$$\begin{aligned} \langle\langle \Omega^n(\xi^\mu, \mathbf{T}) \rangle\rangle &= \int_{-1}^1 dR \int \prod_a d\mu(\mathbf{J}^a) \left\langle\left\langle \prod_a \delta\left(\frac{\mathbf{J}^a \mathbf{T}}{N} - R\right) \right\rangle\right\rangle \prod_{(a,b)} \delta\left(\frac{\mathbf{J}^a \mathbf{J}^b}{N} - R\right) \\ &\quad \times \int \prod_{\mu,a} \frac{d\lambda_\mu^a}{\sqrt{2\pi(1-R)}} \int \prod_\mu \frac{du_\mu}{\sqrt{2\pi(1+nR)}} \prod_{\mu,a} \Theta(\lambda_\mu^a u_\mu) \\ &\quad \times \exp \left[ -\frac{1}{2(1-R)(1+nR)} \sum_\mu \left( [1 + (n-1)R] u_\mu^2 + [1 + (n-1)R] \sum_a (\lambda_\mu^a)^2 \right. \right. \\ &\quad \left. \left. - 2R u_\mu \sum_a \lambda_\mu^a - R \sum_{(a,b)} \lambda_\mu^a \lambda_\mu^b \right) \right]. \end{aligned} \quad (2.35)$$

剩下的平均只对教师进行， $(a, b)$  表示所有满足  $a \neq b$  的成对指标。当  $n = 1$  时，自然恢复式 (2.20)。

再次利用教师与学生之间的对称性，可以进一步简化这一结果。对教师耦合  $\mathbf{T}$  的平均给出额外积分  $\int d\mu(\mathbf{T})$ ，它与  $\mathbf{J}$  积分属于同一类型。类似地， $u_\mu$  积分与  $\lambda_\mu^a$  积分相似，并且按  $\mu$  因子分

<sup>1</sup> 文献 [17] 是复本方法的一部权威指南。

解。令  $\mathbf{T} = \mathbf{J}^{n+1}$  且  $u_\mu = \lambda_\mu^{n+1}$ ，可将 (2.35) 改写为

$$\begin{aligned} \langle\langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle\rangle &= \int_{-1}^1 dR \int \prod_a d\mu(\mathbf{J}^a) \prod_{(a,b)} \delta\left(\frac{\mathbf{J}^a \mathbf{J}^b}{N} - R\right) \\ &\times \left[ 2\sqrt{\frac{1-R}{1+nR}} \int_0^\infty \prod_a \frac{d\lambda^a}{\sqrt{2\pi(1-R)}} \exp\left(-\frac{[1+(n-1)R] \sum_a (\lambda^a)^2 - R \sum_{(a,b)} \lambda^a \lambda^b}{2(1-R)(1+nR)}\right) \right]^{\alpha N}. \end{aligned} \quad (2.36)$$

这里重要的差别是，现在  $a$  从 1 到  $n+1$ ，而不只是到  $n$ 。剩余的  $\mathbf{J}$  积分是高斯型的，可用附录 A 的方法计算，得到

$$\exp\left\{N\left[\frac{n}{2}\ln(1-R) + \frac{1}{2}\ln(1+nR)\right]\right\}, \quad (2.37)$$

这是式 (2.5) 的推广。 $\lambda^a$  积分同样是高斯积分。考虑积分区间  $0 \leq \lambda^a < \infty$  后，它们等于

$$2 \int Dt H^{n+1}\left(-\sqrt{\frac{R}{1-R}}t\right), \quad (2.38)$$

其中使用了简写

$$Dt = \frac{dt}{\sqrt{2\pi}} \exp(-t^2/2), \quad H(x) = \int_x^\infty Dt. \quad (2.39)$$

这些记号也在第 A1.1 节中引入。对于  $n=1$ ，式 (2.38) 也如应当那样与 (2.22) 一致。

因此有

$$\langle\langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle\rangle = \int_{-1}^1 dR \exp\left\{N\left[\frac{n}{2}\ln(1-R) + \frac{1}{2}\ln(1+nR) + \alpha \ln 2 \int Dt H^{n+1}\left(-\sqrt{\frac{R}{1-R}}t\right)\right]\right\}. \quad (2.40)$$

现在可容易取  $n \rightarrow 0$  极限。利用 (2.30)，并注意在  $N \rightarrow \infty$  时剩余  $R$  积分可用鞍点法完成，最终得到

$$S(\alpha) \sim N \max_R \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} + 2\alpha \int Dt H\left(-\sqrt{\frac{R}{1-R}}t\right) \ln H\left(-\sqrt{\frac{R}{1-R}}t\right) \right]. \quad (2.41)$$

对  $R$  求导，得到最大值条件

$$\frac{R}{1-R} = \frac{\alpha}{\pi} \int Dt \frac{\exp[-Rt^2/(2(1-R))]}{H\left(-\sqrt{\frac{R}{1-R}}t\right)}. \quad (2.42)$$

式 (2.41) 和 (2.42) 分别等价于附录 B 中更详细推导得到的 (A2.37) 和 (A2.36)。

图 2.3 给出了由数值求解式 (2.42)，再代入 (2.41) 和 (2.3) 得到的相关量行为。定性行为与退火计算相同。教师-学生重叠  $R$  在  $\alpha=0$  时从  $R=0$  出发，并随  $\alpha$  单调增加，在  $\alpha \rightarrow \infty$  时趋于  $R=1$ 。相应地，泛化误差  $\varepsilon$  从“纯猜测”值  $\varepsilon=0.5$  单调下降，并在  $\alpha \rightarrow \infty$  时趋于零。随着训练样例数增加，版本空间的收缩由淬火熵随  $\alpha$  增加而下降来量化。

为了检验 Gardner 方法的定量精确性，我们已把  $\varepsilon(\alpha)$  的结果作为实线加入图 1.4。可以看到，它与模拟结果符合得很好。中等  $\alpha$  下剩余差异来自模拟使用的是  $N=20$ ，而解析计算严格只在  $N \rightarrow \infty$  下有效。理论与模拟仍然相当一致，这使我们有理由期待，依赖热力学极限  $N \rightarrow \infty$  的统计力学分析，常常也能相当准确地描述有限系统。

## 2.4 小结

简要总结本章主要内容。我们把 Gibbs 学习作为一种自然且有效的算法引入，用于让感知机从样例中学习由教师网络指定的目标映射。网络结构主要决定了可实现分类的先验分布；学习则通




图 2.3: 教师—学生重叠  $R$  (虚线) 和泛化误差  $\varepsilon$  (实线) 随训练集大小  $\alpha$  的变化。插图显示每个耦合的熵随  $\alpha$  增加而下降。点线给出习题 2.9 中要确定的信息增益  $\Delta I$  的行为。

过简单地拒绝所有与训练集中至少一个教师分类相矛盾的假设实现。当输入维数  $N$  很大时，版本空间由两类耦合向量共同支配：它们在训练集上表现完美，同时具有较大的先验概率。随着训练集大小  $\alpha$  增加，这一平衡越来越偏向与目标耦合具有大重叠的耦合，从而导致泛化误差下降。

定量描述中的基本问题，是正确处理训练集样例和目标映射中的随机性。与数理统计和计算机科学许多研究中居核心地位的最坏情形分析互补，统计力学强调的是典型行为；在  $N \rightarrow \infty$  时，典型行为以概率 1 出现。由于感兴趣量的完整概率分布通常过于复杂，必须用解析上可处理的平均来刻画典型行为。为此，需要识别自平均量，即平均值与最可能值一致的量。

我们已经看到，版本空间体积并不是自平均的。尽管其概率分布在  $N \rightarrow \infty$  时变得尖锐，最可能值与平均值仍不一致。基于版本空间体积平均的退火计算，因此不能描述典型行为。不过，由于容易计算，它仍经常有用：它可以提供对系统定性行为的理解，有时还给出相当好的定量近似。在统计力学中，退火平均描述所有自由度都具有随机动力学、并试图最小化相关热力学势的系统。对学习问题而言，这意味着退火估计对应一种学习场景：学生耦合  $\mathbf{J}$  和训练集样例  $\xi^\mu$  都被调整以最小化训练误差。事实上可以证明 [21]，在退火近似下，学习后的样例分布不同于学习前的分布。这种修改程度决定了退火近似的定量精度。在本章分析的简单设定中，它可能相当好；但后续章节会看到，它也可能完全失败。

泛化问题中正确的自平均量是相空间中的熵，即版本空间体积的对数。对于  $N \rightarrow \infty$ ，可借用无序系统统计力学中的复本技巧解析确定它。在复本对称假设下，计算相当直接；研究学习问题时，我们总会首先采用这一假设。不过必须记住，一致处理总要求检验这一假设的可靠性。这个问题将在第 6 章更详细地讨论。对于上述简单学习场景，复本对称假设给出正确结果。这与版本空间连通这一事实有关，<sup>1</sup> 即对任意两个元素，总存在一条完全位于版本空间内的线连接它们。粗略地说，连通版本空间等价于遍历动力学，而在无序系统理论中，遍历动力学可由复本对称正确描述。

<sup>1</sup>它甚至是凸的，见习题 2.8。

最后列出与本章相关的关键参考文献。第一节中给出的泛化误差退火估计由 [22] 和 [23] 提出。Elizabeth Gardner 在一系列开创性论文 [24, 25, 26, 27] 中率先把复本方法应用于形式神经网络。将这些技术用于规则推断问题的可能性见 [28, 29, 27]。教师-学生场景中的 Gibbs 学习这一特殊情形最早由 [30] 研究。相关情形的详细分析见 [21]。

## 2.5 习题

2.1 证明：大  $N$  下， $N$  球面的面积  $\Omega_0$  主导阶为

$$\Omega_0 = \exp \left\{ \frac{N}{2} [1 + \ln(2\pi)] \right\}. \quad (2.43)$$

精确结果是什么？

2.2 计算  $N$  球面上一顶球冠的面积，该球冠由所有与给定方向夹角不超过  $\theta$  的向量组成。证明该面积由球冠边缘支配，并由此验证式 (2.5)。

2.3 证明式 (2.17) 中变量的联合概率密度  $P(\lambda, u)$  确实是具有式 (2.19) 所给矩的高斯分布。可从

$$P(\lambda, u) = \left\langle \delta \left( \lambda - \frac{1}{\sqrt{N}} \mathbf{J} \boldsymbol{\xi} \right) \delta \left( u - \frac{1}{\sqrt{N}} \mathbf{T} \boldsymbol{\xi} \right) \right\rangle \quad (2.44)$$

出发，其中平均对  $N$  球面上随机选取的样例  $\boldsymbol{\xi}$  进行，并使用附录 A 中介绍的技术。

2.4 证明退火熵  $S^{\text{ann}}$  永远不小于淬火熵  $S$ 。什么时候等号成立？

2.5 数值生成  $M$  个随机数  $x$ ，每个  $x$  是  $N$  个相互独立、在 1 到 2 之间均匀分布的随机数之积，其中  $M$  在  $10^3$  到  $10^6$  之间， $N$  在 5 到 50 之间。用直方图近似  $x$  的分布，并比较最可能值  $x_{\text{mp}}$ 、平均值  $\langle x \rangle$  和  $x_{\text{typ}} := \exp(\langle \ln x \rangle)$  随  $N$  的演化。能否说明为什么渐近地 ( $N \rightarrow \infty$ ) 最可能值应与  $x_{\text{typ}}$  一致？为什么在模拟中最可能值总小于  $x_{\text{typ}}$ ？

2.6  $p$  个粒子可占据  $N$  个位置，并满足互斥条件且  $p \leq N$ 。系统可能构型数为组合数  $W = C_N^p = \binom{N}{p}$ 。

$$W = \sum_{\{S_i\}} \delta \left( \sum_{i=0}^N S_i, p \right), \quad (2.45)$$

其中  $S_i = 0, 1$ ， $S_i = 1$  表示位置  $i$  被占据， $\sum_{\{S_i\}}$  表示对  $S_i$  的全部  $2^N$  种可能构型求和。计算  $N \rightarrow \infty$ 、 $p \rightarrow \infty$  且  $\alpha = p/N$  固定时的渐近行为，并用 Stirling 公式检查结果。随后考虑位置以概率  $\rho$  随机阻塞的情形，引入  $x_i = 0, 1$  表示阻塞或可达，分别用退火和淬火平均计算熵  $S = \ln W$ ，并说明只有淬火平均与可达位置数为  $(1 - \rho)N$ 、涨落为  $O(\sqrt{N})$  的事实相符。

2.7 与版本空间体积不同，教师和学生的重叠  $R$  是自平均量。乍看似似乎可以避开复杂复本计算，直接计算平均重叠。然而版本空间体积现在作为归一化因子出现：

$$R = \frac{\int d\mu(\mathbf{J}) \prod_{\mu} \Theta[(\mathbf{T}\boldsymbol{\xi}^{\mu}/\sqrt{N})(\mathbf{J}\boldsymbol{\xi}^{\mu}/\sqrt{N})] \mathbf{J}\mathbf{T}/N}{\int d\mu(\mathbf{J}) \prod_{\mu} \Theta[(\mathbf{T}\boldsymbol{\xi}^{\mu}/\sqrt{N})(\mathbf{J}\boldsymbol{\xi}^{\mu}/\sqrt{N})]}. \quad (2.46)$$

证明：使用  $a^{-1} = \lim_{n \rightarrow 0} a^{n-1}$  后，该计算本质上化为标准 Gardner 计算，其中序参量  $R = \mathbf{J}\mathbf{T}/N$  由鞍点方程 (2.42) 决定。

2.8 证明满足球面约束 (2.1) 的实值耦合感知机版本空间是凸的。为此证明：对版本空间中的任意两个向量  $\mathbf{J}^{(1)}$  和  $\mathbf{J}^{(2)}$ ， $\mathbf{J}(\gamma) = \gamma\mathbf{J}^{(1)} + (1-\gamma)\mathbf{J}^{(2)}$  在适当归一化后，对所有  $\gamma \in (0, 1)$  也对应版本空间中的向量。

2.9 考虑表达式

$$\Delta I = \ln \frac{\Omega(\boldsymbol{\xi}^1, \dots, \boldsymbol{\xi}^{p-1}; \mathbf{T})}{\Omega(\boldsymbol{\xi}^1, \dots, \boldsymbol{\xi}^p; \mathbf{T})}. \quad (2.47)$$

它描述训练集中第  $p$  个样例引起的版本空间体积下降。由于版本空间体积相对缩减的对数就是该样例带来的关于教师耦合的额外信息， $\Delta I$  称为平均信息增益。通过与 (2.27) 和 (2.41) 比较，证明

$$\Delta I = S_{p-1} - S_p = -\frac{1}{N} \frac{dS(\alpha)}{d\alpha} = -2 \int Dt H\left(-\sqrt{\frac{R}{1-R}}t\right) \ln H\left(-\sqrt{\frac{R}{1-R}}t\right), \quad (2.48)$$

并验证图 2.3 中  $\Delta I$  随  $\alpha$  的行为。为什么  $\Delta I$  随  $\alpha$  增加而下降？能否设想一种让所有样例的信息增益保持常数的学习场景？在这种情形中，你预期  $\varepsilon$  随  $\alpha$  如何标度？

2.10 确定大训练集大小  $\alpha$  下描述 Gibbs 学习的各量的渐近行为。从式 (2.42) 出发证明

$$1 - R \sim \left[ \frac{\alpha}{\pi} \int Dt \frac{\exp(-t^2/2)}{H(-t)} \right]^{-2} \simeq \frac{1.926}{\alpha^2}, \quad (2.49)$$

并由式 (2.3)、(2.41) 和 (2.48) 推出

$$\varepsilon \sim \frac{\sqrt{2}}{\int Dt [\exp(-t^2/2)]/H(t)} \frac{1}{\alpha} \sim \frac{0.625}{\alpha}, \quad (2.50)$$

$$S \sim \frac{1}{2} \ln(1-R) \sim -\ln \alpha, \quad (2.51)$$

$$\Delta I \sim -\sqrt{\frac{2(1-R)}{\pi}} \int dt H(t) \ln H(t) \sim \frac{2.60}{\alpha}. \quad (2.52)$$

2.11 考虑所谓最近邻分类器。它把一个新输入模式  $\mathbf{S}$  分类为训练集中与  $\mathbf{S}$  夹角最小的样例  $\boldsymbol{\xi}$  的教师分类。引入概率

$$P(a, b) = \left\langle \left\langle \delta\left(\frac{\boldsymbol{\xi}\mathbf{S}}{\sqrt{N}} - a\right) \delta\left(\frac{\boldsymbol{\xi}\mathbf{T}}{\sqrt{N}} - b\right) \right\rangle \right\rangle_{\boldsymbol{\xi}^\mu}, \quad (2.53)$$

$$P(a) = \left\langle \left\langle \delta\left(\frac{\boldsymbol{\xi}\mathbf{S}}{\sqrt{N}} - a\right) \right\rangle \right\rangle_{\boldsymbol{\xi}^\mu}, \quad (2.54)$$

证明泛化误差为

$$\varepsilon(p) = p \left\langle \left\langle \int_{-\infty}^0 db \int da P(a, b) \left[ \int_{-\infty}^a da' P(a') \right]^{p-1} \right\rangle \right\rangle_{\mathbf{S}}. \quad (2.55)$$

计算  $p = \alpha N \rightarrow \infty$  时  $\varepsilon(p)$  的极限。由此能推断该学习算法在高维问题中的表现如何？遇到困难可参考 [31]。



## 第三章 学习规则的选择

上一章讨论的 Gibbs 规则刻画了构成版本空间的学生所具有的典型泛化行为。因此，它很适合用作一般性的理论分析。然而，对于一个具体的实际问题，它几乎不可能是最佳选择；还有许多其他学习规则往往更直接，也可能表现得更好。本章的目的，是介绍若干有代表性的学习规则，讨论它们的一些性质，并将它们同 Gibbs 规则的性质作比较。

### 3.1 Hebb 规则

最古老、也许也是最重要的学习规则，是 D. Hebb 在 20 世纪 40 年代末提出的。事实上，它可以看作把 Pavlov 的符合训练思想应用到单个神经元层面。在著名实验中，Pavlov 说明了一只狗如果被训练成在灯亮的同时获得食物，那么后来仅仅看到灯亮也会开始分泌唾液。某种意义上，食物与灯光这两个事件的同时出现在狗的大脑中建立了联系，使得即使只发生其中一个事件，也会激发对另一个事件的记忆。Hebb 规则 [32] 背后的基本思想非常相似：共同激发的神经元之间的连接应当得到加强。其结果是，其中一个神经元的激发将促进另一个神经元也被激发。

把 Hebb 规则应用到简单感知机结构时，可得到如下形式。设  $\xi_i^\mu$  是样例  $\xi^\mu$  在神经元输入通道  $J_i$  处的输入。如果所要求的输出  $\sigma_T^\mu = \text{sgn}(\mathbf{T}\xi^\mu)$  与  $\xi_i^\mu$  同号，就发生了符合，连接应当增强： $J_i^{\text{new}} = J_i^{\text{old}} + 1$ 。如果二者异号，原始的 Hebb 规则规定不作改变。不过出于对称性的考虑，我们将降低连接强度： $J_i^{\text{new}} = J_i^{\text{old}} - 1$ 。在这一约定下，Hebb 规则可用向量记号写作  $\mathbf{J}^{\text{new}} = \mathbf{J}^{\text{old}} + \xi^\mu \sigma_T^\mu$ 。对一组  $p$  个训练样例，若每个样例只向网络呈现一次，则得到耦合强度

$$\mathbf{J}_H = \frac{1}{\sqrt{N}} \sum_{\mu} \xi^\mu \sigma_T^\mu, \quad (3.1)$$

其中已经包含了一个归一化因子，它保证在大  $N$  下  $\mathbf{J}^2 \sim N$ 。

Hebb 规则的结构特别简单，因此其训练误差和泛化误差也能较容易地求出。先定义输入  $\xi^\nu$  的稳定性或对齐场  $\Delta^\nu$ ：

$$\Delta^\nu = \frac{1}{\sqrt{N}} \mathbf{J} \xi^\nu \sigma_T^\nu. \quad (3.2)$$

样例  $\xi^\nu$  被正确分类等价于  $\Delta^\nu > 0$ 。为了计算满足这一条件的概率，利用 Hebb 向量 (3.1) 的显式表达式，可把  $\Delta^\nu$  改写为

$$\Delta^\nu = 1 + \frac{1}{N} \sum_{\mu \neq \nu} \xi^\mu \xi^\nu \sigma_T^\mu \sigma_T^\nu. \quad (3.3)$$

这个公式的含义很清楚。右端第一项是所谓信号项，来自样例  $\xi^\nu$  对  $\mathbf{J}_H$  的贡献。它对该样例的稳定性、因而对其正确分类给出正贡献。第二项是所谓噪声项，来自其他样例的串扰；它是一个随机量，会干扰  $\xi^\nu$  的正确分类。

为分析  $\Delta^\nu$  的统计性质，最方便的是假设样例  $\xi^\mu$  按  $N$  球面上的均匀分布  $P_S$  抽取。<sup>1</sup> 现在把所有样例分解为相对于教师向量的正交部分和平行部分：

$$\xi^\mu = \xi_\perp^\mu + \xi_\parallel^\mu, \quad (3.4)$$

<sup>1</sup> 对大  $N$  而言， $P_S$  的一阶和二阶矩才是重要的；这些矩与分布 (1.5) 一致，见问题 1.3。

其中  $\xi_{\parallel}^{\mu} = \xi_{\parallel}^{\mu} \mathbf{T}$ 。由此得到

$$\Delta^{\nu} = 1 + \xi_{\parallel}^{\nu} \sigma_T^{\nu} \frac{1}{N} \sum_{\mu \neq \nu} \xi_{\parallel}^{\mu} \sigma_T^{\mu} + \frac{1}{N} \sum_{\mu \neq \nu} \xi_{\perp}^{\mu} \xi_{\perp}^{\nu} \sigma_T^{\mu} \sigma_T^{\nu}. \quad (3.5)$$

正交部分与分类  $\sigma_T^{\mu}$  不相关, 因此  $\xi_{\perp}^{\mu} \sigma_T^{\mu}$  是  $\mathbf{T}$  的正交子空间中  $(N-1)$  球面上的随机向量。于是  $\sum_{\mu \neq \nu} \xi_{\perp}^{\mu} \xi_{\perp}^{\nu} \sigma_T^{\mu} \sigma_T^{\nu}$  是  $N(p-1)$  个相互独立随机变量之和, 因而收敛到  $N\sqrt{\alpha}y$ , 其中  $y$  是均值为零、方差为一的正态随机变量。

另一方面,  $\xi_{\parallel}^{\mu} \sigma_T^{\mu} = |\xi_{\parallel}^{\mu}|$  是一个正态随机变量  $x$  的绝对值, 且与  $y$  独立。此外,  $\sum_{\mu \neq \nu} |\xi_{\parallel}^{\mu}|$  是  $(p-1)$  个独立随机变量绝对值之和, 因而收敛到  $N\alpha\sqrt{2/\pi}$ 。

因此, Hebb 耦合向量错误分类样例  $\xi^{\nu}$  的概率, 等于  $\Delta^{\nu} = 1 + \alpha\sqrt{2/\pi}|x| + \sqrt{\alpha}y$  为负的概率。训练误差由此为

$$\varepsilon_t = 2 \int_0^{\infty} Dx \int_{-\infty}^{-1/\sqrt{\alpha} - \sqrt{2\alpha/\pi}x} Dy = 2 \int_0^{\infty} Dx H\left(\frac{1}{\sqrt{\alpha}} + \sqrt{\frac{2\alpha}{\pi}}x\right). \quad (3.6)$$

注意, 与按构造训练误差为零的 Gibbs 规则不同, Hebb 规则并不能完全学会训练样例。人们可能会猜想, 它的泛化误差也总是更高。然而事实并非如此。

为了计算泛化误差  $\varepsilon$ , 再次利用  $\xi_{\parallel}^{\mu}$  的统计性质, 并注意

$$\frac{\mathbf{J}_H \mathbf{T}}{N} = \frac{1}{N} \sum_{\mu} \frac{\mathbf{T} \xi_{\parallel}^{\mu} \sigma_T^{\mu}}{\sqrt{N}} = \frac{1}{N} \sum_{\mu} |\xi_{\parallel}^{\mu}| \quad (3.7)$$

由于大数定律是自平均量, 该式等于  $\alpha\sqrt{2/\pi}$ 。用类似论证可知,  $\mathbf{J}_H$  的长度也是自平均的,

$$|\mathbf{J}_H| = \sqrt{N\alpha(1 + 2\alpha/\pi)}.$$

由于  $R = \mathbf{J} \mathbf{T} / (|\mathbf{J}| |\mathbf{T}|)$ , 且泛化误差由 (2.3) 以  $R$  表示, 我们得到

$$\varepsilon = \frac{1}{\pi} \arccos \sqrt{\frac{2\alpha}{2\alpha + \pi}}. \quad (3.8)$$

为了与 Gibbs 学习作比较, 考察小  $\alpha$  和大  $\alpha$  行为是有启发性的:

$$\varepsilon_t \sim \sqrt{\frac{2\alpha}{\pi}} \exp\left(-\frac{1}{2\alpha} + \frac{1}{\pi}\right) H\left(\sqrt{\frac{2}{\pi}}\right), \quad \varepsilon(\alpha) \sim \frac{1}{2} - \sqrt{\frac{2\alpha}{\pi^3}} \quad (\alpha \rightarrow 0), \quad (3.9)$$

并且

$$\varepsilon_t \sim \varepsilon \sim \frac{1}{\sqrt{2\pi\alpha}} \sim \frac{0.40}{\sqrt{\alpha}} \quad (\alpha \rightarrow \infty). \quad (3.10)$$

由此可见, 在  $\alpha \rightarrow \infty$  时, Hebb 规则的泛化误差降到零的速度远慢于 Gibbs 规则 (参见问题 2.10)。不过在某种意义上, 当  $\alpha$  很大时, Hebb 规则并不比大多数其他学习规则差太多, 因为训练误差与泛化误差之差渐近地按  $1/\alpha$  下降。因此, 它的泛化表现较差, 归根结底是因为它无法很好地正确学习训练样例。

小  $\alpha$  时情况很不相同: Hebb 规则使泛化误差随  $\alpha$  的下降快于 Gibbs 规则。事实上, 如下文将看到的那样, 它达到了可能的最低初始泛化误差。

由于基于符合训练这一简单原理, Hebb 规则适用范围很广, 包括多数神经结构和训练方案。因此, 在后续若干章中我们还会使用它。对硬件实现尤其重要的一点是, Hebb 规则是局部学习规则:



只需知道输入端和输出端的状态，就能计算连接突触上的修正。此外，由于显式的加性处方 (3.1)，它极易实现。因此，新的样例可以加入训练集，而不必重新考虑此前的样例。

其缺点是，Hebb 规则具有非零训练误差，因此并不能完美学会可用信息。结果是，对于大的训练集，它的表现相当差。我们还要指出，如果训练集样例彼此相关，Hebb 规则会失败得很严重。

### 3.2 感知机规则

由 Hebb 规则得到的耦合 (3.1) 可写成

$$\mathbf{J} = \frac{1}{\sqrt{N}} \sum_{\mu} x^{\mu} \boldsymbol{\xi}^{\mu} \sigma_T^{\mu}, \quad (3.11)$$

其中所有嵌入强度  $x^{\mu}$  都相等。因此，训练集中的所有样例在耦合中留下相同痕迹，正是这种信息抹平导致了 Hebb 规则在大  $\alpha$  下表现不佳。

克服这一问题的一个显然修改，是从叠加式 (3.1) 中略去那些本来就已正确分类的样例。这最容易以序贯方式完成。设  $\mathbf{J}^{(\text{old})}$  是训练中某一时刻的权向量， $\boldsymbol{\xi}^{\mu}$  是一个新的训练样例。如果它被正确分类，则保持旧权向量不变；否则作出与 Hebb 规则相同的修正，即

$$\mathbf{J}^{(\text{new})} = \begin{cases} \mathbf{J}^{(\text{old})} + \frac{1}{\sqrt{N}} \boldsymbol{\xi}^{\mu} \sigma_T^{\mu}, & \text{若 } \mathbf{J}^{(\text{old})} \boldsymbol{\xi}^{\mu} \sigma_T^{\mu} < 0, \\ \mathbf{J}^{(\text{old})}, & \text{否则.} \end{cases} \quad (3.12)$$

这就是著名的感知机学习规则。它与感知机一起在 20 世纪 60 年代初变得非常流行，这在很大程度上归功于 F. Rosenblatt 的开创性工作 [6]。它显然会产生非平凡的嵌入强度谱  $x^{\mu}$ 。感知机规则最突出的特征是：当它被反复迭代时，只要零训练误差的解存在，它就会在有限步内收敛，即找到一个训练误差为零的  $\mathbf{J}$  向量。收敛证明见附录 C。

泛化误差不能像 Hebb 规则那样简单计算。事实上，作为一个动力学处方，感知机规则最方便在在线学习框架中分析（参见第 9.2 节）。不过，借助与 Hebb 规则的类比，可以构造一个感知机规则的“离线”对应物，其泛化性质见文献 [33]。

感知机规则的一个有趣方面是，它可以很容易地改造成用于 Gibbs 学习的数值分析。直接在模拟中实现 Gibbs 学习并不完全平凡，因为版本空间只是整个  $\mathbf{J}$  空间的一个指数小部分，如何从其中随机选取一个向量并不显然。若在感知机规则中，对耦合的每次更新 (3.12) 都加入一个均值为零、方差适当的随机贡献，就能保证最终大致以随机位置落入版本空间。图 1.4 中的模拟采用的正是这一过程，其中随机部分的方差为系统性贡献的 50 倍。当然，这一修改会减慢算法收敛，但所得耦合向量在非常好的近似下均匀分布于版本空间 [34]。在这一点上，修正后的感知机规则似乎优于其他模拟 Gibbs 学习的方法，例如版本空间中的随机游走 [21, 35]、台球方法 [36]，或随机扩充训练集 [37]。

### 3.3 伪逆规则

任何学习规则都试图让学生输出与教师输出一致。伪逆规则的思想，是绕开神经元激活函数中固有的非线性，直接规定突触后势，或者等价地，规定学生的稳定性  $\Delta^{\mu}$ ，而不是规定其输出。直观上，如果这些稳定性尽可能大，应当会有良好的泛化表现。相应耦合向量会位于版本空间中心附

近, 而版本空间的边界由至少一个  $\mu$  满足  $\Delta^\mu = 0$  给出。具体地说, 伪逆规则要求所有稳定性彼此相等,  $\Delta^\mu = \kappa$ , 并且在固定范数  $\mathbf{J}^2$  时, 使共同值  $\kappa$  尽可能大 [38]。换言之, 伪逆向量是这样一个向量: 它同所有对齐输入  $\xi^\mu \sigma_T^\mu$  夹角相同, 同时这一夹角又尽可能小。

从几何上看, 所有夹角相等这一条件只能在  $p/N = \alpha < 1$  时实现。此外, 伪逆  $\mathbf{J}$  向量必须位于由样例张成的子空间中, 即再次具有 (3.11) 的形式。这一点可如下最简单地看出。在耦合归一化固定时最大化稳定性, 等价于在稳定性固定时最小化范数  $\mathbf{J}^2$ 。 $\mathbf{J}$  中垂直于所有样例的分量不影响稳定性  $\Delta^\mu$ , 但仍会增大范数  $\mathbf{J}^2$ , 因此最优的  $\mathbf{J}$  不应含有这类分量。

为了求伪逆耦合向量, 可令所有  $\mu$  上的  $\Delta^\mu = \kappa = 1$ , 并采用形式 (3.11), 以保证  $\mathbf{J}^2$  的范数最小。随后可用简单线性代数显式构造  $\mathbf{J}$ 。为此从线性方程组

$$\sum_{\nu} C_{\mu\nu} x^\nu = 1 \quad \text{对所有 } \mu \quad (3.13)$$

出发, 其中样例相关矩阵定义为

$$C_{\mu\nu} = \frac{1}{N} \xi^\mu \xi^\nu \sigma_T^\mu \sigma_T^\nu. \quad (3.14)$$

如果向量  $\xi^\mu \sigma_T^\mu$  线性无关, 那么  $C_{\mu\nu}$  非奇异, (3.13) 有唯一解; 对大  $N$  且独立的  $\xi^\mu$ , 这种情况以概率 1 发生。相应耦合向量为

$$\mathbf{J}_{\text{PI}} = \frac{1}{\sqrt{N}} \sum_{\mu, \nu} (C^{-1})_{\mu\nu} \xi^\mu \sigma_T^\mu. \quad (3.15)$$

它也可不通过嵌入强度, 而是利用由列向量  $\xi^\mu \sigma_T^\mu$  构成的  $N \times p$  矩阵的 Moore–Penrose 伪逆得到 [38, 39], 这正是该学习规则名称的由来。它也称为投影规则, 因为  $\mathbf{J}_{\text{PI}} \mathbf{S}$  给出了输入  $\mathbf{S}$  在样例  $\xi^\mu$  所张成子空间上的投影。与感知机规则一样, 它实现零训练误差。在相关输入的情形下, 它非常有效, 因为 (3.15) 实际上对样例作了去相关。另一方面要注意, 由于其非局部性质, 投影规则实现起来很笨拙。向训练集中加入一个新样例, 要求完全重新计算并求逆相关矩阵  $C_{\mu\nu}$ 。因此, 以这种形式来看, 它不太可能成为生物或技术实现中的候选规则。

当  $\alpha > 1$  时, 不可能对所有  $\mu$  满足  $\Delta^\mu = \kappa$ 。此时能尝试的最好办法, 是最小化观察稳定性与所要求稳定性之间的误差。这由 adaline 规则实现。

### 3.4 Adaline 规则

Adaline 是 adaptive linear neuron (自适应线性神经元) 的缩写。它由 Widrow 于 20 世纪 60 年代初提出 [40], 并通过销售一种名为 memistor 的硬件装置实现商业化; 这家 Memistor Corporation 很可能是历史上第一家神经网络公司。线性神经元的输出就是其突触后势:

$$\sigma = \mathbf{J} \xi. \quad (3.16)$$

作为学习规则, Widrow 引入了所谓 delta 规则或 adaline 规则。它可追溯到统计学中熟悉的最小平方误差方法。为实现最小平方误差, 对总平方误差

$$E(\mathbf{J}) = \frac{1}{2} \sum_{\mu} (\mathbf{J} \xi^\mu - \sigma_T^\mu)^2 \quad (3.17)$$

作梯度下降, 得到更新修正

$$\delta \mathbf{J} = -\gamma \frac{\partial E}{\partial \mathbf{J}} = \gamma \sum_{\mu} \delta^\mu \xi^\mu, \quad (3.18)$$

其中引入了学习率  $\gamma$ 。delta 因子  $\delta^\mu = \sigma_T^\mu - \mathbf{J}\xi^\mu$  是样例  $\mu$  贡献的误差，并作为样例  $\mu$  的嵌入强度增量出现。使用这种自适应增量，而不是感知机规则中恒定步长  $\delta x^\mu = 1$ ，其优点之一是算法收敛相当快。事实上可以证明，学习过程中二次误差会随更新次数指数下降，并且特征学习时间  $\tau$  已被计算为训练集大小  $\alpha$  的函数 [41]。delta 规则的另一个优点是，它很容易推广到具有一般可微激活函数的神经元，更重要的是还能推广到多层结构；在那里它表现为著名的反向传播算法（见第十三章）。上面给出的 adaline 规则有一个小缺点： $\mathbf{J}$  向量中位于样例正交子空间的分量不会衰减。伪逆规则给出的显式处方避免了这一特点。不过可以证明，当  $\alpha < 1$  且初始向量在该子空间中没有分量时，adaline 规则收敛到投影规则 (3.15) 给出的耦合  $\mathbf{J}_{\text{PI}}$  [42]。事实上，在这种情况下，它不过是执行伪逆规则所需矩阵求逆的一种序贯算法。

为了与下一章统计力学方法相一致的方式表述 adaline 规则，我们限制在二值输出  $\sigma_T = +1$  或  $-1$  的情形。于是 (3.17) 可改写为

$$E(\mathbf{J}) = \frac{1}{2} \sum_{\mu} (\mathbf{J}\xi^\mu \sigma_T^\mu - 1)^2. \quad (3.19)$$

在 adaline 规则中， $\mathbf{J}$  向量长度构成了必须优化的一组参数的一部分。相反，我们考虑向量  $\mathbf{J}' = \sqrt{N}\mathbf{J}/|\mathbf{J}|$ ，它满足标准归一化约束  $(\mathbf{J}')^2 = N$ ，并引入  $|\mathbf{J}|^{-1} = \kappa$  作为一个新的可最大化参数。省去  $\mathbf{J}'$  上的撇号，代价函数取为

$$E(\mathbf{J}) = \frac{1}{2\kappa^2} \sum_{\mu} (\Delta^\mu - \kappa)^2, \quad (3.20)$$

下文将把它称为 adaline 代价函数。以这种形式，adaline 规则构成了伪逆规则向  $\alpha > 1$  的自然推广。

### 3.5 最大稳定性

第 3.3 节讨论的伪逆规则引入约束：对所有  $\mu$ ， $\Delta^\mu = \kappa$ 。然而，对具有最优稳定性的网络而言，正确条件是

$$\Delta^\mu \geq \kappa > 0, \quad (3.21)$$

其中  $\kappa$  表征学生对训练集样例分类的最小置信度，并且仍应尽可能大。<sup>1</sup> 不过，分析伪逆规则所得嵌入强度  $x^\mu$  时会发现，其中一些为负。这意味着那些碰巧一开始就具有大稳定性的样例实际上被“反学习”了。为了避免反学习，一个很自然的想法是让  $\Delta^\mu > \kappa$  的样例保持不动。这样即可得到最大稳定网络，其耦合向量  $\mathbf{J}_{\text{MS}}$  到版本空间所有边界的距离最大。

优化问题 (3.21) 的一个直接解法如下。对当前权向量  $\mathbf{J}^{(\text{old})}$ ，找出稳定性最小的样例  $\xi^\nu$ ，即

$$\Delta^\nu = \min_{\mu} \Delta^\mu, \quad (3.22)$$

并执行 Hebb 学习步  $\mathbf{J}^{(\text{new})} = \mathbf{J}^{(\text{old})} + \xi^\nu \sigma_T^\nu / \sqrt{N}$ 。这个所谓 minover (minimal overlap, 最小重叠) 算法对任意给定  $c$ ，都会在有限步后收敛到一个满足所有  $\mu$  上  $\Delta^\mu > c$  的解。此外，在  $c \rightarrow \infty$  极限下会生成最大稳定耦合向量  $\mathbf{J}_{\text{MS}}$  [43]。与 adaline 规则一样，其收敛时间  $\tau$  可以计算 [44]；对大的训练集大小  $\alpha$ ，有渐近行为  $\tau \sim 0.65\alpha^2$  [45]。

<sup>1</sup>当然，只有同时固定  $\mathbf{J}$  的长度时，这一条件才有意义；例如可把它选在  $N$  球面上。

不过，求解最大稳定耦合向量的优化问题还有一种更直接、更优雅的方法：利用分解 (3.11)，从一开始就以嵌入强度  $x^\mu$  为变量。于是有

$$\Delta^\mu = \sum_{\nu} C_{\mu\nu} x^\nu, \quad \mathbf{J}^2 = \sum_{\mu, \nu} x^\mu C_{\mu\nu} x^\nu, \quad (3.23)$$

其中相关矩阵  $C_{\mu\nu}$  按 (3.14) 定义。因此，为了确定  $\mathbf{J}_{\text{MS}}$ ，需要在约束  $\sum_{\nu} C_{\nu\mu} x^\nu > 1$  对所有  $\mu$  成立的条件下，最小化  $f(x^\mu) = \sum_{\mu, \nu} x^\mu C_{\mu\nu} x^\nu$ 。这是标准的凸优化问题。由于二次代价函数严格凸，解是唯一的，并且存在一组由 Kuhn–Tucker 条件给出的充要条件；这些条件来自把未定乘子法推广到不等式约束 [46]。在当前问题中，它们要求优化问题的解  $\bar{x}^\mu$  满足

$$\sum_{\nu} C_{\mu\nu} \bar{x}^\nu \geq 1, \quad \bar{x}^\mu \geq 0, \quad \bar{x}^\mu \left( 1 - \sum_{\nu} C_{\mu\nu} \bar{x}^\nu \right) = 0. \quad (3.24)$$

第一组条件与约束本身相同。第二组保证与伪逆规则相反，没有样例被反学习。第三组有如下简单直观含义：如果样例  $\xi^\mu$  的稳定性大于 1，意味着它碰巧已被正确分类，那么就不必把它的 Hebb 项纳入  $\mathbf{J}_{\text{MS}}$ ，因此  $x^\mu = 0$ 。这样的样例称为被动样例。另一方面，如果样例  $\xi^\mu$  需要在  $\mathbf{J}$  中有显式贡献才能正确分类，则称为主动样例。在这种情况下  $x^\mu > 0$ ，同时最大稳定耦合向量  $\mathbf{J}_{\text{MS}}$  会使稳定性  $\Delta^\mu$  恰好等于 1，因为更大的值只会降低其相对于训练集中其他样例的灵活性。

由此很自然地可以设计一种利用主动/被动样例划分的学习算法。这样的算法会让被动样例不动，并用快速 adaline 处方把所有主动样例学习到同一稳定性。这个所谓 adatron 算法 [47]，顾名思义，结合了感知机规则的选择性和 adaline 的自适应步长。具体地，在计算相关矩阵  $C_{\mu\nu}$  后，它采用更新

$$\delta x^\mu = \begin{cases} \gamma(1 - \Delta^\mu), & \text{若 } \Delta^\mu < 1, \\ -x^\mu, & \text{否则,} \end{cases} \quad (3.25)$$

其中  $\gamma$  仍表示学习率。adatron 规则显然产生非负嵌入强度  $x^\mu$ 。此外，它的收敛性可用与感知机规则类似的方式证明。对序贯实现而言，当  $0 < \gamma < 2$  时，只要最大稳定耦合向量存在，adatron 规则就会找到它 [47]。并且，与 adaline 学习一样，收敛是指数式的，也存在非常高效的数值实现 [47, 48, 49]。下一章将说明，这一规则的泛化行为优于此前讨论的所有规则。由于这些原因，adatron 规则可能是感知机学习数值研究中最常用的学习规则。最大稳定性的概念在支持向量机理论中也起着关键作用（见第 14.1 节）。

### 3.6 Bayes 规则

对于泛化问题，一个原则性问题是：是否存在一种最优方式，能够利用训练集分类中包含的关于教师的信息？如果存在，它应当给出泛化误差的一个下界，任何学习规则都不能突破这一界。于是进一步的问题是：实际学习规则能多接近这一理论最优值？能否找到一个显式学习处方来饱和该下界？本节将研究这些问题，因为 Bayes 规则正是这样定义的：它以统计最优方式利用可用信息，从而最小化泛化误差。

首先必须认识到，训练集能告诉我们的关于教师的全部信息，就是教师必须位于版本空间之中。然而，为了寻找最优学生，还需要关于教师在版本空间中更可能出现于何处的额外统计信息。这个信息由教师的所谓先验分布  $P_T$  给出。这里我们只考虑最简单且最自然的情形，即假设“相等先验概率”；更准确地说，规定  $\mathbf{T}$  向量在  $N$  球面上按均匀概率随机选取。于是很清楚，教师将在版本空间中以相等概率占据任意位置。

现在构造泛化误差最低的最优耦合向量  $\mathbf{J}_B$ 。由于泛化误差是重叠  $R$  的单调下降函数，我们需要  $N$  球面上这样一个向量：它在平均意义下实现与教师的最大重叠，而这里平均是对教师分布进行的。对一个基于给定训练集构造的向量  $\mathbf{J}$ ，该平均重叠为

$$R = \frac{1}{N} \frac{\int_{\mathbf{VS}} d\mu(\mathbf{T}) \mathbf{J} \mathbf{T}}{\int_{\mathbf{VS}} d\mu(\mathbf{T})}. \quad (3.26)$$

在这一平均中，向量  $\mathbf{J}$  是固定的，因此可移到对版本空间积分之外。又因为它的长度固定，上式在  $\mathbf{J}$  指向版本空间质心方向时取最大值。因此，Bayes 耦合向量由

$$\mathbf{J}_B \sim \int_{\mathbf{VS}} d\mu(\mathbf{T}) \mathbf{T} \quad (3.27)$$

给出。

为了确定这样构造出的 Bayes 向量  $\mathbf{J}_B$  的泛化误差，我们使用下面这个优雅论证 [37]。生成  $\mathbf{J}_B$  的一个简单近似方式，是抽取大量 Gibbs 向量  $\mathbf{J}^{(i)}$ ， $i = 1, \dots, M$ ，并取它们的质心。事实上，当  $M \rightarrow \infty$  时，这一质心将精确地与  $\mathbf{J}_B$  的方向一致，即

$$\mathbf{J}_B = \lim_{M \rightarrow \infty} \sqrt{N} \frac{\sum_{i=1}^M \mathbf{J}^{(i)}}{\left[ \left( \sum_{i=1}^M \mathbf{J}^{(i)} \right)^2 \right]^{1/2}}. \quad (3.28)$$

利用第 2.3 节讨论的事实：版本空间中随机选出的两个成员之间的重叠是自平均量  $R$ ，可知当  $M$  很大时，分母表现为  $\sqrt{MN + M(M-1)RN} \sim M\sqrt{NR}$ 。于是得到  $R_B = \mathbf{J}_B \mathbf{T} / N = \sqrt{R}$ ，并由 (2.42) 得到  $R_B$  满足的方程

$$\frac{R_B^2}{1 - R_B^2} = \frac{\alpha}{\pi} \int Dt \frac{\exp[-R_B^2 t^2 / (2(1 - R_B^2))]}{H\left(-\frac{R_B}{\sqrt{1 - R_B^2}} t\right)}. \quad (3.29)$$

由该方程可抽取渐近结果

$$\varepsilon(\alpha) \sim \frac{1}{2} - \sqrt{\frac{2\alpha}{\pi^3}} + O(\alpha) \quad (\alpha \rightarrow 0), \quad (3.30)$$

这与 Hebb 规则所得结果 (3.9) 相同；并且

$$\varepsilon(\alpha) \sim \frac{\varepsilon_{\text{Gibbs}}(\alpha)}{\sqrt{2}} \sim \frac{0.442}{\alpha} \quad (\alpha \rightarrow \infty). \quad (3.31)$$

因此，该结果给出了任何感知机学习规则渐近表现的下界。

在按上述过程优化泛化误差时，我们作了一个看起来无害的隐含假设，即最优选择  $\mathbf{J}_B$  不依赖于提出的新问题。事实上，真正 Bayes 最优的过程如下。呈现一个新样例时，让版本空间中的每个成员都给出分类，然后遵从多数表决。这样，错误概率确实被最小化。图 3.1 有助于直观理解这一过程。版本空间被示意为一个封闭区域。一个新样例会把版本空间分成两个子集，分别对应于对该样例的 +1 分类和 -1 分类。由于教师在版本空间中均匀分布，错误概率最低的分类显然是多数区域的分类。因此，对所考察的这个特定样例而言，多数区域中的任何成员都是 Bayes 最优的。现在考虑另一个样例，它由另一条分割版本空间的直线表征。Bayes 规则再次要求遵从新的多数决定，但这对应于版本空间中的另一个子区域。现在可以清楚看到，随着考虑的样例越来越多，是否能在版本空间中找到一个总是落在多数区域中的单一点，就变得可疑。事实上，一般并不存在这样的点；图 3.2 给出了一个简单例子 [36]。不过，热力学极限的一个显著特征是，至少对简单感知机






图 3.1: 版本空间的示意图。呈现一个新样例时, 版本空间被分成相对大小为  $P$  和  $1 - P$  的两个区域。




图 3.2: 把表示版本空间的多边形二等分的直线集并不经过同一点。因此, 不存在一个单一点, 使得对所有可能直线而言它都位于较大区域中。

来说, 版本空间质心以概率 1 具有这一性质。这也正是 Bayes 学习能够在不修改感知机结构的情况下实现的原因。考虑多层网络时, 这一点就不再成立。

上面的几何观点也使我们能够找出一个联系 Bayes 与 Gibbs 泛化误差的简单界 [50]。再次考虑图 3.1 中的情形: 随机选取的新样例  $S$  把版本空间分成两个子集, 分别对应于  $+1$  或  $-1$  分类; 记它们在版本空间中的相对份额为  $P$  和  $1 - P$ 。当教师恰好位于另一个子集中时, 从版本空间选

出的学生会对当前问题给出错误答案。在 Gibbs 场景中，学生从版本空间随机抽取。由于教师也以相等概率位于版本空间中的任意位置，Gibbs 泛化误差等于  $2P(1 - P)$ 。在 Bayes 规则中，遵从多数规则；如果教师恰好位于少数区域，则会出错。因此 Bayes 泛化误差为  $\min(P, 1 - P)$ 。注意  $P$  是未知的，而且实际上是一个依赖于当前问题的随机变量。不过，可以使用对任意  $P \in [0, 1]$  都成立的不等式

$$\min(P, 1 - P) \leq 2P(1 - P) \leq 2\min(P, 1 - P). \quad (3.32)$$

因此，Gibbs 泛化误差总是大于 Bayes 误差（这是应当的），但小于 Bayes 误差的两倍。

最后，人们很容易想用上述论证推出最坏情形场景的泛化误差界。考虑一个“反 Bayes”规则，它遵从少数决定，会怎样？此时泛化误差似乎应为  $\max(P, 1 - P)$ 。但写下这一结果时，我们忽略了一个细节：当少数区域为空，即  $\min(P, 1 - P) = 0$  时，不可能在版本空间中选出一个具有这种错误分类的学生（因为根本没有这样的学生）。因此，最坏情形的泛化误差实际上在  $P \neq 0$  时等于  $\max(P, 1 - P)$ ，而在  $P = 0$  时为零。遗憾的是，如果不知道  $P$  的概率分布，这一显式结果仍不足以同 Bayes 或 Gibbs 误差比较；不过可参见问题 3.8。第 10 章将看到，版本空间中最差学生的泛化误差并不比 Gibbs 或 Bayes 误差大很多。

## 3.7 小结

感知机是一种非常简单学习机器。然而，人们可以为它表述多种学习规则，每种规则都有其特定性质。对这一主题历史感兴趣的读者，可参考文献 [51]，其中收录了若干重印文章，包括 Hebb 和 Rosenblatt 等人的工作。

我们只对 Hebb 学习和 Bayes 学习推导了训练误差和泛化误差。下一章将说明，如何在基于统计力学方法的统一形式体系中讨论所有这些规则。

## 3.8 习题

- 3.1** 写出一串 100 个数  $S_i = +1$  或  $S_i = -1$ ,  $i = 1, \dots, 100$ 。训练一个三输入感知机，使其根据前三个数预测下一个数，例如  $S_i$ 。通过加入第四个输入并使其激活固定为 +1，纳入偏置项。感知机输出为

$$\text{sgn}(J_1 S_{i-1} + J_2 S_{i-2} + J_3 S_{i-3} + J_4).$$

用 Hebb 规则作用于前 50 个样例以构造  $\mathbf{J}$  向量。检验该网络能否在剩余样例上胜过你的猜测。尤其要尽量让序列看起来随机（当然不要使用计算机）。网络是否仍能正确预测剩余 50 个输出中的一半以上？更多细节见 [52]。

- 3.2** 考虑从  $p$  个相互正交的样例  $\xi^\mu$  学习， $\mu = 1, \dots, p$ ，且  $p < N$ 。证明 Hebb 学习、伪逆规则和 Bayes 学习一致。训练误差为零，并且重叠满足  $R_H = R_{PI} = R_B = \sqrt{2\alpha/\pi}$ 。版本空间被缩减为一个  $N$  维象限的类似物。证明从版本空间中随机选取的两个向量的典型重叠为  $q = 2\alpha/\pi$ ，这与 Gibbs 学习中  $q = R = (R_B)^2$  的事实一致。（提示：把样例用作一组正交坐标系的一部分。）

- 3.3** 说服自己：使用正交样例是尽可能快地学习的最佳方式。你能看出在  $\alpha > 1$  时应如何继续吗？



**3.4** 假设版本空间由所有与某方向  $\mathbf{J}_B$  的重叠大于  $R$  的向量  $\mathbf{J}$  构成。证明两个 Gibbs 学生的典型重叠为  $q = R$ 。证明版本空间中两个学生之间的最小重叠为  $2R - 1$ 。这一论证对最差学生相对于 Gibbs 学生的泛化误差渐近行为作出什么预测？

**3.5** 再次考虑问题 1.4 中引入的高低游戏。计算 Hebb 学习和 Bayes 学习的泛化误差。验证 Gibbs 与 Bayes 泛化误差满足第 3.6 节推导出的界。

**3.6** 为了明确显示 Gibbs 学生  $\mathbf{J}^{(i)}$  的多数会以与版本空间质心相同的方式分类一个新样例，验证当  $M \rightarrow \infty$  时

$$\text{sgn} \left( \sum_{i=1}^M \text{sgn}(\mathbf{J}^{(i)} \boldsymbol{\xi}) \right) = \text{sgn} \left( \sum_{i=1}^M \mathbf{J}^{(i)} \boldsymbol{\xi} \right). \quad (3.33)$$

**3.7** 考虑这样一个学习场景：教师和学生都是感知机，并具有同一个连续且可逆的激活函数  $g(x)$ ，即输出

$$\sigma = g \left( \frac{1}{\sqrt{N}} \sum_i J_i \xi_i \right), \quad \sigma_T = g \left( \frac{1}{\sqrt{N}} \sum_i T_i \xi_i \right) \quad (3.34)$$

是实数（通常限制在区间  $(-1, 1)$ ，一个常见选择是  $g(x) = \tanh x$ ）。若将泛化误差定义为

$$\varepsilon = \frac{1}{4}(\sigma - \sigma_T)^2, \quad (3.35)$$

验证伪逆规则

$$J_i = \frac{1}{\sqrt{N}} \sum_{\mu, \nu} g^{-1}(\sigma_T^\mu) (C^{-1})_{\mu\nu} \xi_i^\nu \quad (3.36)$$

在所有  $\alpha > 1$  上实现  $\varepsilon = 0$ ，其中相关矩阵  $C$  按 (3.14) 定义。

**3.8** 证明呈现一个新样例  $\boldsymbol{\xi}$  时版本空间体积缩减  $P$  的概率密度  $\text{Prob}(P)$  为

$$\text{Prob}(P) = 2 \int Dt H \left( \sqrt{\frac{R}{1-R}} t \right) \delta \left[ P - H \left( \sqrt{\frac{R}{1-R}} t \right) \right], \quad (3.37)$$

其中  $R$  是版本空间中两个向量的典型重叠。验证当  $R = 1/2$  时  $\text{Prob}(P) = 2P$ ，当  $R < 1/2$  时  $\text{Prob}(P = 1) = 0$ ，而当  $R > 1/2$  时  $\text{Prob}(P)$  在  $P = 1$  处有一个可积发散。（一个简短而优雅的证明见 [12]。）

## 第四章 扩展的统计力学表述

上一章介绍的一些学习规则，其泛化表现可以用简单的统计论证来刻画，例如 Hebb 规则；也可以利用第二章中关于 Gibbs 学习的结果来刻画，例如 Bayes 规则。然而，对其余学习规则的泛化误差，这两种尝试都不能成功给出答案。

本章将对第二章引入的核心统计力学方法作若干修改，使我们能够分析这些其余规则的泛化行为。主要观察是：所有这些学习规则都可解释为使某个适当选择的代价函数最小化的处方。把 Gibbs 学习的概念推广到非零训练误差，将为以统一方式研究这类最小化问题铺平道路。

不过，在进入这些一般性讨论之前，本章第一节先讨论如何最方便地分析以最大稳定性为目标的学习规则。

本章关于各种规则泛化误差的主要结果汇总在图 4.3 和表 4.1 中。

### 4.1 最大稳定性

第二章引入的统计力学形式体系只需稍作扩展，就足以分析 adatron 规则和伪逆规则的泛化表现。这两种规则的共同特征是：它们都寻找具有最大稳定性的耦合，也就是通过最大化稳定性参数  $\kappa$  来形式化这一目标。因此，与 Gibbs 规则等情形很不相同，所追求的耦合向量是唯一的。正是这种唯一性使统计力学分析相当直接。




图 4.1: 保证稳定性大于  $\kappa$  的那部分版本空间的示意图。随着  $\kappa$  增大，该区域越来越小，最终收缩到由黑点表示的点  $\mathbf{J}_{\text{MS}}$ ，这意味着在  $\kappa = \kappa_{\text{opt}}$  时  $q = 1$ 。注意，如第 3.5 节所讨论的，图中只有一部分直线是主动约束。

先考虑由 adatron 规则产生的最大稳定耦合向量。显然，刻画满足 (3.21) 的耦合向量的指示函数  $\chi(\mathbf{J})$ ，也就是刻画使所有稳定性大于或等于给定  $\kappa$  的耦合向量的函数，为

$$\chi(\mathbf{J}) = \prod_{\mu=1}^p \Theta \left[ \text{sgn} \left( \frac{\mathbf{T}\boldsymbol{\xi}^{\mu}}{\sqrt{N}} \right) \left( \frac{\mathbf{J}\boldsymbol{\xi}^{\mu}}{\sqrt{N}} \right) - \kappa \right]. \quad (4.1)$$

这只是 (2.13) 的一个小修改, 关于序参量  $R$  和  $q$  的鞍点方程可直接从 (A2.34) 和 (A2.35) 读出。它们具有如下形式:

$$\frac{q - R^2}{1 - q} = \frac{\alpha}{\pi} \int Dt H \left( \frac{Rt}{\sqrt{q - R^2}} \right) \exp \left[ -\frac{(\kappa - \sqrt{q}t)^2}{1 - q} \right] \left[ H \left( \frac{\kappa - \sqrt{q}t}{\sqrt{1 - q}} \right) \right]^{-2}, \quad (4.2)$$

以及

$$\begin{aligned} \frac{R\sqrt{q - R^2}}{\sqrt{q}\sqrt{1 - q}} &= \frac{\alpha}{\pi} \int Dt \exp \left[ -\frac{(\kappa - \sqrt{q}t)^2}{2(1 - q)} - \frac{R^2 t^2}{2(q - R^2)} \right] \\ &\times \left[ H \left( \frac{\kappa - \sqrt{q}t}{\sqrt{1 - q}} \right) \right]^{-1}. \end{aligned} \quad (4.3)$$

注意, 这里需要两个方程, 因为  $\kappa$  的引入打破了教师与学生之间的对称性, 因此  $q \neq R$ 。

现在必须找到使耦合向量的解仍然存在的最大  $\kappa$ 。从图 4.1 可见, 把  $\kappa$  从 0 增大到  $\kappa_{\text{opt}}$ , 会伴随  $q$  从  $R$  增大到 1。确实, 由于  $q$  给出两个保证稳定性大于  $\kappa$  的耦合向量  $J^{(1)}$  和  $J^{(2)}$  之间的典型重叠, 而在  $\kappa = \kappa_{\text{opt}}$  时解  $\mathbf{J}_{\text{MS}}$  唯一, 因此此时必有  $q = 1$ 。于是, 最大稳定耦合向量的性质由 (4.2) 和 (4.3) 在  $q \rightarrow 1$  极限下给出。使用  $H$  函数的渐近展开式 (A1.6), 得到

$$1 - R^2 = 2\alpha \int_{-\infty}^{\kappa_{\text{opt}}} Dt H \left( -\frac{Rt}{\sqrt{1 - R^2}} \right) (\kappa_{\text{opt}} - t)^2, \quad (4.4)$$

以及

$$R = \frac{\alpha}{\sqrt{2\pi(1 - R^2)}} \int_{-\infty}^{\kappa_{\text{opt}}} Dt \exp \left( -\frac{R^2 t^2}{2(1 - R^2)} \right) (\kappa_{\text{opt}} - t). \quad (4.5)$$

这两个方程确定了  $\kappa_{\text{opt}}(\alpha)$  和  $R(\alpha)$ 。由后者再利用 (2.3), 即可容易得到泛化误差  $\varepsilon$  随  $\alpha$  的函数。将这些方程数值解所得的  $\varepsilon(\alpha)$  与 Gibbs 学习的泛化误差比较可知, 由 adatron 规则确定的最大稳定向量  $\mathbf{J}_{\text{MS}}$  对所有  $\alpha$  都给出更低的泛化误差 (参见图 4.3)。这看起来是合理的, 因为如图 4.1 所示,  $\mathbf{J}_{\text{MS}}$  位于版本空间中心附近。

$\alpha \rightarrow \infty$  的渐近行为可通过注意到  $\alpha\sqrt{1 - R^2}$  和  $\kappa/\sqrt{1 - R^2}$  在这一极限下保持有限来抽取。可得

$$\varepsilon(\alpha) \sim \frac{c}{\alpha \int_{-\infty}^1 du (1 - u) e^{-u^2/2c}} \sim \frac{0.5005}{\alpha} \quad (\alpha \rightarrow \infty), \quad (4.6)$$

其中常数  $c$  由超越方程

$$\sqrt{\frac{c}{2\pi}} = \frac{\int_{-\infty}^1 du (1 - u)^2 H(-u/\sqrt{c})}{\int_{-\infty}^1 du (1 - u) e^{-u^2/2c}} \quad (4.7)$$

确定。

类似地, 也可以利用  $q \rightarrow 1$  极限推导伪逆规则的泛化表现 (参见问题 4.8)。所得鞍点方程取如下简单形式:

$$1 - R^2 = \alpha \left( \kappa^2 + 1 - 2\sqrt{\frac{2}{\pi}} \kappa R \right), \quad (4.8)$$

以及

$$R = \sqrt{\frac{2}{\pi}} \alpha \kappa. \quad (4.9)$$

这两个方程容易求解, 并得到

$$R = \sqrt{\frac{2\alpha(1 - \alpha)}{\pi - 2\alpha}}. \quad (4.10)$$

所得泛化行为由图 4.3 中的长虚线给出。注意泛化误差作为  $\alpha$  函数时具有一个显著行为: 它在  $\alpha = 0.62$  处经过局部最小值, 随后在  $\alpha = 1$  时重新增大到随机猜测值  $\varepsilon = 0.5$ 。这种非单调行为称

为过拟合，因为它类似于多项式插值中观察到的相应现象。在当前情形中，它来自训练系统时坚持一个“错误概念”。事实上，样例相对于教师的真实稳定性并不全都相同，而强迫学生服从这一处方会破坏其泛化能力。特别是在  $\alpha = 1$  附近，它迫使  $\mathbf{J}_{\text{PI}}$  的大小无限增长，同时变得与所有样例正交，从而导致表现完全丧失。

## 4.2 非零温度下的 Gibbs 学习

为了分析上一章介绍的其余学习规则的泛化表现，我们需要对统计力学方法作另一种推广。作为方便的出发点，本节讨论 Gibbs 学习的一般形式。

第二章引入的 Gibbs 学习，通过在版本空间上作平均来刻画典型相容学生的泛化表现，其中版本空间包含所有实现零训练误差的向量  $\mathbf{J}$ 。另一方面，我们对 Hebb 规则的分析已经表明，即使训练误差非零，也可能有可观的泛化能力。在一些有趣情形中，完美学习要么不可能（见第五章和第六章），要么在实际达到零训练误差之前就已经能够实现几乎相同的泛化质量，因而继续追求零训练误差代价过高。在这些情况下，知道具有给定非零训练误差  $\varepsilon_t$  的学生的典型泛化行为是有意义的。下面看看统计力学方法如何适配这一更一般的情况。

对由教师向量  $\mathbf{T}$  和一组输入  $\xi^\mu$  指定的特定学习情形，训练误差  $\varepsilon_t$  在第一章中定义为教师与学生在样例  $\xi^\mu$  上分类不一致的比例，即

$$\varepsilon_t(\mathbf{J}) = \frac{1}{p} \sum_{\mu=1}^p \Theta(-\Delta^\mu), \quad (4.11)$$

其中稳定性  $\Delta^\mu$  由 (3.2) 定义。相容学生分析中的核心量是版本空间体积（参见 (2.14)）

$$\Omega(\xi^\mu, \mathbf{T}) = \int d\mu(\mathbf{J}) \prod_{\mu=1}^p \Theta(\Delta^\mu). \quad (4.12)$$

显然，为了把具有非零训练误差的耦合向量  $\mathbf{J}$  纳入分析，必须把 (2.13) 中定义的指示函数  $\chi(\mathbf{J})$  替换为一个能按训练误差  $\varepsilon_t$  平滑加权不同  $\mathbf{J}$  向量的函数。统计力学所倡导的选择<sup>1</sup>是

$$\chi(\mathbf{J}) \rightarrow \exp[-\beta E(\mathbf{J})], \quad (4.13)$$

其中

$$E(\mathbf{J}) = \sum_{\mu} \Theta(-\Delta^\mu) = N \alpha \varepsilon_t(\mathbf{J}), \quad (4.14)$$

而  $\beta$  是自由参数。这意味着，基于训练样例表现而选中学生向量  $\mathbf{J}$  的概率为

$$P(\mathbf{J}) \sim \exp[-\beta E(\mathbf{J})], \quad (4.15)$$

因而  $\varepsilon_t > 0$  的耦合也被计入。当然，它们被实现的机会会随  $\varepsilon_t$  增大而快速降低。

简要说明为什么替换 (4.13) 能达到所需目的。考虑某个函数  $g(\mathbf{J})$  的平均，该函数只通过训练误差  $\varepsilon_t(\mathbf{J})$  依赖于  $\mathbf{J}$ 。这一平均可写为

$$\int d\mu(\mathbf{J}) \exp[-\beta E(\mathbf{J})] g(\mathbf{J}) = \int_0^1 d\varepsilon_t \Omega(\varepsilon_t) \exp[-\beta \alpha N \varepsilon_t] g(\varepsilon_t), \quad (4.16)$$

<sup>1</sup>基于统计学的论证见 [53]。

其中

$$\Omega(\varepsilon_t) = \int d\mu(\mathbf{J}) \delta\left(\varepsilon_t - \frac{1}{p} \sum_{\mu=1}^p \Theta(-\Delta^\mu)\right) \quad (4.17)$$

描述了给出训练误差  $\varepsilon_t$  的那部分  $\mathbf{J}$  空间。与第 2.2 节类似，可以证明熵  $S(\varepsilon_t) = \ln \Omega(\varepsilon_t)$  是广延的，因此可写成  $S(\varepsilon_t) = Ns(\varepsilon_t)$ ，其中  $N \rightarrow \infty$  时  $s(\varepsilon_t) = O(1)$ 。于是积分 (4.16) 具有形式

$$\int_0^1 d\varepsilon_t \exp\{N[s(\varepsilon_t) - \beta\alpha\varepsilon_t]\} g(\varepsilon_t). \quad (4.18)$$

因此在大  $N$  下， $g(\mathbf{J})$  的平均由具有典型训练误差  $\varepsilon_t$  的耦合向量  $\mathbf{J}$  支配，该  $\varepsilon_t$  使 (4.18) 指数最大，因而满足  $ds/d\varepsilon_t = \beta\alpha$ 。于是，通过适当选择自由参数  $\beta$ ，可以把整个平均集中到具有特定训练误差  $\varepsilon_t$  的学生向量上。随着  $\beta$  增大，对应的典型训练误差降低。最终在  $\beta \rightarrow \infty$  时恢复第二章的版本空间分析。

温度选择一个特定训练误差、从而选择一个特定  $E$  值这一观察，当然只是统计力学中熟知的正则描述与微正则描述等价性的一个例示。式 (4.14) 定义的  $E(\mathbf{J})$  扮演能量的角色，而  $\beta$  扮演逆温度， $T = 1/\beta$ 。因此，第二章微正则方法所依赖的相空间体积  $\Omega(\varepsilon; \boldsymbol{\xi}^\mu, \mathbf{T})$  的计算，现在被所谓配分函数

$$Z(\beta, \boldsymbol{\xi}^\mu, \mathbf{T}) = \int d\mu(\mathbf{J}) \exp[-\beta E(\mathbf{J})] \quad (4.19)$$

的计算所取代，它归一化了正则分布 (4.15)。正则方法中的核心量变为所谓自由能

$$F(\beta, \boldsymbol{\xi}^\mu, \mathbf{T}) = -T \ln Z(\beta, \boldsymbol{\xi}^\mu, \mathbf{T}), \quad (4.20)$$

它是广延量，因此假定在大  $N$  下自平均。相应自由能密度

$$f(\beta, \alpha) = \lim_{N \rightarrow \infty} \frac{1}{N} \langle\langle F(\beta, \boldsymbol{\xi}^\mu, \mathbf{T}) \rangle\rangle = -T \lim_{N \rightarrow \infty} \frac{1}{N} \langle\langle \ln Z(\beta, \boldsymbol{\xi}^\mu, \mathbf{T}) \rangle\rangle \quad (4.21)$$

可通过对附录 B 中讨论的形式体系稍作修改来计算。由于

$$\begin{aligned} \exp[-\beta E(\mathbf{J})] &= \exp\left[-\beta \sum_{\mu} \Theta(-\Delta^\mu)\right] \\ &= \prod_{\mu} \{e^{-\beta} + (1 - e^{-\beta})\Theta(\Delta^\mu)\}, \end{aligned} \quad (4.22)$$

这一修改归结为在 (A2.5) 中作替换

$$\Theta(\Delta) \rightarrow e^{-\beta} + (1 - e^{-\beta})\Theta(\Delta). \quad (4.23)$$

于是最终结果可从 (A2.33)–(A2.35) 读出：

$$\begin{aligned} f(\beta, \alpha) &= -\text{extr}_{q, R} \left\{ \frac{1}{2\beta} \ln(1 - q) + \frac{q - R^2}{2\beta(1 - q)} \right. \\ &\quad \left. + \frac{2\alpha}{\beta} \int Dt H\left(-\frac{Rt}{\sqrt{q - R^2}}\right) \ln \left[ e^{-\beta} + (1 - e^{-\beta}) H\left(-\sqrt{\frac{q}{1 - q}} t\right) \right] \right\}. \end{aligned} \quad (4.24)$$

相应鞍点方程为

$$\frac{q - R^2}{1 - q} = \frac{\alpha}{\pi} \int Dt H\left(-\frac{Rt}{\sqrt{q - R^2}}\right) \frac{\exp\left[-\frac{q}{1 - q} \frac{t^2}{2}\right]}{\left[\frac{1}{e^\beta - 1} + H\left(-\sqrt{\frac{q}{1 - q}} t\right)\right]^2}, \quad (4.25)$$

以及

$$\frac{R\sqrt{q-R^2}}{\sqrt{q}\sqrt{1-q}} = \frac{\alpha}{\pi} \int Dt \frac{\exp\left\{-\frac{t^2}{2} \left[\frac{R^2}{q-R^2} + \frac{q}{1-q}\right]\right\}}{\frac{1}{e^\beta - 1} + H\left(-\sqrt{\frac{q}{1-q}} t\right)}, \quad (4.26)$$

它们确定序参量  $R$  和  $q$ 。这里  $R$  仍表示典型教师-学生重叠，并通过 (2.3) 决定相应泛化误差  $\varepsilon$ ；而  $q$  对应于两个学生之间的典型重叠。注意，由于缺乏教师-学生对称性， $R \neq q$ 。

自由能、内能  $\alpha\varepsilon_t$  与熵  $s$  之间的关系当然可以照常写成

$$f = \min_{\varepsilon_t} [\alpha\varepsilon_t - Ts(\varepsilon_t)].$$

典型训练误差随后由标准关系给出：

$$\varepsilon_t = \frac{1}{\alpha} \frac{\partial[\beta f(\beta, \alpha)]}{\partial \beta}. \quad (4.27)$$




图 4.2: 非零温度 Gibbs 学习中，泛化误差（实线）和训练误差（虚线）作为训练集大小  $\alpha$  的函数；温度取  $T = 0.2, 0.5, 0.8$ （从下到上）。作为比较，点线给出  $T = 0$  时的泛化误差。

图 4.2 给出了不同  $T$  值下训练误差和泛化误差随  $\alpha$  的变化。可以看到，对中等  $T > 0$ ，泛化误差几乎与零温学习一样小。渐近地，行为仍为  $\varepsilon \sim 1/\alpha$ ，非零训练误差的全部影响归结为一个依赖温度的前因子，并随  $T$  增大而增大（参见问题 4.5）。

最后提到 Gibbs 学习的一个有趣极限情形。对给定的  $\mathbf{J}$ ，考虑训练能量  $E(\mathbf{J}) = N\alpha\varepsilon_t$ 。由于样例  $\xi^\mu$  的随机性，它是一个随机量。其平均值为  $N\alpha\varepsilon(\mathbf{J})$ ，因为按泛化误差的定义有  $\langle\langle\varepsilon_t(\mathbf{J})\rangle\rangle = \varepsilon(\mathbf{J})$ ；而由于训练样例相互独立，涨落为  $\delta E = O(\sqrt{\alpha N})$ 。因此，自由能可写为

$$-\beta F = \ln \int d\mu(\mathbf{J}) \exp[-\beta\alpha N\varepsilon(\mathbf{J}) - \beta\delta E]. \quad (4.28)$$

现在考虑联合极限  $\alpha \rightarrow \infty$ 、 $T \rightarrow \infty$ ，且  $\beta\alpha = \tilde{\alpha} = O(1)$ 。这对应于一个受损学生：训练集很大，但学生几乎不关注训练，温度无限高。可以看到，指数中的第二项为  $O(\beta\sqrt{\alpha}) = O(\sqrt{\beta})$ ，在  $\beta \rightarrow 0$

极限下消失。<sup>1</sup> 在这一称为高温学习的区域中，训练能量  $E(\mathbf{J})$  因而被其平均值简单取代，训练误差与泛化误差一致。不再保留对训练样例随机性的依赖，计算也因此让人想起退火近似中的计算。对于完整复本处理技术上相当复杂的问题，这一极限是有价值的第一条进攻线。注意，它比统计力学通常的高温极限更不平凡；通常高温极限完全由熵项支配，因而最无序的构型占优。而在高温学习中，由于  $\alpha$  与  $T$  以相同速率发散，能量与熵之间仍保留着有趣的相互作用。

### 4.3 一般统计力学表述

现在可以说明：对于上一章介绍的大多数学习规则，都能在统计力学框架内对学习误差和泛化误差作解析计算。关键点是观察到，学习规则等价于选择一个学生向量，使某个适当选择的代价函数取最小值；我们把这个代价函数称为学习误差  $E(\mathbf{J})$ 。

对彼此独立选取的随机样例，最自然的是使用加性形式的学习误差

$$E(\mathbf{J}) = \sum_{\mu} V(\Delta^{\mu}), \quad (4.29)$$

其中稳定性  $\Delta^{\mu}$  按 (3.2) 定义。Gibbs 学习中使用的代价函数 (4.14) 是 (4.29) 的一个特殊情形。

上面引入的学习误差在样例数  $p$  上是广延的，而  $p$  本身又被选择为与输入空间维数  $N$  成正比。在有限温度 Gibbs 学习中已经看到，在统计力学分析中，这一误差扮演能量的角色；巧合的是，它还与能量使用同一个缩写  $E$ 。泛化误差将由这一能量与熵项之间的竞争决定，后者也就是实现给定学习误差值的  $\mathbf{J}$  向量数目。

我们的目标是针对不同势函数  $V$ ，计算泛化表现随训练集大小  $\alpha$  的变化。与上一节的一般 Gibbs 学习分析类似，这可通过引入与误差  $E$  相关联的配分函数来完成：

$$Z = \int d\mu(\mathbf{J}) e^{-\beta E(\mathbf{J})}. \quad (4.30)$$

配分函数通过其对随机选择的训练样例和教师耦合的依赖而成为随机变量。相应自由能  $F = Nf = -T \ln Z$  仍是广延量，预期在热力学极限下自平均。因此， $F$  可通过对样例和教师作平均来求值。所需复本技巧与有限温度 Gibbs 情形的计算路线非常接近，唯一修改是用  $V(\Delta)$  替换  $\Theta(-\Delta)$ 。在复本对称假设下得到

$$f(\beta, \alpha) = -\text{extr}_{q,R} \left\{ \frac{1}{2\beta} \ln(1-q) + \frac{q-R^2}{2\beta(1-q)} + \frac{2\alpha}{\beta} \int Dt H\left(-\frac{Rt}{\sqrt{q-R^2}}\right) \right. \\ \left. \times \ln \int \frac{d\Delta}{\sqrt{2\pi(1-q)}} \exp \left[ -\beta V(\Delta) - \frac{(\Delta - \sqrt{q}t)^2}{2(1-q)} \right] \right\}. \quad (4.31)$$

序参量  $q$  和  $R$  具有通常含义，并由与 (4.31) 相应的极值条件确定。随后把  $R$  的值代入 (2.3)，即可得到泛化误差。

对 (4.30) 中定义的配分函数  $Z$  有实质贡献的耦合向量  $\mathbf{J}$ ，只是那些学习误差  $E(\mathbf{J})$  比可能的最小值  $E_{\min}$  大  $O(1/\beta)$  的向量。因此显然，随着  $\beta$  增大，配分函数和自由能都会越来越由具有更小  $E(\mathbf{J})$  的向量  $\mathbf{J}$  支配。最终，也就是在  $\beta \rightarrow \infty$  极限下，可从 (4.31) 中抽取最小化代价函数的最优耦合向量的性质。

<sup>1</sup>关于这一涨落项的系统展开见 [21]。



从算法角度看, 具有唯一极小值的代价函数  $E(\mathbf{J})$  特别有趣。事实上, 如果确实如此, 该极小值可由标准梯度下降算法找到。很快会看到, Hebb 规则就是这种情形的一个例子。在这种情况下,  $\beta \rightarrow \infty$  会伴随  $q \rightarrow 1$ , 因为不同解  $\mathbf{J}$  都必须收敛到同一个极小值。从与 (4.31) 对应的鞍点方程可以看出, 若令  $x = \beta(1 - q)$  有限, 则  $\beta \rightarrow \infty$  与  $q \rightarrow 1$  是相容的。把关于  $q$  的极值条件替换为关于  $x$  的极值条件, 并对  $\Delta$  积分使用鞍点论证, 在这一极限下自由能密度化为

$$f(T=0, \alpha) = e_{\min}(\alpha) = -\text{extr}_{x, R} \left[ \frac{1 - R^2}{2x} - 2\alpha \int Dt H\left(-\frac{Rt}{\sqrt{1 - R^2}}\right) \min_{\Delta} \left( V(\Delta) + \frac{(\Delta - t)^2}{2x} \right) \right], \quad (4.32)$$

其中  $E_{\min} = Ne_{\min}$  是学习误差  $E(\mathbf{J})$  的最小值。

因此, 对给定势函数  $V(\Delta)$ , 可用以下两步得到使  $V$  最小的  $\mathbf{J}$  向量的泛化表现:

(1) 找到使

$$V(\Delta) + \frac{(\Delta - t)^2}{2x} \quad (4.33)$$

最小的函数  $\Delta^0(t, x)$ 。

(2) 由与 (4.32) 对应的鞍点方程确定  $R$  与  $x$  随  $\alpha$  的值。这些方程为

$$1 - R^2 = 2\alpha \int Dt [\Delta^0(t, x) - t]^2 H\left(-\frac{Rt}{\sqrt{1 - R^2}}\right), \quad (4.34)$$

以及

$$R = \frac{2\alpha}{\sqrt{2\pi(1 - R^2)}} \int Dt \Delta^0(t, x) \exp\left[-\frac{R^2 t^2}{2(1 - R^2)}\right]. \quad (4.35)$$

必须记住, 自由能的上述简化以及相应鞍点表达式, 要求代价函数具有唯一极小值。若极小值简并, 例如由  $V(\Delta) = \Theta(-\Delta)$  表征的 Gibbs 学习,  $\beta \rightarrow \infty$  极限就不意味着  $q \rightarrow 1$ , 也就不可能对 (4.31) 作实质性简化。有些代价函数在  $\alpha < \alpha_c$  时可能具有简并极小值, 而在  $\alpha > \alpha_c$  时具有唯一极小值; 下一节讨论的 adaline 规则便是如此。如果从下方接近  $\alpha_c$ , 这一转变由  $q \rightarrow 1$  标志。另一方面, 如果从大的  $\alpha$  值出发并从上方接近  $\alpha_c$ , 则表现为  $x \rightarrow \infty$ , 因为即使在  $\beta \rightarrow \infty$  时,  $q$  仍小于 1 (见问题 4.11)。

## 4.4 重新审视学习规则

上述形式体系可应用于此前介绍的各种学习规则。作为一个特别简单的例子, Hebb 学习给出了有用的说明。它对应于特定选择

$$V(\Delta) = -\Delta, \quad (4.36)$$

对这一选择, 代价函数  $E(\mathbf{J})$  的极小值可以显式求出:

$$\mathbf{J} \sim \sum_{\mu} \xi^{\mu} \sigma_T^{\mu}, \quad (4.37)$$

这正是 Hebb 规则。由 (4.33)–(4.35) 可得

$$\Delta^0(t, x) = t + x \quad (4.38)$$

以及

$$R = \sqrt{\frac{2\alpha}{2\alpha + \pi}}, \quad (4.39)$$

$$x = \frac{\pi R}{2\alpha}, \quad (4.40)$$

这与 (3.8) 一致。

Gibbs 学习使用训练误差作为代价函数，即

$$V(\Delta) = \Theta(-\Delta), \quad (4.41)$$

因此相应误差函数  $E(\mathbf{J})$  只是计算误分类总数。显然，在这种情形下 (4.31) 退化为 (4.24)。

作为 Hebb 学习和 Gibbs 学习的一种组合，感知机规则对  $\mathbf{J}$  作出与 Hebb 规则相同的修正，但只在所考察样例被误分类，也就是  $\Delta < 0$  时这样做。因此，感知机规则对应于势函数<sup>1</sup>

$$V(\Delta) = -\Delta \Theta(-\Delta). \quad (4.42)$$

作为自然推广，可以要求  $\Delta$  大于某个最小稳定性  $\kappa$ ，才被接受为无误差，由此得到势函数

$$V(\Delta) = (\kappa - \Delta)\Theta(\kappa - \Delta). \quad (4.43)$$

虽然在上一节形式体系内分析这一学习规则的泛化行为是直接的，但需要区分  $\alpha$  的不同区间。由于结果并不特别有启发性，这里略去详细讨论；可参见 [33]。

Adaline 学习由如下最小平方误差目标定义：

$$V(\Delta) = \frac{1}{2\kappa^2}(\Delta - \kappa)^2. \quad (4.44)$$

如第 3.4 节所讨论，该规则在  $\alpha < 1$  时给出伪逆规则的耦合向量，而其泛化行为已在第 4.1 节讨论。现在可如下完成  $\alpha > 1$  时 adaline 学习的分析。由 (4.44) 得到

$$\Delta^0(t, x) = \frac{t + x/\kappa}{1 + x/\kappa^2}, \quad (4.45)$$

于是基态能量表达式 (4.32) 中的积分可以解析完成，并且在包括对  $\kappa$  作极值化后得到

$$e_{\min}(\alpha) = -\text{extr}_{x, R, \kappa} \left[ \frac{1 - R^2}{2x} - \frac{\alpha}{2(\kappa^2 + x)} \left( \kappa^2 + 1 - 2\sqrt{\frac{2}{\pi}} \kappa R \right) \right]. \quad (4.46)$$

极值条件给出以下三个方程：

$$1 - R^2 = \alpha \left( \frac{x}{\kappa^2 + x} \right)^2 \left( \kappa^2 + 1 - 2\sqrt{\frac{2}{\pi}} \kappa R \right), \quad (4.47)$$

$$R = \sqrt{\frac{2}{\pi}} \frac{x}{\kappa^2 + x} \alpha \kappa, \quad (4.48)$$

以及

$$1 - R^2 = \alpha \frac{x^2}{\kappa^2 + x} \left( 1 - \sqrt{\frac{2}{\pi}} \frac{R}{\kappa} \right). \quad (4.49)$$

对  $\alpha > 1$ ，这些方程有唯一解

$$\kappa = \sqrt{\frac{\pi(\alpha - 1)}{\pi + 2\alpha - 4}}, \quad R = \sqrt{\frac{2(\alpha - 1)}{\pi + 2\alpha - 4}}, \quad x = \frac{\pi}{\pi + 2\alpha - 4}. \quad (4.50)$$

<sup>1</sup>上一章讨论的原始感知机规则是一个在线算法，第 9 章会更详细讨论。

$R(\alpha)$  的结果确定了泛化误差的衰减，并已纳入图 4.3。其渐近行为为

$$\varepsilon(\alpha) \sim \sqrt{\frac{\pi-2}{2\pi^2\alpha}}, \quad (4.51)$$

它遵循与 Hebb 规则相同的幂律。为了同伪逆规则的结果相联系，即同  $\alpha < 1$  的情形相联系，只需记住在这种情况下代价函数 (4.44) 的极小值是简并的， $\kappa$  必须被确定为仍允许零训练误差的最大可能值。因此，(4.46) 中关于  $\kappa$  的极值条件必须替换为  $x \rightarrow \infty$ ，它表达了简并基态的出现。这样即可从 (4.47) 和 (4.48) 恢复 (4.8) 和 (4.9)。




图 4.3: 泛化误差  $\varepsilon$  作为训练集大小  $\alpha$  的函数: Hebb 规则 (虚线)、零温 Gibbs 学习 (点划线)、adaline/伪逆规则 (长虚线)、由 adatron 规则等得到的最大稳定向量 (点线) 以及 Bayes 规则 (实线)。  $\alpha \rightarrow \infty$  时的渐近行为列于表 4.1。

由于 adatron 规则使具有大稳定性的样例保持不动，而对其余样例使用与 adaline 学习类似的二次代价函数，适当的势函数为

$$V(\Delta) = \frac{1}{2}(\Delta - \kappa)^2 \Theta(\kappa - \Delta). \quad (4.52)$$

问题 4.11 说明了如何从这一代价函数重新推导结果 (4.4) 和 (4.5)。

至此，对第三章中介绍的学习规则的分析已经完成。结果汇总在表 4.1 和图 4.3 中。

在回顾了与已知学习算法对应的势函数后，人们可能会问，是否还存在一些有趣的新选择。为了引导这一寻找，回忆一下：最小泛化误差由位于版本空间中心的 Bayes 学生达到。因此，在版本空间内考虑基于势函数的代价函数是很有希望的，这些势函数会把学生从版本空间边界“排斥”开。为此，可聚焦于这样的势函数  $V(\Delta)$ ：它们在版本空间外部，也就是  $\Delta < 0$  时为无穷大，并且在  $\Delta > 0$  时是  $\Delta$  的单调递减函数。要求单调性是因为它保证  $E(\mathbf{J})$  是  $N$  球面上的凸函数。因此存在唯一极小值，并且可通过版本空间中的梯度下降找到。幂律势  $V(\Delta) = -\Delta^s/s$  且  $s \leq 1$  的详细解析研究见 [54]。当  $s = -1$  时，使相应代价函数  $E(\mathbf{J})$  最小的感知机，其泛化误差在所有  $\alpha$  值上都只比 Bayes 结果高出至多几个百分点。

表 4.1: 各种学习规则对应的代价函数势以及训练集大小  $\alpha$  很大时泛化误差  $\varepsilon$  的渐近行为。较小  $\alpha$  下的泛化表现见图 4.3。

| 学习规则              | 势函数 $V(\Delta)$                                         | $\varepsilon$ 的大 $\alpha$ 渐近行为  |
|-------------------|---------------------------------------------------------|---------------------------------|
| Hebb              | $-\Delta$                                               | $\frac{1}{\sqrt{2\pi\alpha}}$   |
| Gibbs ( $T = 0$ ) | $\Theta(-\Delta)$                                       | $\frac{0.625}{\alpha}$          |
| adaline           | $\frac{1}{2\kappa^2}(\Delta - \kappa)^2$                | $\sqrt{\frac{\alpha}{\pi - 2}}$ |
| adatron           | $\frac{1}{2}(\Delta - \kappa)^2\Theta(\kappa - \Delta)$ | $\frac{0.5005}{\alpha}$         |
| Bayes             | —                                                       | $\frac{0.442}{\alpha}$          |

## 4.5 最优势

到目前为止还有两个自然问题没有回答：第一，是否存在势函数  $V(\Delta)$  的最优选择？第二，由此得到的泛化误差是否饱和 Bayes 规则给出的下界？一个变分计算使我们能够对这两个问题都给出肯定回答 [55, 56]。定义如下量：

$$F(t, x) = \Delta^0(t, x) - t = -xV'(\Delta^0(t, x)), \quad (4.53)$$

$$X = 2H\left(-\frac{Rt}{\sqrt{1-R^2}}\right), \quad (4.54)$$

以及

$$Y = \sqrt{\frac{2}{\pi}} \exp\left(-\frac{R^2 t^2}{2(1-R^2)}\right), \quad (4.55)$$

其中  $\Delta^0$  由 (4.33) 定义。由 (4.34) 和 (4.35) 可得

$$R^2 = \alpha \frac{\langle YF \rangle^2}{\langle XF^2 \rangle} = \alpha \frac{\langle (Y^2/X)(XF/Y) \rangle^2}{\langle (Y^2/X)(XF/Y)^2 \rangle}, \quad (4.56)$$

其中平均是相对于高斯测度  $Dt$  而言的。容易验证，例如基于 Schwartz 不等式，对任意函数  $u > 0$ ，都有  $\langle uv \rangle^2 \leq \langle u \rangle \langle uv^2 \rangle$ ，等号只有在  $v$  相对于平均变量为常数时达到。由此可知，(4.56) 右端、因而  $R$  的值，在选择

$$F^* = CY/X$$

时最大，其中  $C$  是与  $t$  无关的常数。其值可由 (4.34) 除以 (4.35) 立即得到：

$$C = \frac{\sqrt{1-R^2}}{R}.$$

于是 (4.56) 右端化为  $\alpha \langle Y^2/X \rangle$ 。再作变量替换  $t = u\sqrt{1-R^2}$ ，就发现 (4.56) 等价于 (3.29)，即 Bayes 规则的方程。因此，通过  $F^*$  的显式形式，我们已经识别出一个代价函数，其唯一极小值再现了 Bayes 泛化行为。

这个结果听起来很令人振奋，因为我们能够通过梯度下降再现可能的最低泛化误差。不过也有若干需要谨慎的理由。第一，该势函数特定于随机样例下的教师-学生感知机场景。第二，即便可以显式构造最优势，它也没有简单形式。特别地，更详细的分析 [55] 表明，该势函数对负稳定性为无穷大，因此必须在已经位于版本空间内部时开始梯度下降过程（例如可通过事先应用 adatron

算法做到)。第三, 最优势依赖于  $\alpha$ , 也就是说, 它的形式会随训练集大小改变。预期这一特点相当普遍, 因为最优策略通常会依赖于已经获得的信息量。还要注意, 最优代价函数依赖于  $R$ , 因此若要在模拟中使用它, 必须先解析计算  $R(\alpha)$ , 再把结果用于模拟, 从而依赖于  $R$  的自平均性质。

## 4.6 小结

本章说明了, 一个学生感知机如何从教师感知机学习的问题, 可以在统计力学分析的语境下得到非常详细的讨论。基本特征是熵项与学习误差  $E$  之间的竞争; 熵项即具有给定泛化误差的学生数目, 而学习误差  $E$  则量化学生在训练集上的表现有多好。不同学习算法对应于对这一学习误差的不同选择, 而统计力学方法在处理不同学习规则时显示出很大的灵活性。所有结果都可通过对第二章引入的核心 Gardner 技术作小的修改而得到。

最简单的规则 Hebb 学习, 在整个训练过程中完全同等地对待所有训练样例。该规则在小训练集上表现最优, 小  $\alpha$  时泛化误差按  $(0.5 - \varepsilon(\alpha)) \sim \sqrt{\alpha}$  下降。对大  $\alpha$ , 它无法完美学习训练集的缺陷损害了其泛化能力, 导致泛化误差缓慢地按  $\varepsilon \sim 1/\sqrt{\alpha}$  衰减。多数更复杂的学习规则在渐近上实现  $\varepsilon \sim 1/\alpha$ , 只是前因子不同。

为了在训练集较大时提升表现并实现最优学习, 学生需要在其策略中纳入两个新元素: 自信和惊讶; 一个很好的讨论见 [57]。惊讶这一元素说明, 对给定  $\alpha$ , 不同样例应被赋予不同权重 (即嵌入强度)。基本规则是: 对于那些教师分类方式令学生感到意外的样例, 应给予更多关注。自信则指学生在给定训练量下获得的经验。其作用可从最优算法 (或势函数) 是  $\alpha$  的函数这一事实中清楚看出。在实际中, 使用这一元素当然需要某种自我评估程序。

最后简要回顾一些相关文献。Hebb 规则的泛化误差最早在 [29] 中推导。Adaline 和 adatron 规则在 [58] 中讨论, 感知机规则在 [33] 中讨论。有限温度 Gibbs 学习由 [30] 考虑, 而高温极限由 [21] 引入。Bayes 结果在 [59] 中推导, 质心论证见 [37]。一般势函数  $V$  选择的详细讨论可见 [54]。最优势饱和 Bayes 界的结果在 [55] 中给出。

## 4.7 习题

4.1 从 (4.24) 推导 (2.41)。证明对于 Gibbs 学习, (4.31) 化为 (4.24)。

4.2 考虑版本空间内与 Hebb 学习对应的势函数

$$V(\Delta) = \begin{cases} \infty, & \Delta < 0, \\ -\Delta, & \Delta \geq 0. \end{cases} \quad (4.57)$$

由 (4.33)–(4.35) 计算泛化误差, 并证明它渐近地按  $1/\alpha$  衰减。对版本空间内的反 Hebb 学习 ( $\Delta \geq 0$  时  $V(\Delta) = \Delta$ ) 作同样计算。在这种情况下,  $\alpha \rightarrow \infty$  时的渐近行为是什么?

4.3 在退火近似中, 计算具有一般代价函数 (4.29) 的学习自由能。为此, 考虑与教师具有给定重叠  $R$  的向量  $\mathbf{J}$ , 并证明一个样例的稳定性  $\Delta$  的概率分布为

$$P_R(\Delta) = 2 \frac{\exp(-\Delta^2/2)}{\sqrt{2\pi}} H\left(-\frac{R\Delta}{\sqrt{1-R^2}}\right). \quad (4.58)$$

退火自由能密度于是可写为 (参见 (2.23))

$$\beta f^{\text{ann}}(\beta, \alpha) = -\max_R \left[ \ln(1 - R^2) + \alpha \ln \int d\Delta e^{-\beta V(\Delta)} P_R(\Delta) \right]. \quad (4.59)$$

4.4 从学生耦合向量  $\mathbf{J}$  的训练误差  $\varepsilon_t(\mathbf{J})$  的表达式 (4.11) 出发, 温度  $T$  下 Gibbs 系综的平均训练误差和泛化误差分别定义为

$$\varepsilon_t(\alpha, \beta) = \frac{1}{Z} \int d\mu(\mathbf{J}) \varepsilon_t(\mathbf{J}) \exp[-\beta N \alpha \varepsilon_t(\mathbf{J})] \quad (4.60)$$

以及 (参见 (1.8))

$$\varepsilon(\alpha, \beta) = \frac{1}{Z} \int d\mu(\mathbf{J}) \langle \langle \varepsilon_t(\mathbf{J}) \rangle \rangle_S \exp[-\beta N \alpha \varepsilon_t(\mathbf{J})]. \quad (4.61)$$

证明对所有  $\alpha$  和  $\beta$ , 总有  $\varepsilon_t \leq \varepsilon$ 。并证明在高温学习中等号成立。(提示: 一个优雅证明见 [21] 的附录 A。)

4.5 证明  $T > 0$  的 Gibbs 学习中, 泛化误差的大  $\alpha$  行为具有形式  $\varepsilon \sim C(T)/\alpha$ , 并确定  $C(T)$ 。

4.6 证明第 4.5 节讨论的最优势在  $\alpha \rightarrow 0$  极限下化为 Hebb 形式。

4.7 使用 adaline 代价函数 (4.44), 依次计算  $\Delta$  积分和  $t$  积分, 求出一般  $\alpha$  与  $\beta$  下的自由能 (4.31)。证明当  $\beta \rightarrow \infty$  时, 无论  $\alpha$  取何值, 熵都趋于  $-\infty$ 。如何把这一结果与  $\alpha < 1$  时  $q(\beta \rightarrow \infty) < 1$  的事实协调起来?

4.8 使用指示函数

$$\chi(\mathbf{J}) = \prod_{\mu} \delta(\Delta^{\mu} - \kappa) \quad (4.62)$$

代替 (2.13), 对伪逆规则作统计力学分析。证明所得鞍点方程在  $q \rightarrow 1$  时化为 (4.8) 和 (4.9)。(提示: 注意, 指示函数的改变只相当于在附录 B 的分析中略去  $\lambda_{\mu}^{\alpha}$  积分。)

4.9 实际应用中, 提高泛化能力的一种有用方法, 是允许学生在测试阶段拒绝困难问题。计算泛化误差

$$\varepsilon(R, \ell) = \text{Prob} \left[ (TS)(\mathbf{J}\mathbf{S}) < 0 \mid \frac{\mathbf{J}\mathbf{S}}{\sqrt{N}} > \ell \right] \quad (4.63)$$

对应于那些距离学生决策边界至少  $\ell > 0$  的测试样例  $\mathbf{S}$ 。证明当  $R \rightarrow 1$  时有

$$\varepsilon(R, \ell) \sim \frac{1}{\sqrt{\pi}} \frac{\sqrt{1-R}}{\ell} \exp \left[ -\frac{\ell^2}{4(1-R)} \right], \quad (4.64)$$

即泛化误差指数快速下降。进一步讨论见 [60]。

4.10 与前面的讨论互补, 考虑训练集中所有样例  $\xi^{\mu}$  都距离教师决策边界至少  $\ell > 0$  的情形 [61]。

(a) 首先证明, 形如

$$P(\xi) = \frac{1}{(2\pi)^{N/2}} \exp \left( -\frac{\xi^2}{2} \right) f \left( \frac{\mathbf{T}\xi}{\sqrt{N}} \right) \quad (4.65)$$

且满足  $\int Du f(u) = 1$  的样例分布, 会给出如下复本对称熵表达式:

$$s = \text{extr}_{q, R} \left[ \frac{1}{2} \ln(1-q) + \frac{q-R^2}{2(1-q)} + 2\alpha \int_0^{\infty} Du f(u) \int Dt \ln H \left( -\frac{\sqrt{q-R^2}t + Ru}{\sqrt{1-q}} \right) \right].$$

(b) 使用

$$f(u) = \frac{\Theta(|u| - \ell)}{2H(\ell)}, \quad (4.66)$$

它意味着教师只选择自己有足够信心的样例，验证学生泛化误差的初始下降得到改善。

(c) 证明这一策略对学习最后阶段非常糟糕，因为在大  $\alpha$  时它导致泛化误差极其缓慢地按  $\varepsilon \sim 1/\sqrt{\ln \alpha}$  下降。

因而，在学习早期教授简单问题看来是一种合理策略，但在更高级阶段应当放弃，以免把学生达到完整理解所需的细节隐瞒起来。<sup>1</sup> 这种方法可通过使用变化阈值  $\ell(\alpha)$  进一步细化，其对  $\alpha$  的最优依赖可用变分方法确定 [61]。

**4.11** 使用 adatron 规则的代价函数 (4.52)，证明  $\Delta^0(x, t)$  的解为

$$\Delta^0(x, t) = \begin{cases} \frac{t + \kappa x}{1 + x}, & t \leq \kappa, \\ t, & t \geq \kappa. \end{cases} \quad (4.67)$$

把这一结果代入 (4.34) 和 (4.35)，并考虑对应于选择最优  $\kappa$  的  $x \rightarrow \infty$  极限，重现结果 (4.4) 和 (4.5)。

**4.12** 作为 (4.44) 的替代，若把耦合向量范数也作为要对  $E$  最小化的参数纳入，adaline 学习可由代价函数

$$V(\Delta) = \frac{1}{2}(\Delta - 1)^2 \quad (4.68)$$

描述。略去球面约束，并引入额外序参量

$$Q = \frac{1}{N} \sum_i J_i^2, \quad (4.69)$$

重新推导第 4.4 节得到的 adaline 规则结果。

**4.13** 使用附录 D 的方法证明：在通过最小化具有势函数  $V(\Delta)$  的代价函数进行学习时，复本对称鞍点局部稳定性的条件可写为

$$\alpha \int Dt 2H\left(-\frac{Rt}{\sqrt{1-R^2}}\right) \left[ \frac{\partial \Delta^0(t, x)}{\partial t} - 1 \right]^2 < 1, \quad (4.70)$$

其中  $\Delta^0(t, x)$  由 (4.33) 定义（另见 (A6.24)）。

<sup>1</sup>例如也可参见本书的组织方式。



## 第五章 含噪教师

一般说来，教师并不完全可靠。他们有时会把问题弄混，或者心不在焉地给出回答。如果训练集中的一些样例被随机噪声破坏，一个学生网络还能从中学到多少关于目标规则的信息？在这种更复杂的情形下，学生的最优策略又是什么？

本章的目的，是在两个感知机的框架中详细分析这些问题。我们要强调的是，一般而言，对于随机影响具有一定鲁棒性，是任何信息处理系统不可或缺的要求；无论在生物语境还是技术语境中都是如此。如果从样例中学习只有在训练集完全无误时才可能，那么它就没有多少实际意义。事实上，由于模糊教师正确分类的噪声通常可以认为与样例本身无关，人们预期仍然能够推断出规则，只是大概需要更大的训练集。

含噪泛化任务的一个一般特征是：训练集不再由某个学生可实现的规则产生。这样的问题称为不可实现问题。一个简单例子是训练集中同一个输入带有不同输出；这在含噪教师那里完全可能。这意味着，对于足够大的训练集，不存在能够重现所有分类的学生，版本空间会变为空集。对大型网络而言，这一转变发生在训练集大小的一个尖锐阈值  $\alpha_c$  处。超过这个阈值以后，学生的训练误差  $\epsilon_t$  总是大于零，于是自然要问：在阈值以下坚持零训练误差，是否真的必要，或者是否真的有利？

### 5.1 噪声来源

现在我们在教师感知机和学生感知机的典型设置中详细考察这些问题。与以前一样， $\mathbf{T}$  和  $\mathbf{J}$  分别表示教师感知机和学生感知机的耦合向量， $\xi^\mu$  表示按分布 (1.5) 随机选出的训练集输入。不过，相应的输出现在由

$$\sigma_T'^\mu = \eta^\mu \operatorname{sgn} \left( \frac{1}{\sqrt{N}} \mathbf{T}'^\mu \xi'^\mu \right) \quad (5.1)$$

给出。这个表达式中已经纳入了若干噪声来源。教师自身的耦合可能在每个样例上围绕纯净取值  $\mathbf{T}$  波动，这通过替换  $\mathbf{T} \mapsto \mathbf{T}'^\mu$  来表示。 $T_i'^\mu$  的一个适当分布是

$$P(T_i'^\mu) = \frac{1}{\sqrt{2\pi\sigma_w^2}} \exp \left[ -\frac{(T_i'^\mu - T_i)^2}{2\sigma_w^2} \right], \quad (5.2)$$

其中  $\sigma_w$  表示波动强度。这类噪声称为权重噪声。

另一种情形是，训练集中的错误可能源于教师接收到的不是原始输入  $\xi^\mu$ ，而是被破坏的输入  $\xi'^\mu$ 。这种输入噪声的一般概率分布为

$$P(\xi_i'^\mu) = \frac{1}{\sqrt{2\pi\sigma_{\text{in}}^2}} \exp \left[ -\frac{(\xi_i'^\mu - \xi_i^\mu)^2}{2\sigma_{\text{in}}^2} \right], \quad (5.3)$$

其中  $\sigma_{\text{in}}$  同样刻画噪声强度。在大输入维数  $N$  下，输入噪声的效果与权重噪声相同，因为在两种情形中，教师的局域场都围绕无误差取值  $\mathbf{T}\xi^\mu/\sqrt{N}$  作高斯分布。因此，这两类噪声尤其会影响靠近教师判决边界的样例。

使训练集样例变得模糊的另一个性质上不同的机制，由服从如下分布的参数  $\eta^\mu$  描述：

$$P(\eta^\mu) = \frac{1+a}{2}\delta(\eta^\mu - 1) + \frac{1-a}{2}\delta(\eta^\mu + 1). \quad (5.4)$$

在这种情况下，所有分类中有比例  $(1-a)/2$  被翻转，而这与教师对分类有多“确信”无关。我们将看到，这类输出噪声会对学生的泛化行为产生相当不同的影响。

在这一点上必须注意，对于含噪样例，有两种方式刻画学生逼近教师的程度。我们可以问：对一个随机选取的输入，学生给出与教师不同输出的概率是多少。也可以关心：教师的无噪声分类与学生分类之间存在差异的概率是多少。前者称为预测误差  $\epsilon_p$ ，后者就是泛化误差  $\epsilon$ 。只有在无噪声学习情形下，这两种误差度量才重合。显然，如果学生能够破译目标规则，那么在大训练集极限下泛化误差  $\epsilon$  将趋于零。然而，预测误差  $\epsilon_p$  总会大于某个残余误差  $\epsilon_r$ ，后者刻画破坏教师分类的噪声。

泛化误差和预测误差都是教师-学生重叠  $R$  的简单函数；即使存在噪声， $R$  仍然是自平均量。泛化误差仍由 (2.3) 给出，即  $\epsilon = \arccos R/\pi$ 。预测误差可以用类似论证得到。对输入噪声和权重噪声，由其定义可得

$$\begin{aligned} \epsilon_p &= \langle\langle \theta(-\sigma'_T \sigma) \rangle\rangle_{S, \text{noise}} \\ &= \left\langle \left\langle \theta \left( -\frac{1}{\sqrt{N}} \sum_i T'_i S'_i \frac{1}{\sqrt{N}} \sum_i J_i S_i \right) \right\rangle \right\rangle_{S, \text{noise}}, \end{aligned} \quad (5.5)$$

其中平均现在同时对测试样例  $\mathbf{S}$  和噪声进行。与 (2.17) 一样，引入辅助变量

$$\lambda = \frac{\mathbf{JS}}{\sqrt{N}}, \quad u' = \frac{T'S'}{\sqrt{N}}, \quad (5.6)$$

它们在大  $N$  下是高斯随机变量，其矩为

$$\begin{aligned} \langle\langle \lambda \rangle\rangle &= \langle\langle u' \rangle\rangle = 0, \\ \langle\langle \lambda^2 \rangle\rangle &= 1, \\ \langle\langle u'^2 \rangle\rangle &= (1 + \sigma_{\text{in}}^2)(1 + \sigma_w^2), \\ \langle\langle \lambda u' \rangle\rangle &= R. \end{aligned} \quad (5.7)$$

将 (5.5) 中的无序平均替换为对  $u'$  和  $\lambda$  的平均，并使用 (2.22)，得到输入噪声和权重噪声下

$$\epsilon_p = \frac{1}{\pi} \arccos(\gamma R), \quad (5.8)$$

其中

$$\gamma = \frac{1}{\sqrt{(1 + \sigma_{\text{in}}^2)(1 + \sigma_w^2)}} \quad (5.9)$$

是描述噪声强度的适当参数。即使学生已经完美学会了教师的无误差分类，仍然保留下来的残余误差  $\epsilon_r$  由上式在  $R = 1$  时给出，即

$$\epsilon_r = \frac{1}{\pi} \arccos \gamma. \quad (5.10)$$

对于输出噪声，类似地有

$$\begin{aligned} \epsilon_p &= \langle\langle \theta(-\sigma'_T \sigma) \rangle\rangle_{S, \text{noise}} \\ &= \frac{1+a}{2} \langle\langle \theta(-\sigma_T \sigma) \rangle\rangle_S + \frac{1-a}{2} \langle\langle \theta(\sigma_T \sigma) \rangle\rangle_S \\ &= \frac{1}{\pi} \left( \frac{1+a}{2} \arccos R + \frac{1-a}{2} \arccos(-R) \right) \\ &= \frac{1-a}{2} + \frac{a}{\pi} \arccos R. \end{aligned} \quad (5.11)$$

残余误差当然为

$$\epsilon_r = \frac{1-a}{2}. \quad (5.12)$$

因此，在有噪声存在时，刻画泛化表现的核心量仍然是教师-学生重叠  $R$ 。为了把它计算为训练集大小  $\alpha$  和噪声参数的函数，可以使用附录 B 中方法的直接推广。

## 5.2 尝试完美学习

首先，我们考察一个学生感知机的泛化行为：不论训练集中存在什么噪声，它都试图完全重现所有样例分类。实现这一点的一个合适学习规则，是使用零温 Gibbs 学习；它刻画了版本空间中一个典型学生的表现。

先考虑权重噪声或输入噪声的情形。把概率分布 (5.2) 和 (5.3) 所规定的噪声平均纳入模式平均 (A2.10) 后，可以发现后续计算唯一改变之处，是在能量部分 (A2.19) 中作替换  $R \mapsto \gamma R$ 。因此，两个序参量  $R$  和  $q$  的鞍点方程 (A2.34)、(A2.35) 修改为

$$\begin{aligned} \frac{q-R^2}{1-q} &= \frac{\alpha}{\pi} \int Dt H \left( -\frac{\gamma Rt}{\sqrt{q-\gamma^2 R^2}} \right) \exp \left\{ -\frac{q}{1-q} t^2 \right\} \\ &\times \left[ H \left( -\sqrt{\frac{q}{1-q}} t \right) \right]^{-2} \end{aligned} \quad (5.13)$$

和

$$\begin{aligned} \frac{R\sqrt{q-\gamma^2 R^2}}{\sqrt{q}\sqrt{1-q}} &= \gamma \frac{\alpha}{\pi} \int Dt \exp \left\{ -\frac{t^2}{2} \left( \frac{\gamma^2 R^2}{q-\gamma^2 R^2} + \frac{q}{1-q} \right) \right\} \\ &\times \left[ H \left( -\sqrt{\frac{q}{1-q}} t \right) \right]^{-1}. \end{aligned} \quad (5.14)$$

显然，解  $q=R$  消失了，这反映出教师与学生之间的对称性不再存在。事实上，当  $\gamma < 1$  时，总有  $q > R$ ，并且存在一个临界训练集大小  $\alpha_c$ ，在该处  $q \rightarrow 1$ ，而  $R = R_c < 1$ 。利用  $H$  函数的渐近行为 (A1.6)，在上述鞍点方程中取  $q \rightarrow 1$  极限，经过若干积分后得到

$$\frac{\gamma}{R_c} \sqrt{1-\gamma^2 R_c^2} = \arccos(\gamma R_c) \quad (5.15)$$

以及

$$\frac{1}{\alpha_c} = \frac{1}{\pi} \arccos(\gamma R_c) = \epsilon_p(R_c), \quad (5.16)$$

由此可以容易地数值确定  $R_c$  和  $\alpha_c$ 。

输出噪声的情形给出性质上相似的行为。此时， $\eta$  变量的存在使能量部分表达式 (A2.19) 中出现替换

$$\prod_a \theta(u\lambda^a) \mapsto \left\langle \left\langle \prod_a \theta(\eta u\lambda^a) \right\rangle \right\rangle_\eta.$$

鞍点方程于是变成

$$\begin{aligned} \frac{q-R^2}{1-q} &= \frac{\alpha}{\pi} \int Dt \left[ \frac{1-a}{2} + a H \left( -\frac{Rt}{\sqrt{q-R^2}} \right) \right] \\ &\times \frac{\exp \left\{ -\frac{q}{1-q} t^2 \right\}}{H^2 \left( -\sqrt{\frac{q}{1-q}} t \right)} \end{aligned} \quad (5.17)$$

以及

$$\frac{R\sqrt{q-R^2}}{\sqrt{q}\sqrt{1-q}} = a \frac{\alpha}{\pi} \int Dt \frac{\exp\left\{-\frac{t^2}{2}\left(\frac{R^2}{q-R^2} + \frac{q}{1-q}\right)\right\}}{H\left(-\sqrt{\frac{q}{1-q}}t\right)}. \quad (5.18)$$

同样，当  $a < 1$  时有  $q > R$ 。如上取  $q \rightarrow 1$  极限，得到决定  $\alpha_c$  和  $R_c$  的方程

$$\frac{\sqrt{1-R_c^2}}{R_c} = \pi \frac{1-a}{2a} + \arccos R_c \quad (5.19)$$

以及

$$\frac{1}{\alpha_c} = \frac{a}{\pi} \frac{\sqrt{1-R_c^2}}{R_c} = \epsilon_p(R_c). \quad (5.20)$$

直观上说，当预测误差与训练集大小的乘积接近 1 时，临界训练集大小  $\alpha_c$  就会达到。对两类噪声， $\alpha_c$  随  $\gamma$  的依赖关系如图 5.1 所示。




图 5.1: 临界训练集大小  $\alpha_c$ : 当训练集大于它时，不再能找到完全重现所有样例的学生。实线为强度由 (5.9) 定义的输入噪声或权重噪声结果；虚线为由参数  $a$  刻画输出噪声结果，见 (5.4)。

当  $\gamma \rightarrow 1$  和  $a \rightarrow 1$  时，相应的噪声强度趋于零，见 (5.9)，因而  $\alpha_c \rightarrow \infty$ 。输出噪声对应的  $\alpha_c$  总是小于权重噪声或输入噪声对应的  $\alpha_c$ 。这与如下事实一致：输出噪声会在训练集中引入一些“粗大错误”，而权重噪声和输入噪声只会在教师判决边界处产生错误分类，从而对学生而言形成一个“几乎可实现”的问题。<sup>1</sup>

为了研究  $\alpha > \alpha_c$  时的泛化行为，不能使用上述依赖版本空间平均的方法，因为此时版本空间为空。不过，仍然可以研究使训练误差  $\epsilon_t$  最小化的学生的表现；为此可使用第 4.2 节和第 4.3 节引入的正则相空间分析，并把训练误差作为代价函数。训练误差的最小值通过取零温极限  $\beta \rightarrow \infty$  得到，同时  $q \rightarrow 1$ ，从而产生新的序参量  $x = \beta(1-q)$ 。复本对称计算同样只是对第四章计算的

<sup>1</sup>注意，度量噪声强度的两个参数  $\gamma$  和  $a$  不能直接相互比较。也可以改为比较那些在训练集中产生相同比例错误的噪声情形。在这种比较下，输出噪声对应的  $\alpha_c$  仍会小于输入噪声或权重噪声对应的值。

直接修改，这里不再详细讨论。对输入噪声和权重噪声，其结果给出鞍点方程

$$1 - R^2 = 2\alpha \int_{-\sqrt{2x}}^0 Dt t^2 H\left(-\frac{\gamma Rt}{\sqrt{q - \gamma^2 R^2}}\right) \quad (5.21)$$

和

$$\frac{R}{\sqrt{1 - \gamma^2 R^2}} = \gamma \frac{\alpha}{\pi} \left(1 - \exp\left[-\frac{x}{1 - \gamma^2 R^2}\right]\right), \quad (5.22)$$

它们确定序参量  $R$  和  $x$ 。典型训练误差为

$$\begin{aligned} \epsilon_t = & \frac{1}{\pi} \arccos(\gamma R) - \frac{1 - R^2}{2\alpha x} \\ & + 2 \int_{-\sqrt{2x}}^0 Dt H\left(-\frac{\gamma Rt}{\sqrt{q - \gamma^2 R^2}}\right) \left(\frac{t^2}{2x} - 1\right), \end{aligned} \quad (5.23)$$

它把  $\epsilon_t$  表示为  $R$  和  $x$  的函数。注意，当  $x = \infty$  时，会重现决定  $R_c$  和  $\alpha_c$  的方程 (5.15) 与 (5.16)；这正是应有的结果，因为当  $\alpha < \alpha_c$  时， $\epsilon_t$  的最小值并不唯一，即使  $\beta \rightarrow \infty$ ， $q$  仍小于 1。数值求解 (5.13)、(5.14)、(5.21) 和 (5.22) 的结果如图 5.2 所示，它给出了权重噪声和输入噪声下泛化行为的完整图像。




图 5.2: 在强度  $\gamma = 0.8$  的输入噪声或权重噪声存在时，零温  $T = 0$  Gibbs 学习的泛化误差、训练误差以及序参量随训练集大小  $\alpha$  的变化。实线表示泛化误差，长虚线表示训练误差，点划线表示  $R$ ，虚线表示  $q$ 。竖直点线标出临界训练集大小  $\alpha_c$ 。插图放大了  $\alpha_c$  附近的  $\epsilon(\alpha)$  曲线，显示临界性之前的过拟合。

对输出噪声作等价计算，可得到

$$1 - R^2 = 2\alpha \int_{-\sqrt{2x}}^0 Dt t^2 \left[ \frac{1-a}{2} + aH\left(-\frac{Rt}{\sqrt{q - R^2}}\right) \right] \quad (5.24)$$

和

$$\frac{R}{\sqrt{1 - R^2}} = a \frac{\alpha}{\pi} \left(1 - \exp\left[-\frac{x}{1 - R^2}\right]\right), \quad (5.25)$$

作为序参量  $R$  和  $x$  的鞍点方程；典型训练误差则为

$$\epsilon_t = \frac{1-a}{2} + \frac{a}{\pi} \arccos R - \frac{1-R^2}{2\alpha x} + 2 \int_{-\sqrt{2x}}^0 Dt \left[ \frac{1-a}{2} + aH \left( -\frac{Rt}{\sqrt{q-R^2}} \right) \right] \left( \frac{t^2}{2x} - 1 \right). \quad (5.26)$$

当  $x = \infty$  时，又会恢复决定  $R_c$  和  $\alpha_c$  的 (5.19) 与 (5.20)。图 5.3 给出了输出噪声存在时零温 Gibbs 学习的泛化表现。定性上，其行为与输入噪声或权重噪声情形相似。




图 5.3: 在强度  $a = 0.8$  的输出噪声存在时，零温  $T = 0$  Gibbs 学习的泛化误差、训练误差以及序参量随训练集大小  $\alpha$  的变化。实线表示泛化误差，长虚线表示训练误差，点划线表示  $R$ ，虚线表示  $q$ 。竖直点线标出临界训练集大小  $\alpha_c$ 。插图放大了  $\alpha_c$  附近的  $\epsilon(\alpha)$  曲线，显示临界性之前的过拟合。

最后，考察  $\alpha \rightarrow \infty$  时各误差度量的渐近行为也很有意思。值得注意的是，对这里考虑的所有噪声类型，对鞍点方程作渐近分析都会给出  $R \rightarrow 1$ ，这意味着  $\epsilon \rightarrow 0$  当  $\alpha \rightarrow \infty$ 。换言之，即使样例被随机噪声破坏，学生仍能完美破译样例背后的规则。把序参量的渐近行为代入训练误差和预测误差表达式，可以发现二者在大训练集极限下都会如预期地收敛到相应残余误差。

不过，大  $\alpha$  下泛化误差的详细依赖关系，在权重噪声或输入噪声与输出噪声之间不同。前一类情形中，由 (5.21) 和 (5.22) 得到

$$\epsilon \sim \sqrt{\frac{2}{3\pi}} \left( \frac{1-\gamma^2}{\gamma^2} \right)^{3/8} \alpha^{-1/4}, \quad (5.27)$$

这比无误差样例集上 Gibbs 学习的衰减  $\epsilon \sim 0.625/\alpha$  慢得多，见 (2.50)。另一方面，对输出噪声，(5.24) 和 (5.25) 给出渐近结果

$$\epsilon \sim \frac{C(a)}{\alpha}, \quad (5.28)$$

其中前因子  $C$  对噪声参数  $a$  的依赖必须数值确定。可以发现，在零噪声极限  $a \rightarrow 1$  时  $C \rightarrow 0.625$ ，而当  $a \rightarrow 0$  时  $C \rightarrow \infty$ 。值得注意的是，与权重噪声或输入噪声不同，输出噪声并不改变泛化误差

渐近衰减的定性形式，只是增大前因子。原因与输出噪声使  $\alpha_c$  相当小的原因相同：对于大的训练集，被破坏的样例通常与集合中其余样例如此不一致，以至于学生很容易把它们识别为“明显的胡说”。在权重噪声或输入噪声中情形完全不同。如果  $\epsilon$  已经相当小，学生尤其需要关于教师判决边界附近样例的可靠分类才能进一步进步，而在输入噪声或权重噪声存在时，这些分类又特别难以获得。

从图 5.2 和图 5.3 还可以看出零温学习的一个典型特征。在临界训练集大小  $\alpha_c$  稍下方，泛化误差停止下降，甚至会升高；这一点在插图中清楚可见。这是过拟合的另一个例子：学生试图完美模仿教师，却使用了错误概念。为了精确重现含噪训练集，学生损害了自己对规则的理解。因此，人们可能怀疑：一个“有噪声意识”的学生，如果即使在  $\alpha_c$  以下也使用带非零训练误差的学习规则，或许能够避免过拟合，从而更成功地把握样例中隐藏的规则。下一节将考察这是否真的成立。

为了完成  $T = 0$  分析，最后还必须指出，对于  $\alpha > \alpha_c$ ，会出现一个此前一直忽略的技术复杂性。事实表明，我们一直使用的复本对称鞍点 (A2.28) 会变得不稳定 [30]，因此结果 (5.21)–(5.28) 必须仅被视为近似。不过，从相关问题可知这些近似相当好 [62]，所以这里不讨论纳入复本对称破缺后会发生哪些修改。

### 5.3 带错误学习

当训练集没有噪声时，为了尽可能好地逼近目标规则，试图精确重现所有分类是合理的。另一方面，如果训练集包含错误，上一节已经表明，坚持零训练误差可能会误导学生。在这种情况下，让学生即使在教师出错时也去“模仿”她，或许更可取；也就是说，使用一种从一开始就给出非零训练误差、因而不精确重现训练集的学习规则。实现这一点的一种简单方式，就是第 4.2 节引入的非零温度  $T > 0$  Gibbs 学习，它刻画具有给定训练误差  $\epsilon_t$  的学生感知机的典型表现。

下面仍用统计力学处理的变体，简要讨论这种情形中会发生什么。我们只显式考虑输出噪声的情形；对权重噪声和输入噪声的类似讨论放在习题 5.1 中。直接推广 (4.25) 和 (4.26) 可得序参量满足

$$\frac{q - R^2}{1 - q} = \frac{\alpha}{\pi} \int Dt \left[ \frac{1 - a}{2} + aH \left( -\frac{Rt}{\sqrt{q - R^2}} \right) \right] \exp \left\{ -\frac{q}{1 - q} t^2 \right\} \times \frac{1}{\left[ \frac{1}{e^\beta - 1} + H \left( -\sqrt{\frac{q}{1 - q}} t \right) \right]^2} \quad (5.29)$$

和

$$\frac{R\sqrt{q - R^2}}{\sqrt{q}\sqrt{1 - q}} = a \frac{\alpha}{\pi} \int Dt \frac{\exp \left\{ -\frac{t^2}{2} \left( \frac{R^2}{q - R^2} + \frac{q}{1 - q} \right) \right\}}{\frac{1}{e^\beta - 1} + H \left( -\sqrt{\frac{q}{1 - q}} t \right)}, \quad (5.30)$$

而典型训练误差由 (4.27) 给出：

$$\epsilon_t = 2 \int Dt \left[ \frac{1 - a}{2} + aH \left( -\frac{Rt}{\sqrt{q - R^2}} \right) \right] \frac{H \left( \sqrt{\frac{q}{1 - q}} t \right)}{1 + (e^\beta - 1)H \left( -\sqrt{\frac{q}{1 - q}} t \right)}. \quad (5.31)$$

数值求解这些方程的结果见图 5.4。与图 5.3 所示  $T = 0$  的相应行为相比，主要差别是：对所有  $\alpha$  都有  $q < 1$ ，并且  $\epsilon_t$  从一开始就大于零。还要注意，由于  $R$  从而  $\epsilon$  都是  $\alpha$  的单调函数，因此没有过拟合。






图 5.4: 在参数  $\alpha = 0.8$  的输出噪声存在时, 温度  $T = 0.2$  的 Gibbs 学习中, 泛化误差、训练误差以及序参量随训练集大小  $\alpha$  的变化。实线表示泛化误差, 长虚线表示训练误差, 点划线表示  $R$ , 虚线表示  $q$ 。

图 5.5 比较了  $T > 0$  与  $T = 0$  的泛化行为。可以清楚看到, 在训练数据中存在噪声时, 学习规则中的非零温度有利于从样例中学习。较大的训练误差允许较小的泛化误差, 因为它使学生能够忽略训练集中那些最可能由噪声造成、因而在重现纯目标规则任务中具有误导性的分类。图 5.5 中  $T = 0$  与  $T > 0$  的  $\epsilon$  差别, 在渐近上来自  $1/\alpha$  行为前因子的不同, 因为即使没有噪声也有同样的渐近形式。

值得注意的是, 对于输入噪声和权重噪声, 一般温度  $T > 0$  的 Gibbs 学习仍然不能定性改变这种情况下很慢的泛化误差渐近下降, 见习题 5.2。在这里, 本来希望有更实质性的改进。下一节将考察: 通过把训练误差, 或者等价地把学习温度, 调节到训练集噪声强度, 是否能获得更多收益。

## 5.4 改进

学生从样例中学习时能达到的最优表现, 显然取决于他获得的总体信息。在上一节中我们已经看到, 如果这些信息除了训练集本身以外, 还包括“教师的一些分类不可靠”这一提示, 那么学生可以通过使用非零训练误差的学习规则来改进表现。如果他还碰巧知道破坏训练集的噪声类型和强度, 则还可能进一步改进。学生能从可用信息中最优地获得什么, 是一个典型的数理统计问题; 其答案最优雅地在 Bayesian 密度估计框架中导出 [59, 12]。虽然在实际应用中可获得的改进往往小到不重要, 但由此得到的泛化误差下界具有原则性意义。

这里我们只以相当定性的方式简要讨论最优表现问题。考虑输出噪声的情形。关键在于序参量  $R$  和  $q$  之间的关系; 它们分别描述教师与学生之间、以及两个学生之间的相似性。如果完全没有噪声, 第二章已经发现 Gibbs 学习由  $q = R$  刻画。在有噪声存在时, 教师与学生之间的这种对称性




图 5.5: 在参数  $a = 0.8$  的输出噪声存在时,  $T = 0$  Gibbs 学习 (虚线) 与  $T = 0.2$  Gibbs 学习 (实线) 的泛化误差和训练误差随训练集大小  $\alpha$  的变化。

一般会丧失。如果学生的学习温度很高, 会得到  $q < R$ , 学生高估了教师的错误率。另一方面, 如果温度相当低, 则有  $q > R$ , 学生把教师看得过于认真并冒着过拟合风险。事实表明, 最优  $T$  由  $q = R$  刻画; 此时学生的训练误差恰好等于训练集中错误分类的比例。由 (5.29) 和 (5.30) 可知, 若

$$\beta = \ln \frac{1+a}{1-a}, \quad (5.32)$$

则教师与学生之间的对称性恢复。如果学生知道训练集被参数为  $a$  的输出噪声模糊, 那么这确实给出了他应选择的最优温度 [59]。当  $a = 0.8$  时, 相应取值  $\beta \simeq 2.2$  所得到的  $\epsilon(\alpha)$  曲线, 与图 5.4 中  $\beta = 5$  的曲线几乎难以区分。渐近上, 仍只是前因子略有减小。

在输入噪声或权重噪声情形中, 可以获得更多收益。如果学生知道样例被这类噪声破坏, 他可以使用一个修改过的代价函数, 把泛化误差的渐近衰减从  $\epsilon \sim \alpha^{-1/4}$  改变为  $\epsilon \sim \alpha^{-1/2}$ ; 细节见 [12]。

最后还要指出, 由  $R = q$  也带来一个技术上的优势。在这种情况下, 可以使用第 2.3 节已经用过的、复本技巧的  $n \rightarrow 1$  版本来计算, 而它不受复本对称破缺问题影响。

## 5.5 小结

即使训练集分类被各种随机噪声破坏, 从样例中学习规则仍然是可能的。对任意噪声类型和强度, 都存在一个临界训练集大小  $\alpha_c$ , 超过它以后版本空间为空, 任何学习规则都有非零训练误差。尽管如此, 由于噪声与样例无关, 学生能够把它滤除, 因而成功地以任意期望精度逼近纯净教师。

两个感知机情形中的详细泛化行为, 可以用第二章和第四章发展出的统计力学技术来分析。可以区分两类一般噪声效应。或者教师的局域场被扰动, 例如由于输入噪声或权重噪声, 从而导致

教师判决边界附近输入的错误分类；或者教师输出以给定比率被随机翻转，即输出噪声，从而产生与底层规则完全相悖的“粗大错误”。

在泛化过程开始时，也就是小  $\alpha$  下，具有大教师局域场的输入很重要，因此输出噪声危害更大。这表现为在可比噪声强度下， $\alpha_c$  的取值更小。另一方面，大  $\alpha$  下泛化误差的渐近衰减由教师判决边界附近的输入决定。这时输入噪声或权重噪声更难被学生处理，在这种情况下无噪学习的  $1/\alpha$  衰减会变成慢得多的  $1/\alpha^{1/4}$  行为。值得注意的是，对于输出噪声， $1/\alpha$  规律仍然保持，只是前因子变大。

通过从一开始就使用带非零训练误差的学习规则，可以改进泛化行为。事实上，当  $\alpha < \alpha_c$  时尝试完美学习会导致过拟合，而非零训练误差可以克服这一点，例如  $T > 0$  的 Gibbs 学习。训练误差使学生能够忽略训练集中那些最可能来自噪声、因而在重现纯目标规则时会误导他的分类。对于输出噪声，训练误差的最优选择还能进一步减小渐近  $\epsilon(\alpha)$  依赖中的前因子。对于输入噪声或权重噪声，甚至可能交叉到  $1/\alpha^{1/2}$  衰减。

从含噪数据中学习，是所谓不可实现学习问题的原型，因为不存在能够重现所有分类的学生向量  $\mathbf{J}$ 。人们还研究了若干其他不可实现情形，包括阈值  $\theta \neq 0$  的教师，或具有非单调激活函数的教师，例如“反楔形”感知机，见第 7.3 节 [63]；以及教师和学生结构上不同的情形，例如 Ising 学生  $J_i = \pm 1$  试图从球形教师学习 [21]，或者二者稀疏程度即非零耦合比例不同的情形 [12, 64]。这些情景共享若干重要特征。首先，仅从不可实现问题的定义出发，就存在一个临界训练集大小  $\alpha_c$ ，超过它以后版本空间为空，即若  $\alpha > \alpha_c$ ，则  $\epsilon_t(\alpha) > 0$ 。其次，在所有这些情形中都会观察到，尝试完美学习迟早会失败，表现为  $\partial\epsilon/\partial\alpha > 0$ ，从而发生过拟合。例如，对反楔形教师学习时，使用由 adatron 算法得到的最大稳定学生向量  $\mathbf{J}^{\text{MS}}$ ，可能产生大于 0.5 的泛化误差 [63]！因此，在不可实现情形下，通常有利于使用带非零训练误差的学习规则；事实上，第 4.2 节引入的高温学习表现得相当好，见习题 5.4。最后，在统计力学框架中分析不可实现学习问题时，应意识到复本对称破缺很可能发生。

除了尽可能好地模仿不可实现目标函数之外，人们也可能只想检测一个问题是不可实现的。对于感知机，这可以由 [65] 中引入的算法完成；如果可能，它学习目标函数，否则指出问题非线性可分。

最早使用统计力学方法研究权重噪声和输入噪声存在时的样例学习，见 [66] 和 [30]。非零训练误差可能改进泛化的思想，已经在 [67] 中使用过。关于学生不同噪声类型下最优策略的详细 Bayesian 分析，则由 [59] 和 [12] 发展出来。

## 5.6 习题

5.1 考虑训练集被输入噪声和/或权重噪声破坏时，温度  $T > 0$  的 Gibbs 学习。证明典型训练误差为

$$\epsilon_t = 2 \int Dt H \left( -\frac{\gamma Rt}{\sqrt{q - \gamma^2 R^2}} \right) \frac{H \left( \sqrt{\frac{q}{1-q}} t \right)}{1 + (e^\beta - 1) H \left( -\sqrt{\frac{q}{1-q}} t \right)}, \quad (5.33)$$

其中序参量  $R$  和  $q$  由鞍点方程

$$\begin{aligned} \frac{q - R^2}{1 - q} &= \frac{\alpha}{\pi} \int Dt H \left( -\frac{\gamma R t}{\sqrt{q - \gamma^2 R^2}} \right) \\ &\times \frac{\exp \left\{ -\frac{q}{1-q} t^2 \right\}}{\left[ \frac{1}{e^\beta - 1} + H \left( -\sqrt{\frac{q}{1-q}} t \right) \right]^2} \end{aligned} \quad (5.34)$$

和

$$\frac{R \sqrt{q - \gamma^2 R^2}}{\sqrt{q} \sqrt{1 - q}} = \gamma \frac{\alpha}{\pi} \int Dt \frac{\exp \left\{ -\frac{t^2}{2} \left( \frac{\gamma^2 R^2}{q - \gamma^2 R^2} + \frac{q}{1-q} \right) \right\}}{\frac{1}{e^\beta - 1} + H \left( -\sqrt{\frac{q}{1-q}} t \right)} \quad (5.35)$$

确定。对  $\gamma = 0.8$ ，通过数值求解这些方程，确定  $R$ 、 $q$ 、 $\epsilon$  和  $\epsilon_t$  对  $\alpha$  的依赖，并与图 5.2 所给零温 Gibbs 学习表现比较。

5.2 通过对 (5.34) 和 (5.35) 作渐近分析，证明即使  $T > 0$ ，当  $\alpha \rightarrow \infty$  时  $\epsilon(\alpha)$  的渐近行为仍为  $\epsilon \sim \alpha^{-1/4}$ ，与  $T = 0$  情形相同，见 (5.27)。

5.3 阅读综述 [12]！

5.4 考虑带阈值  $\theta$  的教师感知机，即

$$\sigma_T^\mu = \text{sgn}(\mathbf{T}\boldsymbol{\xi}^\mu + \theta),$$

以及一个没有阈值的学生。在高温学习框架中分析这一不可实现泛化问题。向泛化误差渐近值的衰减是单调的吗？刻画  $\theta \rightarrow 0$  和  $\theta \rightarrow \infty$  两个极限下的问题。

5.5 一个随时间缓慢变化的规则，即随  $\alpha$  变化的规则，通常会给学生造成不可实现问题。为了适应这种更复杂的情形，Hebb 学习可以修改为“带边界学习” [68]。其规则是：只要  $\mathbf{J}$  的分量位于给定区间内，就对它们应用 Hebb 学习；任何会把分量带出这些边界的修正都不执行。请说服自己，这样的网络像一张可重写记录一样工作，也就是说，较早样例的信息会逐渐被擦除，以让位给较新的样例。漂亮的解析讨论见 [69]，相关问题见 [70, 71]。

## 第六章 存储问题

上一章讨论了从含噪来源学习的一个重要极端情形，它值得特别考察。这里的情形是教师极端嘈杂，加入的噪声强到完全支配教师输出。于是，学生的任务变成重现一种输入与输出之间没有相关性的映射，教师这一概念实际上也就失效了。核心问题是：通过适当选择耦合  $\mathbf{J}$ ，典型地能够实现多少个输入-输出对？这就是所谓的存储问题。研究它可以给出一个度量，用来刻画所考察网络在实现不同输入-输出映射方面的灵活性。

本书主要讨论网络的泛化行为，之所以仍要纳入这一问题，原因有三。第一，有一个历史原因：在物理学共同体中，人们先讨论了神经网络的存储性质，随后才把重点放到它们从样例中学习的能力上；若干重要概念也正是在这些较早研究中引入的。第二，在若干情形中，存储问题分析起来稍微简单一些，因此适合作为研究更复杂泛化表现的出发点。第三，我们将在第 10 章看到，网络结构在实现不同输入-输出关系方面的灵活性，也会给出关于其泛化行为的有用信息。

### 6.1 存储容量

先简要回到第一章引入的吸引子神经网络世界。在这类系统中，每个神经元都与其他每个神经元相连；为了使神经元活动的一个模式  $\xi^\mu$  成为动力学

$$S_i(t+1) = \text{sgn} \left( \sum_j J_{ij} S_j(t) \right) \quad (6.1)$$

的稳定点，必须保证

$$\xi_i^\mu \sum_j J_{ij} \xi_j^\mu \geq 0 \quad \text{对所有 } i = 1, \dots, N. \quad (6.2)$$

事实上，为了模式的吸引子性质，施加更强的条件是有利的：

$$\frac{1}{\sqrt{N}} \xi_i^\mu \sum_j J_{ij} \xi_j^\mu \geq \kappa \quad \text{对所有 } i = 1, \dots, N, \quad (6.3)$$

其中  $\kappa > 0$  是稳定性参数。对于对称耦合，大的  $\kappa$  对应于模式处  $H(S)$  的深极小值。非对称突触矩阵也可以产生吸引子动力学，此时大的  $\kappa$  也可粗略地与模式的大吸引盆联系起来。

分别从 (6.2) 和 (6.3) 可以看出，如果不同  $J_{ij}$  之间没有约束，那么吸引子神经网络的存储问题等价于  $N$  个独立感知机的存储问题。<sup>1</sup> 因而，当感知机用作联想记忆时，其存储性质与吸引子神经网络的表现紧密相连。同样清楚的是，(6.2) 和 (6.3) 与带输出噪声的含噪教师学习问题非常相似，其中输出噪声由  $a = 0$  刻画，见 (5.1) 和 (5.4)。

因此，感知机  $\mathbf{J}$  的存储问题由一个稳定性参数  $\kappa \geq 0$  和一组  $p$  个随机输入-输出对  $\{\xi^\mu, \sigma^\mu\}$  定义，其中  $\mu = 1, \dots, p$ ，输入分量和输出都是相互独立的随机变量。与以前一样，我们假定它们都来自均值为零、方差为一的分布。目标是确定  $p$  的最大值  $p_c$ ，使得典型地所有输入-输出映射都能

<sup>1</sup> 由于一个感知机的输出也是所有其他感知机输入的一部分而产生的弱相关，在  $N \rightarrow \infty$  极限下可以忽略。

由感知机实现；也就是说，存在耦合向量  $\mathbf{J}$ ，满足

$$\frac{1}{\sqrt{N}} \sigma^\mu \mathbf{J} \boldsymbol{\xi}^\mu \geq \kappa \quad \text{对所有 } \mu = 1, \dots, p. \quad (6.4)$$

如果沿用上一章的学习问题语言，那么这个问题就是要确定从极端含噪教师学习时，在训练误差仍为零的条件下训练集的最大大小。与泛化问题中一样，我们将发现，在  $N \rightarrow \infty$  极限下  $p_c = O(N)$ ，相应地  $\alpha_c = p_c/N$  称为网络的存储容量。

Elizabeth Gardner 在其著名论文 [24] 中为这个问题引入了一种优雅而灵活的统计力学方法。它从满足 (6.4) 的耦合  $\mathbf{J}$  在相空间中的体积出发：

$$\Omega(\boldsymbol{\xi}^\mu, \sigma^\mu) = \int d\mu(\mathbf{J}) \prod_{\mu=1}^p \theta \left( \frac{\sigma^\mu}{\sqrt{N}} \mathbf{J} \boldsymbol{\xi}^\mu - \kappa \right). \quad (6.5)$$

由于  $\boldsymbol{\xi}^\mu$  和  $\sigma^\mu$  是随机选取的，这个体积本身是随机量。其典型值可由淬火熵得到：

$$s = \frac{1}{N} \left\langle \left\langle \ln \Omega(\boldsymbol{\xi}^\mu, \sigma^\mu) \right\rangle \right\rangle. \quad (6.6)$$

为了计算这一平均，再次使用复本技巧。具体计算与第 2.3 节和附录 B 中的计算非常相似。对输入作平均后，引入序参量矩阵

$$q^{ab} = \frac{1}{N} \sum_i J_i^a J_i^b \quad \text{其中 } a < b, \quad (6.7)$$

它描述满足 (6.4) 的两个解  $J_i^a$  和  $J_i^b$  之间的典型重叠。于是，与 (A2.17) 类似可得

$$\begin{aligned} \langle \langle \Omega^n \rangle \rangle &= \int \prod_a \frac{d\hat{k}^a}{4\pi} \int \prod_{a<b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \\ &\times \exp \left\{ N \left[ \frac{i}{2} \sum_a \hat{k}^a + i \sum_{a<b} q^{ab} \hat{q}^{ab} + G_S(\hat{k}^a, \hat{q}^{ab}) + \alpha G_E(q^{ab}) \right] \right\}, \end{aligned} \quad (6.8)$$

其中熵部分为

$$G_S(\hat{k}^a, \hat{q}^{ab}) = \ln \int \prod_a \frac{dJ^a}{\sqrt{2\pi e}} \exp \left( -\frac{i}{2} \sum_a \hat{k}^a (J^a)^2 - i \sum_{a<b} \hat{q}^{ab} J^a J^b \right), \quad (6.9)$$

能量部分为

$$\begin{aligned} G_E(q^{ab}) &= \int_{\kappa}^{\infty} \prod_a d\lambda^a \int \prod_a \frac{d\hat{\lambda}_a}{2\pi} \prod_a \exp \left[ i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 \right. \\ &\quad \left. - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab} \right]. \end{aligned} \quad (6.10)$$

假定复本对称性

$$q^{ab} = q, \quad \hat{q}^{ab} = \hat{q}, \quad \hat{k}^a = \hat{k},$$

并利用相应鞍点方程消去  $\hat{k}$  和  $\hat{q}$ ，这些表达式简化为

$$G_S = n \left[ \frac{1}{2} \ln(1-q) + \frac{q}{2(1-q)} \right] + O(n^2) \quad (6.11)$$

以及

$$G_E = n \int D\lambda \ln H \left( \frac{\kappa - \sqrt{q} \lambda}{\sqrt{1-q}} \right) + O(n^2), \quad (6.12)$$

从而得到淬火熵的最终表达式

$$s(\alpha) = \text{extr}_q \left[ \frac{1}{2} \ln(1-q) + \frac{q}{2(1-q)} + \alpha \int Dt \ln H \left( \frac{\kappa - \sqrt{q}t}{\sqrt{1-q}} \right) \right]. \quad (6.13)$$

相应地, 决定  $q$  的鞍点方程为

$$\frac{q}{1-q} = \frac{\alpha}{\pi} \int Dt \exp \left[ -\frac{(\kappa - \sqrt{q}t)^2}{1-q} \right] \left[ H \left( \frac{\kappa - \sqrt{q}t}{\sqrt{1-q}} \right) \right]^{-2}. \quad (6.14)$$

由这个方程可以把 (6.4) 的两个不同解之间的典型重叠  $q$  确定为存储比  $\alpha$  的函数。当  $\alpha = 0$  时,  $N$  维球面上的所有向量  $\mathbf{J}$  都是可行解, 因此  $q = 0$ 。随着  $\alpha$  增大, 典型解体积收缩, 这意味着  $q$  增大。最终, 当  $q \rightarrow 1$  时达到临界存储容量  $\alpha_c$ 。在这一极限中, (6.4) 的两个不同解实际上变得相同, 因而典型解体积消失, 见图 6.1, 这一点也可由 (6.13) 看出。利用 (A1.6) 给出的  $H$  函数渐近形式, 在这一极限下由 (6.14) 得到

$$\frac{1}{\alpha_c} = \int_{-\infty}^{\kappa} Dt (\kappa - t)^2. \quad (6.15)$$




图 6.1: 不同  $\alpha$  下解体积  $\Omega$  (阴影区域) 的示意图。图中还画出了两个可能的耦合向量  $\mathbf{J}^1$  和  $\mathbf{J}^2$ , 它们的典型重叠由  $q$  描述。当  $\alpha$  接近存储容量  $\alpha_c$  时, 有  $q \rightarrow 1$  且  $\Omega \rightarrow 0$ 。

存储容量  $\alpha_c$  对稳定性参数  $\kappa$  的依赖如图 6.2 所示。当  $\kappa = 0$  时得到  $\alpha_c = 2$ , 这与第 5.2 节的发现一致, 特别可参见图 5.1 中  $a = 0$  的情形。正如预期,  $\alpha_c$  随  $\kappa$  增大而减小, 这对吸引子神经网络意味着存储容量与吸引盆大小之间存在折衷。

## 6.2 二分法计数: Cover 分析

对于  $\kappa = 0$  得到的结果  $\alpha_c = 2$ , 也可以用一种完全不同的方式导出; 这种方式突出显示了存储问题的几何方面。Cover 早在 1965 年就推导出了这一结果 [72], 不过其背后的数学结果显然要古老得多 [73, 74]。

思想如下。考虑  $N$  维 Euclidean 空间中的  $p$  个点, 它们被染成黑色或白色。如果存在一个过原点的超平面, 把这些点分开, 也就是说所有黑点位于平面一侧而所有白点位于另一侧, 那么这个着色称为一个二分法。图 6.3 给出了  $N = 2$ 、 $p = 3$  时的两个简单例子。如果把这些点的坐标作为  $N$  维输入向量, 并把它们的颜色作为编码输出  $\sigma^\mu = \pm 1$ , 那么显然, 法向量为感知机耦合向量  $\mathbf{J}$






图 6.2: 感知机的存储容量  $\alpha_c$  作为 (6.4) 中定义的稳定性参数  $\kappa$  的函数。

的分离超平面将实现相应的输入-输出关系，因为它与所有白点的标量积会具有同一符号，而与所有黑点的标量积会具有相反符号。<sup>1</sup>




图 6.3: 二维中三个点的两种不同着色。左图给出一个二分法，并画出一个可能的分离超平面。右图中，不存在过原点且能把黑点与白点分开的直线。

下面将确定  $N$  维中  $p$  个点的二分法数  $C(p, N)$ 。一个随机着色是二分法的概率，简单地由  $C(p, N)$  与所有不同可能着色总数  $2^p$  之比给出。

这一分析背后的显著性质是：在相当弱的条件下，数目  $C(p, N)$  确实只依赖于  $p$  和  $N$ ，而不依赖于这些点的详细位置。这一性质是感知机特有的；我们将在第 十二章看到，它会阻碍人们用类似技术对多层网络作精确分析。对于当前感知机分析而言，唯一必要且相当合理的条件是：这些点处于所谓一般位置，也就是说任意  $N$  个或更少点组成的子集都是线性无关的。注意，从连续概率分布随机产生的点，以概率 1 满足这一条件。

<sup>1</sup>这正是感知机能够实现的输入-输出映射称为线性可分的原因。还要注意，超平面必须经过原点这一条件，对应于感知机没有阈值，即  $\theta = 0$ 。

$C(p, N)$  的实际计算用归纳法进行。当然有

$$C(1, N) = 2, \quad C(p, 1) = 2, \quad (6.16)$$

因为无论颜色如何, 一个点总可以被“分开”; 而在一维中, 唯一可用的“超平面”就是原点本身。接着假定已知  $C(p, N)$ , 希望确定  $C(p+1, N)$ 。显然  $C(p+1, N) \geq C(p, N)$ , 因为  $p$  个点的每一个二分法都会至少产生一个  $p+1$  个点的二分法。为了得到它, 只需把新点染成“它那一侧”的颜色即可, 见图 6.4a。

事实上, 有时一个旧二分法甚至可以产生两个新的二分法, 恰好发生在父二分法存在一个经过新点的分离超平面时。于是, 只需把这个超平面向新点两侧稍微旋转, 新点的两种着色就都可能, 见图 6.4b。注意, 由于点处于一般位置, 这种旋转可以做到不让其他点穿过超平面。那么, 经过原点和一个额外点  $P$  的超平面, 会诱导出  $N$  维中  $p$  个点的多少个二分法呢? 把所有点投影到与连接原点和  $P$  的直线垂直的超平面上, 即可看到这些数目正好是  $C(p, N-1)$ 。要求超平面经过  $P$ , 只是把可用维数减少了 1。因此得到

$$C(p+1, N) = C(p, N) + C(p, N-1), \quad (6.17)$$

因为  $p$  个点的所有  $C(p, N)$  个二分法都会给出  $p+1$  个点的一个二分法, 而其中  $C(p, N-1)$  个会额外贡献一个。这个漂亮的递推关系是计算的关键步骤。借助边界条件 (6.16), 现在不难推出  $N$  维中  $p$  个点的二分法数

$$C(p, N) = 2 \sum_{i=0}^{N-1} \binom{p-1}{i}. \quad (6.18)$$




图 6.4: 加入一个新点 (方块) 时, 二分法数  $C(p, N)$  的变化。(a) 新点必须染为白色, 二分法数不增加。(b) 存在一个经过新点、同时分开旧点的超平面。因此, 只需稍微旋转这个超平面 (点线), 新点的两种着色就都线性可分, 二分法数因此增加 1。

图 6.5 使用 (6.18) 作出了随机着色成为二分法的概率  $C(p, N)/2^p$ , 它作为  $\alpha = p/N$  的函数, 取若干  $N$  值。可以清楚看到, 当  $N$  很大时, 在  $\alpha_c = 2$  处存在从概率 1 到概率 0 的尖锐转变, 这与上一节的发现一致。

Cover 方法与 Gardner 方法处理感知机存储问题的方式相当互补。前者计数的是不同可实现映射的数目, 而后者度量的是实现某一个特定映射时的可变性。Cover 方法给出所有  $N$  的结果, 并能探测到超出 Gardner 方法鞍点论证分辨率之外的细微差别。例如, 由 (6.18) 可知, 当  $p \leq N$  时




图 6.5: 随机着色  $N$  维中  $p$  个点成为二分法的概率, 作为  $p/N$  的函数; 这里  $N = 5$  (大点)、 $N = 50$  (小点) 以及  $N = 500$  (线), 均由 (6.18) 确定。

严格有  $C(p, N)/2^p = 1$ , 而当  $N < p < 2N$  时有  $C(p, N)/2^p - 1 = O(e^{-N})$ 。这个极小差别不会出现在 Gardner 计算中; 在那里  $\alpha = 1$  并无特殊之处。

此外, Cover 方法不依赖复本方法这样在数学上可疑的技巧。另一方面, 它并不灵活。迄今为止, 将这种方法推广到  $\kappa > 0$  或其他网络类型的若干尝试都失败了。Gardner 方法的巨大优势在于它应用广泛, 并允许若干有趣修改。不过, 作为一种统计力学技术, 它总是需要取  $N \rightarrow \infty$  极限。

### 6.3 Galileo 式拼贴: Ising 感知机

**Simplicio:** 我有一个很适合用你的方法来确定存储容量的问题。我们再次考虑满足存储条件 (6.4) 的感知机, 不过现在附加约束: 耦合向量的所有分量都只能取正一或负一,

$$J_i = \pm 1. \quad (6.19)$$

这个系统的存储容量结果将显示, 把  $\mathbf{J}$  分量限制为技术上容易处理的取值, 会在多大程度上影响网络表现。知道这一点似乎很有用, 尤其是对于可能的硬件实现。

**Salviati:** 这的确是个好问题。我们把它称为 Ising<sup>1</sup> 感知机, 以区别于此前研究的具有连续耦合的球形感知机。

**Simplicio:** 我看不出如何用 Cover 方法分析 Ising 感知机, 因为它依赖于连续改变  $\mathbf{J}$  方向的可能性, 见图 6.4。因此, 采用 Gardner 方法似乎更好。

**Salviati:** 你又说对了。对 Ising 感知机, 没有已知方法能够导出类似 (6.17) 的递推关系。另一方面, 你会发现 Gardner 方法的应用非常有启发性!

<sup>1</sup>Ising 模型以 Ernst Ising 命名, 是统计力学中著名的铁磁体模型, 其中各个微观磁矩由二值变量  $S_i = \pm 1$  表示。

**Simplicio:** 实际上, 这个计算与第 6.1 节所做的非常相似。仍然关注解体积  $\Omega(\xi^\mu, \sigma^\mu)$  的典型值, 我所要做的只是使用替换

$$\int d\mu(\mathbf{J}) \mapsto \sum_{\{J_i=\pm 1\}}, \quad (6.20)$$

这反映出 Ising 耦合的离散性质。因此, 能量部分 (6.10) 完全没有变化, 而熵部分我得到的不是 (6.9), 而是

$$G_S(\hat{q}^{ab}) = \ln \sum_{\{J^a=\pm 1\}} \exp \left( -i \sum_{a<b} \hat{q}^{ab} J^a J^b \right). \quad (6.21)$$

由此得到复本相空间体积的如下表达式:

$$\langle\langle \Omega^n \rangle\rangle = \int \prod_{a<b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \exp \left\{ N \left[ i \sum_{a<b} q^{ab} \hat{q}^{ab} + G_S(\hat{q}^{ab}) + \alpha G_E(q^{ab}) \right] \right\}. \quad (6.22)$$

鞍点方法使我能够在  $N \rightarrow \infty$  时计算  $q^{ab}$  和  $\hat{q}^{ab}$  上的积分。遗憾的是, 在这一阶段, 共轭序参量  $\hat{q}^{ab}$  不能像球形感知机中那样解析消去。不过, 使用复本对称假设

$$q^{ab} = q, \quad -i\hat{q}^{ab} = \hat{q}, \quad (6.23)$$

$G_S$  的表达式化简为

$$\begin{aligned} G_S(\hat{q}^{ab}) &= \ln \sum_{\{J^a=\pm 1\}} \exp \left( \hat{q} \sum_{a<b} J^a J^b \right) \\ &= \ln \sum_{\{J^a=\pm 1\}} \exp \left( \frac{\hat{q}}{2} \sum_{a,b} J^a J^b - n \frac{\hat{q}}{2} \right) \\ &= -n \frac{\hat{q}}{2} + \ln \int Dz \sum_{\{J^a=\pm 1\}} \exp \left( \sqrt{\hat{q}} z \sum_a J^a \right) \\ &= -n \frac{\hat{q}}{2} + n \int Dz \ln 2 \cosh(\sqrt{\hat{q}} z) + O(n^2), \end{aligned} \quad (6.24)$$

于是对淬火熵最终得到

$$s(\alpha) = \text{extr}_{q, \hat{q}} \left[ -\frac{\hat{q}}{2}(1-q) + \int Dz \ln 2 \cosh(\sqrt{\hat{q}} z) + \alpha \int Dt \ln H \left( \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}} \right) \right]. \quad (6.25)$$

相应的鞍点方程为

$$q = \int Dz \tanh^2(\sqrt{\hat{q}} z) \quad (6.26)$$

和

$$\hat{q} = \frac{\alpha}{2\pi(1-q)} \int Dt \exp \left[ -\frac{(\kappa - \sqrt{q} t)^2}{1-q} \right] \left[ H \left( \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}} \right) \right]^{-2}. \quad (6.27)$$

当  $\kappa = 0$  时, 我从这些方程的数值解发现,  $q$  在  $\alpha \simeq 1.27$  处趋近 1。这是  $\alpha_c$  的一个相当合理取值。它小于 2, 这是应该的, 因为 Ising 感知机是球形感知机的特殊情形。另一方面, 它也表明, 将突触限制为二值, 对存储容量来说并不算特别严苛。

**Salviati:** 你的计算看起来颇有说服力。事实上, 如果集中考虑  $\kappa = 0$  情形, 由  $\hat{q}$  的鞍点方程可在  $q \rightarrow 1$  极限下得到  $\hat{q} \simeq \alpha/[2\pi(1-q)^2]$ 。使用这一点, (6.25) 右端可写成  $(\sqrt{\alpha/\pi} - \alpha/2)/(1-q)$  的形式。为了使  $q \rightarrow 1$  极限良好, 就必须有  $\alpha \rightarrow \alpha_c = 4/\pi$ , 这与你关于  $\alpha_c$  的数值结果相当接近。

**Simplicio:** 很好, 那我们就完成了。




图 6.6: Gardner 球面一部分的示意图, 它包含  $N$  维超立方体的四个角, 对应于 Ising 感知机可能的耦合向量。灰色区域表示球形感知机的解空间。它总是凸的, 因此也是连通的。(a) 一般解体积中所含的两个 Ising 感知机解由超立方体的一条边连接。(b) 沿超立方体的边从一个 Ising 解走到另一个 Ising 解时, 无法不离开解体积。因此, Ising 感知机的解空间未必连通, 这可能使复本对称鞍点不稳定。

**Salviati:** 其实并没有。请注意下面这个问题。你的结果  $\alpha_c \simeq 1.27$  意味着, 通过适当选择耦合  $J_i$ , 我们能够以大  $N$  下概率 1 实现从  $1.27N$  个输入  $\xi^\mu$  到二值输出  $\sigma^\mu$  的任意映射。这意味着我们可以把  $1.27N$  bit 编码到网络结构中。但这个结构本身已经由  $N$  bit 固定, 也就是由  $J_i$  的二值取值固定! 因此,  $\alpha_c$  大于 1 是不可能的。<sup>1</sup>

**Simplicio:** 但这个问题也应该出现在我的复本计算中。我没有找到错误!

**Salviati:** 你的计算在复本对称 ansatz 内是正确的。不过, 使用复本对称鞍点时, 必须总是伴随分析它的稳定性。对于球形感知机, 这一分析表明, 复本对称 (RS) 鞍点对所有  $\alpha < \alpha_c$  都是稳定的 [24, 25, 75]。这与解空间为凸集这一事实一致; 这一点已经在第二章末尾简要讨论过。对 Ising 感知机则未必如此; 定性图像见图 6.6。

事实上, 这幅图提示了如下推理。为了找到存储问题的一个 Ising 解, 球形情形的解体积  $\Omega$  应当至少包含  $N$  维超立方体的  $2^N$  个角之一。如果假定这些角与球形解体积之间没有相关性, 那么只要  $\Omega > 2^{-N}$ , 就预期会以高概率存在 Ising 解。对 (6.13) 的数值研究显示, 当  $\alpha \simeq 0.85$  且  $q \simeq 0.5$  时,  $\Omega \simeq 2^{-N}$ 。因此 0.85 看起来像是  $\alpha_c$  的一个不错的近似候选值。

**Salviati:** 为了澄清这一估计与你的 RS 结果  $\alpha \simeq 1.27$  之间的差别, 考察 Ising 感知机 RS 鞍点的稳定性应当很有启发。附录 D 会给你一些如何去做的提示。

两周以后

**Simplicio:** 我终于完成了稳定性分析。你是对的, RS 鞍点并不总是稳定。当  $\kappa = 0$  时, 我发现  $\alpha > \alpha_{AT} \simeq 1.015$  后出现不稳定。因此, 我的结果  $\alpha_c = 4/\pi$  没有意义, 因为它来自一个 RS ansatz 已经无效的区域。另一方面, 对于确定正确的  $\alpha_c$  值, 稳定性分析似乎帮助不大。我们已经知道  $\alpha_c$  必须小于 1, 因此属于 RS 正确的区域!

**Salviati:** 你的稳定性分析很有用, 因为它证明了复本对称破缺 (RSB) 对 Ising 感知机是重要的。不过, 我们仍不知道 RS 对所有  $\alpha < \alpha_{AT}$  都正确! 局域稳定性是 RS ansatz 可靠性的必要条件, 但不是充分条件。式 (6.22) 中被积函数的指数可能有若干极大值, 并且它们都局域稳定。尽管如此, 当  $N \rightarrow \infty$  时, 只有全局极大值会对积分作出显著贡献。

<sup>1</sup>对解体积作退火计算也会得到同样的上界  $\alpha_c \leq 1$ , 见习题 6.11。

**Simplicio:** 这当然是真的。事实上, 你的意思是, 向 RSB 的转变可能类似统计力学中的一阶相变, 而不是由旧相的局域不稳定性刻画二阶相变。但是我该如何检查在我的问题中, 当  $\alpha < \alpha_{AT}$  时是否还存在不同于 RS 极大值的其他极大值呢?

**Salviati:** 为此, 你必须描述一个不连通的解空间。在这种情况下, 序参量  $q^{ab}$  至少要有两个不同取值: 一个描述属于同一个解空间斑块的两个解之间的典型重叠, 另一个刻画来自不同斑块的两个解之间的典型重叠。幸运的是, 关于无序系统的其他统计力学研究已经遇到过类似问题 [76]。从这些经验可知, 检验 RS 鞍点全局稳定性的适当方式, 是用一步复本对称破缺 (RSB) 的 ansatz 确定复本解体积, 并把结果与 RS 计算比较, 以找到正确极值。

**Simplicio:** 真的没有办法使用 Cover 方法吗?

**Salviati:** 很遗憾, 没有。不过附录 E 为 Ising 感知机的一步 RSB 结果提供了一条安全指南。

又过了两周

**Simplicio:** 我最终用一步 RSB ansatz 得到的熵为

$$s(\alpha) = \underset{q_0, \hat{q}_0, q_1, \hat{q}_1, m}{\text{extr}} \left[ \frac{m}{2} (q_0 \hat{q}_0 - q_1 \hat{q}_1) - \frac{\hat{q}_1}{2} (1 - q_1) \right. \\ \left. + \frac{1}{m} \int Dz_0 \ln \int Dz_1 \left[ 2 \cosh \left( \sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1 \right) \right]^m \right. \\ \left. + \frac{\alpha}{m} \int Dt_0 \ln \int Dt_1 H^m \left( -\frac{\sqrt{q_0} t_0 + \sqrt{q_1 - q_0} t_1}{\sqrt{1 - q_1}} \right) \right]. \quad (6.28)$$

即使数值求解, 相应的五个鞍点方程也相当困难。

**Salviati:** 你的结果是正确的; 幸运的是, 为了确定存储容量, 你不需要所有五个序参量的详细解。参数  $q_1$  描述来自解空间同一个连通部分两个解之间的典型重叠。当  $\alpha \rightarrow \alpha_c$  时, 我们预期这些单独斑块收缩成点, 因此  $q_1 \rightarrow 1$ 。由于不同点分布在球面上, 即使在  $\alpha_c$  处,  $q_0$  的值也会保持小于 1。因此, 通过考虑与 (6.28) 对应的鞍点方程在  $q_1 \rightarrow 1$  极限下的形式, 应当可以提取出  $\alpha_c$  的值。

**Simplicio:** 当  $q_1 \rightarrow 1$  时, 我发现  $\hat{q}_1 \sim 1/\sqrt{1 - q_1} \rightarrow \infty$ , 而关于  $m$  的鞍点方程化为

$$0 = -\frac{m \hat{q}_0}{2} (1 - q_0) + \frac{1}{m} \int Dz \ln 2 \cosh(\sqrt{m \hat{q}_0} z) + \frac{\alpha_c}{m} \int Dt \ln H \left( -\frac{\sqrt{q_0} t}{\sqrt{1 - q_0}} \right). \quad (6.29)$$

**Salviati:** 很好。现在作替换  $\hat{q}_0 \mapsto \hat{q}/m^2$  和  $q_0 \mapsto q$ , 并与 (6.25) 比较, 你会发现这个关于  $m$  的鞍点方程可以写成简单形式

$$s^{\text{RS}}(\alpha_c) = 0. \quad (6.30)$$

现在需要上标 RS 来区分熵的复本对称表达式 (6.25) 与一步 RSB 结果 (6.28)。结果 (6.30) 称为零熵条件, 它确实是确定离散耦合神经网络存储容量的正确方式。从现在起, 我们还会多次使用它。

**Simplicio:** 这么说来, 超出熵的 RS 表达式之外的那些复杂计算全都多余了! 把使 (RS) 熵消失的  $\alpha$  值  $\alpha_{ZE}$  与存储容量  $\alpha_c$  等同起来, 确实相当合理。毕竟  $s(\alpha_{ZE}) = 0$  只是意味着当  $\alpha > \alpha_{ZE}$  时, 存储问题的解  $\mathbf{J}$  只剩下次指数多个。所以, 典型地就找不到解了!

**Salviati:** 零熵判据确实显得相当自然。不过, 如你所见, 它的详细来源十分微妙。事实上, 完整故事还藏着更多意外 [43]。至于你把  $\alpha_{ZE}$  与  $\alpha_c$  等同起来的论证, 要注意在 RS 框架内根本不可



能刻画  $\alpha > \alpha_{ZE}$  的解空间。因此，你这次对 RS 之外世界的小小远行非常有用，即使它最终证明的步骤只使用了 RS 结果。此外，你在破缺复本对称方面的新专长，稍后研究多层神经网络时也会派上用场。

不过，回到 Ising 感知机， $\alpha_c$  的值究竟是多少？

**Simplicio:** 用 (6.26) 和 (6.27) 确定  $q$  与  $\hat{q}$ ，数值寻找 (6.30) 的根，我得到  $\alpha_c \simeq 0.83$ ，且  $q \simeq 0.5$ 。这非常接近你估计的 0.85。

**Salviati:** 你的结果与精确数值计算 [77, 78] 一致，因此被认为是正确的。虽然对相关系统，比如随机能量模型 [79, 76]，已经证明一步 RSB 结果就是精确结果，但迄今还不知道 Ising 感知机是否如此。最后，虽然你的结果与朴素 RS 结果  $4/\pi$  显著不同，它仍显示了存储能力令人印象深刻的鲁棒性。把耦合取值从实数削减到只有 1 和  $-1$ ，是很大的一步；但存储容量只降低到大约 40%。顺带一提，如果允许耦合有三个取值  $J_i = -1, 0, 1$ ，则  $\alpha_c$  的结果会回升到  $\alpha_c = 1.17$  [80]。

## 6.4 稳定性分布

在学习之前，当耦合  $\mathbf{J}$  还与输入  $\xi^\mu$  完全无关时，稳定性

$$\Delta^\mu = \frac{1}{\sqrt{N}} \sigma^\mu \mathbf{J} \xi^\mu \quad (6.31)$$

的分布由中心极限定理给出为 Gaussian 分布

$$P(\Delta) = \frac{1}{\sqrt{2\pi}} \exp(-\Delta^2/2). \quad (6.32)$$

因此，初始时一半输入具有正稳定性，另一半具有负稳定性。由第 6.1 节的分析可知，对所有  $\kappa > 0$ ，只要  $\alpha < \alpha_c(\kappa)$ ，就可以找到耦合  $\mathbf{J}$ ，使所有稳定性都大于  $\kappa$ 。这样的学习过程之后，稳定性分布究竟是什么样子，是一个很有意思的问题。这个分布可以通过对复本方法作一种富有启发性的修改来计算 [81, 26]。

对输入  $\xi^\mu$  作平均后，所有指标  $\mu$  都彼此等价。因此，不失一般性，我们可以用第一个输入，即  $\mu = 1$  的稳定性来定义学习后的  $P(\Delta)$ ：

$$P(\Delta) = \left\langle \left\langle \frac{\int d\mu(\mathbf{J}) \prod_{\mu=1}^p \theta \left( \frac{\sigma^\mu}{\sqrt{N}} \mathbf{J} \xi^\mu - \kappa \right) \delta \left( \frac{\sigma^1}{\sqrt{N}} \mathbf{J} \xi^1 - \Delta \right)}{\int d\mu(\mathbf{J}) \prod_{\mu=1}^p \theta \left( \frac{\sigma^\mu}{\sqrt{N}} \mathbf{J} \xi^\mu - \kappa \right)} \right\rangle \right\rangle. \quad (6.33)$$

这个定义既包括对所有能够成功实现所需输入-输出映射的耦合向量  $\mathbf{J}$  的平均，也包括对随机输入的平均。执行后一个平均时的困难在于，(6.33) 中的分子和分母都依赖于  $\xi^\mu$ ，不能分别对它们取平均。为了绕开这一困难，我们引入复本，把 (6.33) 改写为

$$P(\Delta) = \lim_{n \rightarrow 0} \left\langle \left\langle \int \prod_a d\mu(\mathbf{J}^a) \prod_{\mu,a} \theta \left( \frac{\sigma^\mu}{\sqrt{N}} \mathbf{J}^a \xi^\mu - \kappa \right) \times \delta \left( \frac{\sigma^1}{\sqrt{N}} \mathbf{J}^1 \xi^1 - \Delta \right) \right\rangle \right\rangle. \quad (6.34)$$

注意，现在除了第一个输入指标  $\mu = 1$  以外，第一个复本指标  $a = 1$  也扮演特殊角色。要看出 (6.34) 与 (6.33) 的等价性，最简单的方法是注意到，(6.34) 中关于  $\mathbf{J}^2, \dots, \mathbf{J}^n$  的积分完全相同，因而给出同一个积分的  $n-1$  次幂；在  $n \rightarrow 0$  极限下，这恰好产生 (6.33) 的分母。



现在可以照常求输入平均。为此，我们先把  $P(\Delta)$  写成

$$P(\Delta) = \theta(\Delta - \kappa) \lim_{n \rightarrow 0} \left\langle \left\langle \int \prod_a d\mu(\mathbf{J}^a) \delta \left( \frac{\sigma^1}{\sqrt{N}} \mathbf{J}^1 \boldsymbol{\xi}^1 - \Delta \right) \right. \right. \\ \left. \left. \times \prod_{a>1} \theta \left( \frac{\sigma^1}{\sqrt{N}} \mathbf{J}^a \boldsymbol{\xi}^1 - \kappa \right) \prod_{\mu>1,a} \theta \left( \frac{\sigma^\mu}{\sqrt{N}} \mathbf{J}^a \boldsymbol{\xi}^\mu - \kappa \right) \right\rangle \right\rangle, \quad (6.35)$$

并为  $\delta$  函数和  $\theta$  函数引入积分表示。这得到

$$P(\Delta) = \theta(\Delta - \kappa) \lim_{n \rightarrow 0} \int \prod_a d\mu(\mathbf{J}^a) \int \frac{d\hat{\lambda}_1^1}{2\pi} \int_{\kappa}^{\infty} \prod_{a>1} \frac{d\lambda_1^a}{2\pi} \int \prod_{a>1} d\hat{\lambda}_1^a \\ \times \int_{\kappa}^{\infty} \prod_{a,\mu>1} \frac{d\lambda_\mu^a}{2\pi} \int \prod_{a,\mu>1} d\hat{\lambda}_\mu^a \\ \times \exp \left( i\Delta \hat{\lambda}_1^1 + i \sum_{a>1} \lambda_1^a \hat{\lambda}_1^a + i \sum_{\mu>1,a} \lambda_\mu^a \hat{\lambda}_\mu^a \right) \\ \times \left\langle \left\langle \exp \left( -\frac{i}{\sqrt{N}} \sum_{a,\mu} \hat{\lambda}_\mu^a \mathbf{J}^a \boldsymbol{\xi}^\mu \right) \right\rangle \right\rangle. \quad (6.36)$$

对  $\boldsymbol{\xi}^\mu$  作平均以后，引入通常的序参量，得到

$$P(\Delta) = \theta(\Delta - \kappa) \lim_{n \rightarrow 0} \int \prod_a \frac{d\hat{k}^a}{4\pi} \int \prod_{a<b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \int \frac{d\hat{\lambda}_1^1}{2\pi} \\ \times \int_{\kappa}^{\infty} \prod_{a>1} \frac{d\lambda_1^a}{2\pi} \int \prod_{a>1} d\hat{\lambda}_1^a \\ \times \exp \left( i\Delta \hat{\lambda}_1^1 + i \sum_{a>1} \lambda_1^a \hat{\lambda}_1^a - \frac{1}{2} \sum_a (\hat{\lambda}_1^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}_1^a \hat{\lambda}_1^b q^{ab} \right) \\ \times \exp \left[ \frac{iN}{2} \sum_a \hat{k}^a + Ni \sum_{a<b} q^{ab} \hat{q}^{ab} + NG_S(\hat{k}^a, \hat{q}^{ab}) + (\alpha N - 1) G_E(q^{ab}) \right], \quad (6.37)$$

其中  $G_S(\hat{k}^a, \hat{q}^{ab})$  和  $G_E(q^{ab})$  分别与 (6.9) 和 (6.10) 中给出的表达式完全相同。这个表达式中的序参量积分可以用鞍点方法计算，相应的鞍点方程当然也与第 6.1 节相同。注意，在随后的  $n \rightarrow 0$  极限中，(6.37) 最后一行指数中的项会消失。尽管如此，它仍然十分重要，因为它固定了同样出现在其余项中的序参量取值，也可参见 (A1.21)。

假定复本对称性，并经过现在读者已经熟悉的标准变形之后，可以得到

$$P(\Delta) = \theta(\Delta - \kappa) \lim_{n \rightarrow 0} \int Dt \int \frac{d\hat{\lambda}^1}{2\pi} \int_{\kappa}^{\infty} \prod_{a>1} \frac{d\lambda^a}{2\pi} \int \prod_{a>1} d\hat{\lambda}^a \\ \times \exp \left[ i\Delta \hat{\lambda}^1 + i \sum_{a>1} \lambda^a \hat{\lambda}^a - \frac{1-q}{2} \sum_a (\hat{\lambda}^a)^2 - i\sqrt{q}t \sum_a \hat{\lambda}^a \right].$$

关于  $\hat{\lambda}^2, \dots, \hat{\lambda}^n$  的积分全都相同，给出某个积分的  $n-1$  次幂。取  $n \rightarrow 0$  极限后，最后得到

$$P(\Delta) = \theta(\Delta - \kappa) \frac{1}{\sqrt{2\pi(1-q)}} \int Dt \exp \left[ -\frac{(\Delta - \sqrt{q}t)^2}{2(1-q)} \right] \left[ H \left( \frac{\kappa - \sqrt{q}t}{\sqrt{1-q}} \right) \right]^{-1}, \quad (6.38)$$

其中  $q$  由 (6.14) 决定。于是我们最终恢复了 (6.33) 中从平均一个商出发的结构，只是这里的  $t$  在某种意义上扮演了淬火无序的角色。

$P(\Delta)$  的表达式在存储容量处特别有启发性, 即当  $\alpha = \alpha_c$  时。如第 6.1 节所讨论的, 这时  $q \rightarrow 1$ , 从而 (6.38) 化简为

$$P(\Delta) = \theta(\Delta - \kappa) \frac{1}{\sqrt{2\pi}} \exp(-\Delta^2/2) + H(-\kappa) \delta(\Delta - \kappa). \quad (6.39)$$




图 6.7: 由 (6.39) 给出的稳定性分布  $P(\Delta)$ , 其中  $\alpha = 1.0$ 、 $\kappa = 0.3$ 。初始 Gaussian 分布 (6.32) 中对应于稳定性大于  $\kappa$  的部分不受学习过程改变, 而所有小于  $\kappa$  的稳定性都被移动到  $\Delta = \kappa$  处的  $\delta$  峰上。图中该峰的高度等于 (6.39) 中  $\delta$  函数的前因子。

把这个结果与 (6.32) 给出的学习前稳定性分布比较, 可以看出大于  $\kappa$  的稳定性仍保持 Gaussian 分布, 而所有初始时小于  $\kappa$  的稳定性, 都被学习过程移动到恰好所需的稳定性边界上, 见图 6.7。这显然是实现所有  $\Delta^\mu \geq \kappa$  的一种最优方式, 因为把那些初始时小于  $\kappa$  的稳定性推到超过  $\kappa$  的取值, 会降低对其他输入的灵活性。事实上, 分布 (6.39) 完美反映了第 3.5 节讨论的 adatron 学习规则的策略。不过我们也强调, “从一开始就具有大于  $\kappa$  稳定性的输入可以保持不动” 这一经验说法并不完全正确, 因为学习前后产生  $\Delta > \kappa$  Gaussian 尾部的输入集合一般并不相同。

本节描述的分析可以类似地用于泛化问题, 也就是学习由教师感知机定义的规则, 见习题 6.16。此时, 稳定性分布可用来确定学生分类所能赋予的置信度。相对于只由泛化误差给出的平均估计, 这种分布细化了对学习能力的刻画 [82]。如何利用这一额外信息改进泛化表现的一个简单例子, 就是拒绝困难问题的策略; 它已经在习题 4.9 中讨论过。

## 6.5 超过存储容量之后

最后, 我们简要讨论输入-输出映射数超过  $\alpha_c N$  时, 存储问题的主要特征。按照存储容量的定义, 此时已经不可能实现所有映射, 因此最小可能错误比例  $\epsilon_{\min}$  的问题自然出现。这个量可以用类似于第 4.3 节的方法计算: 把错误分类数视作能量, 并考虑零温极限  $\beta \rightarrow \infty$ , 从而集中到使错

误差最小的耦合向量  $\mathbf{J}$  上 [25]。这个计算当然也类似于第 5.3 节讨论的含噪教师问题中训练误差的确定。因此我们只给出结果，另见习题 6.14。在复本对称假定下，有 [25]

$$\epsilon_{\min} = \text{extr}_x \left[ H(\sqrt{2x} - \kappa) + \frac{1}{2x} \int_{\kappa - \sqrt{2x}}^{\kappa} Dt (\kappa - t)^2 - \frac{1}{2\alpha x} \right]. \quad (6.40)$$

利用关于  $x$  的相应鞍点方程

$$\frac{1}{\alpha} = \int_{\kappa - \sqrt{2x}}^{\kappa} Dt (\kappa - t)^2, \quad (6.41)$$

它在给定  $\alpha$  和  $\kappa$  时固定  $x$ ，(6.40) 化简为

$$\epsilon_{\min} = H(\sqrt{2x} - \kappa). \quad (6.42)$$

当  $\alpha \rightarrow \alpha_c(\kappa)$  时，有  $x \rightarrow \infty$ ，相应地  $\epsilon_{\min} \rightarrow 0$ ，这正是应有的结果。

确定过饱和情形中的稳定性分布  $P(\Delta)$  也很有启发。类似上一节，并再次假定复本对称性成立，可得

$$\begin{aligned} P(\Delta) = & \theta(\kappa - \sqrt{2x} - \Delta) \frac{1}{\sqrt{2\pi}} \exp(-\Delta^2/2) \\ & + \left[ H(\kappa - \sqrt{2x}) - H(\kappa) \right] \delta(\Delta - \kappa) + \theta(\Delta - \kappa) \frac{1}{\sqrt{2\pi}} \exp(-\Delta^2/2), \end{aligned} \quad (6.43)$$

其中  $x$  仍由 (6.41) 确定。现在的分布有三部分，如图 6.8 所示。它在  $\Delta > \kappa$  处是 Gaussian 分布，并且像  $\alpha < \alpha_c$  情形一样，在  $\Delta = \kappa$  处有一个  $\delta$  峰。不过此外还出现了一个稳定性小于  $\kappa$  的 Gaussian 尾部，它包含网络未能实现的输入-输出对。对这段错误稳定性部分积分，当然会重新给出错误比例的结果 (6.42)。




图 6.8: 过饱和感知机的稳定性分布  $P(\Delta)$ ，其中  $\alpha = 1.0$ 、 $\kappa = 0.7$ 。点线给出复本对称表达式 (6.43)，实线是一阶复本对称破缺结果 [62]。分布中的间隙是只计数错误的代价函数的典型特征；间隙左边界处的跳跃会使复本对称性不稳定 [75, 83]。

注意，稳定性分布中存在显著间隙，这意味着出现的错误确实是“粗大”错误。这是所使用代价函数造成的，因为它只计算错误数目，并不关心错误有多严重，也就是其稳定性与所需阈值  $\kappa$  相

差多少。其他代价函数，例如第三章引入的感知机规则和 adatron 规则对应的代价函数，会按照稳定性偏离  $\kappa$  的程度来加权错误。因此，在  $\alpha_c$  之上，它们偏好产生更多但不那么严重的错误的耦合。关于不同代价函数在存储容量以上、复本对称假定下行为的详细分析，可见 [84]。

最后还必须提醒一句：对于  $\alpha_c$  以上的存储问题，复本对称性是不稳定的 [25, 75]，这正是不可实现情形的典型特征，参见第 5.5 节。这与我们的经验规则一致：如果解空间是不连通的，就可能发生复本对称破缺。在  $\alpha_c$  以上，感知机不得不犯错，而哪些输入-输出对不能被正确实现有多种可能。直观上，对应于不同错误集合的耦合向量通常不会彼此连通。

幸运的是，用一步复本对称破缺鞍点研究过饱和感知机表明，某些结果，例如最小错误比例，并不会因复本对称破缺而显著改变 [85, 62]。另一方面，稳定性分布会在一定程度上被重塑，如图 6.8 所示。

仔细分析表明， $P(\Delta)$  在间隙起点处的不连续跳跃，是鞍点不稳定的形式原因 [75]。随后可以证明，任何有限层级的 RSB 都会给出这样的不连续跳跃，因此也会是不稳定的 [83]。于是，人们提出了一个更有雄心的方案：使用完整连续的 Parisi RSB 方案 [86, 17] 来分析 [87]。所需计算相当复杂，并且表明稳定性分布中的间隙仍然存在，但  $P(\Delta)$  会在间隙左边界处连续趋于零 [88, 89]。

## 6.6 习题




图 6.9: 带随机着色的 200 维空间中 250 个随机点，在两个不同二维平面上的投影。

6.1 图 6.9 的生成方式如下：在维数  $N = 200$  的空间中生成  $p = 250$  个随机点，每个点的各个坐标彼此独立地从均值为零、方差为一的 Gaussian 随机数中抽取。同时，这些点也以相等概率彼此独立地被染成黑色和白色。图的左部显示这些点在随机选择的二维平面上的投影；右部显示同一组点，但现在是从一个适当选择的方向观察。用这种方式能得到的黑点与白点之间的最大可能距离是多少？还能否找到一个投影，使所有点都位于某个经过原点的超平面上方？是否对所有  $N$  和  $p$  都存在这样的方向？

6.2 证明 Cover 关于二分法数目的结果 (6.18) 允许如下对偶表述：一般位置中的  $p$  个超平面把  $N$  维空间分成  $C(p, N)$  个区域。

6.3 证明图 6.5 中的所有曲线都交于点  $(2, 0.5)$ 。

6.4 考虑热力学极限  $N \rightarrow \infty$  且  $p = \alpha N$  时, 二分法数目 (6.18) 的结果。用 Stirling 公式近似二项式, 并把求和变换成积分, 证明通过鞍点论证有

$$\frac{1}{N} \ln C(p, N) \begin{cases} = \alpha \ln 2, & \alpha \leq 2, \\ \leq \alpha \ln \alpha - (\alpha - 1) \ln(\alpha - 1), & \alpha > 2, \end{cases} \quad (6.44)$$

从而说明当  $\alpha < 2$  时, 几乎所有二分法都是线性可分的; 而当  $\alpha > 2$  时, 只有指数小的一部分二分法是线性可分的。

6.5 感知机的阈值  $\theta$  可以解释为耦合向量  $\mathbf{J}$  的一个额外分量, 它连接到所有输入向量的常数分量  $S_0 = 1$ 。利用这种解释, 证明  $N$  维空间中处于一般位置的  $p$  个点, 若允许由不一定经过原点的超平面分开, 则可分着色数由  $C(p, N + 1)$  给出。给出一个  $p = 4$ 、 $N = 2$  时不是线性可分的显式例子。

6.6 考虑带符号约束耦合的球形感知机存储问题。在这种情况下, 学习过程只能改变突触强度, 而不能改变它们的符号。这个约束可通过引入  $N$  个数  $\epsilon_i = \pm 1$ , 并要求所有  $i$  都满足  $\epsilon_i J_i \geq 0$  来方便地表述。利用第 6.2 节的 Gardner 方法证明, 在这种情况下, 不依赖于  $\epsilon_i$  的具体实现, 都有  $\alpha_c = 1$ 。(提示: 当用于吸引子神经网络时, 这个结果意味着, 例如只由兴奋性突触构成的网络也可能存储并取回信息。它还与神经生理学发现有关, 即从同一神经元发出的突触往往具有相同符号, 称为 Dale 规则。更多细节见 [90, 91]。)

6.7 用 Cover 方法重新导出上一题的结果 [92]。同时证明, 如果只预先指定比例为  $s$  的突触符号, 则存储容量结果为  $\alpha_c = 2 - s$  [93]。

6.8 确定具有对称耦合  $J_{ij} = J_{ji}$  的吸引子神经网络的临界存储容量。(提示: 这是一道难题, 据我们所知尚未解决。如果你找到了答案, 请别忘了通知我们!)

6.9 把 (6.13) 和 (6.15) 的结果推广到有偏输入和有偏输出, 即推广到如下形式的分布:

$$P_{\xi}(\xi) = \prod_i \left[ \frac{1 + m_{\text{in}}}{2} \delta(\xi_i - 1) + \frac{1 - m_{\text{in}}}{2} \delta(\xi_i + 1) \right],$$

$$P_{\sigma}(\sigma) = \frac{1 + m_{\text{out}}}{2} \delta(\sigma - 1) + \frac{1 - m_{\text{out}}}{2} \delta(\sigma + 1),$$

并考虑一个具有 (1.1) 中阈值  $\theta$  的感知机。

6.10 证明第 6.1 节所描述的球形感知机存储问题中, Gardner 计算给出的复本对称鞍点在  $\kappa < 0$  时变得不稳定。

6.11 证明对 Ising 感知机存储问题, 如果使用退火计算  $\ln \langle \Omega \rangle$  而不是  $\langle \ln \Omega \rangle$ , 则在  $\kappa = 0$  时得到  $\alpha_c = 1$ 。证明这是真实  $\alpha_c$  的严格上界。

6.12 用零熵判据证明, 耦合  $J_i = 0, 1$  的感知机在  $\kappa = 0$  时的存储容量为  $\alpha_c = 0.59$  [94]。

6.13 考虑一个具有固定耦合  $J_i$  的感知机, 其中  $J_i$  独立随机生成, 并研究通过稀释学习的存储问题。这意味着学习过程中唯一允许的修改, 是移除比例为  $1 - c$  的耦合。

(a) 证明  $\alpha_c(c = 0) = \alpha_c(c = 1) = 0$ 。

(b) 引入稀释参数  $c_i = 0, 1$ , 证明淬火熵

$$s(c) = \lim_{N \rightarrow \infty} \frac{1}{N} \left\langle \left\langle \ln \sum_{\{c_i\}} \prod_{\mu} \theta \left( \frac{\sigma^{\mu}}{\sqrt{N}} \sum_i c_i J_i \xi_i^{\mu} - \kappa \right) \delta \left( \sum_i c_i, cN \right) \right\rangle \right\rangle \quad (6.45)$$

中, Kronecker 符号  $\delta(m, n)$  定义于 (A1.13); 在复本对称性下有

$$s(c) = \text{extr}_{\hat{k}, \hat{q}, \hat{Q}, Q} \left\{ \frac{c\hat{k}}{2} + \frac{q\hat{q}}{2} - \frac{Q\hat{Q}}{2} + \alpha \int Dt \ln H \left( \frac{\kappa + \sqrt{q}t}{\sqrt{Q-q}} \right) + \left\langle \int Dz \ln \left[ 1 + \exp \left( \sqrt{\hat{q}} |\mathbf{J}|z + (\hat{Q} - \hat{q}) \frac{\mathbf{J}^2}{2} - \frac{\hat{k}}{2} \right) \right] \right\rangle_J \right\},$$

其中剩下的平均是对耦合分量  $J_i$  的分布取的, 并且引入了序参量

$$q = \frac{1}{N} \sum_i J_i^2 c_i^a c_i^b, \quad Q = \frac{1}{N} \sum_i J_i^2 c_i^a. \quad (6.46)$$

(c) 对只允许  $J_i = \pm 1$  的分布  $P(\mathbf{J})$ , 通过把问题映射到上一题, 证明对所有  $c$  都有  $\alpha_c(c) \leq 0.59$ 。

关于这一学习情景可能具有的神经生理学意义及相关参考文献, 详细分析见 [95]。

6.14 通过计算球形感知机存储问题中  $\alpha > \alpha_c(\kappa)$  时误分类输入的最小比例, 验证 (6.40)。

6.15 利用第 6.4 节的技术, 证明对于最小化势函数  $V(\Delta)$  的学习规则, 稳定性分布为

$$P(\Delta) = \int Dt \delta(\Delta - \Delta_0(x, t)), \quad (6.47)$$

其中  $\Delta_0(x, t)$  是  $V(\Delta) + (\Delta - t)^2/2x$  的最小点。

6.16 把上一结果推广到监督学习, 证明对于学习误差

$$E = \sum_{\mu} V(\Delta^{\mu})$$

的零温学习, 稳定性分布  $P(\Delta)$  为

$$P(\Delta) = \int Dt \delta(\Delta - \Delta_0(t, x)) 2H \left( -\frac{Rt}{\sqrt{1-R^2}} \right), \quad (6.48)$$

其中  $\Delta_0(t, x)$  仍是  $V(\Delta) + (\Delta - t)^2/2x$  的最小点,  $R$  表示教师-学生重叠。特别地, 请导出 Hebb 学习的结果, 并验证训练误差由

$$\epsilon_t = \int_{-\infty}^0 d\Delta P(\Delta)$$

给出。

# 第七章 不连续学习

到目前为止，我们考虑的学习情景中，泛化表现都体现为一种逐渐改进的过程：泛化误差  $\epsilon$  从最初纯猜测的取值  $\epsilon = 0.5$  连续下降到渐近极限  $\epsilon = 0$ 。本章研究的系统表现出相当不同的行为：学习过程中泛化能力会发生突然变化。这种新特征的原因在于，被学习过程调节的参数中存在离散自由度。我们将看到，不连续学习是这种离散性带来的一个相当微妙的后果，而统计力学方法很适合刻画这种情形。特别是，泛化过程中出现的突变可以描述为统计物理中深入研究过的一阶相变。

## 7.1 光滑网络

迄今讨论的学习情景，在统计力学框架中可描述为能量项与熵项之间平衡的连续移动。在完美学习情形中，能量刻画学生向量停留在版本空间中有多困难，见 (2.13)。对于独立样例，它自然由训练集上的求和给出，并且在大  $\alpha$  下按  $e \sim \alpha\epsilon$  缩放，因为泛化误差  $\epsilon$  给出了新样例出现时发生错误从而产生额外代价的概率。另一方面，熵定义为可用相空间体积  $\Omega$  的对数，用来度量实现相同训练误差的不同耦合的多样性。如果系统的耦合  $\mathbf{J}$  是连续的，那么  $\Omega$  是一个  $N$  维体积，其线性尺度为  $\epsilon$ ，因为泛化误差给出教师与学生之间的测地距离。因此有  $\Omega \sim \epsilon^N$ ，每个耦合的熵相应地按  $s \sim \ln \epsilon$  缩放。

能量与熵之间的平衡，在数学上由能量项和熵项之和对  $\epsilon$  的极值条件来描述。对于小  $\alpha$ ，具有较大先验测度的耦合主导版本空间，熵项起决定作用。随着  $\alpha$  增大，这种平衡越来越向能量项移动；在大  $\alpha$  下，多数耦合已被从版本空间中排除，只剩下那些  $e$  较小的耦合。利用上面讨论的能量与熵的渐近形式，通过最小化二者之和可得

$$0 \sim \frac{\partial}{\partial \epsilon} (\ln \epsilon - \alpha \epsilon) = \frac{1}{\epsilon} - \alpha, \quad (7.1)$$

从而得到泛化误差  $\epsilon$  在大训练集大小  $\alpha$  下无处不在的  $1/\alpha$  衰减。不同学习规则只会为这一渐近规律给出不同前因子。对于更一般的学习规则，包括允许学生具有非零训练误差的情形，也可通过引入温度和相应自由能的极值条件得到类似结果，见第 4.3 节。

事实上，从 (7.1) 可以预期，对于所有满足

$$\lim_{\epsilon \rightarrow \epsilon_{\min}} \frac{\partial s}{\partial \epsilon} = \infty \quad (7.2)$$

的学习情景，当训练集大小  $\alpha$  发散时，泛化误差都会平滑收敛到其最小值。

在可微激活函数  $g(x)$  的情形中，这些说法可以稍微定量化，参见习题 3.7。此时训练误差和泛化误差都是耦合向量的可微函数，它们的渐近行为可由围绕最小值的 Taylor 展开推断 [21, 12]。

然而，如果所考察网络的耦合空间不是连续的，小泛化误差下熵的行为就可能大不相同。一个简单例子由 Ising 感知机提供，其耦合分量  $J_i$  被限制为  $\pm 1$ 。第 6.3 节已经研究过它的存储性质。简单组合论论证表明，实现与教师 Ising 感知机  $\mathbf{T}$  的给定重叠  $R$  的耦合  $\mathbf{J}$  的熵为，见习题 7.2，

$$s(R) = -\frac{1+R}{2} \ln \frac{1+R}{2} - \frac{1-R}{2} \ln \frac{1-R}{2}, \quad (7.3)$$



利用  $\epsilon = \arccos R/\pi$ ，这给出

$$s(\epsilon) \sim -\frac{\pi^2}{2} \epsilon^2 \ln \epsilon \quad (7.4)$$

当  $\epsilon \rightarrow 0$ 。现在最小化能量与熵之和，在渐近上得到

$$0 \sim -\pi^2 \epsilon \ln \epsilon - \alpha, \quad (7.5)$$

这与 (7.1) 形成对比。对大  $\alpha$ ，这个方程没有解，表明  $f$  的最小值不在允许的  $\epsilon$  区间内部，而是在边界上。在这种情况下，不能预期泛化误差会随训练集大小增加而连续下降。

具有连续自由度与离散自由度的系统，其熵行为之所以不同，原因在于后一种情形中实际状态的熵永远不能为负。对离散相空间的系统而言，“体积”  $\Omega$  是一个自然数，它计数实现给定宏观状态的不同微观方式。因此，至少在可实现情形中， $\Omega$  的最小值等于 1，相应的熵为 0。

## 7.2 Ising 感知机

由上一节的考虑可以预期，对于具有离散耦合的网络，学习过程的渐近性质会被改变。一个很好的例子是由另一个 Ising 感知机提供分类的 Ising 感知机学习问题；下面我们较详细地分析这个例子。

淬火熵的统计力学计算仍然是附录 B 中一般方法的一个变体。事实上，能量部分  $G_E(q^{ab}, R^a)$  完全不敏感于耦合  $\mathbf{J}$  的性质，因此仍由 (A2.19) 给出。对熵部分，从 (A2.18) 出发，把积分换成求和并省去球形约束，可得

$$G_S(\hat{q}^{ab}, \hat{R}^a) = \ln \sum_{\{J^a = \pm 1\}} \exp \left( -i \sum_{a < b} \hat{q}^{ab} J^a J^b - i \sum_a \hat{R}^a J^a \right), \quad (7.6)$$

当  $R = 0$  时它如应有地与 (6.21) 一致。假定复本对称性，并预期鞍点取虚值，我们使用  $-i\hat{q}^{ab} = \hat{q}$  和  $-i\hat{R}^a = \hat{R}$ 。经过与 (6.24) 所用类似的变形后，得到

$$G_S(\hat{q}, \hat{R}) = -n \frac{\hat{q}}{2} + n \int Dz \ln 2 \cosh(\sqrt{\hat{q}} z + \hat{R}) + O(n^2), \quad (7.7)$$

从而给出淬火熵的如下结果：

$$s = \text{extr}_{q, \hat{q}, R, \hat{R}} \left[ \frac{\hat{q}}{2} (q - 1) - \hat{R} R + \int Dz \ln 2 \cosh(\sqrt{\hat{q}} z + \hat{R}) + 2\alpha \int Dt H \left( -\frac{Rt}{\sqrt{q - R^2}} \right) \ln H \left( -\sqrt{\frac{q}{1 - q}} t \right) \right]. \quad (7.8)$$

为了确定序参量随训练集大小  $\alpha$  的依赖关系，必须求出  $s$  对这些参数的极值。注意，与球形感知机不同，共轭序参量不能被解析消去。不过，由于教师-学生对称性，对应于 (7.8) 的鞍点方程仍可化简，给出解  $q = R$  和  $\hat{q} = \hat{R}$ 。变换积分变量后，余下方程具有形式

$$R = \int Dz \tanh(\sqrt{\hat{R}} z + \hat{R}) \quad (7.9)$$

以及

$$\hat{R} \sqrt{1 - R} = \frac{\alpha}{\pi} \int Dt \frac{\exp(-Rt^2/2)}{H(\sqrt{R}t)}. \quad (7.10)$$




图 7.1: Ising 学生感知机学习由 Ising 教师给出的分类时, 泛化误差 (粗线) 和淬火熵 (细线) 作为训练集大小  $\alpha$  的函数。虚线部分对应不稳定解。插图显示淬火熵作为教师-学生重叠  $R$  的函数, 分别对应  $\alpha = 1.2$ 、 $\alpha_d = 1.245$  和  $\alpha = 1.3$  (从上到下)。

为了求出 (7.8) 中的极值, 需要数值求解这些方程, 并把相应淬火熵结果与边界  $R = 0$  和  $R = 1$  处的取值比较。这一过程的结果见图 7.1。

可以清楚看到, (7.9)、(7.10) 的解确实并不总给出熵的最大值。只有当  $\alpha < \alpha_d \simeq 1.245$  时才是如此; 对更大的  $\alpha$ , 边界值  $s(R = 1) = 0$  给出  $s$  的最大值。在插图所示的熵随  $R$  的曲线中, 可以清楚看到使  $s$  最大的  $R$  发生不连续跳变。因此, 在有限  $\alpha_d \simeq 1.245$  处, 系统发生到完美泛化状态的不连续转变, 该状态由  $R = 1$ 、 $\epsilon = 0$  表征; 在该问题的统计力学分析中, 这表现为一阶相变。于是, 如果一个很大的 Ising 感知机对  $1.245N$  个随机输入给出与相同结构的教师感知机相同的分类, 那么它将以概率 1 对所有  $2^N$  个可能输入都给出相同分类。

上述表达式依赖复本对称假定, 而从第 6.3 节讨论的 Ising 感知机存储问题经验来看, 我们可能预期复本对称性会被破缺。事实上, 图 7.1 中虚线所示结果局域稳定, 但相对于复本对称破缺是全局不稳定的, 这可由一步 RSB 解推出。与 (6.30) 一样, 向 RSB 状态的转变由复本对称熵消失来标志, 而这个零熵判据是一个有用工具, 可以在不进行更复杂 RSB 计算的情况下确定向完美学习的不连续转变点。还要注意, 在泛化问题中, 零熵判据具有非常直观的含义。由于  $s(R = 1) = 0$ , 完美泛化在实现泛化很差相的耦合向量变得指数稀少的点开始出现。由于这也恰好是 RSB 发生的点, 不连续转变把我们从 RSB 的深渊带到  $R = 1$  的安全区域, 整个泛化过程因而可在复本对称框架内分析。

一般而言, 只要至少某些可调参数具有离散性质, 上述类型的不连续学习通常都会出现。例子包括具有有限突触深度的系统 [96] 和稀释参数 [97]。另一个有趣情形是多层网络, 其中二值内部表示充当离散自由度, 并可能导致泛化行为中出现一串一级转变, 见第 12 章。下一节我们讨论反楔形感知机, 在这个意义上它可作为多层网络的玩具模型。

最后强调，这些不连续转变完全不是离散相空间的平凡后果。当然，两个 Ising 向量  $\mathbf{J}$  和  $\mathbf{T}$  之间重叠的最小可能非零取值为  $R_{\min} = 1 - 2/N$ ，但当  $N \rightarrow \infty$  时有  $R_{\min} \rightarrow 0$ 。在 Ising 情景中发生不连续转变处的教师-学生重叠  $R \simeq 0.695$ ，有完全不同的解释。关键在于，重叠  $R$  接近 1 的耦合向量极少，实际上少到它们会在学习过程早期就被消除。因此，一个负熵带很快在  $R = 1$  附近形成，参见习题 7.2 和图 7.1 的插图；最终转变发生在这一负熵带与围绕  $R = 0$  形成的负熵带合并之时。

### 7.3 反楔形感知机

反楔形感知机像通常的感知机一样，按照输入  $\xi^\mu$  在耦合向量  $\mathbf{J}$  上的投影  $\lambda$  来分类；但局域场与输出之间的简单符号函数被替换为

$$\sigma = \text{sgn}[(\lambda - \gamma)\lambda(\lambda + \gamma)]. \quad (7.11)$$

这个激活函数最显著的特征是非单调性，见图 7.2。因此，被分类为  $\sigma = +1$  的输入，既可能具有大于  $\gamma$  的稳定性，也可能落在区间  $(-\gamma, 0)$  中；当然，对分类为  $-1$  的输入也存在类似歧义。因此，反楔形感知机的状态由额外的离散自由度刻画，可称为每个输入的内部表示，用以指定该分类的内部实现。结果是，同类的两个反楔形感知机，也就是具有同一参数  $\gamma$  的两个感知机，可能对某个样例集中的所有样例给出相同输出，但分类的内部组织仍然不同。<sup>1</sup>




图 7.2: 反楔形感知机的非单调激活函数。实现正输出的输入有两类：局域场大于  $\gamma$  的输入（内部表示为“+”），以及局域场位于  $-\gamma$  和 0 之间的输入（内部表示为“-”）。

反楔形感知机看起来相当人为，事实上似乎也没有生物学迹象表明存在具有非单调激活函数的神经元。不过，内部表示的出现正是多层网络的标志，见第 12 和 13 章；它带来一些新的、有趣

<sup>1</sup>把 (7.11) 改写为  $\sigma = \text{sgn}(\lambda - \gamma) \text{sgn}(\lambda) \text{sgn}(\lambda + \gamma)$ ，即可把反楔形感知机映射到一个 parity machine，其输出是三个具有平行超平面的感知机输出之积。内部表示于是由各组成感知机的分类指定。

的存储和泛化性质，值得较详细地研究。另一方面，由于反楔形感知机分析起来并不比简单感知机困难太多，它可作为更复杂多层网络的漂亮玩具模型。

与多层网络的相似性，在研究反楔形感知机的存储问题时已经显现出来。存储容量的复本对称结果相当大，参见习题 7.6。然而，复本对称性会破缺，一步复本对称破缺中的  $\alpha_c$  结果显著减小。事实上，不难说服自己，样例存在不同内部表示意味着 Gardner 体积不再必然连通。如前所述，这可能导致复本对称性失效。

关于泛化能力，我们首先考虑简单可实现情形：一个具有连续耦合向量  $\mathbf{J}$  的反楔形感知机，试图从带标号样例中推断另一个具有相同楔形参数  $\gamma$  的反楔形感知机的连续耦合向量  $\mathbf{T}$ 。为了使用依赖于典型教师-学生重叠  $R$  计算的统计力学方法，我们首先要意识到， $\epsilon$  与  $R$  之间的简单关系 (2.3) 不再成立。事实上，利用教师和学生局域场的统计性质 (2.19)，可得

$$\epsilon = 2 \left( \int_{-\gamma}^0 Du + \int_{\gamma}^{\infty} Du \right) \left[ H \left( \frac{Ru + \gamma}{\sqrt{1-R^2}} \right) - H \left( \frac{Ru}{\sqrt{1-R^2}} \right) + H \left( \frac{Ru - \gamma}{\sqrt{1-R^2}} \right) \right], \quad (7.12)$$

当  $\gamma = 0$  和  $\gamma \rightarrow \infty$  时，它当然都化为 (2.3)。

按照附录 B 的细节进行统计力学分析，假定复本对称性；对于泛化问题，这一假定可证明是可靠的。再利用教师-学生对称性导致的  $R = q$ ，最终得到淬火熵表达式

$$s = \max_R \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} + 2\alpha \int Dt H_{\gamma}(t) \ln H_{\gamma}(t) \right], \quad (7.13)$$

其中

$$H_{\gamma}(t) = H \left( \frac{\sqrt{R}t + \gamma}{\sqrt{1-R}} \right) - H \left( \frac{\sqrt{R}t}{\sqrt{1-R}} \right) + H \left( \frac{\sqrt{R}t - \gamma}{\sqrt{1-R}} \right). \quad (7.14)$$

数值求解对应于 (7.13) 的自治方程可发现，对所有  $\gamma < \gamma_c \simeq 1.6$ ，都存在一段  $\alpha$  取值区间，使熵有两个局域最大值。这产生了图 7.3 所示的典型泛化行为。小  $\alpha$  时，系统起始于泛化能力较差的相，泛化误差只缓慢下降。尽管教师和学生输入最终分类一致，这个相的特征是二者内部表示存在很大失配。随着  $\alpha$  增加，这一相的熵比泛化良好相的熵下降得更快；于是，在某个  $\alpha_d$  处，系统不连续转变到泛化良好相，该相由教师和学生内部表示之间的高度相似性表征。随后泛化误差的最终下降遵循通常的  $1/\alpha$  行为。因此，离散自由度的存在，在这里即内部表示的存在，再次导致学习过程中的不连续转变。与前面讨论的 Ising 感知机不同，这里也存在连续变量，因此在不连续跳变之前和之后都发生光滑学习。还要注意，在这种更一般的情形中，零熵判据不能用来定位转变。

一个有趣的特殊情形出现在  $\gamma = \gamma_c = \sqrt{2 \ln 2}$ 。对于这个参数值，由 (7.11) 给出的反楔形分类  $\sigma$ ，对  $N$  维球面上随机选择的样例  $\xi$  意味着如下对称性质：

$$\left\langle \left\langle \frac{\mathbf{J}\xi}{\sqrt{N}} \sigma \right\rangle \right\rangle = 0. \quad (7.15)$$

正如我们将在第 8 章看到的，这个性质会导致非常特殊的行为，包括延迟学习；这里我们看到它的第一个例子。事实上，在这一情形中，对所有  $\alpha$ ， $R = 0$  都是对应于 (7.13) 的鞍点方程的一个解。因此，泛化较差相的特征是泛化误差保持常数  $\epsilon = 0.5$ 。另一方面，由 (7.13) 可知，这个相由  $s = -\alpha \ln 2$  刻画。因此，在学习初期，版本空间被每个新样例二等分，这对应于其体积的最优缩减；然而，由于内部表示严重失配，学生完全没有获得关于教师的信息！直到后来，才出现一次突然的“顿悟”式转变，把学生带到正确轨道上，并启动最后一段连续学习。




图 7.3: 一个反楔形感知机从另一个具有相同参数  $\gamma$  的反楔形感知机标号的样例中学习时, 泛化误差作为  $\alpha$  的函数。曲线对应  $\gamma = 1.5$ 、 $\gamma = \gamma_c = \sqrt{2 \ln 2} \simeq 1.177$  以及  $\gamma = 0.4$  (从左到右)。

当反楔形感知机具有 Ising 耦合, 即  $T_i = \pm 1$  且  $J_i = \pm 1$  时, 这种不连续转变更加戏剧性。此时可发现, 当  $\gamma = \gamma_c$  时, 泛化误差对所有  $\alpha < 1$  都保持其初始值  $\epsilon = 0.5$ , 随后在  $\alpha_d = 1$  处不连续跳到  $\epsilon = 0$ 。因此, 系统从完全没有学习转变到完美泛化。

这种显著行为已经可以从退火近似中预见。图 7.4 显示这一情形中退火熵作为  $\epsilon$  的函数, 亦可与球形感知机的图 2.2 比较。位于  $\epsilon = 0.5$  的尖点源自  $\partial \epsilon / \partial R(R=0, \gamma = \gamma_c) = 0$ , 这可由 (7.12) 直接验证。它保证了对所有  $\alpha, s$  都在  $\epsilon = 0.5$  处具有一个局域最大值, 其值为  $s(R=0) = (1-\alpha) \ln 2$ 。因此, 具有  $R=0$  的学生向量主导该相, 直到  $\alpha_d = 1$ , 此时  $s(R=0)$  变为负值, 并发生到完美泛化 ( $\epsilon = 0$ ) 的转变。注意, 这里的  $\alpha_d = 1$  应与 Ising 感知机的  $\alpha_d = 1.245$  比较。事实上, 它是可能发生完美泛化转变的最小阈值: 教师具有  $N$  个未知二值耦合, 因此至少需要  $N$  bit 才能固定它们。反楔形 Ising 感知机能够饱和这个信息论界, 是相当令人惊讶的。这个特殊结构的存储性质也具有类似最优性, 见习题 7.8。

## 7.4 不连续学习的动力学

从前几节的结果来看, 不连续学习似乎对应用极具吸引力。确实, 一旦越过临界训练集大小  $\alpha_d$ , 泛化能力就会显著改善, 有时甚至达到完美泛化状态。

遗憾的是, 事实表明, 学习过程本身, 也就是根据样例确定适当耦合向量  $\mathbf{J}$ , 通常是一个极其困难的问题。处理这一问题主要有两类方法。或者直接在离散耦合空间中学习, 并使用第 4.4 节研究的、最小化给定代价函数的学习规则的离散对应物。或者先用相同样例训练一个连续网络, 再试图找到到离散耦合向量的合适映射。对于 Ising 感知机, 这两种方法都已得到相当详细的研究。




图 7.4: Ising 反楔形感知机的退火熵作为泛化误差  $\epsilon$  的函数, 训练集大小为  $\alpha = 0, 0.25, 0.5, 0.75, 1$  (从上到下)。 $\epsilon = 0.5$  处的尖点是临界楔形参数  $\gamma_c = \sqrt{2 \ln 2}$  所特有的。

使用第一种方法时的一般经验是, 最小化过程会陷入亚稳态; 这些态虽然是代价函数的局域极小值, 却远离所需解。使用更精细的算法逃离这类亚稳态, 例如模拟退火 [98], 也不会带来显著改进。这与系统已经在  $T > 0$  下冻结到无序玻璃态有关, 见习题 7.4; 该状态具有非遍历行为和动力学临界慢化 [99]。结果是, 最小化过程通常无法找到适当耦合向量。注意, 系统的动力学冻结发生在复本对称相中, 因此早在不连续转变之前, 学习在实践中就已经变得不可能。

对于小系统大小  $N$ , 可以使用精确枚举方法, 并辅以分枝定界技术, 精确求解最小化问题 [78, 100]。从这一侧面接近问题, 人们同样会意识到 Ising 感知机中的学习是一个困难的组合问题。事实上, 已经证明它是算法复杂性意义下的 NP-complete 问题 [101]; 粗略地说, 这意味着目前没有已知数值过程能够在只按其规模  $N$  的某个幂增长的时间内求解它。<sup>1</sup> 因此, 这种方法局限于非常小的系统大小, 约  $N \lesssim 35$ 。

在离散耦合空间中学习的第二种方法, 建立在我们对连续耦合的经验之上; 对于连续耦合, 有若干学习规则工作得相当好, 见第三章。由连续向量得到 Ising 向量的一个显然方法, 是只保留其分量符号; 这称为截断。通过对第 6.4 节引入的相空间方法作一个有趣修改, 可以计算不同连续耦合学习规则结果经截断后, 正确预测 Ising 耦合的比例 [102]。例如, 对存储问题, 截断 adatron 规则得到的最大稳定网络, 在  $\alpha = 0.1$  时给出 90% 正确的 Ising 耦合, 在  $\alpha = \alpha_c$  时仍有 80%。另一方面, 对泛化问题不难证明, 参见习题 7.10, 只有当  $R > 0.77$  时截断才可能改进教师-学生重叠; 这大致已经对应于超过 88% 的耦合被正确预测。

作为第二种策略的简单例子, 我们考虑学习 Ising 教师  $\mathbf{T}$  时, 截断 Hebb 规则的表现。不失一

<sup>1</sup>严格地说, 这只刻画最坏情形; 典型学习问题完全可能容易得多。不过, 迄今数值经验似乎表明, 即使典型情形也是困难的。另见第 14.2 节。



般性，可假定  $T_i = +1$ 。根据 (3.1)，截断 Hebb 规则的耦合向量为

$$J_i = \text{sgn} \left( \frac{1}{\sqrt{N}} \sum_{\mu} \xi_i^{\mu} \sigma_T^{\mu} \right) = \text{sgn} \left[ \frac{1}{\sqrt{N}} \sum_{\mu} \xi_i^{\mu} \text{sgn} \left( \frac{1}{\sqrt{N}} \sum_j \xi_j^{\mu} \right) \right]. \quad (7.16)$$

我们引入辅助变量

$$y_i^{\mu} = \xi_i^{\mu} \text{sgn} \left( \frac{1}{\sqrt{N}} \sum_j \xi_j^{\mu} \right), \quad Y_i = \frac{1}{\sqrt{N}} \sum_{\mu} y_i^{\mu},$$

并首先确定  $y_i^{\mu}$  等于 +1 的概率：

$$\begin{aligned} \text{Prob}(y_i^{\mu} = 1) &= \text{Prob} \left( \xi_i^{\mu} = 1 \quad \text{且} \quad \frac{1}{\sqrt{N}} \sum_j \xi_j^{\mu} > 0 \right) \\ &\quad + \text{Prob} \left( \xi_i^{\mu} = -1 \quad \text{且} \quad \frac{1}{\sqrt{N}} \sum_j \xi_j^{\mu} < 0 \right) \\ &= \frac{1}{2} \text{Prob} \left( \frac{1}{\sqrt{N}} \sum_{j \neq i} \xi_j^{\mu} > -\frac{1}{\sqrt{N}} \right) \\ &\quad + \frac{1}{2} \text{Prob} \left( \frac{1}{\sqrt{N}} \sum_{j \neq i} \xi_j^{\mu} < \frac{1}{\sqrt{N}} \right) \\ &= \text{Prob} \left( \frac{1}{\sqrt{N}} \sum_{j \neq i} \xi_j^{\mu} > -\frac{1}{\sqrt{N}} \right). \end{aligned} \quad (7.17)$$

现在  $\sum_{j \neq i} \xi_j^{\mu} / \sqrt{N}$  是均值为零、方差为一的 Gaussian 变量，因此

$$\text{Prob} \left( \frac{1}{\sqrt{N}} \sum_{j \neq i} \xi_j^{\mu} > -\frac{1}{\sqrt{N}} \right) = \int_{-1/\sqrt{N}}^{\infty} Dz \simeq \frac{1}{2} + \frac{1}{\sqrt{2\pi N}}. \quad (7.18)$$

对大  $N$ ，这意味着  $\langle y_i^{\mu} \rangle = 2/\sqrt{2\pi N}$ ，并且  $\langle (y_i^{\mu})^2 \rangle = 1$ 。因此， $Y_i$  也是一个 Gaussian 变量，其平均值为  $2\alpha/\sqrt{2\pi}$ ，方差为  $\alpha$ 。这最终给出教师-学生重叠

$$\begin{aligned} R &= \frac{1}{N} \sum_i J_i = \langle J_i \rangle = \text{Prob}(Y_i > 0) - \text{Prob}(Y_i < 0) \\ &= 1 - 2H \left( \sqrt{\frac{2\alpha}{\pi}} \right). \end{aligned} \quad (7.19)$$

因此，对大  $\alpha$  有

$$1 - R \sim \frac{1}{\sqrt{\alpha}} \exp \left( -\frac{\alpha}{\pi} \right), \quad (7.20)$$

表明大  $\alpha$  下泛化误差指数衰减。这种指数衰减可解释为：截断 Hebb 向量用一个连续过程近似了最优耦合向量的不连续转变。它无法实现到完美泛化的不连续下降，只能以非常快的渐近衰减来模仿它。

在离散耦合空间中学习通常是一个非常困难的问题。上面讨论的两种方法各有优缺点。迄今最好的结果来自把二者结合起来。一方面，可通过固定那些被某个截断过程正确预测的耦合，减少必须枚举的耦合数目 [103]；另一方面，由截断连续耦合向量得到的近似结果，可以为分枝定界算法提供有用界限。



## 7.5 小结

本章研究了表现出“顿悟”式不连续转变的学习情景，其特征是在训练集大小  $\alpha$  的某些特定取值处，泛化误差  $\epsilon$  突然下降。这类转变的基本前提，是学习过程中需要调节的离散自由度的存在。当所有自由度都是离散的，不连续跳变通常会直接抵达由  $R = 1$ 、 $\epsilon = 0$  表征的完美泛化状态。此时学生几乎是教师的完美复制，二者最多只在非广延比例的耦合上不同。如果某些可调参数是离散的而另一些是连续的，则泛化过程会表现为逐步改进阶段被不连续跳变打断。在这两种情况下，不连续转变的原因都在于具有离散自由度的系统中熵的特殊性。

从统计力学角度看，不连续学习是相当自然的现象，因为它对应于一阶相变。这样的不连续转变用机器学习的方法更难分析，并且长期以来也是心理学中争论的对象，见例如 [104]。从实际角度看，不连续学习的吸引力会被在离散耦合空间中执行学习过程的复杂性所削弱。

最后再次给出简短文献导引。关于 Ising 感知机场景中出现不连续学习的最早提示，来自 [27] 报告的数值研究。随后不久，[105] 给出了这一问题的完整统计力学分析。反楔形感知机的存储性质在 [106] 中分析，其泛化行为在 [107] 中研究。具有 Ising 耦合的反楔形感知机的特殊性质最早由 [108] 研究。离散耦合空间中学习动力学的复杂性则在 [99] 中阐明。

## 7.6 习题

7.1 利用 (2.3) 和 (2.41) 验证：对于第二章讨论的基本学习情景，大  $\alpha$  下熵的渐近行为确实由  $s \sim \ln \epsilon$  给出。

7.2 考虑教师和学生都是 Ising 感知机的情形，即  $J_i = \pm 1$  且  $T_i = \pm 1$ 。

(a) 证明学习之前，具有泛化误差  $\epsilon$  的学生数目按如下方式缩放：

$$\Omega_0(\epsilon) \sim \exp N \left[ -\frac{1 - \cos \pi \epsilon}{2} \ln \frac{1 - \cos \pi \epsilon}{2} - \frac{1 + \cos \pi \epsilon}{2} \ln \frac{1 + \cos \pi \epsilon}{2} \right]. \quad (7.21)$$

提示：显式计数实现与给定 Ising 向量  $\mathbf{T}$  具有某个重叠  $R$  的方式。

(b) 用这个表达式替换 (2.5)，在退火近似中计算泛化误差，并证明它预言在  $\alpha \simeq 1.45$  处发生到完美泛化的不连续转变。

7.3 从一开始就利用教师-学生对称性，并像第 2.3 节那样使用  $n \rightarrow 1$  复本技巧，重新导出鞍点方程 (7.9)、(7.10) 以及相应的淬火熵表达式。

7.4 考虑第 7.2 节讨论的 Ising 情景中  $T > 0$  的 Gibbs 学习，证明到完美泛化的不连续转变仍然发生。事实上，它甚至在高温学习极限中仍然存在！注意，从统计力学角度看，一个系统已经在非零温度下“冻结”到零熵状态，是相当值得注意的。

7.5 考虑一个不可实现问题，其中 Ising 学生试图从连续教师学习，即  $J_i = \pm 1$ ，而  $\mathbf{T}$  是满足球形约束  $\mathbf{T}^2 = N$  的实向量。

(a) 证明泛化误差有下界，即残余误差

$$\epsilon_r = \frac{1}{\pi} \arccos \left( \sqrt{\frac{2}{\pi}} \right) \simeq 0.206.$$

通过定位最接近  $\mathbf{T}$  的 Ising 向量来解释这一结果。

(b) 使用高温学习或退火近似，计算大  $\alpha$  下泛化误差的渐近行为，并验证它们给出  $\epsilon - \epsilon_r \sim \alpha^{-2}$ 。完整的统计力学解见 [21]，其中包括复本对称破缺，并表明  $\epsilon$  向  $\epsilon_r$  的渐近接近比 (b) 中预言的更慢。

7.6 在复本对称 ansatz 内计算反楔形感知机的存储容量。证明最大值在  $\gamma \simeq 1.224$  处取得，并且  $\alpha_c^{\text{RS}} \simeq 10.5$  [106]。

7.7 考虑两个具有相同楔形参数  $\gamma$  的反楔形感知机。考虑概率  $P$ ：对同一个新随机样例，二者给出相同分类，但内部表示仍然不同。证明它由

$$P = 8 \int_{\gamma}^{\infty} Du \left[ H \left( \frac{Ru}{\sqrt{1-R^2}} \right) - H \left( \frac{\gamma + Ru}{\sqrt{1-R^2}} \right) \right] \quad (7.22)$$

给出。 $R=0$  时  $P$  的最大值是多少？最大值是否出现在  $\gamma = \gamma_c = \sqrt{2 \ln 2}$ ？

7.8 证明具有最优楔形参数  $\gamma = \sqrt{2 \ln 2}$  的反楔形 Ising 感知机，在存储容量上饱和和信息论界  $\alpha_c = 1$ 。（提示：尝试使用退火计算，以使代数尽可能简单。）

7.9 考虑一个 Ising 教师向量  $\mathbf{T}$ ，以及一个实值学生向量  $\mathbf{J}$ ，其中  $\mathbf{J}^2 = N$  且  $\mathbf{J}\mathbf{T}/N = R$ 。证明在假定  $\mathbf{J}$  围绕  $\mathbf{T}$  的分布具有柱对称性时，由分量  $\tilde{J}_i = \text{sgn } J_i$  给出的截断学生向量  $\tilde{\mathbf{J}}$ ，其与教师的重叠  $\tilde{R}$  平均而言只有在  $R > R_c \simeq 0.77$  时才大于  $R$ 。（提示：注意由于  $T_i = \pm 1$ ，有  $T_i \text{sgn } J_i = \text{sgn}(T_i J_i)$ ，并利用  $R$  的自平均性质。）

7.10 推广上一题，考虑一个变换向量  $\tilde{\mathbf{J}}$ ，其分量为  $\tilde{J}_i = f(J_i)$ 。假定具有连续分量的学生向量  $\mathbf{J}$  与 Ising 教师向量  $\mathbf{T}$  具有自平均重叠  $R$ ，证明  $\tilde{\mathbf{J}}$  与  $\mathbf{T}$  的重叠  $\tilde{R}$  为 [109]

$$\tilde{R} = \frac{\langle f(x) \rangle}{\sqrt{\langle f^2(x) \rangle}}, \quad (7.23)$$

其中

$$\langle g(x) \rangle = \int_{-\infty}^{+\infty} P(x) g(x) dx,$$

而  $P(x)$  是  $x = J_j T_j$  的概率密度。利用  $\mathbf{J}$  围绕教师向量  $\mathbf{T}$  的分布的柱对称性，证明  $P(x)$  为

$$P(x) = \frac{1}{\sqrt{2\pi(1-R^2)}} \exp \left[ -\frac{1}{2} \frac{(x-R)^2}{1-R^2} \right]. \quad (7.24)$$

验证当  $f(x) = \text{sgn}(x)$  时，可恢复截断结果 (7.19)。证明使重叠增加最大的变换函数为  $f = f^{\text{opt}}$ ，其中

$$f^{\text{opt}}(x) = \tanh \left( \frac{R}{1-R^2} x \right). \quad (7.25)$$

# 第八章 无监督学习

在前面几章中，我们详细研究了学生感知机从教师感知机学习的情景。这是通常所谓有监督学习的一个典型例子。不过，我们都很愿意承认，从样例中学习并不总是需要教师在场。

然而，除了教师给出的某种特定样例分类之外，还能学到什么呢？关键观察是：如果未分类样例的分布具有某种内在结构，那么从这些样例中学习就是可能的。因此，无监督学习的主要问题，是仅仅根据一组样例抽取这些内在特征。这个问题是许多模式识别和数据压缩任务的核心，并具有多种重要应用 [110]。

我们并不打算综述已有的众多无监督学习方法；本章将说明前面引入的统计力学方法如何应用于若干特殊的无监督学习情景，而这些情景又与教师-学生感知机问题密切相关。一方面，这将展示统计力学如何用于分析无监督情形；另一方面，通过把有监督问题改写为无监督问题的特例，我们也会获得对有监督问题的新理解。

## 8.1 有监督学习与无监督学习

考虑从某个概率分布  $P$  随机抽取的一组  $p$  个样例。无监督学习的目标，是根据这些样例抽取关于  $P$  的信息。为简单起见，并且为了保持与迄今讨论的有监督问题的连续性，我们假定样例可由  $N$  维向量  $\xi = \{\xi_i, i = 1, \dots, N\}$  表示，且位于  $N$  维球面上，即  $\xi^2 = N$ 。

我们只研究结构非常弱的数据点分布。更准确地说，输入分布被假定为只有一个破缺对称性的方向，而在与该方向正交的高维子空间中均匀分布。记这个特殊的对称性破缺方向为向量  $\mathbf{B}$ ，且  $\mathbf{B}^2 = N$ 。概率分布相对于该方向的非均匀性，将体现在样例沿  $\mathbf{B}$  的对齐场

$$h = \frac{\mathbf{B}\xi}{\sqrt{N}} \quad (8.1)$$

的分布  $P^*(h)$  中。回忆一下，对于任一垂直于  $\mathbf{B}$  的方向，对齐场都会是均值为零、方差为一的 Gaussian 变量。因此，方便的做法是用  $P^*(h)$  偏离 Gaussian 分布的程度来刻画样例分布的非均匀性；为此引入势  $V^*$ ，定义为

$$P^*(h) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{h^2}{2} - V^*(h)\right). \quad (8.2)$$

这里归一化常数已吸收到  $V^*$  的定义中。由 (8.2) 很容易得到：在给定对称性破缺方向  $\mathbf{B}$  的一个实现时，样例的分布  $P(\xi|\mathbf{B})$  为

$$P(\xi|\mathbf{B}) = \frac{1}{(2\pi)^{N/2}} \exp(-\xi^2/2) \exp[-V^*(h)]. \quad (8.3)$$

为了揭示这一概率分布的结构，我们引入向量  $\mathbf{J}$ 。它在某一学习规则的帮助下仅由样例决定，并作为未知方向  $\mathbf{B}$  的估计。因此，我们关心的是使重叠  $R = \mathbf{J}\mathbf{B}/N$  最大化。基于有监督情形中的经验，该问题在统计力学语境下的表述现在很直接。我们仍像第 4.3 节那样用一个能量函数刻画学习规则，其一般形式为

$$E(\mathbf{J}) = \sum_{\mu=1}^p V(\lambda^\mu), \quad (8.4)$$

其中学生对齐场为

$$\lambda^\mu = \frac{\mathbf{J}\xi^\mu}{\sqrt{N}}, \quad (8.5)$$

学习过程等价于寻找  $E(\mathbf{J})$  的最小值。假定由自由能

$$F(\beta) = -\frac{1}{\beta} \langle \ln Z \rangle \quad (8.6)$$

在热力学极限中自平均，其中  $Z$  是配分函数

$$Z = \int d\mu(\mathbf{J}) e^{-\beta E(\mathbf{J})}. \quad (8.7)$$

则可用附录 B 的技术完成对输入的平均。使代价  $E(\mathbf{J})$  最小的  $\mathbf{J}$  向量性质，照常由零温极限

$$e_0(\alpha) = \lim_{\beta \rightarrow \infty} f(\alpha, \beta) \quad (8.8)$$

推断。

第 4.4 节中讨论的许多有监督学习规则都有无监督对应物；只需把稳定性  $\Delta = \mathbf{J}\xi_{\sigma_T}/\sqrt{N}$  替换为对齐场  $\lambda$  即可得到。一个简单例子是由势

$$V(\lambda) = -\lambda \quad (8.9)$$

定义的无监督 Hebb 规则。它作为对称性破缺方向  $\mathbf{B}$  的估计，显然生成一个沿样例质心方向的向量  $\mathbf{J}^H \sim \sum_\mu \xi^\mu$ 。

另一个常用选择为

$$V(\lambda) = -\lambda^2, \quad (8.10)$$

对应 Oja 规则 [111, 112]。显然，这里的目标是使对齐场的二阶矩最大化。当样例的一阶矩等于零时，这一点尤其有意义：二阶矩此时等于方差，因此，使能量函数最小的  $\mathbf{J}$  向量给出了数据散布最大的方向。事实上，最大方差方向也称为分布的第一主成分。主成分分析是数据分析中最基本、最常用的算法之一 [110]。此外，如果对齐场分布是 Gaussian 的，那么最大方差等同于最大信息。换言之，具有最大方差的方向，也是包含关于样例的最多信息的方向。Linsker 引入的信息最大化原则 [113] 断言，如果希望以最小损失压缩信息，那么这些方向就是最佳选择。

在转向无监督学习的详细分析之前，令人满意的是可以看到，前面讨论过的教师-学生感知机场景的若干变体都能转换成无监督问题。为说明这一点，我们回到学生感知机从教师感知机学习的基本有监督情景。关键观察是，此时学习规则和代价函数是根据对齐后的样例  $\text{sgn}(\mathbf{T}\xi^\mu)\xi^\mu$  构造的。由于原始样例  $\xi^\mu$  是随机选择的，对齐后的样例均匀分布在上半球面上，其中  $\mathbf{T}$  扮演“北极”的角色，见图 8.1a。因此，我们可以把这一问题看作无监督学习问题的一个特例：从  $N$  维球面的半球均匀分布中独立抽取  $p$  个样例，任务是近似北极方向，而它是该分布唯一的对称性破缺方向。在这种情况下，对齐分布  $P^*(h)$  为

$$P^*(h) = \frac{2}{\sqrt{2\pi}} \exp(-h^2/2) \theta(h). \quad (8.11)$$

还有一些情形，其“无监督”版本便于同前面的结果比较。带输出噪声的感知机教师，见 (5.4) 和图 8.1b，对应于

$$P^*(h) = \frac{1}{\sqrt{2\pi}} \exp(-h^2/2) [(1+a)\theta(h) + (1-a)\theta(-h)], \quad (8.12)$$




图 8.1: 对应于有监督问题的若干非均匀分布示例: (a) 教师-学生感知机; (b) 同一情形但教师带输出噪声; (c) 反楔形感知机; (d) Gaussian 情景。为了得到正确的直观图像, 应把阴影想象为位于高维  $N$  维球面表面上的样例密度。投影到页面二维平面上的样例密度是由  $\exp[-V^*(h)]$  调制的双 Gaussian; 情形 (a) 的这种表示见图 2.1。

带权重噪声的教师感知机, 比较 (5.2), 对应于

$$P^*(h) = \frac{2}{\sqrt{2\pi}} \exp(-h^2/2) \left[ \left(1 - H\left(\frac{h}{\sigma_w}\right)\right) \theta(h) + H\left(\frac{h}{\sigma_w}\right) \theta(-h) \right], \quad (8.13)$$

而反楔形感知机, 比较 (7.11) 和图 8.1c, 则对应于

$$P^*(h) = \frac{2}{\sqrt{2\pi}} \exp(-h^2/2) [\theta(h - \gamma) + \theta(h + \gamma)\theta(-h)]. \quad (8.14)$$

我们还提到所谓 Gaussian 情景, 见图 8.1d,

$$P^*(h) = \sqrt{\frac{2(1+a)}{\pi}} \exp\left[-\frac{(1+a)h^2}{2}\right], \quad (8.15)$$

对此可以得到完整的解析结果 [114]。

注意, 虽然对一般无监督问题自然会假定  $P^*(h)$  是光滑分布, 但与有监督问题等价的无监督情景通常由非光滑分布刻画, 参见 (8.11)、(8.12) 和 (8.14) 中 Heaviside 函数  $\theta$  的出现。此外, 某些分布具有特殊对称性, 例如一阶矩消失  $\langle h \rangle = 0$ , 如 (8.14) 在  $\gamma = \sqrt{2 \ln 2}$  时以及 (8.15)。如下所见, 这些不同特征会导致观察到的学习行为出现定性差异。

## 8.2 随机性的欺骗

也许令人惊讶的是，我们将从没有任何结构的样例开始研究无监督学习，也就是说，从完全均匀分布中选取的样例开始。之所以这样做，是因为它揭示了无监督学习的一个严重陷阱：它可能发现那些仅仅由随机实现偶然产生的结构。事实上，正如马上会看到的，这种偶然有序在与真正的非随机结构竞争时，会导致延迟学习现象。

于是，考虑一组在  $N$  维球面上均匀分布的  $p$  个样例  $\xi$ 。我们想研究这组样例是否沿某个优选方向成簇。这个方向的一个合理猜测是指向质心的方向

$$\mathbf{J}^H = C \sum_{\mu=1}^p \xi^\mu, \quad (8.16)$$

其中常数  $C$  被选为使  $|\mathbf{J}^H|^2 = N$ 。这一选择对应于无监督 Hebb 学习 (8.9)。为说明这种构造如何产生误导，我们确定  $\mathbf{J}^H$  与数据集中任一向量  $\xi^\nu$  的对齐场。

在  $N \rightarrow \infty$ 、 $p \rightarrow \infty$  且  $\alpha = p/N$  固定的极限中，这很容易做到，只需把  $\xi^\nu$  对  $\mathbf{J}^H$  的贡献分离出来。可以发现，所得对齐场  $\lambda$  是一个 Gaussian 随机变量，其弥散度和不相关向量  $\mathbf{J}$  的情形相同，见图 8.2a；但现在均值不为零，而等于  $1/\sqrt{\alpha}$ ，见图 8.2b。这个结果会造成一种错误印象：数据点似乎来自一个沿质心方向具有优选取向的非均匀概率分布。然而，观察到的结构只是偶然性的产物，尽管在上述极限中，它会以概率 1 出现，并且完全可重现。<sup>1</sup>




图 8.2: 随机且独立样例的对齐场分布，其中  $\mathbf{J}$  向量最小化  $E(\mathbf{J})$ ，见 (8.4)，且  $\alpha = 1$ ：(a)  $V = 0$ ，(b)  $V = -\lambda$ ，(c)  $V = -\lambda^2$ ，(d)  $V = -|\lambda|$ ；虚线对应一步 RSB 结果。

这种无法认识到结构缺失的失败并不限于 Hebb 规则。事实上，对于本节考虑的完全随机样例情形，沿着 (8.6)–(8.8) 的路线研究一般代价函数  $E(\mathbf{J})$ ，只是附录 B 中标准步骤的一个小修改。由

<sup>1</sup>更准确地说，对于另一组  $p$  个随机且独立的样例，会得到指向另一个方向的  $\mathbf{J}^H$  向量，但沿该方向的对齐场分布仍由同一个平移 Gaussian 给出。



于没有教师，也就没有序参量  $R$ ，它甚至比以前更简单，并且与某个代价函数的容量计算相同；其中第 6 章讨论的标准情形对应于  $V(\lambda) = \theta(-\lambda)$ 。略去细节，复本对称计算给出的自由能密度为

$$f(\alpha, \beta) = -\text{extr}_q \left\{ \frac{q}{2\beta(1-q)} + \frac{1}{2\beta} \ln(1-q) + \frac{\alpha}{\beta} \int Dt \ln \int \frac{d\lambda}{\sqrt{2\pi(1-q)}} \exp \left[ -\beta V(\lambda) - \frac{(\lambda - \sqrt{q}t)^2}{2(1-q)} \right] \right\}. \quad (8.17)$$

如果在 (4.31) 中令  $R = 0$ ，这一结果就与之相同。这并不令人惊讶，因为对于一个被迫位于  $\mathbf{J}$  正交子空间中的教师而言，当样例随机选取时，额外因子  $\sigma_T$  不会影响样例的统计性质。

按照 (8.8) 取零温极限  $\beta \rightarrow \infty$ ，由 (8.17) 得到

$$e_0(\alpha) = -\text{extr}_x \left\{ \frac{1}{2x} - \alpha \int Dt \min_{\lambda} \left[ V(\lambda) + \frac{(\lambda - t)^2}{2x} \right] \right\}. \quad (8.18)$$

对于  $V(\lambda) = \theta(-\lambda)$ ，这正如应有的那样等价于 (6.40)。

此外，使  $E$  最小的向量  $J^*$  与参与构造  $E$  的数据点  $\xi^\mu$  之间的对齐场分布  $P(\lambda)$ ，也再次与第 6.4 节中容量问题的表达式非常相似，见习题 8.1：

$$P(\lambda) = \int Dt \delta(\lambda - \lambda_0(t, x)), \quad (8.19)$$

其中  $\lambda_0(t, x)$  是使 (8.17) 中  $\lambda$  积分指数里的表达式最小的  $t$  与  $x$  的函数，而  $x$  是使基态能量 (8.18) 取极值的  $\alpha$  的函数。通过直接计算，或通过应用 cavity 论证，可以验证  $\lambda_0(t, x)$  有如下简单含义，比较习题 8.1。令  $t$  为一个新的随机样例与向量  $\mathbf{J}$  的正态分布对齐场。将这一新样例也纳入代价函数  $E(\mathbf{J})$  后，使代价函数最小的向量记为  $\mathbf{J}'$ ，则  $\lambda_0(t, x)$  是这个样例与  $\mathbf{J}'$  的对齐场。换言之， $\lambda_0(t, x) - t$  是学习该新样例后对齐场的调整量。它依赖于初始对齐场  $t$ ，也通过  $x$  对  $\alpha$  产生依赖。

对于无监督 Hebb 规则  $V(\lambda) = -\lambda$ ，可以得到  $\lambda_0(t, x) = t + x$  和  $x = 1/\sqrt{\alpha}$ ，从而恢复前面引用的结果。这个特定  $V$  反映了寻找一个方向、使重叠  $\lambda$  尽可能大的意图。另一方面，由势 (8.10) 刻画的最大方差学习给出的  $P(\lambda)$  确实是一个均值为零、弥散度为  $\langle \lambda^2 \rangle = (1 + \sqrt{\alpha})^2/\alpha$  的展宽 Gaussian，见图 8.2c；因此，人们再次找到了自己正在寻找的东西。作为另一种变体，我们考虑一个惩罚对齐场绝对值的势：它并不对应于某个具体算法，但在后面的讨论中会很重要：

$$V(\lambda) = -|\lambda|. \quad (8.20)$$

相应的重叠分布为，见图 8.2d，

$$P(\lambda) = \begin{cases} \frac{1}{\sqrt{2\pi}} \exp \left[ -\frac{1}{2}(\lambda + x)^2 \right], & \lambda \leq -x, \\ 0, & -x < \lambda < x, \\ \frac{1}{\sqrt{2\pi}} \exp \left[ -\frac{1}{2}(\lambda - x)^2 \right], & \lambda \geq x, \end{cases} \quad (8.21)$$

其中  $x = 1/\sqrt{\alpha}$ 。

这一结果包含两个小小的意外。首先，重叠分布具有宽度为  $2/\sqrt{\alpha}$  的真正空隙。在球面表面的一个有限比例区域  $-x < \lambda < x$  内，完全没有数据点。因此可以得出结论：尽管数据点是从球面均匀分布中采样的，但从特殊方向  $J^*$  看去，它们高度结构化。当然，这与存储问题非常相似，参见第 6 章，特别是习题 6.1；在那里我们成功地把随机选择的  $N$  维球面点限制到半球面内，直



到容量极限  $\alpha = 2$ 。事实上，在  $\alpha = 2$  时，带状区域  $-x < \lambda < x$  对应于球面总表面积的比例  $1 - 2H(1/\sqrt{2}) \simeq 0.52$ ，与容量问题中的因子  $1/2$  非常接近。

其次，de Almeida–Thouless (AT) 复本对称稳定性条件被破坏了。这个条件具有如下形式，见习题 4.13 和附录 F：

$$\alpha \int Dt \left[ \frac{\partial \lambda_0(t, x)}{\partial t} - 1 \right]^2 < 1, \quad (8.22)$$

其中  $x$  仍取 (8.18) 的极值处。一步复本对称破缺计算的结果，见图 8.2d，比较附录 E。可以看到，空隙宽度略有减小。复本对称破缺的发生表明，与 (8.20) 对应的能量函数具有大量极小值，揭示了在有限  $\alpha$  下均匀分布实现中出现的内在玻璃态结构。

至此，我们结束对无结构分布的无监督学习讨论。随机性的实现通常比相应分布本身更少对称，这当然是众所周知的。一个有充分记录的例子是随机行走者的轨迹 [115]。然而，我们这里的观点是：当使用专门搜索某类结构的算法时，应该能够识别并隔离那些偶然出现的贡献。

### 8.3 学习对称性破缺方向

现在考虑一个真正的无监督学习问题，即探测样例分布的对称性破缺方向。为此，我们回到由 (8.6) 定义的自由能计算，但现在要对样例作平均；这些样例沿单一对称性破缺方向  $\mathbf{B}$  具有非均匀分布 (8.3)，而在正交子空间中均匀。对样例分布的平均仍可通过附录 B 的标准计算作小修改后完成。假定复本对称，得到自由能密度

$$f(\alpha, \beta) = -\text{extr}_{q, R} \left\{ \frac{q - R^2}{2\beta(1 - q)} + \frac{1}{2\beta} \ln(1 - q) + \frac{\alpha}{\beta} \int Dt_1 \int D^* t_2 \ln \int \frac{d\lambda}{\sqrt{2\pi(1 - q)}} \right. \\ \left. \times \exp \left[ -\beta V(\lambda) - \frac{(\lambda - Rt_2 - \sqrt{q - R^2} t_1)^2}{2(1 - q)} \right] \right\}, \quad (8.23)$$

其中  $D^* t := dt P^*(t)$ 。这里  $R$  是典型向量  $\mathbf{J}$  与对称性破缺方向  $\mathbf{B}$  的重叠，而  $q$  表示两个不同向量  $\mathbf{J}$  之间的典型重叠。当  $P^*$  取 (8.11) 所给形式时，上述结果化为 (4.31)，这与上一节的讨论一致。还要注意，当  $V^* = 0$  时，即对应于没有优选方向的纯随机样例时，会恢复 (8.17)。

零温极限  $\beta \rightarrow \infty$  特别重要。如果代价函数具有唯一最小值，则  $q$  趋于 1，同时  $x = \beta(1 - q)$  有限。于是由 (8.8) 得到

$$e_0(\alpha) = -\text{extr}_{x, R} \left\{ \frac{1 - R^2}{2x} - \alpha \int Dt_1 \int D^* t_2 \min_{\lambda} \left[ V(\lambda) + \frac{(\lambda - t)^2}{2x} \right] \right\}, \quad (8.24) \\ t = Rt_2 + \sqrt{1 - R^2} t_1.$$

上述结果使我们能够详细研究各种算法如何探测和识别沿方向  $\mathbf{B}$  存在的非随机结构；这些算法对应于  $V$  的不同选择，而非随机结构由  $V^*$  刻画。除了对齐分布  $P(\lambda)$ ，现在感兴趣的量是重叠  $R = \mathbf{J}\mathbf{B}/N$ 。完整的详细研究只能在某些特殊情形中完成，例如 Gaussian 情景 [114]。注意，在后者情形中，分布完全对称，因此鞍点方程的解会退化，包含  $R$  和  $-R$  两个值。此时还会出现另一个问题：在热力学极限中，样例的质心严格等于零。为避免这些复杂性，下面我们将隐含地假定，完全对称分布是带有微小偏置的分布的极限，而该偏置在所有计算完成之后再取零。

下面我们将重点讨论 Gibbs 学习算法及其与使重叠  $R$  最大化的最优算法之间的关系。先定义无监督问题中的 Gibbs 学习含义。由于这里没有相容学生与不相容学生之间的尖锐区分，我们必

须转而讨论：给定向量  $\mathbf{J}$  成为对称性破缺取向的可能性有多大。给定一组样例  $\xi^\mu$ ，相应分布是所谓后验概率密度，记为  $P(\mathbf{J}|\xi^\mu)$ 。在有监督问题中，这个后验概率具有相当简单的形式：它在版本空间之外为零，在版本空间内部均匀。因此，从版本空间中随机选择一个教师的 Gibbs 算法，就对应于从这个后验分布采样。

无监督问题的后验分布可以由 Bayes 定理得到 [116]。为简单起见，我们仍假定  $\mathbf{J}$  的先验概率  $P_0$  在  $N$  维球面上均匀。利用样例的独立性以及生成样例的密度的具体形式，比较 (8.3)，可得

$$\begin{aligned} P(\mathbf{J}|\xi^\mu) &= \mathcal{N} \prod_{\mu=1}^p P(\xi^\mu|\mathbf{J}) P_0(\mathbf{J}) \\ &= \mathcal{N}' \delta(\mathbf{J}^2 - N) \exp \left[ - \sum_{\mu=1}^p V^*(\lambda^\mu) \right], \end{aligned} \quad (8.25)$$

其中  $\mathcal{N}$  与  $\mathcal{N}'$  是归一化常数。Gibbs 学习对应于从这个分布采样。与 (8.4) 和 (8.7) 比较可知，它可以通过选择势  $V = V^*$ 、并令“温度”等于 1 即  $\beta = 1$  来实现。由于  $\mathbf{B}$  与 Gibbs 学生  $\mathbf{J}$  之间完全对称，可以预期  $R = q$ ，从而自由能可进一步简化。使用变量的正交变换

$$\begin{aligned} t &= \sqrt{R} t_2 + \sqrt{1-R} t_1, & t_1 &= \sqrt{1-R} t - \sqrt{R} t', \\ t' &= \sqrt{1-R} t_2 - \sqrt{R} t_1, & t_2 &= \sqrt{R} t + \sqrt{1-R} t', \end{aligned} \quad (8.26)$$

它蕴含  $Dt Dt' = Dt_1 Dt_2$ ，并令

$$\lambda = \sqrt{R} t + \sqrt{1-R} t'', \quad (8.27)$$

自由能 (8.23) 取得形式

$$f(\alpha, \beta = 1) = -\text{extr}_R \left[ \frac{R}{2} + \frac{1}{2} \ln(1-R) + \alpha \int Dt X(\sqrt{R}, t) \ln X(\sqrt{R}, t) \right], \quad (8.28)$$

其中

$$X(R, t) = \int Dt' \exp \left[ -V^* \left( Rt + \sqrt{1-R^2} t' \right) \right], \quad (8.29)$$

满足归一化条件

$$\int Dt X(R, t) = 1. \quad (8.30)$$

$$(8.31)$$

定义

$$\begin{aligned} Y(R, t) &= \int Dt' t' \exp \left[ -V^* \left( Rt + \sqrt{1-R^2} t' \right) \right] \\ &= \frac{\sqrt{1-R^2}}{R} \frac{\partial X(R, t)}{\partial t}, \end{aligned} \quad (8.32)$$

则由 (8.28) 得到的  $R$  的鞍点方程，经分部积分后可写成

$$R = \alpha \int Dt \frac{Y^2(\sqrt{R}, t)}{X(\sqrt{R}, t)}. \quad (8.33)$$

这就完成了对 Gibbs 规则的分析。对于  $V^*$  由 (8.11) 给出的有监督情形，(8.33) 化为 (2.42)；也可见 (4.56)，注意后一个方程给出 Bayes 重叠  $R_B = \sqrt{R}$ 。

在这里要注意，若要应用 Gibbs 算法，需要预先知道势  $V^*$ 。在有监督情形 (8.11) 中， $V^*$  在版本空间之外为无穷大、在内部为常数；这项知识同样被使用，只是由于从版本空间采样看起来相

当自然而被掩盖了。习题 8.6 揭示了一个令人惊讶的事实：至少在热力学极限中，关于  $V^*$  的知识实际上可以在  $\alpha$  上没有额外代价地获得。

下面讨论最优学习，即实现最大重叠的规则。可以重复第 3.6 节的一般论证，得出结论：最大平均重叠  $R$  由后验概率的质心实现。事实上，一个根据给定训练样例集构造出的向量  $\mathbf{J}$ ，与对称性破缺方向  $\mathbf{B}$  的平均重叠为

$$\left\langle \frac{\mathbf{J}\mathbf{B}}{N} \right\rangle = \int d\mathbf{B} P(\mathbf{B}|\xi^\mu) \frac{\mathbf{J}\mathbf{B}}{N}. \quad (8.34)$$

由于  $\mathbf{J}$  与积分变量无关，它可以移到积分号之外；最大值由后验分布的质心达到：

$$\mathbf{J}^B \sim \int d\mathbf{B} P(\mathbf{B}|\xi^\mu) \mathbf{B}, \quad (8.35)$$

其中归一化常数选为使  $(\mathbf{J}^B)^2 = N$ 。还可重复第 3.6 节中把所得重叠  $R_B$  与 Gibbs 重叠  $R$  联系起来的论证，得到  $R_B = \sqrt{R}$ 。因此，结合 (8.33) 便可得到最优规则的重叠。

对于 (8.33) 中的  $R$ ，因而也对  $R_B$ ，一般不存在显式通解；但可以导出小  $\alpha$  和大  $\alpha$  下的解析结果。这里我们只引用最优重叠  $R_B$  的结果。首先考察小  $\alpha$  行为。不难看出，在  $R \rightarrow 0$  的极限中，(8.33) 右边的积分收敛到  $\alpha \langle h \rangle^2$ ，其中

$$\langle h \rangle = \int dh P^*(h)h.$$

当  $\langle h \rangle \neq 0$  时，可得  $R_B(\alpha) = \sqrt{\alpha \langle h \rangle^2}$ ，这是渐近小  $\alpha$  的结果。顺便一提，这与无监督 Hebb 规则得到的小  $\alpha$  结果一致，比较习题 8.9。另一方面，如果  $\langle h \rangle = 0$ ，则很容易验证  $R = 0$  始终是 (8.33) 的一个解。为了研究非零解通过二阶相变出现，可以验证 (8.33) 右边展开的首项为  $\alpha(1 - \langle h^2 \rangle)^2 R$ 。当  $R$  的系数越过 1 时，非零  $R$  解出现。因此， $R_B(\alpha) = 0$  会在一个有限区间  $[0, \alpha_r]$  内成立，其中  $\alpha_r = (1 - \langle h^2 \rangle)^{-2}$ 。这一现象被称为延迟学习 [117, 118, 108]。在有监督问题中，这个初始阶段相当引人注目，因为已学习样例可以被完美记忆，即训练误差为零，而底层规则完全没有被发现，即泛化误差等于 1/2；例如第 7.3 节中讨论的反楔形感知机在  $\gamma = \gamma_c = \sqrt{2 \ln 2}$  时就是如此。学习在阈值  $\alpha_r$  以上开始。作为真正无监督问题中延迟学习的例子，我们给出 Gaussian 情景 (8.15) 下重叠的显式结果：

$$R_B(\alpha) = \begin{cases} 0, & \alpha < \alpha_r, \\ \sqrt{\frac{\alpha - \alpha_r}{\alpha - \sqrt{\alpha_r}}}, & \alpha > \alpha_r, \end{cases} \quad (8.36)$$

其中  $\alpha_r = (1 + 1/a)^2$ 。

上面的微扰分析既不能预言也不能排除一阶相变的出现。需要更细致的分析。结果表明，一阶转变相当常见。它们可以出现在二阶相变阈值之前，也可以出现在其之后；例子见 [119]。

现在转向大  $\alpha$  行为。对于光滑样例分布，可以得到

$$1 - R_B(\alpha) \sim \left( 2\alpha \int dh \left[ \frac{dV^*(h)}{dh} \right]^2 P^*(h) \right)^{-1}, \quad (8.37)$$

也就是说，只要积分收敛， $R$  就按  $1/\alpha$  衰减。正如预期，样例分布中的结构越显著，即  $dV^*(h)/dh$  越大，最优学习就越容易。

当分布具有不连续性，即存在奇异导数  $dV^*(h)/dh$  时，上述积分发散标志着渐近规律发生变化。为简单起见，我们限制在一个特别有趣的特例：假定当  $h < h_1$  时  $P^*(h) = 0$ ，当  $h > h_1$  时

$P^*(h)$  光滑, 并且  $\lim_{h \rightarrow +h_1} P^*(h) = \Delta P^* > 0$ 。这种情形通常出现在有监督问题中, 比较 (8.11)。更仔细地看, 在  $R \rightarrow 1$  时对 (8.33) 中积分有显著贡献的  $t$  与  $t'$  区域内, 可将  $\exp[-V^*(\tau)]$ , 其中  $\tau = Rt + \sqrt{1-R^2}t'$ , 替换为  $\exp[-V^*(h_1)]\theta(\tau - h_1)$ 。这给出主阶渐近式

$$1 - R_B(\alpha) = \pi \left( \alpha \Delta P^* \int Dt \frac{e^{-t^2/2}}{H(t)} \right)^{-2}. \quad (8.38)$$

对于同类的其他不连续性, 也会发现具有相似系数的  $\alpha^{-2}$  衰减。

因此, 光滑分布的渐近行为与非光滑分布显著不同。事实上, 在讨论带噪声教师时我们已经遇到过这一特征: 权重噪声等价于具有光滑分布的无监督问题, 而输出噪声对应于非光滑情形; 见 (8.12)、(8.13) 以及习题 8.3 和 8.5。其解释相当清楚: 样例分布中存在尖锐边界, 使得重建垂直于该边界的对称性破缺方向更容易。因此, 向解的渐近接近会更快。

## 8.4 通过竞争学习聚类

顾名思义, 聚类就是把数据点分成不同集合。这个任务往往是无监督的, 也就是说, 没有外部指导告诉我们如何把样例分离成不同簇。事实上, 这种分离会根据具体问题服务于不同目的。例如, 它可用于压缩数据: 落在给定簇中的所有样例都用单个点表示。在另一些情形中, 人们希望不同簇能够识别系统的不同状态。这里, 聚类对应于真正的学习过程, 因为它从样例中抽取关于系统状态的信息。在这两类情形中, 我们都预期簇的数目远小于数据点数。

我们先考虑最简单的情形, 即把样例聚成两个不同集合, 每个集合由一个簇轴  $\mathbf{J}_m$  表征,  $m = 1, 2$ 。问题现在是寻找这两个方向, 使数据点以某种最优方式被分成两类。由于可以预期随机性的欺骗也会影响这类算法, 本节首先集中于随机选取样例的情形。为保持与前面讨论的连续性, 我们考虑方向性聚类, 也就是把样例放在  $N$  维球面上, 并研究它们的方向性聚类性质。

由于方向性聚类只关心角度, 重要的量是样例与簇轴  $\mathbf{J}_m$  的对齐场  $\lambda$ 。基于单个  $\mathbf{J}$  情形中的经验, 自然可把最优方向定义为能量函数  $E(\mathbf{J}_1, \mathbf{J}_2)$  的最小值:

$$E(\mathbf{J}_1, \mathbf{J}_2) = \sum_{\mu=1}^p V(\lambda_1^\mu, \lambda_2^\mu), \quad (8.39)$$

其中

$$\lambda_1^\mu = \frac{\mathbf{J}_1 \boldsymbol{\xi}^\mu}{\sqrt{N}}, \quad \lambda_2^\mu = \frac{\mathbf{J}_2 \boldsymbol{\xi}^\mu}{\sqrt{N}}. \quad (8.40)$$

注意, 簇的编号可以互换, 因此我们假定势反映这一对称性, 即  $V(\lambda_1, \lambda_2) = V(\lambda_2, \lambda_1)$ 。此外, 在下面处理的应用中, 势具有特定形式  $V(\lambda_1, \lambda_2) = V_+(\lambda_+) + V_-(\lambda_-)$ , 其中  $\lambda_+ = (\lambda_1 + \lambda_2)/\sqrt{2}$ ,  $\lambda_- = (\lambda_1 - \lambda_2)/\sqrt{2}$ 。这种形式会简化讨论, 并使其可与前几节得到的结果比较。引入配分函数

$$Z = \int d\mu(\mathbf{J}_1) \int d\mu(\mathbf{J}_2) e^{-\beta E(\mathbf{J}_1, \mathbf{J}_2)} \quad (8.41)$$

并计算相应自由能  $F$ 。在  $N \rightarrow \infty$ 、 $p \rightarrow \infty$  且  $\alpha = p/N$  有限的极限中, 预期  $F$  自平均。采用 RS ansatz, 并为简单起见只给出零温结果 [120], 对于均匀样例分布可得

$$e_0(\alpha) = - \text{extr}_{Q, x_+, x_-} \left[ \frac{1}{2x_+} - \alpha \int Dt_+ \min_{\lambda_+} \left( V_+(\lambda_+) + \frac{(\lambda_+/\sqrt{1+Q} - t_+)^2}{2x_+} \right) \right. \\ \left. + \frac{1}{2x_-} - \alpha \int Dt_- \min_{\lambda_-} \left( V_-(\lambda_-) + \frac{(\lambda_-/\sqrt{1-Q} - t_-)^2}{2x_-} \right) \right], \quad (8.42)$$

其中  $Q = (J_1 J_2)/N$ ，表示簇轴之间的重叠。

把  $e_0$  的极值分两步求出是方便的。首先固定  $Q$  的值，并对  $x_+$  与  $x_-$  求极值。与 (8.18) 比较，这对应于寻找向量

$$\mathbf{J}_+ = \frac{\mathbf{J}_1 + \mathbf{J}_2}{\sqrt{2(1+Q)}}, \quad \mathbf{J}_- = \frac{\mathbf{J}_1 - \mathbf{J}_2}{\sqrt{2(1-Q)}},$$

它们分别使  $V_+(\lambda_+ \sqrt{1+Q})$  与  $V_-(\lambda_- \sqrt{1-Q})$  最小。这两个最小化过程与单一对称性破缺取向问题中遇到的过程完全相同。第二步再对  $Q$  最小化所得总代价，从而确定  $\mathbf{J}_1$  与  $\mathbf{J}_2$  之间的最优角度。




图 8.3: 通过竞争学习聚类的简单例子。由六个叉号表示的一组点聚成两个子集，每个子集含三个叉号。这个结构可以在没有教师的情况下被探测出来。考虑两个感知机，由其耦合向量  $\mathbf{J}_1$  与  $\mathbf{J}_2$  表示。当呈现一个样例  $\xi$  时，与该样例重叠较大的感知机，即“胜者”的突触向量，在应用 Hebb 规则后会更接近  $\xi$ 。迭代这一算法后，两个突触向量有望收敛到大致位于两个簇中心的位置。

对齐场分布  $P(\lambda_1, \lambda_2)$  为

$$P(\lambda_1, \lambda_2) = \int Dt_+ \int Dt_- \delta(\lambda_1 - \lambda_1^0) \delta(\lambda_2 - \lambda_2^0), \quad (8.43)$$

其中  $\lambda_+^0 = (\lambda_1^0 + \lambda_2^0)/\sqrt{2}$  和  $\lambda_-^0 = (\lambda_1^0 - \lambda_2^0)/\sqrt{2}$  是  $Q, x_+, x_-, t_+, t_-$  的函数，并使 (8.42) 中大括号内的表达式最小。

现在把这个结果应用于竞争学习 [3]。竞争学习是标准聚类算法之一，也称为 K-means 算法 [121]。在实际应用中，该算法如下运行，亦见图 8.3。考虑一个随机选取的样例  $\xi$ 。识别最近的簇中心，例如  $\mathbf{J}_1$ 。在方向性聚类中，它就是与  $\xi$  夹角最小的方向  $\mathbf{J}_1$ ，称为胜者。然后通过把胜者向当前样例移动来更新它。这是用熟悉的 Hebb 规则完成的。如果只更新胜者，就称为“胜者全取”。<sup>1</sup>注意，竞争学习可以很自然地在由线性感知机构成的神经网络中实现，其中输出通过抑制性连接相互联系。输出最大的感知机获胜，抑制其他感知机，并按 Hebb 规则调节权重。对我们而言，重要观察是：该算法等价于最小化具有如下势的能量函数：

$$V(\lambda_1, \lambda_2) = -\lambda_1 \theta(\lambda_1 - \lambda_2) - \lambda_2 \theta(\lambda_2 - \lambda_1) \quad (8.44)$$

<sup>1</sup>在更复杂的方案中，例如 Kohonen 算法，也会更新与胜者相关的其他向量，例如通过其空间位置相关，见 [38]。

$$= -\frac{\lambda_1 + \lambda_2}{2} - \frac{|\lambda_1 - \lambda_2|}{2}. \quad (8.45)$$

事实上, (8.44) 中的 Heaviside 函数保证了特定  $\mathbf{J}$  向量的表现, 只由那些与它夹角最小的样例的对齐场决定。此外, 这些样例在决定特定  $\mathbf{J}$  的表现时的相对重要性, 恰好是 Hebb 型的。确实, 人们识别出 Hebb 贡献  $-\lambda_m$ ,  $m = 1, 2$ , 乘上一个  $\theta$  函数; 这个  $\theta$  函数根据哪个重叠  $\lambda_i^u$  最大, 把样例“分类”为属于簇 1 或簇 2。另一种说法是, 在 (8.45) 中, 我们把势写成一个纯 Hebb 项, 即沿  $\mathbf{J}_1 + \mathbf{J}_2$  方向的  $V_+(\lambda) = -\lambda_+/ \sqrt{2}$ , 和一个最大绝对值项, 即沿  $\mathbf{J}_1 - \mathbf{J}_2$  方向的  $V_-(\lambda) = -|\lambda_-|/ \sqrt{2}$  的和。这两个单  $\mathbf{J}$  势在上一节已讨论过, 因此我们可以利用相应结果。

先考虑重叠分布。对于随机取向的  $\mathbf{J}_m$ ,  $m = 1, 2$ , 该分布是双正态分布。由于沿  $\lambda = \lambda_1 + \lambda_2$  的 Hebb 型势贡献, 分布会沿这条线平移一段距离  $1/\sqrt{\alpha}$ 。此外, 作用在  $\lambda = \lambda_1 - \lambda_2$  方向上的最大绝对值势, 使重叠分布被一分为二并沿该方向分开, 比较图 8.4。这个空隙的宽度按  $2/\sqrt{\alpha}$  减小。只有在  $\alpha \rightarrow \infty$  的极限中,  $\lambda_1 - \lambda_2$  平面中的重叠分布才会回到随机样例所具有的双正态形式。重叠  $Q$  为

$$Q(\alpha) = -\frac{2\sqrt{\alpha/(2\pi)} \left(1 + \sqrt{\alpha/(2\pi)}\right)}{1 + 2\sqrt{\alpha/(2\pi)} \left(1 + \sqrt{\alpha/(2\pi)}\right)}. \quad (8.46)$$

因此, 簇中心之间的夹角从  $\alpha = 0$  时的  $\pi/2$  增大到  $\alpha \rightarrow \infty$  时的  $\pi$ 。与单  $\mathbf{J}$  情形一样, 势中的最大绝对值贡献导致重叠结构出现不连续性, 因而复本对称被破坏。因此, 我们在图 8.4 中也给出了一步 RSB 计算结果。结果表明, RSB 对自由能和  $Q$  的修正相当小, 而对齐分布和两个簇之间的空隙则以类似图 8.2d 的方式被修改。图 8.4 再次清楚展示了将聚类算法应用于随机样例分布时发现的欺骗性结构: 当从竞争学习所选择的特殊方向观察样例时, 会看到两个清楚分离的簇。




图 8.4: 竞争学习应用于随机样例时, 对齐场分布  $P(\lambda_1, \lambda_2)$  的等高线: 左图为复本对称预测, 右图为进一步复本对称破缺预测, 均取  $\alpha = 1$ 。

最后转向竞争学习在非均匀分布样例上的应用。为简单起见, 我们集中于概率密度

$$P(\xi) = \frac{1}{2} \prod_{i=1}^N \frac{\exp \left[ -\frac{1}{2} \left( \xi_i - \rho B_i / \sqrt{N} \right)^2 \right]}{\sqrt{2\pi}} + \frac{1}{2} \prod_{i=1}^N \frac{\exp \left[ -\frac{1}{2} \left( \xi_i + \rho B_i / \sqrt{N} \right)^2 \right]}{\sqrt{2\pi}}, \quad (8.47)$$

其中  $\mathbf{B}$  是长度归一化为  $\sqrt{N}$  的向量。由于输入与生成结构的向量  $\mathbf{B}$  有优选对齐场  $h = +\rho$  或  $-\rho$ , 我们预期簇轴会反映这一结构。此外, 由于计算和解析表达式相对繁琐, 而结果又是单  $\mathbf{J}$  情形结果的自然推广, 我们只作简要说明。可以发现, 存在一个临界值  $\alpha_r$ , 低于它时  $R_- = (\mathbf{J}_1 - \mathbf{J}_2)\mathbf{B}/N$



精确为零，并且所有统计性质都与随机输入情形相同。换言之，数据点中底层的非随机结构完全没有被发现。在 RS 下得到  $\alpha_r = \pi/2\rho^4$ ，而一步 RSB 预言一个稍小的值  $\alpha_r \simeq 1.13/\rho^4$ 。当  $\alpha > \alpha_r$  时，重叠  $R_-$  不再为零，并且实际上在  $\alpha \rightarrow \infty$  时收敛到 1。

由此可见，竞争学习在与对称性破缺方向正交的子空间中揭示出的欺骗性结构，在训练集大小低于临界值时再次完全占据主导。与单  $\mathbf{J}$  情形一样，这种延迟学习是不可避免的；也就是说，在低于临界值  $\alpha_r$  时，不可能识别出簇中心的方向。

## 8.5 通过调节温度聚类

无监督学习方案中的一个困难问题，是估计样例需要被细察到何种精度。在前面关于聚类的讨论中，我们一开始就决定使用两个簇中心，并把分析限制在基态  $T = 0$ ，因此没有遇到这个问题。不过，包括著名的自适应共振理论 [122] 在内，已经设计出多种算法，其中“活跃”簇中心的数目会根据预设精度阈值自动调节。随着精度要求提高，已有簇会分裂成更细的簇，从而揭示样例集的底层层级结构。这里我们讨论另一种方法 [123]，它在精神上更接近统计力学，并通过改变类似逆温度的参数  $\beta$  来控制簇中心数目。假定每个样例  $\xi^\mu$ ， $\mu = 1, \dots, p$ ，都与从  $M$  个可用簇中选出的单个簇相关联，对应簇中心为  $\mathbf{J}_m$ ， $m = 1, \dots, M$ 。把将特定样例  $\xi^\mu$  归属于簇  $m$  的代价记作  $V_m(\xi^\mu)$ 。为简单起见，我们只考虑平方距离代价  $V_m(\xi^\mu) = (\xi^\mu - \mathbf{J}_m)^2$ 。此外，定义量  $X_m^\mu$  来标识样例  $\mu$  被归属到哪个簇：如果  $\xi^\mu$  被归属于第  $m$  个簇，则  $X_m^\mu = 1$ ，否则为 0。注意，只允许如下形式的表示：

$$X_m^\mu = \delta(m, m^\mu), \quad (8.48)$$

其中对任意  $\mu = 1, \dots, p$ ， $X_m^\mu$  只对单个  $m$  取值 1。对于给定的归属变量  $\{X_m^\mu\}$  和簇中心  $\{\mathbf{J}_m\}$ ，总成本为

$$E(\{\mathbf{J}_m\}, \{X_m^\mu\}) = \sum_{\mu, m} X_m^\mu (\xi^\mu - \mathbf{J}_m)^2. \quad (8.49)$$

我们将按照 Boltzmann 因子接受这样的选择：

$$\text{Prob}(\{\mathbf{J}_m\}, \{X_m^\mu\}) \sim e^{-\beta E(\{\mathbf{J}_m\}, \{X_m^\mu\})}, \quad (8.50)$$

其中，照常，逆温度  $\beta$  控制代价和熵之间的竞争。随着  $\beta$  增大，簇中心的位置和归属会发生变化，因为最小化代价的重要性变得更强。为了与本章前面的讨论相联系，注意当  $\xi^\mu$  和  $\mathbf{J}_m$  位于  $N$  维球面上时，代价 (8.49) 除一个平凡常数外，对应于 Hebb 势  $V(\lambda) = -\lambda$  的代价。特别地，对于给定的归属变量  $X_m^\mu$ ，代价  $E$  的最小值在

$$\mathbf{J}_m = \sum_{\mu} X_m^\mu \xi^\mu \quad (8.51)$$

处取得，因此每个簇中心就是归属于它的样例的质心。这当然是使用二次代价函数的结果，或用神经网络语言说，是 Hebb 学习规则的结果。另一方面，我们把每个样例恰好归属于一个簇中心这一事实，意味着这些中心之间也存在某种竞争。它与上一节讨论的竞争学习的区别在于，样例并不会自动归属于离它最近的簇中心。事实上，现在的基本量是熵，它来自在不改变  $E$  值的情况下可对样例作出的所有置换。特别地，这包括属于给定簇的所有样例之间的置换。因此，熵倾向于较大的簇。代价  $E$  则对较小且围绕各中心聚焦的簇更低；二者竞争导致当温度  $\beta^{-1}$  被调节时，簇中心发生非平凡重排。



为研究 Boltzmann 采样 (8.50) 对簇中心位置的影响, 定义一个依赖于簇中心的自由能:

$$F(\{\mathbf{J}_m\}) = -\frac{1}{\beta} \ln \sum_{\{X_m^\mu\}} e^{-\beta E(\{\mathbf{J}_m\}, \{X_m^\mu\})}. \quad (8.52)$$

由 (8.48), 对于一般  $f_m^\mu$  有恒等式

$$\begin{aligned} \sum_{\{X_m^\mu\}} \exp \left( \sum_{\mu, m} f_m^\mu X_m^\mu \right) &= \sum_{m_1=1}^M \cdots \sum_{m_p=1}^M \exp \left( \sum_{\mu} f_{m_\mu}^\mu \right) \\ &= \prod_{\mu=1}^p \left( \sum_{m=1}^M e^{f_m^\mu} \right). \end{aligned} \quad (8.53)$$

这使我们消去归属变量  $X_m^\mu$ , 从而把自由能 (8.52) 化简为

$$F(\{\mathbf{J}_m\}) = -\frac{1}{\beta} \sum_{\mu} \ln \sum_m \exp [-\beta(\boldsymbol{\xi}^\mu - \mathbf{J}_m)^2]. \quad (8.54)$$

在  $p \rightarrow \infty$ 、 $N \rightarrow \infty$  且  $\alpha = p/N$  有限的热力学极限中, 可以再次论证强度自由能密度  $F/N$  自平均, 并用复本技术求值; 关于两个簇中心的这类计算见 [124]。这里我们沿用 [123], 考虑更简单的自平均极限  $p \rightarrow \infty$  且  $N$  有限。它展示了一个本质的新特征, 同时可由初等计算分析。

在高温极限  $\beta = 0$  下, 所有簇中心重合, 并指向整个样例集的质心:

$$\mathbf{J}_m \sim \frac{1}{p} \sum_{\mu} \boldsymbol{\xi}^\mu \quad (8.55)$$

对所有  $m$  都成立。为简化记号, 把原点放在这个质心处。我们预期, 随着温度降低, 这个唯一簇会在某个临界值  $\beta_c$  处分裂成更小的簇。对 (8.54) 关于  $\mathbf{J}_m$  求导, 可得自由能极值满足

$$\sum_{\mu} \frac{(\boldsymbol{\xi}^\mu - \mathbf{J}_m) \exp [-\beta(\boldsymbol{\xi}^\mu - \mathbf{J}_m)^2]}{\sum_k \exp [-\beta(\boldsymbol{\xi}^\mu - \mathbf{J}_k)^2]} = 0. \quad (8.56)$$

把这个表达式展开到  $\beta$  的一阶修正项和  $\mathbf{J}_m$  的线性项, 得到

$$(1 - 2\beta C)\mathbf{J}_m + \frac{1}{M} \sum_k 2\beta C \mathbf{J}_k = 0, \quad (8.57)$$

其中  $C$  是样例集的协方差矩阵,

$$C = \frac{1}{p} \sum_{\mu} \boldsymbol{\xi}^\mu \boldsymbol{\xi}^\mu. \quad (8.58)$$

当温度降低时, 若由 (8.57) 中系数组成的矩阵出现负本征值, 解  $\mathbf{J}_m = 0$  的稳定性就会受损。记  $C$  的最大本征值为  $\lambda_{\max}$ , 于是临界  $\beta$  为

$$\beta_c = \frac{1}{2\lambda_{\max}}. \quad (8.59)$$

因此, 如所预期, 它由样例分布沿最大主轴的方差决定, 而第一次簇分裂就沿该方向发生。在  $p \rightarrow \infty$  极限中, 这种分裂对应于真正的二阶相变。随着温度进一步降低, 预期还会发生进一步分裂。

作为一个简单例子, 考虑一维样例分布

$$P(\xi) = \frac{\delta(\xi - 1) + \delta(\xi - 3)}{4} + \frac{\delta(\xi + 2)}{2}. \quad (8.60)$$




图 8.5: 对于分布 (8.60), (8.56) 的解  $\mathbf{J}_m$  ( $m = 1, 2, 3$ ) 作为  $\beta^{-1}$  的函数。

矩阵  $C$  化为标量变量  $C = 9/2$ , 因此临界值为  $\beta_c = 1/9$ 。在图 8.5 中, 我们画出了完整非线性问题 (8.56) 的解。可以清楚观察到在  $\beta_c = 1/9$  处发生二阶相变, 对应于所有样例的质心分裂成上、下两个簇; 随后在  $\beta \simeq 1/2$  处发生第二次转变, 其中上方簇进一步分裂。

最后, 我们评论前几节关于真正结构会被偶然结构遮蔽的观察。为什么最大方差方向没有被随机性压制? 原因很简单: 这里考虑的是  $p \rightarrow \infty$  且  $N$  有限的极限, 因此  $\alpha = \infty$ 。事实上, 对于有限  $\alpha$  的分析 [124] 的确揭示了真正结构与随机性之间的竞争。可以观察到, 当  $\alpha$  低于临界阈值并且温度足够低时, 会出现沿随机方向的聚类相。

## 8.6 讨论

本章说明了如何在统计力学语境中讨论聚类技术, 从而量化它们在均匀和非均匀分布的高维样例集上的性质与表现。

第一个教训是, 人们有可能找到自己正在寻找的东西。如果样例数与样例空间维数同阶, 那么随机性的实现极其丰富, 实际上包含几乎任何类型的结构。而且, 这种偶然有序在热力学极限中是完全可重现的。例如, 即使样例是从均匀分布中随机生成的, 竞争学习也会揭示一种可重现且尖锐的簇状样例分布。统计力学方法的一个好处是, 可以刻画这种偶然有序的性质。

第二个教训是, 随机数据的典型实现中固有的结构可能遮蔽真正的底层结构。在某些情形中, 这导致延迟学习的出现: 当数据集大小低于临界值时, 完全无法抽取关于底层结构的信息。于是, 通过样例进行的无监督学习以相变形式开始, 而这种相变可以是一阶的, 也可以是二阶的。这里分析的一个收益是, 它能表明延迟学习在某些情形中不可避免。此时试图战胜它是没有用的。

第三点是, 延迟学习之所以出现, 是因为非均匀分布与随机分布共享某些对称性。这种对称性可能相当显然, 例如反射、旋转或置换对称性, 也可能是隐藏的。例如, 当样例沿对称性破缺方向的平均重叠为零, 即  $\langle h \rangle = 0$  时, 就会出现延迟学习, 但重叠分布未必是偶函数。可以猜测, 这些对称性是在从样例学习中遇到的最严重、最不可避免的限制。长期以来人们已经知道, 隐藏对称性

确实是从样例学习过程中的麻烦来源。用统计力学显式分析简单情景，使人能够理解和刻画所涉及的对称性类型，以及必须为它们付出的训练集大小代价。

最后，统计力学为样例集分裂成越来越细的簇提供了一种新解释：这是在类温度参数降低时连续发生相变的结果。事实上，这类思想在真实世界数据中的应用看起来相当成功，例如见 [125]。

最后给出一个简短的相关文献指南。使用统计力学技术研究无监督学习的早期文献包括 [123, 112, 126, 118, 117]。竞争学习最早在 [120] 中研究。关于具有单一对称性破缺方向的问题的一般讨论，包括有监督学习与无监督学习之间的关系，见 [127]。有监督学习中延迟学习的例子见 [108]，而关于非均匀分布样例上的有监督学习的讨论见 [128]。延迟学习存在性的严格证明见 [129]。

## 8.7 习题

8.1 验证  $\lambda_0(t, x)$  的解释以及由此得到的概率密度公式 (8.19)。一方面可作与第 6.4 节容量问题中类似的直接计算，另一方面可应用附录 F 的 cavity 方法。

8.2 对随机样例应用最小方差学习

$$V(\lambda) = \lambda^2. \quad (8.61)$$

计算所得对齐场分布。你是否预期复本对称会被破缺？

8.3 将 (8.12) 与 (8.33) 结合，计算学生感知机从带输出噪声的教师感知机学习时的 Gibbs 重叠，并证明它与最优温度下的 Gibbs 重叠相同；比较 (5.29)，其中  $R = q$ ，且  $\beta = \ln[(1+a)/(1-a)]$ 。

8.4 类似地，将 (8.14) 与 (8.33) 结合，重现第 7.3 节中得到的反楔形感知机结果。

8.5 验证从带权重噪声的教师感知机学习的 Gibbs 学生，其泛化误差的渐近行为与第 5.4 节关于最优温度学习的讨论一致。为什么在这种情况下，最优温度学习不能饱和 Bayes 极限？

8.6 查阅 [130] 并验证：在  $N \rightarrow \infty$  极限中，可以用  $p'$  个样例的一个子集精确确定  $P^*$ ，其中  $p' \rightarrow \infty$ ，但  $\alpha' = p'/N \rightarrow 0$ 。因此，寻找对称性破缺取向本身需要  $p \sim N$ ，比寻找  $P^*$  更昂贵。

8.7 第 8.3 节定义的无监督 Gibbs 学习，实际上是有监督情形中零温 Gibbs 学习的对应物。那么，为什么必须取  $\beta = 1$ ？

8.8 从 (8.24) 出发，求出  $R$  和  $x$  的鞍点方程。证明存在一个最优势，使得重叠等于 Bayes 重叠  $R_B = \sqrt{R}$ ，其中 Gibbs 重叠由 (8.33) 给出；亦见第 4.5 节。

8.9 证明：将零温无监督 Hebb 规则应用于具有单一对称性破缺取向的样例时，重叠  $R$  为，比较 (8.24)，

$$R = \langle h \rangle \sqrt{\frac{\alpha}{1 + \alpha \langle h \rangle^2}}. \quad (8.62)$$

证明当  $\alpha \rightarrow 0$  时，这一结果与最优重叠  $R_B$  相同。

8.10 考虑最大方差竞争学习，其势定义为

$$\begin{aligned} V(\lambda_1, \lambda_2) &= -\lambda_1 [1 + \gamma(\lambda_1 - \lambda_2)] - \lambda_2 [1 + \gamma(\lambda_2 - \lambda_1)] \\ &= -(\lambda_1 + \lambda_2) - \gamma(\lambda_1 - \lambda_2)^2. \end{aligned} \quad (8.63)$$

证明对于随机样例,  $Q$  为

$$Q = \begin{cases} -1 + \frac{\alpha}{8\gamma^2(1+\sqrt{\alpha})^4}, & \alpha \leq \alpha_- \text{ 或 } \alpha > \alpha_+, \\ 1, & \alpha_- \leq \alpha \leq \alpha_+, \end{cases} \quad (8.64)$$

其中  $\alpha_+$  与  $\alpha_-$  被定义为方程  $4\gamma(1+\sqrt{\alpha})^2 - \sqrt{\alpha} = 0$  的正实根。当  $\gamma > 1/16$  时, 这些根不存在。在这种情况下, (8.64) 的第一行对所有  $\alpha$  都成立, 而  $Q(\alpha)$  在  $\alpha = 1$  处取得其最大值 (小于 1)。注意, 与竞争学习中发生的情况相反, 现在  $Q$  关于  $\alpha$  是非单调的。证明对齐场分布为

$$P(\lambda_1, \lambda_2) = \frac{1+\sqrt{\alpha}}{2\pi\sqrt{\alpha}} \exp \left[ -\frac{1}{2} \left( \frac{\lambda_1 + \lambda_2}{\sqrt{2(1+Q)}} - \frac{1}{\sqrt{\alpha}} \right)^2 - \frac{1}{2} \left( \frac{1+\sqrt{\alpha}}{\sqrt{\alpha}} \frac{\lambda_1 - \lambda_2}{\sqrt{2(1-Q)}} \right)^2 \right]. \quad (8.65)$$

8.11 再次考虑上一题定义的最大方差竞争学习, 但现在把它应用于由 (8.47) 刻画的非随机样例。证明  $\alpha_r = 1/\rho^4$ 。

# 第九章 在线学习

到目前为止，我们一直关注各种学习规则的性能如何依赖训练集大小；这些样例都在训练开始前选定，并在整个训练期间保持可用。然而，在现实生活以及许多实际情形中，训练样例会随时间出现又消失。学习于是必须在线进行，即在任一时刻只使用当时可用的那个训练样例。这与前面讨论的情形形成对照：前一种情形称为离线学习或批学习，其中所有训练样例在任何时刻都可用。

对于 Hebb 规则，离线和在线情形是一致的：每个样例给突触向量提供一个加性贡献，并且这个贡献与其他样例无关。我们已经在第三章提到过，该规则在大训练集上的表现相当差，原因正是它以完全相同的方式处理所有学习样例。本章的目的，是介绍更高级或可替代的在线学习规则，并把它们的性能同相应离线版本的性能作比较。

## 9.1 随机梯度下降

在在线情形中，训练样例  $(\xi^\mu, \sigma_T^\mu)$  按顺序只呈现一次，而耦合向量  $\mathbf{J}$  在每个时间步只利用这一个样例的信息来更新。把在样例  $\mu$  之前的样例基础上构造出的耦合向量记为  $\mathbf{J} = \mathbf{J}^\mu$ ，则在线学习由更新规则

$$\mathbf{J}^{\mu+1} = \mathbf{J}^\mu + \frac{1}{\sqrt{N}} F^\mu \xi^\mu \quad (9.1)$$

定义，其中  $F^\mu$  称为**学习幅度**。式 (9.1) 中引入因子  $1/\sqrt{N}$ ，是为了使向量  $\mathbf{J}$  在热力学极限中具有归一化  $\mathbf{J}^2 \sim N$ 。

下面从 tabula rasa 初态  $\mathbf{J}^0 = 0$  出发写出 (9.1) 的显式解，它能帮助说明  $F$  的含义：

$$\mathbf{J}^{\nu+1} = \frac{1}{\sqrt{N}} \sum_{\mu=1}^{\nu} F^\mu \xi^\mu. \quad (9.2)$$

因此， $F^\mu \sigma_T^\mu$  是离线学习中嵌入强度  $x^\mu$  的在线对应物，比较 (3.11)。不过要注意，一般说来  $F^\mu$  会依赖向量  $\mathbf{J}^\mu$ ，而该向量是由样例  $\mu$  之前的样例构造出来的。因此嵌入强度依赖历史，刻画离线学习的所有样例统计等价性在在线学习中不再成立。

还可以通过将 (9.1) 两边同  $\xi^\mu$  相乘来得到  $F^\mu$  的另一种解释：

$$F^\mu = \lambda^\mu - t^\mu, \quad (9.3)$$

其中

$$t^\mu = \frac{\mathbf{J}^\mu \xi^\mu}{\sqrt{N}} \quad (9.4)$$

以及

$$\lambda^\mu = \frac{\mathbf{J}^{\mu+1} \xi^\mu}{\sqrt{N}} \quad (9.5)$$

分别是在用样例  $\mu$  学习前后的对齐场。换言之， $F^\mu$  是呈现该样例后突触向量相对于  $\xi^\mu$  的重新对齐幅度。

现在转向在线处方 (9.1) 所蕴含的  $\mathbf{J}$  向量动力学。下面我们只用样例数来计量时间，并把学习描述为耦合空间中关于时间变量  $\mu$  的运动。从 (9.1) 或 (9.2) 以及样例随机选取这一事实可知，该运动是随机的。不过，我们仍然预期如下“序参量”

$$\rho^\mu = \frac{\mathbf{J}^\mu \mathbf{T}}{N}, \quad Q^\mu = \frac{\mathbf{J}^\mu \mathbf{J}^\mu}{N} \quad (9.6)$$

在热力学极限中是自平均的。这里给出一个启发式推导，它同时给出这些量的运动方程。严格处理见 [131]。

将 (9.1) 乘以教师向量  $\mathbf{T}$ ，得到

$$N(\rho^{\mu+1} - \rho^\mu) = F^\mu \frac{\mathbf{T} \xi^\mu}{\sqrt{N}}, \quad (9.7)$$

迭代后得到

$$N \frac{\rho^{\mu+l} - \rho^\mu}{l} = \frac{1}{l} \sum_{i=0}^{l-1} F^{\mu+i} \frac{\mathbf{T} \xi^{\mu+i}}{\sqrt{N}}. \quad (9.8)$$

记住热力学极限  $N \rightarrow \infty$ ,  $p \rightarrow \infty$ ，且  $\alpha = p/N$  有限。我们现在考虑  $l \rightarrow \infty$  但  $l/N = d\alpha \rightarrow 0$  的极限。在这个极限中， $\alpha$  扮演连续时间变量的角色，而 (9.8) 描述  $\rho^\mu = \rho(\alpha)$  在一个小时间增量  $d\alpha$  内的微小变化。式 (9.8) 右端是大量随机变量之和。我们将假定，由于  $F^\mu$  对先前样例的依赖而出现的相关性是弱的，因此可以调用大数定律。于是右端是自平均的，即等于对训练样例取的平均。因此，左端也自平均，并且显然等于  $\rho$  对时间  $\alpha$  的导数。于是可写为

$$\frac{d\rho}{d\alpha} = \langle Fu \rangle, \quad (9.9)$$

其中

$$u = \frac{\mathbf{T} \xi}{\sqrt{N}} \quad (9.10)$$

是教师的局域场，平均是关于随机选出的样例  $\xi$  进行的。

同样，对 (9.1) 两边平方，并按上面描述取极限，可得到  $Q^\mu = Q(\alpha)$  的方程

$$\frac{dQ}{d\alpha} = \langle F(F + 2t) \rangle. \quad (9.11)$$

我们再次强调，对齐场

$$t = \frac{\mathbf{J} \xi}{\sqrt{N}} \quad (9.12)$$

属于一个新的样例  $\xi$ ，而向量  $\mathbf{J}$  是由先前样例构造出来的。因此  $\xi$  与  $\mathbf{J}$  不相关。正是这种相关性的缺失，使在线学习的数学分析比其离线对应物容易得多。

表达式 (9.9) 与 (9.11) 是描述感知机中在线学习的基本方程。一旦训练规则，即  $F$  的形式被指定，这些方程中出现的平均就可以完成。剩下的问题，是求出所得演化方程的显式解  $\rho(\alpha)$  和  $Q(\alpha)$ 。与泛化误差相关的、教师与学生之间正确归一化的重叠由比值  $R = \rho/\sqrt{Q}$  给出。

在第 四 章中，我们研究了学生  $\mathbf{J}$  在最小化各种全局代价函数  $E(\mathbf{J}) = \sum_\mu V(t^\mu \sigma_T^\mu)$  时的泛化性能。这些学习规则的在线对应物，是在样例  $\mu$  被呈现时考虑局部代价  $V(t^\mu \sigma_T^\mu)$ 。通过降低局部代价来近似最小化总代价的自然在线类似物称为**随机梯度下降**，其学习幅度定义为

$$F^\mu = -\eta V'(t^\mu \sigma_T^\mu) \sigma_T^\mu \quad (9.13)$$

或者，在连续时间极限中，

$$F = F(t, \text{sgn}(u)) = -\eta V'(t \text{sgn}(u)) \text{sgn}(u), \quad (9.14)$$

其中  $\eta$  称为学习率。利用 (9.14) 代入 (9.9) 和 (9.11)，就可以研究多种在线学习情景。

## 9.2 具体例子

为了计算 (9.9) 和 (9.11) 中的平均, 记住 (2.19) 会很有帮助:  $u$  和  $t/\sqrt{Q}$  是均值为零的相关 Gaussian 随机变量, 其二阶矩为

$$\langle u^2 \rangle = 1, \quad \left\langle \frac{t^2}{Q} \right\rangle = 1, \quad \left\langle u \frac{t}{\sqrt{Q}} \right\rangle = \frac{\rho}{\sqrt{Q}} = R. \quad (9.15)$$

此外, 由于样例  $\xi$  在这些方程中只通过  $u$  和  $t$  出现, 对  $\xi$  的平均就化为对这些相关 Gaussian 变量的平均。

先从 Hebb 学习开始。此时  $V(t) = -t$ , 所以  $F = \eta \operatorname{sgn}(u)$ 。利用  $t$  和  $u$  的 Gaussian 性质容易得到

$$\begin{aligned} \frac{d\rho}{d\alpha} &= \eta \sqrt{\frac{2}{\pi}}, \\ \frac{dQ}{d\alpha} &= \eta^2 + 2\eta\rho \sqrt{\frac{2}{\pi}}. \end{aligned} \quad (9.16)$$

于是, 由  $\rho(0) = Q(0) = 0$  得

$$\rho(\alpha) = \eta \sqrt{\frac{2}{\pi}} \alpha \quad (9.17)$$

以及

$$Q(\alpha) = \eta^2 \left( \alpha + \frac{2}{\pi} \alpha^2 \right), \quad (9.18)$$

这重现了 (3.8) 中的结果; 当然该结果与  $\eta$  的取值无关。

离线学习语境中讨论过的其他  $V(t)$  选择, 也可以类似处理。我们集中讨论两个会给出意外结果的有趣情形。首先是感知机算法。由于 Rosenblatt 最初正是把它表述为一个在线算法, 因此有必要讨论它的性质。感知机算法对应于选择  $V(t) = -t\theta(-t)$ , 于是

$$F = \eta\theta(-tu) \operatorname{sgn}(u). \quad (9.19)$$

推导  $\rho, Q$  以及最终  $R$  的方程只涉及 Gaussian 积分, 因此相当直接, 见习题 9.1。可得

$$\begin{aligned} \frac{d\rho}{d\alpha} &= \frac{\eta}{\sqrt{2\pi}} \left( 1 - \frac{\rho}{\sqrt{Q}} \right), \\ \frac{dQ}{d\alpha} &= \frac{\eta^2}{\pi} \arccos \frac{\rho}{\sqrt{Q}} + \sqrt{\frac{2}{\pi}} \eta (\rho - \sqrt{Q}), \end{aligned} \quad (9.20)$$

从而

$$\frac{dR}{d\alpha} = \frac{\eta(1-R^2)}{\sqrt{2\pi Q}} - \frac{R\eta^2}{2\pi Q} \arccos R. \quad (9.21)$$

图 9.1 给出了由 (9.21) 数值求解得到的泛化误差  $\epsilon = (\arccos R)/\pi$ , 并与 Hebb 规则的结果 (3.8) 一起绘出。注意, (9.20) 的稳态解包括直线  $\rho = \sqrt{Q}$ , 即  $R = 1$ 。从  $R$  渐近接近这个不动点的方式, 可得到对应泛化误差的渐近行为

$$\epsilon(\alpha) \sim \left( \frac{2}{3} \right)^{1/3} \pi^{-1} \alpha^{-1/3}. \quad (9.22)$$

这个结果出人意料地差。事实上, 最简单、最基本的在线算法, 也就是 Hebb 规则, 具有更快的渐近衰减  $\sim \alpha^{-1/2}$ 。不过, 这一观察多少有些误导, 因为感知机算法的  $\alpha^{-1/3}$  行为会在相当一般的样例分布下保持 [132]; 另一方面, 对于非均匀样例分布, Hebb 规则通常无法收敛到零渐近泛化误



差，见习题 9.18。就感知机算法而言，问题似乎在于其性能对学习幅度非常敏感。事实上，如果随训练集大小  $\alpha$  以适当方式减小  $\eta$ ，见习题 9.4，就可以实现  $\epsilon(\alpha) \sim \alpha^{-1}$  的渐近衰减，这与离线算法相当。这种随  $\alpha$  改变学习率的做法称为**退火**，类比于热力学系统中为了定位基态而缓慢降低温度的过程。最后还要注意，在实际应用中，感知机算法通常以正稳定性  $\kappa$  运行；只要  $\kappa > 0$ ，即使学习率恒定，也会得到  $\epsilon \sim \alpha^{-1/2}$  的渐近衰减，见习题 9.2。




图 9.1: 泛化误差  $\epsilon$  作为不同在线情景中训练集大小  $\alpha$  的函数。图中给出 Hebb 规则（虚线，与图 4.3 相同）、感知机规则（ $\eta = 1$ ，点划线）、adatron 规则（ $\eta = 1$ ，长虚线），以及第 9.3 节讨论的最优在线规则（实线）。

接着讨论第 4.4 节中介绍的零稳定性  $\kappa = 0$  下的 adatron 学习。此时  $V(t) = t^2\theta(-t)/2$ ，因此  $F = -\eta t\theta(-tu) = \eta|t|\theta(-tu)\text{sgn } u$ 。Gaussian 积分仍然很直接。这里仅给出最终得到的  $R$  方程；它有一个很好的性质，即与  $Q$  变量解耦：

$$\frac{dR}{d\alpha} = -\frac{\eta^2 R \arccos R}{2\pi} + \frac{\eta}{\pi}(1 - R^2)^{3/2} + \frac{\eta^2 R^2 \sqrt{1 - R^2}}{2\pi}. \quad (9.23)$$

由 (9.23) 数值求解得到的泛化误差也画在图 9.1 中。为提取  $\alpha \rightarrow \infty$  时的渐近行为，将 (9.23) 右端在  $R = 1$  附近展开到首阶，得

$$\frac{dR}{d\alpha} = \left(-\frac{\eta^2}{3} + \eta\right) \frac{2\sqrt{2}}{\pi}(1 - R)^{3/2}, \quad (9.24)$$

于是泛化误差满足

$$\epsilon(\alpha) \sim \frac{3}{\eta(3 - \eta)} \frac{1}{\alpha}. \quad (9.25)$$

这个结果出人意料地好：它显示出多数离线算法典型的  $1/\alpha$  行为。特别地，这意味着在线算法与位于版本空间中的学生表现一样好。

(9.23) 的相对简单形式，使人能够详细讨论学习率  $\eta$  的作用。 $R = 1$  始终是一个不动点，但当学习率  $\eta$  超过临界值  $\eta_c = 3$  时，它会变得不稳定；这从 (9.24) 可立即看出。更详细的分析，见习

题 9.6, 表明在  $\eta > 3$  时会出现另一个稳定不动点  $R < 1$ 。解  $R = 1$  在  $\eta = \eta_c$  处通过分岔丧失稳定性, 并在  $\eta > \eta_c$  时被  $R < 1$  的解取代。由此可见, 当学习率过大  $\eta > \eta_c$  时, 即使训练集无限大, 在线规则也无法完美学习。这是在线学习众所周知且有文献记载的弱点 [133]。

### 9.3 最优在线学习

在线 adatron 算法的显著结果引出了一个问题: 最好的在线性能究竟是什么。由于泛化误差是  $R$  的单调递减函数, 我们将寻求使  $dR/d\alpha$  的平均值最大化。由 (9.9) 和 (9.11) 可得

$$\frac{dR}{d\alpha} = \frac{\langle 2QFu - \rho F(F + 2t) \rangle}{2Q^{3/2}}. \quad (9.26)$$

乍看之下, 人们可能会想通过选择

$$F = -t + \frac{Qu}{\rho} \quad (9.27)$$

来最大化平均括号内关于  $F$  的二次表达式。然而, 教师的局域场  $u$  对学生而言是未知的。学习幅度  $F$  只能依赖学生可得的量, 例如  $t$  和  $\sigma_T$ 。先在 (9.26) 中对不可得自由度, 也就是  $F$  不能依赖的那些自由度取平均, 就会发现  $u$  被它在给定  $t$  和  $\sigma_T = \text{sgn}(u)$  条件下的平均值取代。随后对  $F$  优化, 得到的不是 (9.27), 而是

$$F_{\text{opt}} = -t + \frac{Q}{\rho} \langle u \rangle \Big|_{t, \sigma_T}, \quad (9.28)$$

条件平均的记号含义显然。注意  $F_{\text{opt}}$  依赖  $Q$  和  $R$ 。不过, 作为自平均序参量, 它们的适当取值对几乎所有学习过程的实现都可供学生使用。事实上, 对于这里给出的最优算法, 在初始条件  $\sqrt{Q(0)} = R(0) = 0$  下, 有额外性质  $\sqrt{Q(\alpha)} = R(\alpha)$  对所有  $\alpha$  成立, 见习题 9.8。因此  $\sqrt{Q} = R$  的值可由  $\mathbf{J}$  的长度得到, 比较 (9.6)。将 (9.28) 代入 (9.26), 得到重叠的最优增长

$$\frac{dR}{d\alpha} = R \frac{\langle F_{\text{opt}}^2 \rangle}{2Q}, \quad (9.29)$$

其中剩余平均是关于  $t$  和  $\sigma_T$  的。由于  $t/\sqrt{Q}$  与  $u$  是具有 (9.15) 所给相关性的 Gaussian 变量, 可得

$$\begin{aligned} P(t, \sigma_T) &= \int du P(t, u) \theta(u \sigma_T) \\ &= \frac{\exp(-t^2/2Q)}{\sqrt{2\pi Q}} H\left(-\frac{R}{\sqrt{1-R^2}} \frac{t}{\sqrt{Q}} \sigma_T\right). \end{aligned} \quad (9.30)$$

于是, 由 Bayes 定理 [116] 得到

$$\begin{aligned} P(u|t, \sigma_T) &= \frac{P(t, u, \sigma_T)}{P(t, \sigma_T)} \\ &= \theta(u \sigma_T) \frac{\exp\left(-\left(u - \frac{R}{\sqrt{Q}} t\right)^2 / 2(1-R^2)\right)}{\sqrt{2\pi(1-R^2)} H\left(-\frac{R}{\sqrt{1-R^2}} \frac{t}{\sqrt{Q}} \sigma_T\right)}. \end{aligned} \quad (9.31)$$

进而条件平均  $u$  为

$$\begin{aligned} \langle u \rangle|_{t, \sigma_T} &= \int du u P(u|t, \sigma_T) \\ &= \sigma_T \frac{\sqrt{1-R^2}}{\sqrt{2\pi}} \frac{\exp\left(-\frac{R^2}{2(1-R^2)} \frac{t^2}{Q}\right)}{H\left(-\frac{R}{\sqrt{1-R^2}} \frac{t}{\sqrt{Q}} \sigma_T\right)} + R \frac{t}{\sqrt{Q}}. \end{aligned} \quad (9.32)$$

因此最优学习幅度具有如下形式：

$$F_{\text{opt}} = \frac{\sigma_T}{\sqrt{2\pi}} \frac{\sqrt{Q(1-R^2)}}{R} \frac{\exp\left(-\frac{R^2}{2(1-R^2)} \frac{t^2}{Q}\right)}{H\left(-\frac{R}{\sqrt{1-R^2}} \frac{t}{\sqrt{Q}} \sigma_T\right)}. \quad (9.33)$$

(9.29) 的右端现在可以显式计算。作变量替换  $x = -Rt\sigma_T/\sqrt{(1-R^2)Q}$ ，最终得到

$$\frac{dR}{d\alpha} = \frac{(1-R^2)^{3/2}}{2\pi R^2} \int Dx \frac{e^{-x^2/2R^2}}{H(x)}. \quad (9.34)$$

这个方程的数值解也包含在图 9.1 中。正如预期，对所有  $\alpha$ ，它给出的泛化误差都低于其他曲线。小  $\alpha$  与大  $\alpha$  行为相当有趣。小  $\alpha$  下有

$$R(\alpha) \approx \sqrt{\frac{2\alpha}{\pi}}, \quad (9.35)$$

这与离线 Bayes 和 Hebb 结果相同。这本可预期，因为对于小样例集，Hebb 学习是 Bayes 最优的，比较 (3.9) 和 (3.30)。另一方面，当  $\alpha \rightarrow \infty$  时，有

$$R(\alpha) \sim 1 - \frac{1}{\alpha^2} \frac{2\pi^2}{\left(\int Dx e^{-x^2/2} H(x)^{-1}\right)^2}, \quad (9.36)$$

这与离线 Bayes 结果相同，只是把  $\alpha$  替换为  $\alpha/2$ ，比较 (3.29) 和 (3.31)。换言之，在  $\alpha \rightarrow \infty$  的渐近意义下，最优在线学习只需两倍样例就能达到离线 Bayes 性能，因此效率惊人。

最优在线学习与离线学习的联系实际上更深。利用 (4.54) 和 (4.55) 的定义，可将  $F_{\text{opt}}$  改写为

$$F_{\text{opt}} = \frac{\sigma_T \sqrt{Q(1-R^2)}}{R} \frac{Y(R, \sigma_T t / \sqrt{Q})}{X(R, \sigma_T t / \sqrt{Q})}. \quad (9.37)$$

当  $Q = 1$  时，也就是采用离线情形中的归一化约定时，可得  $F_{\text{opt}}(R, t) = \sigma_T F^*(R, t\sigma_T)$ ，其中  $F^*$  是第 4.5 节确定的离线学习最优学习幅度。额外的  $\sigma_T$  因子来自第 4.5 节中将该因子吸收到  $t$  与  $\Delta$  的定义中。因此，在最优情形下，对齐场似乎是相同的。但必须记住在线与离线学习之间的基本差异，这也解释了性能差异。在离线学习中，样例统计性质具有完全的置换对称性。因此上述最优对齐对所有样例都能实现；而在在线学习中，它只对最后呈现的那个样例实现。还要注意，对应的最优优势并不相同：在线学习中  $F$  与学习前对齐场  $t$  的势导数相关，比较 (9.14)；而离线学习中，它用学习后对齐场的导数来表示，比较 (4.53)。

最后，对观察到的最优对齐  $F_{\text{opt}}$  作一点解释。注意，正如预期，它与  $\sigma_T$  成正比，因为修正应当使当前样例得到正确符号。聚焦于修正幅度  $F_{\text{opt}}\sigma_T$ ，可以看到它是  $R$  与  $t\sigma_T$  的一个非常特定的函数。 $t\sigma_T$  的符号告诉我们，现有突触向量  $\mathbf{J}$  对新样例  $\xi$  的分类是否与教师一致：正号表示一致，负号表示不一致。此外，很自然地可将  $|t\sigma_T|$  解释为学生给出分类时的确信程度。一个合理的学习算法应当对已经正确再现的样例施加较小修正；而在出错时应施加显著修正，若错误分类还带有很强确信，则修正更应增大。最优势确实表现出这种行为，见图 9.2。

$F_{\text{opt}}\sigma_T$  随参数  $R$  的变化也可类似解释。不过为了保持正确视角，需要考虑  $\mathbf{J}$  模长的变化。因此我们考察归一化幅度  $F_{\text{opt}}\sigma_T/\sqrt{Q}$  作为归一化对齐  $t\sigma_T/\sqrt{Q}$  的函数。当  $R \rightarrow 0$  时， $F_{\text{opt}}$  收敛为常数，也就是说 Hebb 学习是最优的。随着学习进行并且  $R$  接近 1，学生获得信心，修正会变小；对于已经正确再现的样例尤其如此，再次见图 9.2。在  $R \rightarrow 1$  极限中，(9.33) 收敛到 adatron 结果  $F_{\text{opt}} \approx -t\theta(-t\sigma_T)$ 。




图 9.2: 对齐幅度  $F_{\text{opt}}\sigma_T/\sqrt{Q}$  作为  $t\sigma_T/\sqrt{Q}$  的函数。自上而下, 重叠取值分别为  $R = 0.2, 0.5, 0.9$ 。

## 9.4 具有光滑传递函数的感知机

具有二值输出的感知机有一个缺点：不能直接对输出误差进行局部梯度下降。这个非常标准的算法植根于统计学中最小二乘误差近似的传统，并在神经网络中以“反向传播”之名成为最常用的训练规则之一，见 [10]。为了从统计力学角度讨论这一算法，我们现在考虑一个具有连续输出  $\sigma = g(\mathbf{J}\xi/\sqrt{N})$  的感知机，如习题 3.7 所引入。我们仍限制在一个简单情景中：该感知机由一个具有相同传递函数的教师  $\mathbf{T}$ 、 $\mathbf{T}^2 = N$  来训练。二次误差定义为

$$V\left(\frac{\mathbf{J}\xi^\mu}{\sqrt{N}}\right) = \frac{1}{2} \left[ g\left(\frac{\mathbf{J}\xi^\mu}{\sqrt{N}}\right) - g\left(\frac{\mathbf{T}\xi^\mu}{\sqrt{N}}\right) \right]^2, \quad (9.38)$$

梯度下降修正为，比较 (9.1) 和 (9.13)，

$$\mathbf{J}^{\mu+1} = \mathbf{J}^\mu + \frac{1}{\sqrt{N}} F^\mu \xi^\mu, \quad (9.39)$$

其中

$$F^\mu = -\eta [g(t^\mu) - g(u^\mu)] g'(t^\mu). \quad (9.40)$$

由于传递函数通常取其自变量的单调递增函数，知道教师输出现在就意味着对齐场  $u^\mu$  是可得的。按与前面完全相同的方式，可以再次推出关于序参量  $\rho$  和  $Q$  的两个方程，比较 (9.9) 和 (9.11)。此外，当取具体函数  $g(x) = 1 - 2H(x)$ ，且  $g'(x) = 2 \exp(-x^2/2)/\sqrt{2\pi}$  时，这些方程中的平均可显式计算。经过冗长但直接的计算 [134]，得到

$$\frac{d\rho}{d\alpha} = \frac{2}{\pi} \frac{\eta}{1+Q} \left[ \frac{1+Q-\rho^2}{\sqrt{2(1+Q)-\rho^2}} - \frac{\rho}{\sqrt{1+2Q}} \right] \quad (9.41)$$

以及

$$\begin{aligned} \frac{dQ}{d\alpha} = & \frac{4}{\pi} \frac{\eta}{1+Q} \left[ \frac{\rho}{\sqrt{2(1+Q)-\rho^2}} - \frac{Q}{\sqrt{1+2Q}} \right] \\ & + \frac{4}{\pi^2} \frac{\eta^2}{\sqrt{1+2Q}} \left[ \arcsin \frac{Q}{1+3Q} + \arcsin \frac{1+2Q-2\rho^2}{2(1+2Q-\rho^2)} \right. \\ & \left. - \arcsin \frac{\rho}{\sqrt{2(1+2Q-\rho^2)(1+3Q)}} \right]. \end{aligned} \quad (9.42)$$

不深入分析细节，我们只指出这个例子再次说明了学习率  $\eta$  的关键重要性。对于小  $\eta$ ，学生向量将平滑地朝教师方向移动，直到达到零二次误差，即  $\rho = 1, Q = 1$ 。这种接近速度可通过改变  $\eta$  控制。然而，存在一个临界学习率  $\eta_c = \pi\sqrt{5}/3 \simeq 4.06$ ；超过它后，不动点  $\rho = 1, Q = 1$  丧失稳定性。事实上，将 (9.41) 和 (9.42) 右端在该不动点附近线性化，可得到所得  $2 \times 2$  矩阵的特征值

$$\gamma_1 = 4 \frac{\sqrt{5}}{3} \frac{\eta}{\eta_c} \left( \frac{\eta}{\eta_c} - 1 \right), \quad (9.43)$$

$$\gamma_2 = -2\sqrt{5} \frac{\eta}{9\eta_c}. \quad (9.44)$$

由于  $\eta > \eta_c$  时  $\gamma_1$  变为正，对应不动点变得不稳定，并由一个不完美学习的不动点接管。此外，在另一个临界值  $\eta = \pi/\sin(1/3) \simeq 9.24$  以上，不存在稳定不动点，并且在  $\alpha \rightarrow \infty$  极限中有  $\rho, Q \rightarrow \infty$ 。最后，还存在一个最优学习率  $\eta_{\text{opt}}$ ，即  $\eta_{\text{opt}} = 2\eta_c/3 \simeq 2.704$ ，它给出  $\alpha \rightarrow \infty$  时二次误差最快的渐近衰减。这些结果与带符号阈值函数的感知机中 adatron 学习的结果非常相似。

## 9.5 查询

到目前为止研究的许多离线和在线学习规则，对于大训练集大小都表现出泛化误差的缓慢代数衰减，其原因很简单。早在第一章介绍性的数字排序例子中，我们就已经认识到，使用随机样例很难获得与输入最低有效位相连的耦合信息。一般地说，在学习过程后期，当学生几乎与教师平行时，大多数新样例不传递太多信息，因为相应超平面很少切过已经很小的版本空间。这也可以从图 2.3 中 Gibbs 学习的信息增益  $\Delta I(\alpha)$  的行为直接看出：当  $\alpha \rightarrow \infty$  时，它正比于  $\epsilon$  收敛到零，使学习变得乏味而缓慢。

因此，人们很自然会想修改学习情景，避免呈现大量冗余样例，从而使信息以更恒定的流量传给学生。事实上，若假设信息增益  $\Delta I = \partial s / \partial \alpha$  在  $\alpha \rightarrow \infty$  时趋于常数，而熵  $s \sim \ln \epsilon$ ，这对于光滑网络很典型，比较第 7.1 节，则渐近地有

$$\frac{\partial s}{\partial \alpha} = \frac{\partial s}{\partial \epsilon} \frac{\partial \epsilon}{\partial \alpha} \sim \frac{1}{\epsilon} \frac{\partial \epsilon}{\partial \alpha} \rightarrow \text{const.}, \quad (9.45)$$

从而意味着大  $\alpha$  下泛化误差指数衰减。最快的此类衰减发生在这样一种情形：从教师获得的每个输入标签都传递最大可能的一比特信息。

为了实现超过随机样例的信息流，需要一种学习策略，使样例分布与学习过程的当前状态相关。换言之，允许学生提出在特定学习时刻最有帮助的特殊问题，即所谓**查询**。这种处方本质上是在线的，因此可以用本章引入的技术来研究。

一个简单而有吸引力的想法 [135] 是，从垂直于当前学生向量  $\mathbf{J}$  的子空间中随机选择新样例  $\boldsymbol{\xi}$ ，即

$$\frac{\mathbf{J}\boldsymbol{\xi}}{\sqrt{N}} = 0, \quad (9.46)$$

也就是说，学生询问那些自己此刻最不确定的输入分类，即  $t = 0$ 。Hebb 规则下的显式分析尤其简单。利用 (9.46) 和  $F = \text{sgn}(u)$  代入 (9.11)，立即得到

$$\frac{dQ}{d\alpha} = 1, \quad (9.47)$$

再结合  $Q(0) = 0$ ，得到  $Q = \alpha$ 。类似地，(9.9) 给出

$$\frac{d\rho}{d\alpha} = \langle |u| \rangle. \quad (9.48)$$

为计算剩余平均，注意教师与学生向量之间的夹角为  $\theta = \theta(\alpha) = \arccos(\rho(\alpha)/\sqrt{\alpha})$ 。因此，教师向量在样例张成的子空间中的投影长度为  $\sqrt{N} \sin \theta$ ，相应地， $u$  是一个均值为零、方差为  $\sin^2 \theta$  的 Gaussian 随机变量，即

$$P(u) = \frac{1}{\sqrt{2\pi} \sin \theta} \exp\left(-\frac{u^2}{2 \sin^2 \theta}\right). \quad (9.49)$$

取平均后，得到重叠的演化方程

$$\frac{d\rho}{d\alpha} = \sqrt{\frac{2}{\pi}} \sqrt{1 - \frac{\rho^2}{\alpha}}. \quad (9.50)$$

这个微分方程必须数值求解，再由解  $\rho(\alpha)$  按通常方式通过  $\epsilon = \theta/\pi$  确定泛化误差。解表明，对所有  $\alpha$ ， $\epsilon$  都小于独立选取样例时的情形。小  $\alpha$  下两种情形具有相同的渐近行为，这是合理的；大  $\alpha$  下，查询学习的泛化误差是未筛选样例学习的一半。

对于 Hebb 规则这一特殊情形，查询学习优于从随机样例学习，这令人安心。然而，改善幅度相当有限。事实上，如上所述，我们预期恒定的信息流会带来随训练集大小指数下降的泛化误差。因此 Hebb 规则无法充分利用查询学习的优势。更令人惊讶的是，感知机或 adatron 这类更复杂的学习规则也表现得并不更好。由于它们与 Hebb 规则的区别仅在于学习率的  $t$  依赖，而查询学习中  $t = 0$ ，故得到与 Hebb 规则相同的渐近衰减。因此，对这些学习规则来说，查询性能甚至差于从未筛选样例学习。表面原因是：虽然每个新样例本身都提供关于教师的非零信息量，但由于在线学习过程的在线性质，它会显著干扰并破坏先前样例中积累的信息。

在这种情况下，有两种办法可以改进性能。第一种是坚持在线处方，但让学习幅度依赖训练集大小  $\alpha$ 。第二种是转向从查询进行离线学习，也就是说，随机生成垂直于学生的新样例；在它们被加入训练集后，整个集合被重新学习。

先从第一种可能性开始，考虑使用第 9.3 节推导出的最优幅度进行在线查询学习。令  $t = 0$ ，由 (9.33) 得到查询学习所需的形式

$$F_{\text{opt}}^{\text{query}} = \frac{\sigma_T}{\sqrt{2\pi}} \frac{2\sqrt{(1-R^2)Q}}{R}. \quad (9.51)$$

由 (9.29) 立即得到

$$\frac{dR}{d\alpha} = \frac{1}{\pi} \frac{1-R^2}{R}, \quad (9.52)$$

其解为

$$R(\alpha) = \sqrt{1 - \exp\left(-\frac{2\alpha}{\pi}\right)}. \quad (9.53)$$

于是大  $\alpha$  下有  $\epsilon \sim \exp(-\alpha/\pi)$ 。因此，如果适当降低学习幅度，就确实能在在线查询情景中获得泛化误差的指数衰减。事实上，利用 (9.51) 中  $R$  的结果可以看到，学习率也随  $\alpha$  指数下降。为了不破坏已经取得的结果，在在线查询学习中必须强烈降低后续输入对耦合的影响。



第二种方案称为离线查询学习，其数学描述并不直接，因为很难让对样例  $\xi$  的 quenched 平均依赖动力学变量  $\mathbf{J}$ 。为绕开这一困难，我们把样例与学生向量的相关性替换为一个技术上更简单的情景：样例与教师向量相关。至少在大  $\alpha$  下，当  $\mathbf{J}$  与  $\mathbf{T}$  几乎彼此平行时，我们预期会得到相似结果。与数值模拟比较表明，学习的中间阶段也已经能被相当准确地刻画。

因此，假设样例分布为

$$P(\xi^\mu) = \frac{1}{(2\pi)^{N/2}} \exp\left(-\frac{(\xi^\mu)^2}{2}\right) f_\mu\left(\frac{\mathbf{T}\xi^\mu}{\sqrt{N}}\right) \quad (9.54)$$

其中

$$f_\mu(u) = \frac{1}{\sin\theta_\mu} \exp\left(-\frac{u^2}{2} \cot^2\theta_\mu\right). \quad (9.55)$$

采用  $f_\mu(u)$  的这一特殊形式，是因为它会为教师对齐场  $u$  产生与查询情形相同的分布 (9.49)。不过，并非所有从 (9.54) 抽取的样例都垂直于学生。还要注意， $f_\mu$  通过依赖  $\theta_\mu$  而依赖  $\mu$ ，暂时无需进一步指定这一依赖。

一般统计力学分析随后与附录 B 类似进行，亦见习题 4.10a；我们恢复 (A2.16)，但作替换  $Du_\mu \mapsto Du_\mu f_\mu(u^\mu)$ 。此时的主要新特征是， $u^\mu$  的分布显式依赖  $\mu$ 。因此不能把所有  $u^\mu$  上的平均替换为某一个平均的  $\alpha N$  次幂，而是得到

$$\begin{aligned} \int \prod_\mu du_\mu \prod_\mu P_\mu(u_\mu) \prod_\mu F(u_\mu) &= \prod_\mu \int du P_\mu(u) F(u) \\ &= \exp\left(\sum_\mu \ln \int du P_\mu(u) F(u)\right). \end{aligned} \quad (9.56)$$

因此，计算中的能量部分取得形式

$$G_E(q^{ab}, R^a) = \frac{1}{N} \sum_\mu \int Du f_\mu(u) \dots \quad (9.57)$$

其中省略号表示其余表达式与 (A2.19) 中完全相同。当  $N \rightarrow \infty$  时，调用替换

$$\frac{1}{N} \sum_{\mu=1}^{\alpha N} \dots f_\mu(u) \dots \mapsto \int_0^\alpha d\alpha' \dots f_{\alpha'}(u) \dots \quad (9.58)$$

并利用 (9.55)，最终得到 quenched 熵，比较 (A2.33)，

$$\begin{aligned} s = \text{extr}_{q,R} &\left[ \frac{1}{2} \ln(1-q) + \frac{q-R^2}{2(1-q)} \right. \\ &+ 2 \int_0^\alpha d\alpha' \int Dt H\left(\frac{R \sin\theta(\alpha')}{\sqrt{q-R^2}} t\right) \\ &\left. \times \ln H\left(\sqrt{\frac{q-R^2 \cos^2\theta(\alpha')}{1-q}} t\right) \right]. \end{aligned} \quad (9.59)$$

这个表达式对应的鞍点方程允许我们在已知所有  $\alpha' < \alpha$  上的  $\theta(\alpha')$  时确定  $R(\alpha)$  和  $q(\alpha)$ 。现在作关键假设  $\theta(\alpha') = \arccos R(\alpha')$ ，它把鞍点方程转化为关于  $R(\alpha)$  和  $q(\alpha)$  的闭合积分方程组。注意，这一假设并不平凡，也不能更早引入到计算中；在那里， $\theta$  作为 quenched 变量分布的参数，不能携带复本指标，而  $R$  又不能依赖  $\mu$ ，这样才能解耦能量和熵积分。

离线查询学习导出在  $\alpha$  上非局部的序参量方程，这一点相当吸引人。数值求解这些方程，或研究大  $\alpha$  下的渐近形式，可以表明  $\alpha \rightarrow \infty$  时信息增益确实趋于非零极限，泛化误差指数下降。对



于第 7.2 节讨论的 Ising 感知机，可以使用零熵判据说明，查询学习中通向完美泛化的一阶转变已经发生在  $\alpha \simeq 1.17$ ，而未筛选样例下为  $\alpha \simeq 1.24$ 。

上面讨论的查询选择处方依赖于感知机分类的简单几何解释。对于更复杂的学习机器，找到生成查询的判据可能并不容易。这时，利用系统本身的性质是有利的。其思想是考虑一个接收相同输入的学生系综，并选择那些使学生之间分歧最大的输入作为查询。如果学生数非常大，这显然总能产生平分版本空间的查询。但即使只有两个学生，这种委员会查询算法也工作得相当好，并导致泛化误差指数下降。另一方面，付出的代价是找到一个新查询会变得越来越困难。毕竟，在 Gibbs 学习中找到一个使两个学生意见不合的输入的概率正比于泛化误差本身，因此会随  $\alpha$  快速下降。因此，如果生成新输入便宜、而获得相应教师分类昂贵，那么委员会查询是有利的。

从查询学习通常非常高效。最后给出一个警告：由于查询是经过选择的，查询的有效概率分布可能与原始输入分布相当不同，而后者毕竟用于确定泛化误差。于是有可能出现这样一种情形：虽然版本空间体积随  $\alpha$  快速减小，泛化误差却只缓慢下降。一个简单例子是，从垂直于教师的样例进行感知机学习。在最优情形下，每个新样例都可能平分版本空间；然而教师与学生向量之间不会建立任何对齐，另见第 7.3 节中关于临界楔宽参数下反楔形感知机的讨论。

## 9.6 无监督在线学习

在线学习的另一些重要特征，会在第 8 章讨论过的无监督问题的在线版本中显现出来；现在转向这一问题。可重复第 9.1 节的步骤，只需作如下小修改。基本方程 (9.9) 和 (9.11) 仍然有效，但学习幅度  $F$  现在由

$$F = -\eta V'(t) \quad (9.60)$$

给出，因为不再提供教师分类  $\sigma_T$ 。此外，沿用无监督情形中的记号，对齐场  $u$  被替换为

$$h = \frac{\mathbf{B}\boldsymbol{\xi}}{\sqrt{N}}, \quad (9.61)$$

其中  $\mathbf{B}$  是对称性破缺方向。与前几节的主要差异在于，样例  $\boldsymbol{\xi}$  现在从非均匀分布中采样。对齐场的概率不再是正态分布，而是由  $P^*(h) = \exp(-h^2/2 - V^*(h))/\sqrt{2\pi}$  给出，比较 (8.3)。

为了计算 (9.9) 和 (9.11) 中的平均，需要联合概率分布  $P(t, h)$ 。由于分布  $P^*(h)$  已显式给出，条件概率  $P(t|h)$  的形式可从下述论证推出；显式计算见习题 9.15。我们预期，在应用某个具体在线算法后，向量  $\mathbf{J}$  在大小为  $\alpha$  的训练集之后会达到与  $\mathbf{B}$  的某个自平均重叠  $R$ 。因此  $\mathbf{J} = R\mathbf{B} + \mathbf{J}_\perp$ ，其中  $\mathbf{J}_\perp$  是  $\mathbf{J}$  在垂直于  $\mathbf{B}$  的方向上的分量。于是

$$t = \frac{\mathbf{J}\boldsymbol{\xi}}{\sqrt{N}} = Rh + \frac{\mathbf{J}_\perp\boldsymbol{\xi}}{\sqrt{N}}. \quad (9.62)$$

由于垂直于  $\mathbf{B}$  的  $(N-1)$  维子空间中没有对称性破缺，向量  $\mathbf{J}_\perp$  与  $\boldsymbol{\xi}$  在该子空间中均匀分布。此外， $\mathbf{J}_\perp^2 = (1-R^2)N$ ，且  $\boldsymbol{\xi}^2 = N$ ，因此  $\mathbf{J}_\perp\boldsymbol{\xi}/\sqrt{N}$  是一个均值为零、方差为  $1-R^2$  的 Gaussian 随机变量。由 (9.62) 可知， $P(t|h)$  是均值  $\langle t|h \rangle = Rh$ 、方差  $1-R^2$  的 Gaussian 分布。结合已知分布  $P^*(h)$ ，这就完全给出了联合分布  $P(t, h) = P(t|h)P^*(h)$ 。一旦指定对称性破缺的  $P^*$  和学习规则  $F$ ，就可计算 (9.9) 和 (9.11) 中的平均；注意这里用  $h$  替代了  $u$ 。

与其把这些结果应用于某些具体例子，我们出于更大的理论兴趣，集中讨论学习幅度的最优选择。第 9.3 节的讨论可以重复，结果为

$$F_{\text{opt}} = -t + \frac{\sqrt{Q}}{R} \langle h \rangle \Big|_t \quad (9.63)$$

以及

$$\frac{dR}{d\alpha} = R \frac{\langle F_{\text{opt}}^2 \rangle}{2Q}, \quad (9.64)$$

其中剩余平均是关于  $t$  的。计算平均后，得到关于  $R$  的闭合演化方程

$$\frac{dR^2}{d\alpha} = (1 - R^2) \int \text{D}x \frac{Y^2(R, x)}{X(R, x)} \quad (9.65)$$

其中  $Y(R, x)$  和  $X(R, x)$  分别按 (8.29) 和 (8.32) 定义。注意它与离线学习中 Bayes 重叠方程 (8.33) 形式上的惊人相似。

在转向 (9.65) 的一般讨论之前，先提几个有趣的特殊情形。对于

$$P^*(h) = \frac{2 \exp(-h^2/2) \theta(h)}{\sqrt{2\pi}},$$

比较 (8.11)，也就是有监督教师-学生感知机学习，会恢复第 9.3 节的结果。对于 Gaussian 情景

$$P^*(h) = \frac{\exp(-(1+a)h^2/2)}{\sqrt{2\pi/(1+a)}},$$

比较 (8.15)，可得

$$\frac{dR}{d\alpha} = \frac{a^2 R (1 - R^2)^2}{2(1+a)(1+a - aR^2)}. \quad (9.66)$$

这个结果揭示了在线学习的一个令人不安的特征。在当前情形中，无法从零开始在线学习对称性破缺方向： $R(\alpha=0)=0$  意味着对所有  $\alpha$ ，都有  $R(\alpha) \equiv 0$ 。这可能是所谓在线学习中“平台”问题的最简单例子。这个名称指学习曲线  $\epsilon(\alpha)$  中本质上平坦的区域。在实际应用中这些平台并非无限长，其原因是有限尺寸效应。确实，记住 (9.66) 是热力学极限中的结果。另一方面， $R=0$  是一个不稳定不动点，因此任意小的初始偏离都会被放大。在有限维  $N$  的系统中，预期会有  $1/\sqrt{N}$  量级的小涨落。因此可以论证，这些平台长度按  $\ln N$  缩放，另见习题 9.16。更详细的分析需要计算  $R$  所服从方程的有限尺寸修正，见 [136]。

解释了从边缘不动点逃逸之后，就可以转向  $\alpha \rightarrow \infty$  的渐近行为。由 (9.66) 可得  $R(\alpha) \sim 1 - (1+a)/(2a^2\alpha)$ ，这与离线学习结果完全相同，比较 (8.36)。换言之，在渐近大  $\alpha$  时，在线学习与离线学习同样高效；当然前提是已经从  $R=0$  不动点逃逸出来。

现在进行更一般的讨论，以确立 Gaussian 情景中观察到的特征会在哪些条件下出现。小  $\alpha$  和大  $\alpha$  下的  $R(\alpha)$  渐近性质可直接从 (9.65) 提取。计算与离线情形类似，因为离线和在线公式彼此相似，分别比较 (8.33) 和 (9.65)。

对于小  $\alpha$  且  $R \approx 0$ ，(9.65) 的右端收敛到  $\langle h \rangle^2$ ，因此  $R \sim \sqrt{\langle h \rangle^2 \alpha}$ ，这与 Hebb 和离线 Bayes 学习相同。然而，当  $\langle h \rangle = 0$  时，可得  $R(\alpha=0)=0$ ，并由此发现所有  $\alpha$  下都有  $R(\alpha)=0$ 。因此平台的出现并不限于 Gaussian 分布：任何具有对称性  $\langle h \rangle = 0$  的分布，都不可能从零开始在线学习。来自有监督学习情景的例子见习题 9.14。

对大  $\alpha$  的结果，由 (9.65) 可得

$$R(\alpha) \approx 1 - \left[ 2\alpha \int \left( \frac{dV^*(h)}{dh} \right)^2 P^*(h) dh \right]^{-1}, \quad (9.67)$$

前提是 (9.67) 右端的积分收敛。这个结果包含若干意外。首先，(9.67) 与离线 Bayes 结果 (8.37) 完全相同。因此，Gaussian 情形中观察到的在线学习渐近性能与离线学习一样好，似乎相当普遍。

但是, 这如何与第 9.3 节中有监督学习得到的结果相协调? 在那里我们发现, 离线学习渐近地只需一半样例。此外, 注意到 (9.67) 中  $R$  以  $1/\alpha$  接近 1; 对有监督问题, 这意味着泛化误差相当缓慢地按  $\epsilon \sim \alpha^{-1/2}$  衰减, 这与前面报告的  $1/\alpha$  衰减相矛盾。关键在于, 以分类中尖锐判决边界为特征的有监督学习情景, 会导致势  $V^*$  的导数具有奇性, 从而使上述渐近分析失效。一个值得注意的例外是第 5 章讨论的带噪声权重教师, 比较 (8.13)。由此产生的判决边界模糊确实使识别这种教师更加困难, 并导致  $\epsilon \sim \alpha^{-1/2}$  行为, 比较第 5.4 节和习题 8.5。

为了与有监督学习情景相联系, 现在转向导数  $dV^*(h)/dh$  奇异的情形。为简单起见, 限制在如下特殊情形:  $h < h_0$  时  $P^*(h) = 0$ , 而  $P^*(h)$  在  $h = h_0$  跳到有限值  $\Delta P^* > 0$ , 并且在  $h > h_0$  光滑。经过一些代数可由 (9.65) 得出, 此时的主导渐近行为为

$$R(\alpha) = 1 - 4\pi \left( \alpha \Delta P^* \int Dt \frac{e^{-t^2/2}}{H(t)} \right)^{-2}. \quad (9.68)$$

$R$  以  $\alpha^{-2}$  接近 1, 与熟悉的泛化误差  $1/\alpha$  衰减一致。更精确地说, 将 (9.68) 与 (8.38) 比较可见, Bayes 离线学习“使用样例的效率”是这里讨论的最优在线规则的两倍, 即  $R^{\text{off-line}}(\alpha) = R^{\text{on-line}}(2\alpha)$ 。这证实并推广了第 9.3 节中针对具体学生-教师感知机场景所作的观察。

由于以光滑分布为特征的问题比具有尖锐判决边界的问题更难学习, 可以说, 学习任务越容易, 在线和离线 Bayes 之间的渐近差异越明显。研究一个更加奇异分布, 即带有 delta 峰分布, 例如  $P^*(h) = \delta(h - h_0)$ , 也证实了这一观点。此时离线 Bayes 在有限值  $\alpha = 1$  处达到  $R = 1$ , 而在线学习只是在  $\alpha \rightarrow \infty$  极限中指数地接近  $R = 1$ , 见习题 9.17。

## 9.7 自然梯度

前几节讨论的在线学习效率相当惊人。因此, 最后我们讨论这种性能与统计学几何方法之间一个颇为意外的联系。

我们遵循 Bayes 观点, 把学习过程看作参数  $\mathbf{J}$  的概率分布的持续重塑。主要观察是, 如果在耦合空间  $\mathbf{J}$  中进行的梯度下降能尽可能多地缩短耦合实际概率分布与期望概率分布之间的距离, 那么它对学习过程就是最高效的。事实表明, 一般不能通过在  $\mathbf{J}$  空间中使用 Euclidean 度量  $|\mathbf{J}|^2 = \sum_i J_i^2$  来实现这一点, 而必须使用更一般的 Riemann 度量概念

$$d\mathbf{J}^2 = \sum_{i,j} g_{ij}(\mathbf{J}) dJ_i dJ_j \quad (9.69)$$

其中度量张量  $g_{ij}$  依赖位置  $\mathbf{J}$  [137]。此外, 似乎只有一个度量满足在改变  $\mathbf{J}$  变量时保持不变这一基本要求, 它就是所谓 Fisher 矩阵

$$g_{ij}(\mathbf{J}) = \left\langle \frac{\partial \ln P_{\mathbf{J}}}{\partial J_i} \frac{\partial \ln P_{\mathbf{J}}}{\partial J_j} \right\rangle, \quad (9.70)$$

其中平均相对于  $P_{\mathbf{J}}$  本身进行。

再次考虑一个函数  $V(\mathbf{J})$ , 并询问最陡下降方向。这个方向  $d\mathbf{J}$  应使  $V(\mathbf{J}+d\mathbf{J}) - V(\mathbf{J}) \approx d\mathbf{J} \cdot \nabla V(\mathbf{J})$  在给定 (9.69) 所定义的固定  $d\mathbf{J}^2$  时最大。引入 Lagrange 乘子后, 很容易证明最陡下降方向是  $-g^{-1} \cdot \nabla V =: -\tilde{\nabla} V$ 。对于度量 (9.70), 这个方向称为自然梯度 [137]。

从这一角度看, 随机梯度下降 (9.1)、(9.13) 被替换为

$$\mathbf{J}^{\mu+1} = \mathbf{J}^{\mu} - \frac{\eta}{\sqrt{N}} \tilde{\nabla} V = \mathbf{J}^{\mu} + \frac{1}{\sqrt{N}} F^{\mu} g^{-1}(\mathbf{J}^{\mu}) \boldsymbol{\xi}^{\mu}. \quad (9.71)$$

这种表述的优点，是它不依赖变量的选择：无论使用何种参数化，学习过程都使未知参数的概率分布更接近其真实分布。

在第 10.5 节中，我们将回到自然梯度在线学习规则的性能，并把它与所谓 Cramer–Rao 界进行比较。届时将看到，自然梯度在大  $\alpha$  极限中对于光滑分布是最优的。这样，本章关于最优在线学习在  $\alpha \rightarrow \infty$  时实际上能够饱和最优离线性能的显著观察，就在光滑分布情形下获得了更广泛的基础。

## 9.8 讨论

除了在线学习的实际意义和生物相关性之外，本章给出的理论描述还揭示了此类学习的另外两个主要优点。第一个优点是，在线学习的分析看起来远没有其离线对应物那样技术繁复。至少在热力学极限中，其基本性质由一组常微分方程描述。第二个优点是，与计算代价高得多的离线方案相比，在线学习可以表现得出奇地好。对于小训练集，也就是小  $\alpha$ ，最优性能事实上相同；对于大训练集的渐近最优性能，即  $\alpha \rightarrow \infty$ ，如果所考虑的问题是“困难”的，例如以光滑输入分布为特征，那么二者也相同。对于“较容易”的问题，例如有监督教师–学生感知机场景，在线学习渐近地需要两倍学习样例才能达到与离线学习相同的性能。

理论分析还凸显了在线过程的另外两个重要特征，即学习率  $\eta$  的关键作用和平面的出现。这两个效应都由序参量动力学的不动点、吸引子和排斥子的结构决定。为了加快学习过程，需要足够大的  $\eta$ 。但超过某个临界值  $\eta > \eta_c$  后，对应于正确或最优解，例如教师突触向量的吸引子可能消失，完美学习不再可能。另一方面，平台问题与鞍点的存在有关，而鞍点又源于底层问题或结构中的对称性。动力学必须沿鞍点的不稳定流形从这些不动点逃逸。然而，由于典型初始条件非常接近稳定流形，并且在热力学极限中事实上位于其上，这可能需要很长时间。结果是在学习曲线中观察到平台。我们在离线学习中也遇到过类似特征，当时称为延迟学习。但请记住，至少在这一方面，离线学习相对于在线学习有明确优势，因为我们发现当  $\alpha > \alpha_c$  且使用合适学习规则时，可以摆脱对称性诱导的瘫痪。而在在线学习中，从鞍点稳定流形逃逸是有限尺寸效应；因此严格说来，在热力学极限中，在线学习可能完全无法学习。

最后提到，我们将在第 13 章回到多层结构中的在线学习；在那里，在线学习相对简单的技术性质以及它与实际应用的联系，为分析提供了额外动机。

最后简要回顾相关文献。用常微分方程描述在线学习的可能性最早在 [135] 中被观察到。不久之后，人们认识到，当时令人惊讶的结果是：在线学习的最优渐近性能与离线学习相同，只是在训练集大小上差一个因子 2；这见 [138]。感知机和 adatron 规则的在线学习在 [139] 中讨论。关于学习率作用的详细分析见 [140]。在线学习在处理随时间变化的问题时相当高效，例子见 [141, 142]。查询学习最早在 [135] 中被考虑，而最优在线情景中泛化误差的指数衰减在 [143] 中推导。研究从查询进行离线学习的方法在 [144] 中发展，委员会查询由 [35] 提出并分析。关于不可学习规则的在线学习讨论见 [145]。无监督情景下的在线学习在 [136, 112, 146] 中讨论；光滑问题中在线和离线学习渐近性能相同这一事实见 [137, 146, 147]。自然梯度倾向于避开平台的数值证据可见 [148]。关于若干在线学习算法的较新综述以及更复杂动力学效应的讨论见 [149]。关于可应用于非光滑代价函数的在线算法分析见 [150]。对于具有离散自由度的问题，已经证明，如果强制规则以有限个离散状态运行，则在线学习是不可能的 [151]。涨落对于从对称平台逃逸很重要。有限  $N$  情形中出现的涨落的早期研究见 [136]。

## 9.9 习题

### 9.1 证明

$$\langle \theta(-tu) \rangle = \frac{1}{\pi} \arccos \frac{\rho}{\sqrt{Q}}, \quad (9.72)$$

$$\langle t\theta(-tu) \operatorname{sgn} u \rangle = \frac{\rho - \sqrt{Q}}{\sqrt{2\pi}}, \quad (9.73)$$

$$\langle \theta(-tu) | u \rangle = \frac{\sqrt{Q} - \rho}{\sqrt{2\pi Q}}, \quad (9.74)$$

其中平均是关于满足 (9.15) 的相关 Gaussian 变量进行的。并重现 (9.20) 和 (9.21)。

9.2 对具有稳定性  $\kappa$  的感知机算法重复上述计算，其中

$$V(t) = -(t - \kappa)\theta(-(t - \kappa)).$$

证明当  $\kappa > 0$  时，泛化误差的渐近行为为，比较 (9.22)，

$$\epsilon(\alpha) \sim \sqrt{\frac{\frac{1}{2} - H(\kappa)}{(1 - e^{-\kappa^2})\pi\alpha}}.$$

9.3 考虑  $\eta = 2$  的 adatron 学习。证明对于这一学习率， $\mathbf{J}$  向量的归一化会自动保持不变，即  $dQ/d\alpha = 0$ 。

9.4 对  $F$  中一般的  $\alpha$  依赖学习率  $\eta = \eta(\alpha)$ ，结果 (9.9) 和 (9.11) 仍然有效，比较 (9.8)。考虑在线感知机学习。证明渐近最优选择

$$\eta_{\text{opt}}(\alpha) \sim \frac{2\sqrt{2\pi Q}}{\alpha} \quad (9.75)$$

会导致泛化误差相应快速下降：

$$\epsilon(\alpha) \sim \frac{4}{\pi\alpha}. \quad (9.76)$$

提示：取  $\eta(\alpha) = K(\alpha)\sqrt{Q(\alpha)}$ ，这会给出关于  $R$  的闭合方程；随后对  $K(\alpha)$  优化。

9.5 对具有优化学习率  $\eta_{\text{opt}}(\alpha)$  的在线 adatron 学习重复计算。证明  $\lim_{\alpha \rightarrow \infty} \eta_{\text{opt}}(\alpha) = 3/2$ ，且与恒定最优学习率的情形一样， $\epsilon \sim 4/(3\alpha)$ 。令人惊讶的是，带优化学习率的在线感知机规则在渐近意义下优于 adatron 规则，比较习题 9.4；更多细节见 [149]。

9.6 adatron 学习的不动点解是下列方程的解，比较 (9.23)：

$$\eta \left( R \arccos R - R^2 \sqrt{1 - R^2} \right) = 2(1 - R^2)^{3/2}.$$

证明在  $\eta_c = 3$  处发生分岔，并在  $\eta > \eta_c$  时出现第二个解  $R < 1$ 。证明它的稳定性。

9.7 将在线学习规则 (9.1) 替换为

$$\mathbf{J}^{\mu+1} = \frac{\sqrt{N}}{\sqrt{\left(\mathbf{J}^\mu + \frac{1}{\sqrt{N}} F^\mu \boldsymbol{\xi}^\mu\right)^2}} \left( \mathbf{J}^\mu + \frac{1}{\sqrt{N}} F^\mu \boldsymbol{\xi}^\mu \right), \quad (9.77)$$

该规则的优点是保持归一化  $|\mathbf{J}^\mu|^2 = N$ ，从而可以直接得到重叠  $R$  的闭合方程。对最优  $F$  的选择，重现结果 (9.34)。一般说来，上述保范学习规则产生的结果与 (9.1) 得到的结果并不相同。事



实上, 采用 (9.1) 时, 新样例的贡献比 (9.77) 更大或更小, 取决于  $\mathbf{J}$  的大小恰好偏小还是偏大。因此, (9.1) 中  $\mathbf{J}$  大小随  $\alpha$  的动力学, 实际上对应于学习率的自调节退火。

9.8 证明对于最优在线学习,  $Q$  的演化方程为

$$\frac{d\sqrt{Q}}{d\alpha} = \frac{\langle F_{\text{opt}}^2 \rangle}{2\sqrt{Q}}. \quad (9.78)$$

与  $R$  的方程 (9.29) 比较, 可知如果初始条件相同,  $R$  与  $\sqrt{Q}$  将重合。

9.9 考虑在二次势  $V(y) = y^2/2$  中的梯度下降,

$$\frac{dy}{d\alpha} = -\eta V'(y) = -\eta y, \quad (9.79)$$

并采用离散近似

$$y^{\mu+1} - y^\mu = -\eta y^\mu. \quad (9.80)$$

证明当  $\eta < \eta_c = 2$  时  $y = 0$  是稳定不动点, 但当  $\eta > \eta_c$  时丧失稳定性。

9.10 研究习题 1.4 中引入的 high-low 游戏的离线查询学习, 并证明泛化误差随训练集大小  $\alpha$  指数衰减。每个样例的信息增益是多少?

9.11 感知机学习中查询的概率分布通常应具有如下形式:

$$P(\boldsymbol{\xi}) = \frac{1}{(2\pi)^{N/2}} \exp\left(-\frac{\boldsymbol{\xi}^2}{2}\right) f\left(\frac{\mathbf{J}\boldsymbol{\xi}}{\sqrt{QN}}\right) \quad (9.81)$$

且  $\int D\mathbf{t} f(t) = 1$ 。证明使用第 9.3 节引入的最优势时, 重叠  $R(\alpha)$  的演化方程为

$$\begin{aligned} \frac{dR}{d\alpha} &= \frac{1}{4\pi} \frac{1-R^2}{R} \int D\mathbf{t} f(t) \exp\left(-\frac{R^2 t}{1-R^2}\right) \\ &\times \left[ \frac{1}{H(Rt/\sqrt{1-R^2})} + \frac{1}{H(-Rt/\sqrt{1-R^2})} \right]. \end{aligned} \quad (9.82)$$

用变分论证验证, 第 9.5 节使用的选择  $f(t) = \sqrt{2\pi}\delta(t)$  确实最大化  $dR/d\alpha$ , 因而是最优感知机查询学习中的最佳选择判据。

9.12 在前几章中, 我们多次论证: 当  $N \rightarrow \infty$  时, 随机抽取且独立于耦合向量  $\mathbf{J}$  的样例  $\boldsymbol{\xi}$  以概率 1 与  $\mathbf{J}$  正交。那么, 满足  $\mathbf{J}\boldsymbol{\xi} = 0$  的查询与普通样例之间有什么区别?

9.13 将无监督在线学习结果 (9.65) 应用于带输出噪声教师的情形。

9.14 考虑学生反楔形感知机从教师反楔形感知机学习的无监督版本, 比较 (8.14)。推导最优在线学习的演化方程。解释在楔宽  $\gamma = \sqrt{2\ln 2}$  时  $R = 0$  处不稳定不动点的存在。

9.15 利用附录 A 的技术验证

$$\begin{aligned} P(t|h) &= \mathcal{N} \int d\boldsymbol{\xi} \int d\mathbf{J} P(\boldsymbol{\xi}|\mathbf{B}) \delta(\mathbf{J}^2 - N) \delta(\mathbf{J}\mathbf{B} - NR) \\ &\times \delta\left(\frac{\mathbf{B}\boldsymbol{\xi}}{\sqrt{N}} - h\right) \delta\left(\frac{\mathbf{J}\boldsymbol{\xi}}{\sqrt{N}} - t\right) \\ &= \frac{1}{\sqrt{2\pi(1-R^2)}} \exp\left(-\frac{(t-hR)^2}{2(1-R^2)}\right), \end{aligned} \quad (9.83)$$

其中  $\mathcal{N}$  是保证  $\int P(t|h) dt = 1$  的归一化常数。

9.16 考虑描述从 Gaussian 分布在线学习的方程 (9.66) 在  $R \rightarrow 0$  极限中的形式:

$$\frac{dR}{d\alpha} = \frac{a^2 R}{2(1+a)^2}. \quad (9.84)$$

为了模拟有限尺寸效应, 取初始条件  $R(0)$  为均值等于 0、二阶矩正比于  $N^{-1}$  的 Gaussian 随机变量。这意味着初始平台长度的统计按  $\alpha \sim (1+a)^2 \ln N/a^2$  缩放。对有限  $N$  下从 Gaussian 分布进行无监督 Hebb 学习 ( $F^\mu = \eta$ ) 作模拟, 并验证这是否给出良好近似。

9.17 考虑带 delta 函数奇性的样例分布  $P^*(h) = \delta(h - h_0)$ 。证明最优在线学习中重叠的演化方程为

$$\frac{dR^2}{d\alpha} = (1 - R^2) (R^2 + h_0^2(1 - R^2)), \quad (9.85)$$

并由此说明在  $\alpha \rightarrow \infty$  极限中,  $R$  指数地接近 1。证明离线 Bayes 学习在有限值  $\alpha = 1$  处达到  $R = 1$ 。

9.18 考虑学生感知机从教师感知机作 Hebb 学习, 但样例由非均匀分布生成。证明为了得到零渐近泛化误差, 教师必须是样例协方差矩阵的本征向量, 见例如 [152]。



# 第十章 与统计学建立联系

泛化问题可以看作（数学）统计学中一个基本问题的变体：在给定训练集的基础上拟合模型参数，并希望模型在新的样例上也有良好的预测能力。在这种语境中，神经网络只是非线性参数估计的一种较复杂形式，突触向量  $\mathbf{J}$  就是需要估计的基本参数集合。不过，统计学与统计力学在总体思想和可用工具箱上都有很大差异。本章将回顾统计学中的两个重要结果，即 Vapnik–Chervonenkis 界与 Cramer–Rao 不等式，并把它们同统计力学得到的结果进行比较。

## 10.1 频率到概率的收敛

在导论第一章中，我们已经提到泛化问题与统计学的一个基本组成部分之间的关系，即频率向概率的收敛。本章将进一步澄清并量化这一点。我们先在一种特别清楚地显示其与学习问题关系的框架中，重新表述频率向概率收敛的问题。

考虑定义在定义域  $\Omega$  上、取值为  $+1$  或  $-1$  的函数  $f$ ，

$$\begin{aligned} f : \Omega &\rightarrow \{+1, -1\}, \\ \xi &\mapsto f(\xi). \end{aligned} \tag{10.1}$$

这些函数给出了样例空间  $\Omega$  的所有可能二元分类。我们从中选取一个函数，例如  $f_T$ ，作为所谓的教师函数。在学习语境中，我们关心的是“错误”概率  $\epsilon_f$ ，它定义为随机选取样例  $\xi \in \Omega$  时， $f$  与  $f_T$  给出不同分类的概率。这个泛化误差告诉我们，函数  $f$  预测教师  $f_T$  输出的好坏程度。

为了估计  $\epsilon_f$ ，自然的做法是在一组  $p$  个样例上测试函数  $f$ 。直观上，当测试集足够大时，在该样本上观察到的错误频率  $\nu_f^p$  应当接近错误概率  $\epsilon_f$ 。这就是泛化与统计学之间的第一个基本联系：量化错误答案频率向真实错误概率的收敛。

事实上，为了在不穷举所有可能输入模式的情况下估计某个特定函数  $f$  的  $\epsilon_f$ ，我们可以调用大数定律，得出在独立试验数  $p \rightarrow \infty$  的极限中，观测到的错误频率  $\nu_f^p$  收敛到真实概率  $\epsilon_f$ 。Hoeffding 不等式 [153] 给出了这种收敛随测试集大小  $p$  增大而发生的速度：

$$\text{Prob} \left( \left| \nu_f^p - \epsilon_f \right| > \delta \right) \leq 2e^{-2\delta^2 p}. \tag{10.2}$$

粗略地说，可以得出频率向概率的收敛按  $1/\sqrt{p}$  进行；这正是中心极限定理所熟悉的那类收敛。

除了评估某个特定函数  $f$  的性能之外，在泛化语境中还需要第二个基本要素：人们试图选择最好的“学生”函数  $f$  来匹配教师  $f_T$  的输出。自然的做法是考虑一整类候选函数  $\mathcal{F}$ ，而不是单个函数，并根据给定测试集上的表现来选择一个函数。所考虑的函数类称为规则空间或假设空间。例如， $\mathcal{F}$  可以对应于某一特定神经网络结构能够实现的函数类。

这时很容易再次援引 Hoeffding 不等式，并声称所选函数的真实错误概率与观测错误概率会彼此接近。然而，这个不等式不再适用，因为这些样例已经被用来选择  $f$ ，于是测试集与被选中的函数之间会产生相关性：测试集实际上已经变成训练集，而  $\nu_f^p$  成了训练误差，也就是导论中记为  $\epsilon_t$  的量。为了用一个具体例子说明 Hoeffding 不等式为何失效，考虑一个包含所有二元分类的规则空

间。我们选取所有在给定测试集上与  $f_T$  完全一致的函数，于是它们的测试误差或训练误差恰好为零。然而，同一批函数在其他样例上却实现了所有可能的分类，因此在这种情形中，训练误差与真实误差之间根本没有相关性。

正确的处理方式，是为整个函数类  $\mathcal{F}$  中频率与相应概率的最大偏差给出界；更精确地说，是为如下概率建立界：

$$\text{Prob} \left( \max_{f \in \mathcal{F}} |\nu_f^p - \epsilon_f| > \delta \right). \quad (10.3)$$

这样做时，我们没有选择任何特定函数，因此不会遇到与测试集产生相关性的问题。也正因为如此，我们仍可保留记号  $\nu_f^p$ ，并把它理解为测试误差，而不是训练误差  $\epsilon_t$ 。代价是我们实际上研究的是最坏可能情形：界 (10.3) 必须适用于每一个函数，特别是适用于我们最终选出的函数，也适用于收敛表现最差的那个函数。

如果函数类  $\mathcal{F}$  是有限的，设它含有  $F$  个元素，那么这样的界可以很容易地从 Hoeffding 不等式推出。确实，若 (10.3) 中的不等式成立，便意味着它至少对某个  $f \in \mathcal{F}$  发生了。由于若干事件并集发生的概率至多等于各事件概率之和，我们得到

$$\text{Prob} \left( \max_{f \in \mathcal{F}} |\nu_f^p - \epsilon_f| > \delta \right) \leq 2Fe^{-2\delta^2 p}. \quad (10.4)$$

于是我们说，错误频率一致收敛到相应的错误概率。举例来说，考虑可由具有  $N$  个二元权重的网络实现的函数类。一个特例是第 6.3 节和第 7.2 节中讨论的 Ising 感知机类。在这种情形中，可将上述结果用于  $F = 2^N$ 。在  $p, N \rightarrow \infty$  且比值  $\alpha = p/N$  固定的极限中，可以得出：以概率 1，没有任何观测频率会以超过精度阈值  $\delta_{\text{th}} = \sqrt{\ln 2 / (2\alpha)}$  的幅度偏离其相应的错误概率。注意，这一结果与教师  $f_T$  无关。

## 10.2 Sauer 引理

从上面的推导看来，对于元素数目无限的函数类  $\mathcal{F}$ ，频率向概率的一致收敛似乎很难说出什么。不过，人们预期存在一些这样的函数类，虽然元素无限，其“分类多样性”仍然非常有限。为了量化这种分类多样性，我们考虑所有函数  $f \in \mathcal{F}$  在样例集  $\{\xi^1, \dots, \xi^p\}$  上可诱导出的不同分类数  $\Delta(\{\xi^\mu\})$ 。然后定义所谓的增长函数

$$\Delta(p) = \max_{\{\xi^\mu\}} \Delta(\{\xi^\mu\}), \quad (10.5)$$

它给出  $\mathcal{F}$  中的函数在  $p$  个样例上所能诱导出的最大不同分类数。

为了初步理解这个函数可能的形态，考虑这样一类函数：至多有  $d$  个输入模式被分类为 +1。如果  $\Omega$  中元素数为无穷，则这类函数的数目也是无穷的。显然，当  $p \leq d$  时，每一种可能分类都可被诱导出来。另一方面，当  $p > d$  时，只能实现那些 +1 的数目不大于  $d$  的分类。因此有

$$\Delta(p) = \begin{cases} 2^p, & p \leq d, \\ \sum_{l=0}^d \binom{p}{l}, & p > d. \end{cases} \quad (10.6)$$

对于  $p > d > 1$ ，以下界 [154] 给出了分类数受限的程度：

$$\sum_{l=0}^d \binom{p}{l} \leq 1.5 \frac{p^d}{d!} \leq \left( \frac{ep}{d} \right)^d. \quad (10.7)$$

因此，当  $p > d$  时，能够实现的分类数不再是指数大的  $2^p$ ，而只是多项式大的数目。

Vapnik 和 Chervonenkis [168] 以及独立地 Sauer [156] 证明了， $\Delta(p)$  的这种行事实上当一般。对于任意函数类  $\mathcal{F}$ ，存在唯一的整数  $d_{VC}$ ，称为 Vapnik–Chervonenkis 维数（VC 维数，它也可能等于无穷），使得当  $p \leq d_{VC}$  时，所有  $2^p$  个分类都能实现（至少对某一种  $p$  个样例的选取如此），而当  $p > d_{VC}$  时，这一点不再成立。此外，上面的例子，即增长函数 (10.6)，给出了所有 VC 维数  $d_{VC} = d$  的情形中可能出现的最大分类数。因此，一旦知道 VC 维数，便可得出（比较式 (10.7)）

$$\Delta(p) \begin{cases} = 2^p, & p \leq d_{VC}, \\ \leq \sum_{l=0}^{d_{VC}} \binom{p}{l} \leq \left(\frac{ep}{d_{VC}}\right)^{d_{VC}}, & p > d_{VC}. \end{cases} \quad (10.8)$$

这个所谓 Sauer 引理的证明，在精神上与 Cover 对超平面二分数的推导非常相似，参见第 6.2 节；当  $p > d_{VC}$  时，缺失分类是从  $p = d_{VC} + 1$  处的单个缺失分类开始，经由级联效应产生的 [156]。

VC 维数因而提供了一种识别分类方案受限的函数类的方法。许多具有有限 VC 维数的重要函数类已经被识别出来： $\mathbb{R}^N$  中的矩形与半平面（等价于无阈值感知机）、Boolean 函数、一般神经网络等 [157, 158]。分类多样性的限制 (10.8) 对泛化能力的影响，由下面的定理加以量化。

### 10.3 Vapnik–Chervonenkis 定理

对于具有有限 VC 维数的函数类，Vapnik 和 Chervonenkis [168] 能够推出一个上界，控制所有  $f \in \mathcal{F}$  中任一频率  $\nu_f^p$  与其对应“真实”频率  $\epsilon_f$  相差超过  $\delta$  的概率。其原始界后来由若干作者 [155, 159, 160] 改进为

$$\text{Prob} \left( \max_{f \in \mathcal{F}} |\nu_f^p - \epsilon_f| > \delta \right) \leq c_1 \Delta(2p) e^{-\delta^2 p}, \quad (10.9)$$

其中  $c_1 = 6e^{2\delta}$ 。这个结果的证明见附录 G。比较 VC 界 (10.9) 与 Hoeffding 不等式 (10.4) 可见，比例因子  $\Delta(2p)$  扮演了函数类中有效元素数的角色。

对于 VC 维数有限的函数类，当  $p > d_{VC}$  时，前因子  $\Delta(p)$  只按  $p$  的幂增长，因此我们再次得出结论：观测频率  $\nu_f^p$  与概率  $\epsilon_f$  的差异会在  $p \rightarrow \infty$  时一致缩小。将增长函数的不等式 (10.8) 用进去，并引入变量  $\alpha = p/d_{VC}$ （对  $\alpha > 1$ ），可清楚地说明这一点：

$$\text{Prob} \left( \max_{f \in \mathcal{F}} |\nu_f^p - \epsilon_f| > \delta \right) \leq c_1 \exp \left[ -d_{VC} (\alpha \delta^2 - \ln(2\alpha) - 1) \right]. \quad (10.10)$$

在许多应用中，尤其是在统计力学文献所考虑的应用中，感兴趣的是一种类似热力学极限的区域，其中  $d_{VC} \rightarrow \infty$ 。此时 (10.10) 右端关于精度  $\delta$  呈现阈值行为。存在一个精度阈值

$$\delta_{th}(\alpha) = \sqrt{\frac{\ln(2\alpha) + 1}{\alpha}}, \quad (10.11)$$

当  $\delta$  高于该阈值时，(10.10) 右端在热力学极限中消失。因此，以概率 1，所有错误概率  $\epsilon_f$  都落在半径为  $\delta_{th}(\alpha)$ 、中心为相应频率  $\nu_f^p$  的区间内，其中测试样本大小为  $p = \alpha d_{VC}$ 。通过一些组合技巧 [160]，上述界还可以进一步锐化，得到阈值  $\delta_{th}(\alpha) = \sqrt{\ln \alpha / (2\alpha)}$ 。

在可学习规则的情形下，Vapnik–Chervonenkis 定理有一个有趣变体。Hoeffding 不等式给出的界与观测错误频率  $\epsilon_f$  无关。然而，在泛化语境中，人们尤其关心观测频率接近零时的收敛性质。

特别是，对于可学习问题，可以把注意力集中在版本空间中的学生函数上，即那些在测试集上完全不犯错误的函数。正如下面将看到的，在这种情况下可以得到显著更强的界。

先注意，Hoeffding 不等式可以替换成一个更强的界。对于给定函数  $f$ ，观测频率  $\nu_f^p$  等于 0 而真实误差  $\epsilon_f$  大于  $\delta$  的概率可界定为

$$\text{Prob}\left(\nu_f^p = 0 \text{ and } \epsilon_f > \delta\right) = \int_{\delta}^1 d\epsilon_f P(\epsilon_f)(1 - \epsilon_f)^p \leq (1 - \delta)^p \leq e^{-\delta p}, \quad (10.12)$$

其中  $P(\epsilon_f)$  是真实误差等于  $\epsilon_f$  的概率。可以看到，现在  $\epsilon_f$  大致按  $1/p$  下降，而 Hoeffding 不等式 (10.2) 中观察到的是  $1/\sqrt{p}$  行为。

现在考虑版本空间  $\mathcal{F}_p^* = \{f \mid f \in \mathcal{F} \text{ and } \nu_f^p = 0\}$ ，它由在  $p$  个训练样例上表现完美的所有函数组成。我们将假定这个类非空，也就是说，考虑的是可学习规则的情形。使用与原始 VC 证明基本相同的论证，可以推出如下改进的 VC 界：

$$\text{Prob}\left(\max_{f \in \mathcal{F}_p^*} \epsilon_f > \delta\right) \leq 4\Delta(2p)2^{-\delta p}. \quad (10.13)$$

注意，与 VC 定理 (10.9) 相比，这里右端指数中是因子  $\delta$  而不是  $\delta^2$ ，这是重要改进。再次考虑  $p \rightarrow \infty$ 、 $d_{\text{VC}} \rightarrow \infty$  且比值  $\alpha = p/d_{\text{VC}}$  固定的热力学极限，可得（对  $\alpha > 1$ ）精度阈值为

$$\delta_{\text{th}}(\alpha) = \frac{1 + \ln(2\alpha)}{\alpha \ln 2}. \quad (10.14)$$

通过更精细的论证，并用 (10.7) 中出现的组合和的精确渐近表达式替代其上界，精度阈值还可进一步改进为 [161]

$$\delta_{\text{th}}(\alpha) = \frac{2\alpha \ln(2\alpha) - (2\alpha - 1) \ln(2\alpha - 1)}{\alpha \ln 2} =: \epsilon^{\text{VC}}(\alpha). \quad (10.15)$$

于是我们得出结论：在热力学极限中，以概率 1，所有相容学生的错误概率  $\epsilon_f$  都小于  $\epsilon^{\text{VC}}(\alpha)$ 。

由于 VC 维数刻画了假设空间  $\mathcal{F}$  的分类多样性，我们预期它也应与所考虑分类器的存储容量有关。事实上，从 Sauer 引理 (10.8) 不难证明，存储容量  $\alpha_c = p_c/d_{\text{VC}}$  必须小于 2，其中  $p_c$  是可以被正确存储的随机样例最大数目（见习题 10.5）。VC 维数同时出现在存储与泛化问题中，指出了二者之间一个有趣的关系。如果一个分类器类面对的样例集大小远小于其 VC 维数，它可以在不利用分类中可能编码的相关性的情况下复现该集合。在这个区域，系统作为纯记忆工作，泛化能力相当差。相反，如果训练集大小远大于 VC 维数，系统远超其存储容量，通常没有机会实现所有分类。若仍要复现整个训练集，唯一的方式就是利用所有可能的相关性，这些相关性来自训练集分类事实上由教师函数产生。这样，教师与学生之间会建立起对齐，并带来可观的泛化能力。从这个意义上说，泛化在记忆终结处开始。一个能实现所有可能分类的系统是完美的存储装置，并且（正因为如此）完全不能泛化。另一方面，VC 维数很小的系统只能存储极少项目，但会相当快地泛化（当然，只能泛化到它有能力实现的少数分类之一）。这凸显了数据建模中总是存在的权衡：复杂模型能够复现所有特征，但需要大的数据集才足以泛化；简单模型会迅速泛化，却可能无法复现数据，使问题变得不可实现。因此，最好的模型是能够复现所有数据的最简单模型，这一原则有时称为 Occam 剃刀。

## 10.4 与统计力学的比较

上面推导出的 VC 界非常一般，因此并不知道它们在具体情形中有多紧。于是，人们自然会想用统计力学对一个具体场景得到的显式结果来检验它们：学生感知机向教师感知机学习。如前所

述，统计力学旨在研究典型性质而不是最坏情形。不过，正如下面将看到的，也可以分析部分最坏情形，并以这种方式提取某种“典型最坏情形”的信息。

作为例子，我们将分析版本空间中最差学生的泛化误差。这对应于一种部分最坏情形分析，因为我们没有包括最坏可能教师和最坏可能样例分布。相反，我们仍像以前一样使用标准样例分布 (1.5)，并对教师分布取平均，由此刻画可称为“典型最差学生”的对象。

这个计算与第 2.3 节中为确定典型相容学生的泛化行为而进行的计算非常相似。在那里我们发现，版本空间可以分解为与教师重叠  $R$  固定的切片，且  $R = q$  的学生在数目上指数占优，因此表现出典型的泛化能力。另一方面，最差学生由最小的  $R$  值  $R_{\min}$  决定，在这个值上版本空间的相应切片仍然非空（见图 10.1）。这个切片可由对应的自重叠  $q$  应趋于 1 这一事实识别出来。在  $q$  的鞍点方程 (A2.34) 中考虑  $q \rightarrow 1$  的极限，主阶得到

$$1 - R_{\min}^2 = 2\alpha \int_0^\infty Dt H\left(\frac{R_{\min}t}{\sqrt{1 - R_{\min}^2}}\right) t^2, \quad (10.16)$$

积分后最终得到决定  $R_{\min}$  的方程

$$1 - R_{\min}^2 = \frac{\alpha}{\pi} \left( \arccos R_{\min} - R_{\min} \sqrt{1 - R_{\min}^2} \right). \quad (10.17)$$




图 10.1: 左：学生空间的三维示意图。图中画出了与教师  $\mathbf{T}$  的重叠固定为  $R > 0$  与  $R < 0$  的两个环。若将一个模式  $\xi$  加入训练集，与它垂直的平面会切去这些环中与教师分类不相容的部分。右：若  $R < 0$ ，两个模式总会留下环中的一个连通部分；而对于  $R > 0$ ，属于版本空间的环部分可能不连通。这会导致  $R > 0$  时的复本对称性破缺。

该方程的数值解如图 10.2 所示。它反映了预期行为  $R_{\min}(\alpha = 0) = -1$  以及  $\alpha \rightarrow \infty$  时  $R_{\min} \rightarrow 1$ 。此外，结果  $R_{\min}(\alpha = 2) = 0$  说明，在超过存储极限之后，这里存储极限为  $\alpha_c = 2$ ，感知机为了留在版本空间中确实需要利用样例背后的规则。当  $\alpha = \alpha_c$  时，最差学生仍可把样例当作随机分类来复现 ( $R = 0$ )；而当  $\alpha$  更大时，若要在所有样例上都表现完美，与教师的相关性 ( $R > 0$ ) 就是不可或缺的。

在图 10.2 的插图中，我们还给出了最差学生泛化误差  $\epsilon_{\text{ws}}(\alpha) = \arccos(R_{\min}(\alpha))/\pi$  的相应依赖关系，并同时画出了由 (2.42) 得到的典型学生结果  $\epsilon(\alpha)$ ，以及 VC 界 (10.15) 预测的阈值  $\epsilon^{\text{VC}}(\alpha)$ 。对所有  $\alpha$ ，都有  $\epsilon \leq \epsilon_{\text{ws}} \leq \epsilon^{\text{VC}}$ ，这正是应有的关系。对大  $\alpha$ ，由 (10.17) 可得  $\epsilon_{\text{ws}} \sim 3/(2\alpha)$ ，与此相比  $\epsilon^{\text{VC}} \sim \ln \alpha / \alpha$ ，而  $\epsilon \sim 0.625/\alpha$ 。






图 10.2: 版本空间中最差学生的重叠  $R_{\min}$  随训练集大小  $\alpha$  的变化: 实线为复本对称结果, 虚线为一步复本对称性破缺结果。修正始终很小。插图显示版本空间中最差学生的泛化误差 (实线)、典型学生的泛化误差 (点线), 以及由 VC 定理得到的上界  $\epsilon^{\text{VC}}$  (虚线)。

因此, 对由教师感知机训练的感知机来说, VC 界在大  $\alpha$  时把最坏情形性能高估了一个  $\ln \alpha$  因子。事实上, 版本空间中学生的“典型最坏情形性能”与典型学生一样, 都具有泛化误差按  $1/\alpha$  衰减的渐近形式, 只是前因子稍大。由此也许会猜想, 在可学习情形中, VC 定理的最坏情形界过于悲观。然而并非如此; 习题 10.10 中给出的简单学习场景说明, 当考虑最坏可能教师时, VC 界会被饱和。

上述结果依赖复本对称假设。另一方面, 一个简单几何论证表明, 环  $R = \mathbf{J}\mathbf{T}/N$  中属于版本空间的部分只在  $R < 0$  时总是连通的。对于  $R > 0$ , 它可能被切割成分离的片段, 从而形成不连通集合 (见图 10.1)。这一观察提示, 当  $R_{\min} \geq 0$ , 即  $\alpha \geq 2$  时, 复本对称性可能破缺。沿附录 D 的路线检验复本对称解在复本空间中相对于横向涨落的稳定性, 确实发现当  $\alpha \geq \alpha_{\text{AT}}$  时出现不稳定性, 其中  $\alpha_{\text{AT}}$  由  $\epsilon_{\text{ws}}(\alpha_{\text{AT}}) = 1/\alpha_{\text{AT}}$  给出, 即  $\alpha_{\text{AT}} = 2$ , 这与几何论证一致。对  $\alpha > \alpha_{\text{AT}}$  的一步复本对称性破缺计算表明, 对所有  $\alpha$ ,  $\epsilon_{\text{ws}}$  的修正都非常小。特别地, 大  $\alpha$  时的渐近行为  $\epsilon_{\text{ws}} \sim 3/(2\alpha)$  保持不变 [162]。

上述对部分最坏情形的分析缩小了统计力学概念与数学学习理论概念之间的距离。有趣的是, 也可以沿相反方向前进, 把数理统计的方法应用到统计力学中典型的问题。作为例子, 我们简要讨论一个由 VC 理论推出的典型学生泛化误差上界 [163]。

再次考虑图 3.1 所示的情形: 由样例  $\xi^{(p+1)}$  将对应于  $p$  个样例的版本空间分成相对大小为  $P$  和  $1 - P$  的两部分。与 (3.32) 类似, 可以注意到典型相容学生的泛化误差总是小于平均信息增益的一半 (见习题 2.9):

$$\epsilon_{\text{Gibbs}}(\alpha) = 2P(1 - P) \leq \frac{1}{2} [-P \log_2 P - (1 - P) \log_2 (1 - P)] = \frac{1}{2} \Delta I(\alpha). \quad (10.18)$$

把所有  $0 < p < \alpha d_{VC}$  的这些不等式相加，可得累积 Gibbs 误差

$$\frac{1}{d_{VC}} \sum_{p=1}^{\alpha d_{VC}} \epsilon_{\text{Gibbs}} \sim \int_0^\alpha d\alpha' \epsilon(\alpha') \quad (10.19)$$

由总信息增益所界定；而总信息增益又由  $\log_2 \Delta(\alpha d_{VC})$  所界定，这对应于所有  $\Delta(\alpha d_{VC})$  个可能分类等概率的情形。另一方面，由 (10.8) 可知，对  $\alpha > 1$ ，增长函数的对数表现为  $\log_2 \Delta(\alpha d_{VC}) \sim (1 + \ln \alpha)$ ，这与 (10.19) 一起提示大  $\alpha$  时  $\epsilon \sim 1/\alpha$ 。使用更精细的技术 [163]，确实可以严格证明

$$\epsilon_{\text{Gibbs}}(\alpha) \leq \frac{2}{\alpha} \quad (10.20)$$

在大  $\alpha$  时渐近成立。注意，对感知机而言这个界相当紧，因为我们有  $\epsilon \sim 0.625/\alpha$ 。因此，通过考虑累积误差，可以用最坏情形分析的结果来界定典型行为。

## 10.5 Cramer–Rao 不等式

Vapnik–Chervonenkis 定理及其变体用最坏情形的表现来界定系统的实际表现。Cramer–Rao 界给出一个互补图像：它把实际表现同最佳可能情形相比较。为了引入这个界，我们先回到第 9.7 节已经讨论过的 Fisher 信息概念。考虑依赖未知参数  $\lambda$  的概率分布  $P_\lambda(x)$ 。当从  $P_\lambda(x)$  中抽样得到  $x$  时，我们希望量化这一次抽样对  $\lambda$  的值提供了多少信息。如下所述，Fisher 信息  $F_\lambda$

$$F_\lambda = \left\langle \left( \frac{\partial \ln P_\lambda}{\partial \lambda} \right)^2 \right\rangle = \int dx \left( \frac{\partial \ln P_\lambda(x)}{\partial \lambda} \right)^2 P_\lambda(x) \quad (10.21)$$

是一个合适的度量。首先，它显然是非负量， $F_\lambda \geq 0$ 。其次，它符合独立抽样信息可加这一直观概念。确实，设  $x_1$  与  $x_2$  分别是来自概率分布  $P_{\lambda_1}(x_1)$  与  $P_{\lambda_2}(x_2)$  的独立抽样。我们将相应 Fisher 信息分别记为  $F_{\lambda_1}$  与  $F_{\lambda_2}$ 。不过，也可以把向量随机变量  $(x_1, x_2)$  看作来自  $P_\lambda(x_1, x_2) = P_{\lambda_1}(x_1)P_{\lambda_2}(x_2)$  的一次抽样。其 Fisher 信息为  $F_\lambda = F_{\lambda_1} + F_{\lambda_2}$ 。注意，这种可加性也适用于来自同一分布  $P_\lambda(x)$  的  $p$  次独立抽样  $(x_1, x_2, \dots, x_p)$ ：总 Fisher 信息等于  $pF_\lambda$ ，其中  $F_\lambda$  是每次抽样的信息。

到目前为止，我们还没有解释为什么 Fisher 信息是衡量一次抽样对参数  $\lambda$  的值所提供信息的良好度量。这个理由由 Cramer–Rao 不等式给出。事实上，该不等式以 Fisher 信息为单位，界定了从观测样本  $x$  估计参数  $\lambda$  时可能达到的精度。令  $y(x)$  是  $\lambda$  的一个无偏估计量，即它是依赖于  $x$ （但不依赖未知的  $\lambda$ ）的随机量，并满足  $\langle y(x) \rangle = \lambda$ 。定义  $\delta y = y - \langle y \rangle$ ，Cramer–Rao 界断言

$$\langle \delta y^2 \rangle \geq F_\lambda^{-1}. \quad (10.22)$$

用文字说：最佳无偏估计的均方误差至少等于 Fisher 信息的倒数。这与直观观察一致：若一次抽样携带了大量关于参数  $\lambda$  的信息，原则上就可以构造均方误差很小的估计量。

Cramer–Rao 界是 Schwarz 不等式的直接结果，因为

$$\langle \delta y^2 \rangle \left\langle \left( \frac{\partial \ln P_\lambda}{\partial \lambda} \right)^2 \right\rangle \geq \left\langle \delta y \frac{\partial \ln P_\lambda}{\partial \lambda} \right\rangle^2 = \left( \frac{\partial}{\partial \lambda} \langle y(x) \rangle \right)^2 = 1, \quad (10.23)$$

其中使用了  $y$  的定义。此外，也很容易看出界 (10.22) 是紧的，见习题 10.11。换言之，若没有关于  $P_\lambda$  的进一步信息，它无法被改进。当然，这并不意味着该上界会在每一个具体情形中实现。

在神经网络语境中， $x$  和  $\lambda$  通常是高维向量；在无监督问题中， $x$  对应于  $N$  维球面上的样例  $\xi$ ，在有监督问题中则对应于样例输出对  $(\xi, \sigma_T)$ ，而  $\lambda$  分别扮演对称性破缺向量  $\mathbf{B}$  或教师向量  $\mathbf{T}$  的角色。



为了说明 Cramer-Rao 界在统计力学研究的学习问题中的应用，我们考虑第 8 章的无监督问题。样例  $\xi$  从具有单个未知对称性破缺方向  $\mathbf{B}$  的分布中抽取。其分布可写成  $P_{\mathbf{B}}(\xi) \propto \delta(\xi^2 - N) \exp[-V^*(h)]$ ，其中对齐  $h = \mathbf{B}\xi/\sqrt{N}$ ，见 (8.3)。我们先注意到，第 8 章中用各种学习规则构造的  $\mathbf{J}$  向量事实上给出了  $\mathbf{B}$  的无偏估计量。确实，在热力学极限中，它们与  $\mathbf{B}$  的重叠  $R$  是自平均的；同时，由于模式分布绕  $\mathbf{B}$  具有旋转对称性，它们的平均方向与  $\mathbf{B}$  的方向一致。因此， $\mathbf{J}/R$  的平均恰好等于  $\mathbf{B}$ ，故  $\mathbf{J}/R$  是  $\mathbf{B}$  的无偏估计量。

为了把 Cramer-Rao 界应用到这一情形，需要 (10.22) 的多维推广；这里不加证明地引用 [164]：

$$\left\langle \left( \frac{\mathbf{J}}{R} - \mathbf{B} \right) \left( \frac{\mathbf{J}}{R} - \mathbf{B} \right) \right\rangle \geq \left[ p \left\langle \frac{\partial \ln P_{\mathbf{B}}}{\partial \mathbf{B}} \frac{\partial \ln P_{\mathbf{B}}}{\partial \mathbf{B}} \right\rangle \right]^{-1}. \quad (10.24)$$

Cramer-Rao 界现在是一个矩阵不等式：左端矩阵与右端矩阵之差应为正矩阵。式 (10.24) 右端出现因子  $1/p$ ，源于无偏估计量  $\mathbf{J}$  是基于  $p = \alpha N$  次独立抽样构造的；根据可加性，对应 Fisher 信息等于单次抽样 Fisher 信息的  $p$  倍。

如果考虑绕  $\mathbf{B}$  的旋转对称性，上述不等式会大大简化，因为这些矩阵都是对角的。确实，

$$\frac{\partial \ln P_{\mathbf{B}}}{\partial B_i} = \frac{\partial \ln P_{\mathbf{B}}}{\partial h} \frac{\partial h}{\partial B_i} = - \frac{dV^*(h)}{dh} \frac{\xi_i}{\sqrt{N}}. \quad (10.25)$$

注意  $\langle \xi_i \xi_j \rangle = \delta_{ij}$ ，而在任一垂直于  $\mathbf{B}$  的轴上有  $\langle J_i^2 \rangle = 1 - R^2$ ，于是可得 inequality (10.24) 沿这类轴的形式为

$$\frac{1 - R^2}{R^2} \geq \frac{1}{\alpha} \left\langle \left( \frac{dV^*(h)}{dh} \right)^2 \right\rangle^{-1}. \quad (10.26)$$

通过比较 (10.26) 与 (8.33)，可以验证 Bayes 重叠所实现的最优性能满足 Cramer-Rao 界，这是应当如此的。进一步地，在  $R \rightarrow 1$  的极限中，由 (10.26) 得到

$$R \leq 1 - \frac{1}{2\alpha} \left\langle \left( \frac{dV^*(h)}{dh} \right)^2 \right\rangle^{-1}. \quad (10.27)$$

这个上界与  $\alpha \rightarrow \infty$  极限中 Bayes 重叠的渐近行为完全一致，见 (8.37)。

无监督问题中的 Bayes 重叠在  $\alpha \rightarrow \infty$  时饱和 Cramer-Rao 界，这一点令人安心。特别地，无处不在的  $1/p$  或  $1/\alpha$  行为来自 Fisher 信息对独立抽样的可加性。然而必须认识到，Cramer-Rao 不等式对非光滑分布不给出信息（因为 Fisher 信息发散），也不能用于参数  $\lambda$  取离散值的情形（因为无法计算导数）；而在这些情形中，统计力学计算仍然可以进行。特别是，上面为光滑无监督问题推出的  $R$  以  $1/\alpha$  接近 1 的行为，应同例如具有尖锐决策边界的有监督问题中典型的  $1/\alpha^2$  行为相对照，后者对应于  $\epsilon \sim 1/\alpha$ 。另一方面，Cramer-Rao 界在若干方面有比统计力学更广的适用范围。特别是，它不需要考虑热力学极限，而且样例分布完全一般。此外，可以证明沿自然梯度进行在线学习时的重叠（见第 9.7 节）在大样例集的渐近极限中同样饱和 Cramer-Rao 界 [137]。因此，对光滑分布，在线学习在渐近上与最优离线程序一样有效；第 9 章中我们已经对无监督问题显式证明了这一事实。

## 10.6 讨论

统计学与统计力学为学习研究提供了不同且在许多方面互补的途径。两类领域各自使用的具体技术，在很大程度上决定了能够得到哪类结果。一般性是统计学的主要优势，但这也是它的弱

点，因为它不允许人们区分不同选择，例如不同学习算法、结构以及学习程序中的其他变化。由于统计学大多基于不等式推进，这种一般性显然要付出代价：结果对应于极端情形，而这些界在问题的典型实现中到底有多紧并不清楚。例子包括 Vapnik–Chervonenkis 定理中的最坏情形，以及 Cramer–Rao 界中的最佳情形。

另一方面，统计力学集中于计算自平均量，因此集中于典型结果。不过，也可以在一定程度上用这些技术研究最坏和最佳情形；参见本章对版本空间中最差学生的计算，或第 3.6 节对 Bayes 最优学生的分析。统计力学得到的显式结果证实，在许多情况下，统计学界与实际结果之间可能确实存在显著偏离，不同学习策略之间也可能有很大差异。例如，在两个感知机的场景中，我们发现版本空间中的典型学生与最差学生，其泛化误差都按  $1/\alpha$  衰减；相比之下，VC 定理预测的是  $\ln \alpha/\alpha$ ，而 Hebb 学习给出  $1/\sqrt{\alpha}$  的结果。在不连续学习的情形中，差异甚至可能更加显著，见例如 [165]。

还要注意，统计学中的大量结果基于无限抽样极限  $p \rightarrow \infty$  而  $N$  有限，例如中心极限定理；而在统计力学中，我们能够研究有限比例  $\alpha = p/N$  的影响（当然，这通常是在  $N \rightarrow \infty$  下完成的）。

此外，由于统计学中推导出的许多界在面对非光滑概率分布或取离散值的变量时要么变得平凡，要么不再适用，统计学结果在这些情形中不能提供信息；而统计力学计算仍然可以进行。学习过程中这类情形所典型具有的不连续性，会在统计力学处理中表现为相变；虽然严格说来相变只发生在热力学极限中，它们已经能刻画具有中等多自由度系统的性能。最后还要指出，尽管感知机实现的线性判别函数非常特殊，但容量、泛化误差等相应性质似乎相当典型，并再现了更复杂结构的许多特征。因此，对这个模型及其变体的细致研究，为统计学结果提供了丰富而有启发性的补充。

最后，我们简要回顾相关文献。VC 方法与学习之间的联系在 [13, 166] 中讨论过，另见 [167]；多层网络的 VC 维数估计见 [158]。VC 定理的最早推导出现在 Vapnik 约 1965 年的博士论文中，另见 [168]。这里我们紧密遵循了改进 VC 定理的表述与推导 [160]，另见 [163]。教师–学生感知机场景中的最差学生分析见 [162]；另一种最坏情形场景由 [169] 引入。Cramer–Rao 不等式在神经网络中的应用曾被用来证明在线学习的渐近最优性 [137]，另见第 9.7 节。本章所讨论问题的一般性介绍见 [170]。

## 10.7 习题

**10.1** 验证 Cover 推导出的二分数 (6.18) 满足 Sauer 界但并不饱和该界。你能解释为什么该界没有被饱和吗？

**10.2** 证明不等式 (10.7) 在热力学极限中变得紧。

**10.3** 使用附录 G 的方法证明可学习情形的 VC 界 (10.13) [160]。

**10.4** 在热力学极限中考虑 Sauer 引理，假设  $N \rightarrow \infty$  时  $p = \alpha N$ ，且  $d_{VC} = \alpha_{VC} N$ 。使用 Stirling 公式，将求和近似为积分，并用鞍点论证对积分作渐近估计，证明

$$\frac{1}{N} \log \Delta(p) \begin{cases} = \alpha \ln 2, & \alpha \leq 2\alpha_{VC}, \\ \leq \alpha \ln \alpha + \alpha_{VC} \ln \alpha_{VC} - (\alpha - \alpha_{VC}) \ln(\alpha - \alpha_{VC}), & \text{otherwise.} \end{cases} \quad (10.28)$$

**10.5** 使用 Sauer 引理证明，分类器系统的存储容量  $\alpha_c = p_c/d_{VC}$  总是小于 2，其中  $p_c$  是可被正确存储的随机样例最大数目。注意，对连续分量感知机而言， $d_{VC} = N$ ，且该上界被饱和。进

一步考虑耦合只取 0 或 1 的感知机。证明其 VC 维数仍等于  $N$ ，并把这个结果同习题 6.12 中确定的存储容量作比较。

- 10.6** 考虑这样一类系统：它们按照规则  $\sigma(n) = \text{sgn}(\sin(kn))$  对自然数  $n$  分类，其中  $k$  是实参数。证明，尽管只有一个参数，VC 维数仍然是无穷大 [171]。（提示：假设你已经知道任意大  $N$  下所有  $n < N$  的分类，并说服自己你仍然无法预测  $N$  的分类。）
- 10.7** 证明不存在实数  $k$ ，使得映射  $\sigma(n) = \text{sgn}(\sin(kn))$  实现分类  $\sigma(1) = 1$ 、 $\sigma(2) = 1$ 、 $\sigma(3) = -1$ 、 $\sigma(4) = 1$ 。你如何把这个结果同上一题的解协调起来？
- 10.8** 再次考虑习题 1.4 中讨论过的 high-low 游戏。

- (a) 对此情形，计算可学习任务的 VC 定理 (10.13) 中出现的最坏情形概率，并验证它满足 VC 界。
- (b) 现在考虑一个特殊教师的问题，该教师把所有样例都分类为 1。阈值为  $x$  的学生，在呈现样例集  $\{y_i\}$  时，具有如下测试误差与泛化误差：

$$\nu_x^p = \frac{1}{p} \sum_{i=1}^p \theta(x - y_i), \quad \epsilon_x = x. \quad (10.29)$$

为了估计最坏情形偏差，需要估计

$$\text{Prob} \left( \sup_{x \in [0,1]} |\nu_x^p - \epsilon_x| > \delta \right), \quad (10.30)$$

其中概率是关于随机变量  $y_i$  的。一个令人愉快的观察是，这个问题已经在完全不同的语境中被提出并解决，即经验分布函数理论中，名为 Dvoretzky–Kiefer–Wolfowitz 定理。查阅 [154] 以理解这一联系，并将结果同 VC 定理比较。

- 10.9** 考虑版本空间中最差学生的泛化误差。证明退火近似对二元耦合感知机给出合理结果，但当耦合连续时完全失效。
- 10.10** 考虑区间  $(0,1)$  上示性函数的学习问题。教师由区间  $(t_1, t_2)$  定义：对输入  $y \in (0,1)$ ，若  $t_1 < y < t_2$  则教师输出为 1，否则输出为 0。假设输入  $y$  与教师阈值  $t_1, t_2$  都从单位区间上的均匀概率密度独立随机抽取。
- (a) 证明，当选取  $p$  个点  $y_i$  时，在大  $p$  下相邻点之间的平均距离为  $1/p$ ，而相邻点之间的最大距离按  $(\ln p)/p$  标度。
- (b) 利用这些结果证明，对典型教师而言，最坏可能学生的泛化误差渐近地按  $1/p$  衰减。（提示：使用你求解习题 10.8 的经验。）
- (c) 在当前问题中，最难的教师是“空”教师，它对所有输入都给出输出 0。证明在这种情形中，大  $p$  下最差学生的泛化误差只按  $\ln p/p$  下降。

注意，这个结果支持了在完整最坏情形场景中，VC 界中对数项的必要性。

- 10.11** 对已知方差  $\sigma^2$  但未知均值  $\lambda$  的 Gaussian 分布

$$P_\lambda(x) = \frac{e^{-(x-\lambda)^2/2\sigma^2}}{\sqrt{2\pi}\sigma}, \quad (10.31)$$

计算 Fisher 信息，并说明它确实度量了从  $P_\lambda(x)$  抽样得到的  $x$  对  $\lambda$  的值所传达的信息。证明在这个例子中 Cramer–Rao 界被饱和。（提示：取  $y(x) = x$  作为  $\lambda$  的无偏估计量。）

# 第十一章 鸟瞰：多重分形

对于一组固定的输入样例，可以把  $N$  维球面分解成若干胞元，每个胞元由所有对这些样例给出同一分类的感知机耦合向量  $\mathbf{J}$  构成。前几章讨论的感知机学习的若干方面，都与这种分解的几何性质有关；事实表明，这种分解具有随机多重分形性质。我们对多重分形方法相关数学技术的概述当然会简短而切中要点；更详细的介绍见 [172, 173]。不过，这种替代表述为感知机的不同学习性质提供了更深入、更统一的视角。它突出了热力学极限的一些更微妙方面，以及该极限在感知机学习的统计力学分析中所起的作用。这样，我们用一个包容性的多重分形描述结束对感知机的讨论，并为把这种方法用于多层网络分析做好准备。

## 11.1 破碎的耦合空间

考虑一组  $p = \alpha N$  个样例  $\xi^\mu$ ，它们从  $N$  维球面上的均匀分布独立随机产生。每个与某一输入垂直的超平面，都会按照该样例的两种可能分类，把球形感知机的耦合空间，也就是同一个  $N$  维球面，切成两个半球。因此， $p$  个样例把  $N$  维球面随机划分为至多  $2^p$  个胞元

$$C(\sigma) = \{\mathbf{J} \mid \sigma^\mu = \text{sgn}(\mathbf{J}\xi^\mu)\}, \quad (11.1)$$

这些胞元由不同的可能输出序列  $\sigma = \{\sigma^\mu\}$  标记。同一胞元中的耦合向量  $\mathbf{J}$  对这些样例实现相同分类。图 11.1 给出了  $N$  和  $p$  都很小时的一个简单例子。




图 11.1: 由  $p = 4$  个样例对具有  $N = 3$  个输入的球形感知机耦合空间作出的随机划分。注意这里只生成了  $14 < 2^4$  个胞元。阴影部分是一对镜像胞元，对应于变换  $(\mathbf{J}, \sigma) \mapsto (-\mathbf{J}, -\sigma)$ 。

由于超平面取向是随机的，胞元的大小和形状会有很大差异。特别地，许多分类可能无法实现，因此其对应胞元事实上具有零大小。另一方面，显然对每个与输出序列  $\sigma$  相联系的胞元，都存在

一个输出为  $-\sigma$  的“镜像胞元”，它具有完全相同的形状和大小，可通过把原胞元中的所有耦合向量相对于  $N$  维球心反演而生成。

与输出序列  $\sigma$  对应的胞元体积为

$$\Omega(\sigma) = \int d\mu(\mathbf{J}) \prod_{\mu=1}^p \theta\left(\frac{\mathbf{J}\xi^\mu \sigma^\mu}{\sqrt{N}}\right). \quad (11.2)$$

积分测度保证归一化

$$\text{Tr}_\sigma \Omega(\sigma) = 1, \quad (11.3)$$

这意味着  $\Omega(\sigma)$  可解释为如下概率：从  $N$  维球面上的均匀分布随机抽取一个耦合向量  $\mathbf{J}$ ，它实现输出序列  $\sigma$ 。

为了在热力学极限中刻画胞元大小，回忆非平凡的感知机学习要求样例数在  $N \rightarrow \infty$  时按  $p = \alpha N$  标度。因此我们预期典型胞元大小随  $N$  指数小。于是，胞元大小最好用如下量刻画：

$$k(\sigma) = -\frac{1}{N} \ln \Omega(\sigma), \quad (11.4)$$

它告诉我们给定胞元大小在  $N \rightarrow \infty$  时以哪个指数趋于零。胞元大小分布可由给定大小的胞元数指定：

$$\mathcal{N}(k) = \text{Tr}_\sigma \delta(k - k(\sigma)), \quad (11.5)$$

对典型的  $k$  值，这个数将随  $N$  指数增长。因此，适合用

$$c(k) = \frac{1}{N} \ln \mathcal{N}(k) \quad (11.6)$$

描述胞元大小分布，它给出给定大小  $k$  的胞元数随  $N$  指数增长的速率。

在多重分形理论中，函数  $c(k)$  称为多重分形谱。<sup>1</sup> 粗略地说，所有大小为  $k$  的子集形成一个分形，其分形维数为  $c(k)$ 。如果  $c(k)$  是常数，即与  $k$  无关，那么所研究对象就是简单分形，只需一个分形维数即可描述。多重分形的定义性性质是，对应于不同参数  $k$  的子集具有不同分形维数。因此，为了完整刻画多重分形的标度性质，需要整个非平凡函数  $c(k)$ 。

$k(\sigma)$  和  $c(k)$  仍然依赖随机样例序列  $\{\xi^\mu\}$ 。不过，在  $N \rightarrow \infty$  时，我们预期二者都是自平均的。这个假设可在得到结果后作后验检查，也得到数值模拟 [174] 的支持。因此，只需分别计算  $k(\sigma)$  和  $c(k)$  关于输入分布的平均，即可对任一特定输入集  $\{\xi^\mu\}$  以概率 1 得到正确结果。

## 11.2 感知机的多重分形谱

通过使用所谓多重分形热力学形式主义的一个变体 [175, 176]，可以显式计算感知机的平均多重分形谱。为此，把  $c(k)$  解释为一个自旋系统  $\sigma$  的微正则熵很有用，该系统能量为  $k(\sigma)$ 。这样，它可由相应的系综平均自由能

$$f(\beta) = -\frac{1}{N\beta} \left\langle \left\langle \ln \text{Tr}_\sigma e^{-\beta N k(\sigma)} \right\rangle \right\rangle_{\xi^\mu} \quad (11.7)$$

经 Legendre 变换得到。确实，使用 (11.6) 容易得到

$$\text{Tr}_\sigma e^{-\beta N k(\sigma)} = \int dk \mathcal{N}(k) e^{-\beta N k} = \int dk \exp(N[c(k) - \beta k]), \quad (11.8)$$

<sup>1</sup>在多重分形文献中，它通常记为  $f(\alpha)$ 。

于是对  $N \rightarrow \infty$  有

$$-\beta f(\beta) = \max_k [c(k) - \beta k], \quad (11.9)$$

或等价地

$$c(k) = \min_{\beta} [\beta k - \beta f(\beta)]. \quad (11.10)$$

另一方面，回忆  $k(\sigma)$  的定义 (11.4)，可将  $f(\beta)$  重写为

$$f(\beta) = -\frac{1}{N\beta} \langle\langle \ln \text{Tr}_{\sigma} \Omega^{\beta}(\sigma) \rangle\rangle_{\xi^{\mu}}, \quad (11.11)$$

从而把自由能同胞元大小分布  $\Omega(\sigma)$  的矩联系起来。<sup>1</sup>

现在，(11.11) 中的 quenched 平均可通过复本技巧的一个有趣变体完成 [177]。该变体使用两组复本：一组记为  $a = 1, \dots, n$ ，以通常方式处理对数；第二组记为  $\gamma = 1, \dots, \beta$ ，用来表示胞元体积的  $\beta$  次幂。与通常的复本技巧一样，我们先对整数  $\beta$  计算  $f(\beta)$ ，并假设最后可以找到对实数  $\beta$  的有意义延拓。不过，与通常的复本技巧不同， $\beta$  是一个自由参数，并不一定趋于零。

因此从下式出发：

$$\begin{aligned} & \langle\langle (\text{Tr}_{\sigma} \Omega^{\beta}(\sigma))^n \rangle\rangle_{\xi^{\mu}} \\ &= \left\langle\left\langle \text{Tr}_{\sigma^a} \int \prod_{a=1}^n \prod_{\gamma=1}^{\beta} d\mu(\mathbf{J}^{a\gamma}) \prod_{a,\gamma,\mu} \theta\left(\frac{\mathbf{J}^{a\gamma} \xi^{\mu} \sigma^{\mu a}}{\sqrt{N}}\right) \right\rangle\right\rangle_{\xi^{\mu}}. \end{aligned} \quad (11.12)$$

注意，输出序列  $\sigma$  只携带一个复本指标。因此，具有相同指标  $a$  的耦合向量对应于同一个输出序列  $\sigma^a$ ，从而属于同一个胞元。类似地，第一指标不同的耦合向量属于不同胞元。

借助附录 B 的技术，现在可以对输入  $\xi^{\mu}$  作平均；引入序参量

$$q_{\gamma\delta}^{ab} = \frac{1}{N} \sum_i J_i^{a\gamma} J_i^{b\delta} \quad (11.13)$$

后，各种积分可被解耦，所得表达式可以像通常那样写成关于序参量的鞍点积分。

先研究在鞍点处假设复本对称所得到的结果。必须注意，由于存在第二个复本指标，即使在复本对称层面也必须引入两个不同的重叠。更精确地说，序参量的适当复本对称 ansatz 为

$$q_{\gamma\delta}^{ab} = \begin{cases} 1, & a = b, \gamma = \delta, \\ q_1, & a = b, \gamma \neq \delta, \\ q_0, & a \neq b, \end{cases} \quad (11.14)$$

其中  $q_1$  表示同一胞元（相同第一指标）中两个耦合之间的典型重叠， $q_0$  刻画不同胞元（不同第一指标）中耦合之间的典型重叠。注意， $q_1$  和  $q_0$  都是  $\beta$  的函数，而  $\beta$  又通过  $k = \partial(\beta f(\beta))/\partial\beta$  与  $k$  相联系（比较 (11.10)）。因此， $q_0$  是相同大小的不同胞元之间的典型重叠。

使用 ansatz (11.14)，所得表达式可按与一步复本对称性破缺中的常规复本计算相当类似的方

<sup>1</sup>对所研究测度的矩进行分析，是多重分形理论的核心。在那里  $f(\beta)$  称为质量指数，通常记作  $\tau(q)$ 。



式加以简化（比较附录 E），最终得到

$$\begin{aligned}
 -\beta f(\beta) = \text{extr}_{q_0, q_1} & \left[ \frac{\beta-1}{2} \ln(1-q_1) + \frac{1}{2} \ln(1-q_1 + \beta(q_1 - q_0)) \right. \\
 & + \frac{\beta q_0}{2(1-q_1 + \beta(q_1 - q_0))} \\
 & \left. + \alpha \int Dt_0 \ln \left[ 2 \int Dt_1 H^\beta \left( \frac{\sqrt{q_0} t_0 + \sqrt{q_1 - q_0} t_1}{\sqrt{1-q_1}} \right) \right] \right].
 \end{aligned} \quad (11.15)$$

考察与这个表达式对应的鞍点方程可知， $q_0 = 0$  总是一个解。这并不意外。毕竟  $q_0$  是来自不同胞元的两个耦合向量之间的典型重叠，而胞元覆盖整个  $N$  维球面，因此  $q_0 = 0$  非常合理。它也与图 11.1 所示镜像胞元的存在一致，因为对某个给定胞元中的每个向量  $\mathbf{J}$ ，向量  $-\mathbf{J}$  都属于另一个大小完全相同的胞元。若预先考虑到这种对称性的含义，整个计算甚至可以引入复本指标  $a$ ，也就是说，可以计算  $\Omega^\beta(\sigma)$  的 annealed 平均（见习题 11.2）。不过要注意， $q_0 = 0$  未必是鞍点方程的唯一解；如果存在多个解，还需要更多工作来确定 (11.15) 中正确的极值（见下文）。

使用  $q_0 = 0$ ，自由能表达式 (11.15) 可进一步简化为

$$\begin{aligned}
 -\beta f(\beta) = \text{extr}_{q_1} & \left[ \frac{\beta-1}{2} \ln(1-q_1) + \frac{1}{2} \ln(1 + (\beta-1)q_1) \right. \\
 & \left. + \alpha \ln \left[ 2 \int Dt H^\beta \left( \frac{\sqrt{q_1} t}{\sqrt{1-q_1}} \right) \right] \right].
 \end{aligned} \quad (11.16)$$

最后对  $q_1$  的极值化必须数值完成。借助 (11.10)，即可为不同  $\alpha$  值确定多重分形谱  $c(k)$ 。图 11.2 展示了以这种方式得到的一些结果。




图 11.2: 球形感知机的胞元大小分布所对应的多重分形谱  $c(k)$ 。图中  $\alpha = 0.2, 0.35, 0.5, 1.0, 2.0$ （从左到右），结果来自复本对称 ansatz。圆点标出各曲线的最大值；菱形左侧的结果对复本对称性破缺不稳定。点线部分对应于自由能 (11.11) 奇异的区域，见正文。

如预期， $\alpha$  较小时，大胞元的数目较少；随着  $\alpha$  增大，小胞元（对应于更大的  $k$ ）的数目增加。多重分形谱的最大值在图中以圆点标出，它们给出最频繁胞元的大小  $k_0 = \operatorname{argmax} c(k)$  和数目  $c(k_0) = \max c(k)$ ，这些胞元在总胞元数中指数占优。另一方面，虽然这些胞元数目最多，它们只覆盖  $N$  维球面表面的可忽略部分。事实上，把 (11.3) 中相同大小的胞元合并，有

$$1 = \operatorname{Tr}_{\sigma} \Omega(\sigma) = \int dk \mathcal{N}(k) e^{-Nk} = \int dk \exp(N[c(k) - k]), \quad (11.17)$$

这意味着在  $N \rightarrow \infty$  时，耦合空间体积由大小为  $k_1$  的胞元主导，其中  $k_1$  由

$$\frac{dc}{dk}(k_1) = 1 \quad (11.18)$$

定义。更大的胞元过于稀少，更频繁的胞元又太小而无关紧要。因此，总胞元数和它们覆盖的总体积分别由不同大小的胞元  $k_0$  与  $k_1$  主导。<sup>1</sup> 还要注意，(11.17) 意味着直线  $c(k) = k$  对所有  $\alpha$  都在  $k = k_1$  处与多重分形谱  $c(k)$  相切（比较图 11.2）。

现在来看看这些几何特征如何同感知机的学习性质联系起来。在  $N \rightarrow \infty$  时，随机选取的胞元以概率 1 具有大小  $k_0$ ，因为所有其他大小都指数罕见。但是随机选取一个胞元等价于要求对给定输入  $\xi^\mu$  随机选取一个输出序列  $\sigma$ ，这又等价于第 6 章讨论的存储问题。因此， $e^{-Nk_0}$  正是 (6.5) 中定义的 Gardner 体积  $\Omega(\xi^\mu, \sigma^\mu)$  在  $\kappa = 0$  时的典型值。事实上，由 (11.9) 可知  $k \rightarrow k_0$  意味着  $\beta \rightarrow 0$ ，且不难证明 (6.13) 在这一极限中等价于 (11.16)（见习题 11.3）。相应地，当  $\alpha$  接近存储容量  $\alpha_c(\kappa = 0) = 2$  时， $k_0 \rightarrow \infty$ ，说明典型胞元大小趋于零，且以概率 1 找不到能够实现随机输出序列  $\sigma$  的耦合向量。对于  $\alpha > \alpha_c$ ，胞元大小分布  $c(k)$  单调增加，典型胞元在对应  $k$  值为  $+\infty$  的意义下为空。因此，第 6.1 节中 Gardner 方法所确定的球形感知机存储性质，编码在多重分形谱的最大值中。

但这个谱告诉我们的不止于此：除了大小  $k_0$  以外，我们还知道典型胞元的数目  $c(k_0)$ 。这个数正是第 6.2 节中 Cover 存储问题方法的核心量。事实上，对  $\alpha < 2$ ，由  $k_0 < \infty$  与 (11.10) 得到  $c(k_0) = -\lim_{\beta \rightarrow 0} (\beta f(\beta))$ ；使用 (11.16) 可得  $c(k_0) = \alpha \ln 2$ 。因此，对  $\alpha < 2$ ，以概率 1，所有  $2^{\alpha N}$  个胞元都被实现，这与第 6.2 节的结论完全一致。对  $\alpha > 2$ ，有  $k_0 \rightarrow \infty$ ，从而  $c(k_0) < \alpha \ln 2$ ，只有所有可能分类中的指数小部分可以实现（比较习题 11.5 与 6.4）。因此，随机着色以概率 1 不是线性可分的。由此可见，多重分形方法很好地调和了 Cover 与 Gardner 关于感知机存储问题的两种互补方法：图 11.2 中的横轴对应于测量胞元大小的 Gardner 方法，而纵轴代表 Cover 计数胞元数目的方法。

另一方面，我们也可以不随机选取样例的分类并讨论相应胞元性质，而是从  $N$  维球面上的均匀分布随机抽取一个向量  $\mathbf{T}$ ，并询问它所属胞元的大小。对于有限  $N$ ，这个大小当然是随机量。但回忆在热力学极限中，大小为  $k_1$  的胞元完全填满  $N$  维球面表面，除去指数小的一部分。因此，随机选取的向量  $\mathbf{T}$  以概率 1 位于大小为  $k_1$  的胞元中。而同一个胞元按定义包含所有对输入分类与  $\mathbf{T}$  完全相同的耦合向量  $\mathbf{J}$ 。所以它的大小正是第 2.3 节中计算的、给定  $\alpha$  下的版本空间体积。因此，泛化误差  $\epsilon$  随训练集大小  $\alpha$  的行为也编码在多重分形谱中，即编码在  $c(k)$  与直线  $c = k$  的接触点中。同样，不难在极限  $\beta \rightarrow 1$  下从多重分形谱的一般表达式 (11.16) 推出 (2.41)（比较习题 11.3）。事实上，如果预先知道  $q_0 = 0$ ，导出 (11.16) 的多重分形谱计算在这个极限中就和第 2.3 节使用的  $n \rightarrow 1$  复本技巧相同。

多重分形谱上  $k_1$  与  $k_0$  之间的点也可获得解释：它们对应于带噪声教师的学习问题，并在由  $k_1$  描述的无噪声泛化任务与由  $k_0$  相关的存储问题之间插值；详见 [178]。

<sup>1</sup> 这同样几乎是多重分形的定义性性质：分布的不同矩由不同的分形子集主导。

目前得到的结果仍依赖复本对称和  $q_0 = 0$  这两个假设。仔细的稳定分析 [179] 表明，这两个假设会在

$$\beta_{\pm} = 1 \pm \sqrt{\frac{\alpha}{q_1(\alpha)}} \quad (11.19)$$

处失效，因此对  $\beta > \beta_+ > 0$  和  $\beta < \beta_- < 0$ ，计算出的多重分形谱并不可靠。此外，对所有  $\beta < 0$ ，都存在一个不连续转变，其中  $q_1$  从其鞍点值跳到  $1/(1 - \beta)$ ，从而产生奇异自由能。很容易把这些发散同空胞元  $\Omega(\sigma) = 0$  的存在联系起来，因为空胞元会使 (11.11) 中负  $\beta$  的求和发散。这个解释也许能为把多重分形谱同感知机的 VC 维数联系起来开路；不过到目前为止，数学困难一直阻碍这种联系的显式建立。

为了表示多重分形谱的 RS 结果可靠性有限，图 11.2 中  $c(k)$  负斜率的部分（对应于  $\beta < 0$ ）画成点线，而  $\beta_+$  的取值由菱形界定。应注意，可以由 (11.19) 证明，使用  $q_0 = 0$  的复本对称结果在所有  $\alpha$  下的整个区间  $[k_1, k_0]$  内都是正确的。因此，多重分形谱的这些部分由 (11.16) 正确确定。

通过类似计算，可以确定 Ising 感知机的多重分形谱；图 11.3 给出了一组代表性结果。我们简要讨论几个突出离散耦合神经网络特殊性的要点；详细分析见 [179]。对 Ising 感知机，耦合空间由  $N$  维超立方体的角点组成，相应地，胞元就是离散点的集合。胞元的“体积”只是点的数目乘以  $2^{-N}$ ，也就是说，在 (11.2) 中必须作替换

$$\int d\mu(\mathbf{J}) \rightarrow \frac{1}{2^N} \text{Tr}_{\mathbf{J}}. \quad (11.20)$$

因此，最小非零胞元体积为  $\Omega_{\min} = 2^{-N}$ ，这对应于  $k$  的上界  $k_{\max} = \ln 2$ 。大于这个  $k$  值的  $c(k)$  结果代表只包含一个点的某个分数的胞元，故未在图 11.3 中显示。




图 11.3: Ising 感知机的胞元大小分布所对应的多重分形谱  $c(k)$ 。图中  $\alpha = 0.2, 0.4, 0.833, 1.245, 1.4$ （从左到右），结果来自复本对称 ansatz。圆点标出各曲线的最大值；菱形左侧的结果对复本对称性破缺不稳定。点线部分对应于自由能 (11.11) 奇异的区域，见正文。对  $\alpha = 1.4$ ，谱的连续部分在三角形处终止，并由正方形标出的孤立点  $(\ln 2, \ln 2)$  补全。

当  $\alpha$  较小时，Ising 感知机的多重分形谱与球形情形的相应结果非常相似。这是预期之中的，

因为此时胞元仍相当大，包含巨大数目的点，耦合空间的离散性质尚未显现。特殊值  $k_0$  与  $k_1$  的意义当然与球形情形相同；负斜率  $\beta$  部分的不稳定性，以及在  $\beta_+$  处向复本对称性破缺的转变也类似。

随着  $\alpha$  增大，与球形情形的差别变得更加明显。对  $\alpha_c \simeq 0.833$ ，有  $k_0 = \ln 2$ （见图 11.3），这意味着典型胞元只包含超立方体的单个点。对更大的  $\alpha$ ，典型胞元为空，以概率 1 找不到能够实现随机输入–输出映射的 Ising 耦合向量。因此，要求  $k_0 = \ln 2$  定义了存储容量  $\alpha_c$ ，其数值当然与第 6.3 节中得到的相同。

继续增大  $\alpha$ ，会达到这样一点：即使是主导体积的胞元也小到只包含单个耦合向量。在对应值  $\alpha_d \simeq 1.245$  处，随机选取的向量  $\mathbf{T}$  几乎必定位位于一个没有其他元素的胞元中。这标志着第 7.2 节发现的到完美泛化的不连续转变。与存储问题一样，耦合空间的离散结构阻止版本空间大小连续减小，于是发生不连续转变。用  $k_0 = \ln 2$  与  $k_1 = \ln 2$  分别确定这两个转变的处方，当然与第 6.3 节和第 7.2 节中使用的零熵判据完全相同（比较习题 11.4）。

对更大的  $\alpha$ ，自由能计算中向  $q_1 = 1$  的不连续转变会在多重分形谱中产生一个间隙。连续部分在某个  $k_{\max} < \ln 2$  处结束，谱由孤立点  $(\ln 2, \ln 2)$  补全，如图 11.3 中  $\alpha = 1.4$  的特殊情形所示。这个点对应于大量（即  $2^N$  个）只包含单个耦合向量的胞元，它们同时主导胞元数目和耦合空间体积。另有少数胞元要大得多，而一整段胞元大小完全没有实现。

最后注意，在 Ising 感知机情形中，可以用精确枚举技术数值确定函数  $c(k)$ ，这为解析结果提供了有价值的检验 [174]。

### 11.3 内部表示的多重分形组织

对上一节引入的技术稍作修改，也能改进我们对具有内部自由度的神经网络（例如多层网络）存储与泛化性质的理解。反楔形感知机是第 7.3 节作为多层网络玩具模型引入的；这种方法在它上面展示得最为简洁。

我们首先回到习题 7.6 中研究过的反楔形感知机存储问题。使用输入–输出关系 (7.11)，并不失一般性地假设所有  $\mu$  都有  $\sigma^\mu = 1$ ，则输入序列  $\{\xi^\mu\}$  的 Gardner 体积为

$$\Omega(\xi^\mu) = \int d\mu(\mathbf{J}) \prod_{\mu} \theta_{\gamma} \left( \frac{\mathbf{J} \xi^\mu}{\sqrt{N}} \right), \quad (11.21)$$

其中  $\theta_{\gamma}(x) = \theta((x - \gamma)x(x + \gamma))$  是适当的指示函数。在复本对称 ansatz 内，quenched 熵为

$$s = \frac{1}{N} \langle \ln \Omega(\xi^\mu) \rangle_{\xi^\mu} = \text{extr}_q \left[ \frac{1}{2} \ln(1 - q) + \frac{q}{2(1 - q)} + \alpha \int Dt \ln H_{\gamma}(t) \right], \quad (11.22)$$

其中

$$H_{\gamma}(t) = H \left( \frac{\sqrt{q}t + \gamma}{\sqrt{1 - q}} \right) - H \left( \frac{\sqrt{q}t}{\sqrt{1 - q}} \right) + H \left( \frac{\sqrt{q}t - \gamma}{\sqrt{1 - q}} \right). \quad (11.23)$$

取  $q \rightarrow 1$  的极限，可得存储容量

$$\alpha_c^{-1} = \int_0^{\gamma/2} Dt t^2 + \int_{\gamma/2}^{\infty} Dt (t - \gamma)^2. \quad (11.24)$$

这个表达式极大地高估了存储容量。事实上，已知对所有  $\gamma > 0$ ，复本对称性都会在  $\alpha = \alpha_c$  处破缺，而一步 RSB 计算给出的  $\alpha_c$  显著降低 [106]。复本对称性破缺发生的直观原因，是解空间高度

不连通；这种不连通来自内部表示存在指数多个选择，这些选择指定样例的正输出究竟是由大于  $\gamma$  的局域场实现，还是由区间  $(-\gamma, 0)$  中的局域场实现。其结果是复本对称性破缺，可靠计算存储容量需要 RSB。

虽然 Gardner 体积对所有  $\alpha$  值显然都是不连通的（比较图 7.2），但对 RSB 的不稳定性只在  $\alpha > \alpha_{\text{RSB}}(\gamma) > 0$  时出现，这说明解空间结构与复本对称性稳定性之间的关系更加微妙。内部表示的组织事实证明是改进理解这一关系的关键。事实上，总 Gardner 体积 (11.21) 可分解为对应于内部表示某一具体选择的胞元：

$$\Omega(\xi^\mu) = \text{Tr}_\tau \Omega(\tau; \xi^\mu), \quad (11.25)$$

其中

$$\Omega(\tau; \xi^\mu) = \int d\mu(\mathbf{J}) \prod_\mu \theta_\gamma \left( \frac{\mathbf{J}\xi^\mu}{\sqrt{N}} \right) \theta \left( \frac{\mathbf{J}\xi^\mu}{\sqrt{N}} \tau^\mu \right). \quad (11.26)$$

乘积中第一项选出所有实现正确输出的耦合  $\mathbf{J}$ ，而第二个  $\theta$  函数进一步把总解体积分解成对应于特定内部表示向量  $\tau = \{\tau^\mu\}$  的子集。这里  $\tau^\mu = +1$  表示  $\mathbf{J}\xi^\mu/\sqrt{N} > \gamma$ ，而  $\tau^\mu = -1$  表示  $-\gamma < \mathbf{J}\xi^\mu/\sqrt{N} < 0$ 。

现在引入对数体积尺度  $k(\tau; \xi^\mu) = -\ln \Omega(\tau; \xi^\mu)/N$ ，并按与上一节类似的方式计算给定体积的胞元数  $\mathcal{N}(k) = \exp(Nc(k))$ 。假设复本对称，仍须引入两个序参量： $q_1$  给出实现所有输入的同一内部表示的两个耦合向量之间的典型重叠； $q_0$  表示大小相等但对应于不同内部表示向量  $\tau$  的胞元中，两个耦合向量之间的典型重叠。自由能表达式为（比较 (11.15)）

$$\begin{aligned} -\beta f(\beta) = \text{extr}_{q_0, q_1} & \left[ \frac{\beta-1}{2} \ln(1-q_1) + \frac{1}{2} \ln(1-q_1 + \beta(q_1 - q_0)) \right. \\ & + \frac{\beta q_0}{2(1-q_1 + \beta(q_1 - q_0))} \\ & \left. + \alpha \int Dt_0 \ln \int Dt_1 \left[ H_+^\beta + (H_- - H_0)^\beta \right] \right], \\ H_\pm = H & \left( \frac{\pm\gamma + \sqrt{q_0}t_0 + \sqrt{q_1 - q_0}t_1}{\sqrt{1-q_1}} \right), \quad H_0 = H \left( \frac{\sqrt{q_0}t_0 + \sqrt{q_1 - q_0}t_1}{\sqrt{1-q_1}} \right). \end{aligned} \quad (11.27)$$

显然，我们通常不能再期望  $q_0 = 0$ ；事实上， $q_0$  应当类似于标准 Gardner 方法中  $q$  的值，后者给出来自解空间的两个耦合的重叠，而不管它们实现了哪一种内部表示。

图 11.4 展示了对 (11.27) 进行数值分析所得的一些典型多重分形谱结果。定性行为与简单感知机类似。同样，曲线最大值给出最频繁胞元的大小与数目，而解空间体积由 (11.18) 定义的大小为  $k_1$  的胞元主导。

当  $\alpha$  较小时，典型胞元非空，即  $k_0 < \infty$ ，所有可能的内部表示都可实现，即  $c(k_0) = \alpha \ln 2$ 。随着存储比增大，胞元变得更小且数目更多，直到某个  $\alpha$  值之后不再可能实现所有  $2^{\alpha N}$  个不同内部表示，于是  $k_0 \rightarrow \infty$  且  $c(k_0) < \alpha \ln 2$ 。注意，只要还剩下至少一个内部表示  $\tau$ ，存储问题就可以被解决。因此，我们预期存储容量  $\alpha_c$  对应于  $c(k_0) = \lim_{k \rightarrow \infty} c(k) = 0$  的点。不过，在这之前还存在另一个值  $\alpha_{\text{disc}} < \alpha_c$ ，在该值处  $c(k_1)$  变为负数。此时，主导解空间体积的胞元数在  $N$  中变成亚指数的。事实表明，对多数  $\gamma$  值，有  $\alpha_{\text{disc}} \simeq \alpha_{\text{RSB}}$ 。当  $\alpha < \alpha_{\text{disc}}$  时，Gardner 体积由指数大量的胞元主导。从解空间中随机抽取的两个向量  $\mathbf{J}^a$  与  $\mathbf{J}^b$  因而以压倒性概率属于不同内部表示，其相互重叠总是由  $q_0$  给出。所以，尽管 Gardner 体积由大量不连通区域组成，只有一个重叠尺度可观测，复本对称描述是合适的。相反，当  $\alpha > \alpha_{\text{disc}}$  时，只剩下少数大小为  $k_1$  的胞元，而它们仍然主导解体积。此时抽到同一胞元中两个耦合向量的概率非零，第二个重叠  $q_1$  变得相关。在聚






图 11.4: 反楔形感知机的 Gardner 体积分解为不同内部表示所对应胞元时的多重分形谱。这里  $\gamma = 1$ ,  $\alpha = 0.1, 0.5, 1.0, 2.0$ , 以及  $\alpha = \alpha_{\text{disc}} \sim 3.0$  和  $\alpha = \alpha_c \sim 4.6$  (从左到右)。负斜率部分以点线表示; 虚线对应于  $c$  的负值。圆圈标出主导总 Gardner 体积的胞元大小  $k_1$ 。

焦总解空间的标准 Gardner 计算中, 这表现为 RS 鞍点的不稳定性。因此, 多重分形方法澄清了: 向 RSB 的转变与  $c(k_1) = 0$  有关, 而存储容量由  $c(k_0) = 0$  给出。如果  $c(k_0)$  的确定可在复本对称内完成, 那么与总 Gardner 体积的一步 RSB 计算相比, 多重分形技术显然具有优势。两种计算的数学复杂度相当, 但前者被认为是精确的, 而后者只是近似方案的第一步。

$\alpha_c$  与  $c(k_0) = 0$  的点, 以及  $\alpha_{\text{disc}}$  与  $\alpha_{\text{RSB}}$  分别并不完全重合, 这可追溯到 (11.27) 与一步 RSB 中 Gardner 体积 quenched 熵表达式之间的差异。造成这种差异的原因是, 不同内部表示的胞元与遍历组分这两个概念并不等价 [177]。不过, 这些定量差异很小, 不会削弱多重分形方法给出的定性洞见。

上述对存储性质的分析可以扩展到反楔形感知机的泛化问题。除了胞元的数目和大小之外, 多重分形谱还描述胞元相对于教师耦合  $\mathbf{T}$  的相对取向。该计算允许确定随着训练集大小增大, 胞元收缩与胞元消失对泛化误差下降各自的重要性, 并对第 7.3 节中讨论的从弱泛化相到强泛化相的不连续转变给出细致理解。在前一相中, 多重分形谱与图 11.4 所示纯存储问题的结果非常相似, 这强调了样例背后的规则被探测得多么差。此外, 在主导相中总有  $c(k_1) > 0$ , 这解释了为什么在泛化问题中复本对称性总是成立, 尽管版本空间是不连通的。

## 11.4 讨论

通过分析随机输入在耦合空间中诱导出的镶嵌结构, 可以获得许多关于简单神经网络模型学习性质的有趣洞见。不断演化的随机胞元结构的几何标度性质, 由多重分形谱定量刻画; 在统计力学框架内, 这个谱可以被显式计算。对于简单感知机, 这种方法统一了 Cover 与 Gardner 对存储问题的互补途径, 也纳入了对泛化性质的描述。将它用于分析具有内部自由度的网络时, 可以详细



刻画内部表示的组织，而这种组织在标准 Gardner 总版本空间体积计算中是隐藏的。因此，复本对称性不稳定性与解空间连通性之间的微妙关系可被进一步澄清，而且在标准框架中需要复本对称性破缺的系统，也可用复本对称表达式加以研究。

最后给出一份简短文献指南。胞元大小分布与感知机学习性质的相关性最早在 [78] 中提到。第一个显式多重分形谱计算，是在 [177] 中针对反楔形感知机存储问题完成的。球形感知机和 Ising 感知机的详细分析见 [179]；包含有限训练误差的一个变体见 [180]。Ising 感知机学习前耦合分布的多重分形性质在 [181] 中讨论。反楔形感知机的泛化问题在 [182] 中分析，Ising 反楔形感知机见 [183]。该方法在简单多层网络中的应用见 [184, 185, 186]。一种使用不同指示函数判断胞元是否存在的相关有趣方法见 [187]。

## 11.5 习题

11.1 证明不存在任何超平面取向能够在图 11.1 中生成超过 14 个胞元。

11.2 不使用 (11.11) 中的 quenched 平均，而使用  $\Omega^\beta(\sigma)$  的 annealed 平均，重新推导球形感知机多重分形谱的结果 (11.16)。为什么这个计算对应于  $q_0 = 0$ ？

11.3 证明 (11.9) 意味着  $k = k_0$  对应于  $\beta = 0$ ，而  $k = k_1$  对应于  $\beta = 1$ 。利用这些对应关系，从多重分形谱 (11.16) 的适当极限推出 Gardner 体积的 quenched 熵表达式 (6.13)，以及版本空间的 quenched 熵表达式 (2.41)。

11.4 在 (11.2) 中作替换 (11.20)，证明在 Ising 感知机中，用于确定存储容量和完美泛化转变的要求  $k_0 = \ln 2$  与  $k_1 = \ln 2$ ，分别等价于第 6.3 节和第 7.2 节使用的相应零熵判据。

11.5 由 (11.16) 证明，对  $\alpha \geq 2$ ，总胞元数由

$$\lim_{k \rightarrow \infty} c(k) = \alpha \ln \alpha - (\alpha - 1) \ln(\alpha - 1) \quad (11.28)$$

描述。将这个表达式同习题 6.4 中得到的 Cover 结果 (6.18) 的渐近形式比较。

(提示：对  $\alpha > 2$ ，极限  $\beta \rightarrow 0$  意味着  $q_1 \rightarrow 1$ ，且  $\beta/(1 - q_1)$  保持 1 阶，这与最频繁胞元极小、 $k_0 \rightarrow \infty$  的事实一致。使用这个标度可得  $\lim_{\beta \rightarrow 0} \beta k(\beta) = 0$ 。)

11.6 在习题 3.8 中，我们发现对所有  $\alpha$ ，随机新样例都会以概率 1 把版本空间切成两部分。另一方面，由 Cover 结果 (6.18) 可知，当  $p > 2N$  时，总分类数，也就是总胞元数，不再随  $p$  指数增长。如何协调这两个结果？

11.7 在习题 10.10 中，考虑了单位区间上示性函数学习的最坏可能教师。使用多重分形分析的结果，对感知机学习提出一个类似问题是很自然的。对 (11.15) 取极限  $\beta \rightarrow \infty$ ，可提取关于最大胞元的信息；该胞元对应于“最难教师”。为了执行这个极限，需要注意  $q_0$  与  $q_1$  会收敛到同一个  $q$  值，因为只剩下单个胞元。引入  $x = \beta(q_1 - q_0)$ ，证明

$$\begin{aligned} f(\beta \rightarrow \infty) = & -\text{extr}_{q,x} \left[ \frac{q}{2(1-q+x)} + \frac{1}{2} \ln(1-q) \right. \\ & \left. + \alpha \int Dt \text{extr}_z \left( -\frac{1-q}{2x} z^2 + \ln H \left( -\frac{\sqrt{q}t}{\sqrt{1-q}} + z \right) \right) \right]. \end{aligned} \quad (11.29)$$

通过自洽地假设在大  $\alpha$  极限中  $x \rightarrow 3/2$ ，且  $1 - q \sim 1/(\alpha^{2/3} \ln \alpha)$ ，从这个表达式中提取泛化误差在大  $\alpha$  时的渐近行为。将结果同 VC 定理比较，并讨论该定理的适用性以及 (11.29) 的可靠性；更多细节见 [169]。

## 第十二章 多层网络

前几章中，我们利用感知机结构简单、允许相当细致的数学分析这一事实，描述了感知机学习的各种性质。然而，感知机有一个重大缺陷，并正是这一缺陷导致它在 20 世纪 60 年代末一度衰落：它只能实现线性可分的 Boolean 函数，因此计算能力相当有限。一个显然的推广，是在输入与输出之间放置一层或多层形式神经元的前馈多层网络（比较图 1.1c）。一方面，这类网络可以看成由单个感知机构成，因此其理论分析可建立在我们已经为感知机完成的工作之上。另一方面，内部自由度的加入使它们在计算上强大得多。事实上，多层神经网络能够实现输入与输出之间所有可能的 Boolean 函数，这使它们在实际应用中很有吸引力。研究多层网络还有神经生理学动机，因为生物神经网络中的大多数神经元都是中间神经元，它们既不直接连接感觉输入，也不直接连接运动输出。

与简单感知机相比，多层网络复杂度更高，这使其学习能力的统计力学分析更加困难；一般而言，也排除了像感知机那样一般而细致的刻画。不过，对于定制结构和合适的学习场景，仍可得到非常有启发性的结果，本章将讨论其中一部分。

鉴于多层网络标准学习设置更复杂，限制到在线学习处方所带来的简化甚至比在感知机中更加关键。因此，我们将用整整一章来回顾多层网络在线学习中的一些技术和结果，并把这个主题推迟到第十三章。

### 12.1 基本结构

前馈多层神经网络由若干层形式神经元定义，只有相邻层之间通过有向突触耦合相连，参见第 1.1 节。感知机的布局基本固定，而多层网络类中的结构则有相当大的可变性，可在隐层数和隐层大小上有所不同。为了进行有意义的理论分析，首先必须选取一些简单但仍能展示大多数相关性质的情形。作为第一步，我们再次限制到只有单个输出单元的网络。由于同一层的元素之间没有耦合，具有多个输出的网络只比一组单输出网络稍微复杂一点。

此外可以证明，具有单个隐层且含有足够多单元的前馈神经网络，已经能够实现输入层与输出层之间的任意 Boolean 函数 [188]。这个引人注目的事实使我们可以进一步把注意力限制到只有一个隐层的网络。顺便提到，对连续神经网络的相应结果 [189] 表明，只要在隐层中放入足够多的单元，单隐层多层网络就能以任意期望精度逼近输入变量的任意函数<sup>1</sup>（另见习题 12.3）。

因此，含有  $K$  个元素的单隐层多层网络由  $K$  个耦合向量  $\mathbf{J}_1, \dots, \mathbf{J}_K$  指定，它们把  $N$  个输入  $S_i$  连接到隐单元  $\tau_1, \dots, \tau_K$ （见图 12.1）。给定输入  $\mathbf{S}$  时，隐单元的活性为

$$\tau_k = \operatorname{sgn} \left( \frac{\mathbf{J}_k \mathbf{S}}{\sqrt{N}} \right), \quad k = 1, \dots, K. \quad (12.1)$$

向量  $\boldsymbol{\tau} = (\tau_1, \dots, \tau_K)$  称为输入  $\mathbf{S}$  的内部表示。隐单元的活性状态通过耦合  $W_1, \dots, W_K$  决定输出

<sup>1</sup>这个结果与 Kolmogorov 受 Hilbert 第 13 问题启发而得到的一个著名定理 [190] 密切相关。粗略地说，该定理表明，多变量的任意非线性函数都可以写成单变量函数的线性组合。

$\sigma$ :

$$\sigma = \text{sgn} \left( \frac{1}{\sqrt{K}} \sum_{k=1}^K W_k \tau_k \right) = \text{sgn} \left( \frac{\mathbf{W}\boldsymbol{\tau}}{\sqrt{K}} \right). \quad (12.2)$$




图 12.1: 具有一个隐层的多层网络的全连接结构 (左) 与树结构 (右)。

即使只有一个隐层，网络仍然相当复杂，到目前为止还无法在统计力学框架内作一般分析。因此，为了进一步简化，我们假设隐单元数  $K$  远小于输入单元数  $N$ 。在最终总会考虑的热力学极限  $N \rightarrow \infty$  中，这意味着  $K$  要么保持 1 阶，要么  $K \lesssim \ln N$ 。此外，一般而言，我们将假定隐单元数在学习过程中不变，尽管这排除了一些有趣的启发式学习规则；在这些规则中，隐单元会不断加入，直到能够完成期望任务（比较习题 12.7）。

对于  $K \ll N$ ，可以想象，如果从隐层到输出层的少数几个耦合根本不被修改，多层网络的学习能力也不会受到实质影响 [191]。稍微更一般地，我们可以假定从内部表示  $\boldsymbol{\tau}$  到输出  $\sigma$  的映射由一个预先布线的 Boolean 函数  $F(\boldsymbol{\tau})$  编码，整个学习过程只涉及输入与隐单元之间耦合  $\mathbf{J}_1, \dots, \mathbf{J}_K$  的适应。常用的  $F$  包括

$$F(\tau_1, \dots, \tau_K) = \prod_{k=1}^K \tau_k \quad (12.3)$$

和

$$F(\tau_1, \dots, \tau_K) = \text{sgn} \left( \frac{1}{\sqrt{K}} \sum_{k=1}^K \tau_k \right), \quad (12.4)$$

它们分别给出所谓奇偶机和委员会机 [192]。注意，若要借助 McCulloch–Pitts 神经元实现奇偶函数 (12.3)，需要额外增加一层隐单元。另一方面，委员会机很容易通过令所有  $k$  都有  $W_k = 1$  来实现。还要注意，当 Ising 耦合  $W_k = \pm 1$  时，委员会机已经是最一般的两层网络，因为输入-输出映射在变换  $J_{ki} \rightarrow -J_{ki}$ 、 $W_k \rightarrow -W_k$  下不变。

于是，我们最终得到图 12.1 所示的两类多层网络原型。这两种结构之间剩下的重要差别在于输入层与隐层的连接方式。在树结构中，每个隐单元从不同输入单元接收输入；在全连接结构中，所有隐单元都连接到所有输入。因此，这两种情形有时也分别称为隐单元的非重叠感受野与重叠感受野。注意，全连接情形在输入层与隐层之间有多出  $K$  倍的可调耦合。对树结构，方便的做法是改变隐单元处场的归一化，在 (12.1) 中用  $\sqrt{N/K}$  代替  $\sqrt{N}$ 。

人们也许会怀疑，本章导言中提到的多层网络那些惊人的计算能力，在上述严厉简化之后还剩下多少。事实上， $K = 3$  的委员会机看起来可能相当“感知机式”，因此我们希望大幅改进感知机性能的期待也许会落空。正如下面将看到的，确实存在一些情形，其中上述简单多层结构表现出的

学习性质与感知机相当相似。不过，相比感知机，它们也有重要改进。还要注意，根据第 10 章的发现，这些特殊多层结构即便只有适度的存储容量结果，也意味着有吸引力的泛化能力。

作为基本学习任务，我们将再次考虑存储问题，即网络实现独立随机产生的输入-输出映射的能力；以及泛化问题，其中目标映射必须由带标签样例推断出来。在后一种情形中，和以前一样，把要学习的规则想象为由教师网络表示是方便的。当然，教师和学生必须具有相同的输入维数，但它们的隐层结构可以不同。教师有  $M$  个隐单元、学生有  $K$  个隐单元的一般情形，包括不可实现情形 ( $K < M$ )、可实现情形 ( $K = M$ )，以及所谓过可实现情形 ( $K > M$ )，其中学生复杂度大于教师复杂度。三种情形都表现出有趣的泛化行为。

与感知机情形一样，统计力学技术同热力学极限  $N \rightarrow \infty$  相联系，只有当样例数  $p$  随系统大小标度时，才得到非平凡结果。与感知机不同，后者的输入空间维数、可调参数数目和 VC 维数都重合；对多层网络，不同标度区域都可能有意义。对树结构，显然的选择仍是  $p = \alpha N$ 。对全连接网络， $p = \alpha N$  与  $p = \alpha NK$  两种标度都有意义，并对应于泛化过程中的不同区域。

根据感知机中的经验，我们预期不同学习场景的统计力学分析会产生适当序参量的方程，这些序参量指定教师与学生耦合向量之间的重叠。泛化误差作为这些序参量的函数，原则上可按类似 (2.3) 的推导方式得到，尽管结果很容易变得相当繁琐。对树结构，教师和学生输入层与隐层之间的子感知机存在唯一配对，而且所有子感知机具有相同统计性质。这使我们能够利用感知机得到的结果。

先考虑一个树奇偶机向同结构教师学习的可实现情形。根据 (12.3)，若隐层中不一致的数目为奇数，则两个相应输出不同。记  $\epsilon_k$  为学生第  $k$  个隐单元与教师相应隐单元不一致的概率， $\text{Prob}(\text{odd/even})$  为不一致数目为奇数或偶数的概率。由奇偶函数 (12.3) 的置换对称性，以及单个感知机泛化误差的自平均性质，可知所有  $k$  都有  $\epsilon_k = \epsilon_\tau$ ，并有 [193]

$$(1 - 2\epsilon_\tau)^K = ((1 - \epsilon_\tau) - \epsilon_\tau)^K = \text{Prob}(\text{even}) - \text{Prob}(\text{odd}) = 1 - 2\epsilon^{\text{PAR}},$$

从而

$$\epsilon^{\text{PAR}} = \frac{1}{2} [1 - (1 - 2\epsilon_\tau)^K]. \quad (12.5)$$

对委员会树，计算更复杂，因为教师的不同内部表示彼此并不等价。例如，当  $K = 3$  时，若教师内部表示为  $(+, +, +)$ ，学生只有在两个隐单元未能复现相应教师值时才会误分类。另一方面，如果教师内部表示为  $(+, +, -)$ ，学生会在两种情形失败：在  $+$  位点犯一个错而在  $-$  位点不犯错，或者两个  $+$  位点都错。合起来得到

$$\epsilon_{K=3}^{\text{COM}} = \frac{3}{2}\epsilon_\tau - \frac{3}{2}\epsilon_\tau^2 + \epsilon_\tau^3. \quad (12.6)$$

对更大的  $K$ ，处理组合复杂性可得，在再次假设所有  $k$  都有  $\epsilon_k = \epsilon_\tau$  时 [194]，

$$\epsilon_K^{\text{COM}} = \frac{1}{2} - \frac{1}{2\pi^2} \sum_{\substack{k=0 \\ k \text{ even}}}^{K-1} \binom{K}{k} \left[ \frac{\Gamma(\frac{K-k}{2}) \Gamma(\frac{k+1}{2})}{\Gamma(\frac{K+1}{2})} \right]^2 (1 - 2\epsilon_\tau)^{K-k}. \quad (12.7)$$

对很大的  $K$ （但仍有  $K \ll N$ ），注意  $k$  求和的主要贡献来自大的  $k$ 。使用 Stirling 公式给出  $\Gamma$  函数的渐近行为，可得

$$\epsilon_{K \rightarrow \infty}^{\text{COM}} = \frac{1}{\pi} \arccos(1 - 2\epsilon_\tau). \quad (12.8)$$

这个简单结果也可直接由如下假设推出：大  $K$  时隐单元之间只存在很弱相关；然后完全仿照 (2.3) 的推导进行（比较习题 12.4）。




图 12.2: 输入空间按照奇偶机（左）和委员会机（右）输出所作的划分；两者都有  $K = 3$  个隐单元且各自阈值非零。

## 12.2 界

由于结构更复杂，多层网络的学习与泛化性质比感知机更难分析。因此，精确结果很少可能得到，且一般需要相当大的数学工作。在这种情况下，可由相对简单方法推出的近似特别有意义。

先尝试把 Cover 对存储问题的方法推广到多层网络。感知机的特征是单个分离超平面，而现在在有  $K$  个这样的平面，对应于多层网络的  $K$  个子感知机。这些超平面把输入空间划分成不同总体分类的区域。图 12.2 展示了  $K = 3$  奇偶机和委员会机的这类划分。




图 12.3:  $N = 2$  维中两组  $p = 6$  个输入。白圈（黑圈）表示正（负）输出。左图所示标记无法由  $K = 2$  奇偶机实现；但若输入的相对取向如右图，则所有标记都能由这样的机器实现。

类似第 6.2 节中的分析，我们现在可以尝试计数不同超平面取向可在  $p$  个输入上诱导的不同分类数。为此，需要确定加入一个新输入时可能划分数目的变化。使这种方法不可行的主要障碍是，不同划分的数目不仅依赖于输入数目，还依赖于它们彼此的相对位置。图 12.3 用一个简单例子展示了这一点。因此，与感知机情形不同，一般位置中的所有  $p$  个输入集合并不给出相同的划分数目。这排除了推导类似 (6.17) 的简单递推关系。

尽管无法沿 Cover 方法完成完整分析，仍可推出多层网络存储容量的一个有用界。为明确起见，考虑一个具有  $K$  个隐单元的树结构网络。对于一般位置中的  $p = \alpha N$  个输入，由 (6.18) 可知，每个子感知机最多可实现  $C(p, N/K)$  个不同分类，因此最多有  $[C(p, N/K)]^K$  个不同内部表示。不同输出串的数目显然小于内部表示数，因为若干内部表示会映射到同一输出。使用不等式 (10.7)，可得不同输出序列数与不同输入集合数之比由上界给出：

$$\frac{[C(p, N/K)]^K}{2^p} \lesssim \exp(N[1 + \ln \alpha + \ln K - \alpha \ln 2]). \quad (12.9)$$

存储容量  $\alpha_c$  定义为该比值降到小于  $1/2$  时的  $\alpha$  值。对大  $N$ ，当指数改变符号时，这会突变地发



生。因此得到  $\alpha_c < \alpha^{\text{MD}}$ , 其中  $\alpha^{\text{MD}}$  由方程

$$0 = 1 + \ln \alpha^{\text{MD}} + \ln K - \alpha^{\text{MD}} \ln 2 \quad (12.10)$$

定义。这就是具有  $K$  个隐单元的树结构多层网络存储容量的所谓 Mitchison–Durbin 界 [195]。对大的  $K$ , 渐近地有

$$\alpha_c \lesssim \alpha^{\text{MD}} \sim \frac{\ln K}{\ln 2}. \quad (12.11)$$

对全连接结构作类似计算, 渐近地得到

$$\alpha_c \lesssim \alpha^{\text{MD}} \sim K \frac{\ln K}{\ln 2}. \quad (12.12)$$

这些界为用复本方法进行更精确计算提供了有价值的方向 (比较习题 12.6)。

转向泛化问题, 可用第 2.1 节对感知机使用过的 annealed 近似, 得到泛化误差随训练集大小变化的近似结果。对树结构这尤其简单, 因为树中泛化误差与子感知机重叠之间的关系 (12.5) 和 (12.7), 允许容易地推出熵部分和能量部分。

例如, 对于奇偶树, 可得 (比较 (2.6))

$$\begin{aligned} s^{\text{ann}}(\epsilon) &= \frac{1}{2} \ln(1 - R^2(\epsilon)) + \alpha \ln(1 - \epsilon) \\ &= \frac{1}{2} \ln \left[ 1 - \sin^2 \left( \frac{\pi}{2} (1 - 2\epsilon)^{1/K} \right) \right] + \alpha \ln(1 - \epsilon). \end{aligned} \quad (12.13)$$

简单的数值极值化给出泛化误差  $\epsilon(\alpha)$  随训练集大小的近似曲线, 如图 12.4 所示。对所有  $K > 2$ , 都存在从由  $\epsilon = 0.5$  表征的纯猜测态出发的不连续转变; 该转变发生在开区间  $(0, 0.5)$  中  $s^{\text{ann}}(\epsilon)$  的最大值与  $s^{\text{ann}}(0.5)$  相等时。因此, 在 annealed 近似内, 对所有  $K > 1$  都得到第 7.3 节和第 8.3 节已经讨论过的延迟学习。正如下面将看到的 (比较第 12.4 节), 精确结果与这些简单近似在定性上相似。

委员会树的结果可以类似得到: 在  $K \rightarrow \infty$  时使用 (12.8), 或对有限  $K$  数值反演 (12.7)。相应曲线也包含在图 12.7 中。

有趣的是, 泛化问题熵的 annealed 近似也可用于推出存储容量  $\alpha_c$  的一个下界 [196]。这对奇偶树同样特别有效。先注意, 在 annealed 近似中得到的、 $\epsilon$  从初始值 0.5 不连续下降的点  $\alpha_d^{\text{ann}}(K)$ , 是理论真实转变点  $\alpha_d(K)$  的下界, 另见图 12.6。原因如下。转变发生在  $s(0.5, \alpha)$  等于  $0 < \epsilon < 0.5$  区间内  $s(\epsilon, \alpha)$  的最大值时。对  $\epsilon = 0.5$ , annealed 熵和 quenched 熵重合, 因为  $R = 0$ ; 而对  $\epsilon < 0.5$ , annealed 熵是真实熵的上界。因此, 精确理论中的转变永远不会早于 annealed 近似中的转变。此外,  $\alpha < \alpha_d$  时  $\epsilon = 0.5$  意味着学生可以在不与教师对齐的情况下复现所有映射, 即把输出看成与输入无关。于是任务等同于存储问题, 因此必有  $\alpha_d \leq \alpha_c$ 。

预期大  $K$  时转变发生在越来越大的  $\alpha$  值处, 并跳到越来越小的  $\epsilon$  (比较图 12.4), 可由小  $\epsilon$  时  $s^{\text{ann}}(\epsilon)$  的渐近形式推出  $\alpha_d^{\text{ann}}$  的大  $K$  行为。由 (12.13) 容易证明, 在这一极限中

$$s^{\text{ann}}(\epsilon) \sim \ln 2 + \ln \epsilon - \ln K - \alpha \epsilon. \quad (12.14)$$

对  $\epsilon$  极值化, 并令结果等于  $s^{\text{ann}}(\epsilon = 0.5) = \alpha \ln 2$ , 主阶得到  $\alpha_d \sim \ln K / \ln 2$ 。这个下界渐近上与 Mitchison–Durbin 界 (12.11) 相匹配, 而后者是一个上界。因此, 奇偶树存储容量的渐近行为必为

$$\alpha_c \sim \frac{\ln K}{\ln 2}, \quad (12.15)$$




图 12.4: 树结构奇偶机的泛化误差随训练集大小的变化; 隐单元数  $K = 2, 3, 4, 5, 6, 7$  (从左到右)。结果来自 annealed 近似 (12.13)。

这是仅由简单界得到的非平凡结果。注意, 结合习题 10.5, 这个结果还意味着对大  $K$  奇偶树, 其 VC 维数显著大于自由参数数目  $N$ 。

当然, 第 10 章推出的一般界也适用于多层网络。特别是, 泛化误差的界 (10.20) 对预期行为给出了有价值的提示。最后, 第 4.2 节末尾引入的高温学习也可有效用于多层网络学习场景的近似结果。

## 12.3 存储问题

实现随机输入-输出映射的问题, 是研究多层网络学习能力的合适起点。因此, 在本节中我们将简要讨论与隐单元存在相关的存储问题特殊性。

先考虑树结构网络, 并固定隐层到输出的映射  $\sigma = F(\tau_1, \dots, \tau_K)$ 。实现  $p$  个输入-输出对  $\{\xi^\mu, \sigma^\mu\}$  的耦合  $\mathbf{J}_k$  的联合体积为

$$\Omega(\xi^\mu, \sigma^\mu) = \int \prod_{k=1}^K d\mu(\mathbf{J}_k) \prod_{\mu} \theta \left[ \sigma^\mu F \left( \frac{\mathbf{J}_1 \xi_1^\mu}{\sqrt{N/K}}, \dots, \frac{\mathbf{J}_K \xi_K^\mu}{\sqrt{N/K}} \right) \right], \quad (12.16)$$

其中

$$d\mu(\mathbf{J}_k) = \prod_{i=1}^{N/K} \frac{dJ_{ki}}{\sqrt{2\pi e}}, \quad (12.17)$$

$\xi_k^\mu$  表示输入中馈入第  $k$  个隐单元的适当部分 (比较图 12.1)。

按照附录 B 中概述的通常程序, 可计算  $\ln \Omega(\xi^\mu, \sigma^\mu)$  对  $\xi^\mu$  和  $\sigma^\mu$  标准无偏分布的平均。能量

部分  $G_E(q^{ab})$  最简洁的写法，是把积分变量  $\lambda_k^a$  分成符号  $\tau_k^a$  与绝对值：

$$\int \prod_{k,a} d\lambda_k^a f(\lambda_k^a) = \text{Tr}_{\{\tau_k^a\}} \int_0^\infty \prod_{k,a} d\lambda_k^a f(\lambda_k^a \tau_k^a). \quad (12.18)$$

对序参量矩阵使用复本与位点对称 ansatz

$$q_k^{ab} = \frac{K}{N} \sum_{i=1}^{N/K} J_{ki}^a J_{ki}^b = q, \quad a \neq b, \quad (12.19)$$

可得 quenched 熵

$$s(\alpha) = \text{extr}_q \left[ \frac{1}{2} \ln(1-q) + \frac{q}{2(1-q)} + \alpha \int \prod_k Dt_k \ln \text{Tr}_{\{\tau_k\}} \theta(F(\tau_1, \dots, \tau_K)) \prod_k H\left(\frac{\sqrt{q} t_k \tau_k}{\sqrt{1-q}}\right) \right]. \quad (12.20)$$

这个结果有一个简单解释。把 (12.20) 与感知机熵 (6.13) 比较可知，对数中的表达式不过是对所有给出正确输出的可能内部表示求和，每个内部表示的权重是相应内部表示下各个子感知机 Gardner 体积的乘积。

如第 6.1 节所述，存储容量可由熵表达式中的  $q \rightarrow 1$  极限确定。对 (12.20) 取这个极限得到

$$\frac{1}{\alpha_c} = K \int_0^\infty Dt t^2 g(t), \quad (12.21)$$

其中函数  $g(t)$  依赖于所考虑的特殊 Boolean 函数  $F(\tau_1, \dots, \tau_K)$ 。使用 (12.3) 与 (12.4)，对奇偶树可得（比较习题 12.6）

$$g^{\text{PAR}}(t) = [2H(t)]^{K-1}, \quad (12.22)$$

而对委员会树可得

$$g^{\text{COM}}(t) = \sum_{k=0}^{(K-1)/2} \binom{K-1}{k} [H(t)]^{K-1-k} [1-H(t)]^k. \quad (12.23)$$

由这些表达式得到的存储容量  $\alpha_c$  相当大。例如，对奇偶树， $K = 2, 3, 4, 5$  时分别有  $\alpha_c = 5.5, 10.4, 16.6, 24.1$ ；而对委员会树， $K = 3, 5, 7$  时得到  $\alpha_c = 4.02, 5.78, 7.31$ 。这让人想起习题 7.6 中反楔形感知机的情况。此外，使用 (12.22) 和 (12.23) 可发现，当隐单元数  $K$  很大时，奇偶树有  $\alpha_c \sim K^2$ ，委员会树有  $\alpha_c \sim \sqrt{K}$ 。这两种渐近行为都违反 Mitchison–Durbin 界 (12.11)，因此 (12.21) 给出的存储容量表达式不可能正确。

沿附录 D 的路线，对 (12.20) 推导中使用的复本对称鞍点进行稳定性分析可知，当  $\alpha > \alpha_{\text{AT}}$  且  $\alpha_{\text{AT}} < \alpha_c$  时，复本对称性确实破缺。因此，对多层网络存储容量的可靠确定一般需要复本对称性破缺。与反楔形感知机情形一样，复本对称性破缺发生的直观原因在于不同内部表示的可能性以及由此产生的解空间不连通性。

使用附录 E 中描述的一步复本对称性破缺，已经对奇偶树 [197] 和委员会树 [198, 199] 的存储容量作了计算。在所有情形中，得到的存储容量都降低，且通常与数值结果符合良好。对奇偶树，可以证明在一步复本对称性破缺中，存储容量满足精确渐近式 (12.15)；这可被看作一个迹象，表明这一层级的复本对称性破缺也许已经给出精确结果，类似于某种相关的随机能量模型 [79, 76]。

对委员会树，计算相当复杂，到目前为止还没有人能在上述框架内推导出  $K \rightarrow \infty$  时  $\alpha_c$  的渐近结果。不过，可以借助第 11 章引入的多重分形技术的一个变体取得进展 [184]。再次类似反楔形感知机的分析（比较第 11.3 节），我们把总 Gardner 体积 (12.16) 分解成对应于不同内部表示的胞元：

$$\Omega(\xi^\mu, \sigma^\mu) = \sum_{\tau} \Omega(\tau; \xi^\mu, \sigma^\mu), \quad (12.24)$$

其中

$$\begin{aligned} \Omega(\tau; \xi^\mu, \sigma^\mu) = & \int \prod_{k=1}^K d\mu(\mathbf{J}_k) \prod_{\mu} \theta \left[ \sigma^\mu F \left( \frac{\mathbf{J}_1 \xi_1^\mu}{\sqrt{N/K}}, \dots, \frac{\mathbf{J}_K \xi_K^\mu}{\sqrt{N/K}} \right) \right] \\ & \times \prod_k \theta \left( \tau_k \frac{\mathbf{J}_k \xi_k^\mu}{\sqrt{N/K}} \right). \end{aligned} \quad (12.25)$$

再次定义  $k(\tau; \xi^\mu, \sigma^\mu) = -(\ln \Omega(\tau; \xi^\mu, \sigma^\mu))/N$ ，这些胞元大小的分布  $c(k)$  可由相应自由能

$$-\beta f(\beta) = \frac{1}{N} \langle \ln \text{Tr}_{\tau} \Omega^{\beta}(\tau; \xi^\mu, \sigma^\mu) \rangle \quad (12.26)$$

经 Legendre 变换得到。与第 11 章一样，内部表示总数与多重分形谱  $c(k)$  的最大值  $c(k_0)$  相关；而由 (11.18) 定义的  $k_1$  处的  $c(k_1)$ ，刻画主导总 Gardner 体积  $\Omega(\xi^\mu, \sigma^\mu)$  的胞元数。类似导出 (11.27) 的复本对称计算给出 [184]

$$\begin{aligned} -\beta f(\beta) = & \text{extr}_{q_0, q_1} \left[ \frac{\beta-1}{2} \ln(1-q_1) + \frac{1}{2} \ln(1-q_1 + \beta(q_1 - q_0)) + \frac{\beta q_0}{2(1-q_1 + \beta(q_1 - q_0))} \right. \\ & + \alpha \int \prod_k D t_k \ln \text{Tr}_{\tau} \theta \left( \frac{1}{\sqrt{K}} \sum_k \tau_k \right) \\ & \left. \times \int \prod_k D s_k H^{\beta} \left( \frac{\sqrt{q_1 - q_0} s_k + \sqrt{q_0} \tau_k t_k}{\sqrt{1 - q_1}} \right) \right]. \end{aligned} \quad (12.27)$$

存储容量被识别为  $c(k_0)$  变成负值时的  $\alpha$ ，因为那时可用内部表示的典型数目变为指数小。由 (12.27) 可按这种方式在大  $K$  下得到主阶

$$\alpha_c \sim \frac{16}{\pi} \sqrt{\ln K}. \quad (12.28)$$

稳定性分析表明，这个计算中使用的复本对称鞍点在  $K \rightarrow \infty$  时是边际稳定的，因此 (12.28) 被认为给出了委员会树存储容量的正确渐近行为。注意，Mitchison–Durbin 界被满足。

与感知机相比，多层网络增强的存储能力主要来自隐层中的额外自由度。内部表示的详细组织表达了不同隐单元之间的分工，可由相关

$$c_{i_1, \dots, i_n} = \frac{1}{\alpha N} \sum_{\mu} \tau_{i_1}^{\mu} \tau_{i_2}^{\mu} \cdots \tau_{i_n}^{\mu} \quad (12.29)$$

刻画。事实表明，当  $\alpha$  趋于存储容量  $\alpha_c$  时，这些相关会趋于由隐单元与输出之间 Boolean 函数  $F(\tau)$  所决定的特定值。利用第 6.4 节中引入的方法的推广，可以显式计算这些相关 [200, 201]。对置换对称 Boolean 函数  $F(\tau)$ ，相关系数只依赖于所包含的隐单元数，即  $c_{i_1, \dots, i_n} = c_n$ 。

作为对不同 Boolean 函数计算  $c_n$  的补充，也可以用相关系数  $c_n$  的具体值替代  $F(\tau)$ ，从而把多层网络近似为一组相关感知机 [202]。这使人们能够考虑具有不同隐层到输出映射  $F(\tau)$  的多层网络之间的平滑过渡。

最后考虑全连接网络，这里我们只报告少数结果。新的主要特征是隐单元之间的置换对称性，它源于所有隐单元都由相同输入馈入（比较图 12.1）。在统计力学计算中，这会导致额外序参量

$$C_{kl}^a = \frac{1}{N} \sum_i J_{ki}^a J_{li}^a, \quad D_{kl}^{ab} = \frac{1}{N} \sum_i J_{ki}^a J_{li}^b, \quad (12.30)$$

它们表示由耦合到相同输入而诱导的隐单元之间的相关。对小  $\alpha$ ，网络处在置换对称相，其中由隐单元置换彼此相关的解属于同一解体积。增大  $\alpha$  通常会导致置换对称性破缺的状态，此时不同隐单元置换对应的解不再彼此连通。在假设复本对称和位点对称时，可以证明对委员会机，在  $\alpha \rightarrow \alpha_c$  且  $q \rightarrow 1$  时  $D \rightarrow C$ ，并且在存储容量处  $C = -1/(K-1)$ 。隐单元之间这种弱反相关与如下事实一致：在存储容量处，大多数输入具有这样的内部表示，其中  $(K+1)/2$  个  $\tau_k$  等于期望输出，而  $(K-1)/2$  个与输出相反。对大的  $K$ ，这些相关消失，提示在此极限中，存储容量可能只是树结构结果乘以  $K$ 。然而使用多重分形技术作更精细研究可得 [203]

$$\alpha_c \sim \frac{16}{\pi - 2} K \sqrt{\ln K}. \quad (12.31)$$

把这个结果同 (12.28) 比较可知，微小相关仍然起作用，并改变了渐近行为的前因子。对全连接奇偶机，可得  $\alpha_c \sim K \ln K / \ln 2$  [204]，它同样饱和 Mitchison–Durbin 界 (12.12)。

## 12.4 奇偶树的泛化

作为多层网络从样例中学习规则问题的一个有启发性的例子，我们考虑如下可实现问题：一个具有  $K$  个隐单元的奇偶树，学习由另一个完全同结构奇偶树给出的目标分类。照常把教师网络的耦合记为  $\mathbf{T}_k$ ，版本空间体积为

$$\Omega(\xi^\mu, \mathbf{T}_k) = \int d\mu(\mathbf{J}) \prod_\mu \theta \left[ \prod_k \frac{\mathbf{T}_k \xi_k^\mu}{\sqrt{N/K}} \prod_k \frac{\mathbf{J}_k \xi_k^\mu}{\sqrt{N/K}} \right]. \quad (12.32)$$

现在已成标准的 quenched 熵计算，最方便地通过利用教师-学生对称性并使用  $n \rightarrow 1$  版本的复本技巧完成（比较第 2.3 节）。在复本对称内，且已知该情形下复本对称成立，可得

$$\begin{aligned} s(\alpha) = \text{extr}_R & \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} \right. \\ & + 2\alpha \int \prod_k Dt_k \left( \text{Tr}_{\{\tau_k\}} \theta \left( \prod_k \tau_k \right) \prod_k H \left( \frac{\sqrt{R} t_k \tau_k}{\sqrt{1-R}} \right) \right) \\ & \left. \times \ln \left( \text{Tr}_{\{\tau_k\}} \theta \left( \prod_k \tau_k \right) \prod_k H \left( \frac{\sqrt{R} t_k \tau_k}{\sqrt{1-R}} \right) \right) \right], \end{aligned} \quad (12.33)$$

这显然类似于 (12.20)。现在，通过与推导 (12.5) 时类似的论证，可以证明

$$\text{Tr}_{\{\tau_k\}} \theta \left( \prod_k \tau_k \right) \prod_k H \left( \frac{\sqrt{R} t_k \tau_k}{\sqrt{1-R}} \right) = \frac{1}{2} \left[ 1 + \prod_k \left( 2H \left( \frac{\sqrt{R} t_k}{\sqrt{1-R}} \right) - 1 \right) \right]. \quad (12.34)$$

利用  $2H(x) - 1$  是  $x$  的奇函数这一事实并展开对数，quenched 熵的结果可写为 [193]

$$\begin{aligned} s(\alpha) = \text{extr}_R & \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} - \alpha \ln 2 \right. \\ & \left. + \alpha \sum_{m=2,4,\dots}^{\infty} \frac{1}{m(m-1)} \left[ \int Dt \left( 2H \left( \frac{\sqrt{R} t}{\sqrt{1-R}} \right) - 1 \right)^m \right]^K \right]. \end{aligned} \quad (12.35)$$

这种形式对数值确定极值特别有用，因为它只涉及一个积分。通过数值求解与 (12.35) 对应的鞍点方程，并使用 (12.5)，得到的  $\epsilon(\alpha)$  结果对不同  $K$  如图 12.5 所示。它们在定性上与 annealed 近似得到并在图 12.4 中展示的结果相当相似。




图 12.5: 树结构奇偶机的泛化误差随训练集大小的变化；隐单元数  $K = 2, 3, 4, 5, 6, 7$ （从左到右）。结果来自对 (12.35) 的数值极值化。

有两点值得特别注意。第一，如同 annealed 近似，我们对所有  $K > 1$  都发现延迟学习，也就是说，当  $\alpha$  较小时，泛化误差保持等于 0.5。这与奇偶函数 (12.3) 的反演对称性有关，见习题 12.11。随着训练集大小增大，系统转入  $\epsilon < 0.5$  的非平凡泛化；该转变在  $K = 2$  时连续发生（在  $\alpha = \pi^2/8$  处），而对所有  $K > 2$  都在某个  $\alpha_d(K)$  处不连续发生。第二，对大  $\alpha$ ，不同  $K$  的曲线变得非常相似。事实上，考虑 (12.35) 中的  $\alpha \rightarrow \infty$  与  $R \rightarrow 1$  极限，可以证明泛化误差的渐近衰减与  $K$  无关，并由

$$\epsilon \sim \frac{1}{\sqrt{\pi} \left| \int dt H(t) \ln H(t) \right|} \frac{1}{\alpha} \simeq \frac{0.625}{\alpha} \quad (12.36)$$

给出。这与习题 2.10 中确定的感知机渐近结果一致（另见习题 12.10）。因此，泛化误差的渐近衰减只由输入空间维数  $N$  决定。另一方面，考察泛化误差从  $\epsilon = 0.5$  不连续下降的  $\alpha_d$  对  $K$  的依赖，可发现它渐近按  $\alpha_d \sim \ln K / \ln 2$  标度，即与存储容量和 VC 维数完全相同。这在图 12.6 中展示。因此，尽管泛化误差的渐近衰减对 VC 维数的具体值不敏感，非平凡泛化开始的阈值却与网络存储能力密切相关；这同第 10.3 节的一般讨论一致，即“泛化在记忆结束处开始”。

## 12.5 委员会树的泛化

由于奇偶机具有高度对称性，其存储和泛化能力可以作相对简单的分析。另一方面，从隐层到输出的奇偶函数无法用 McCulloch–Pitts 神经元以简单方式实现。在这方面，委员会机是多层网络更自然的代表。不幸的是，它的细致研究更为复杂。

本节将研究可实现泛化场景，其中具有  $K$  个隐单元的委员会树学习由完全同结构教师网络给






图 12.6: 奇偶树中非平凡泛化不连续转变发生的训练集大小  $\alpha_d$ , 作为隐单元数  $K$  的函数。圆点来自 quenched 理论 (12.35), 三角形来自 annealed 近似 (12.13)。直线描述存储容量的渐近行为 (12.15)。

出的目标分类。考虑  $K \rightarrow \infty$  极限时, 我们将发现总体行为与感知机情形相当相似, 后者对应于  $K = 1$ 。因此, 人们相信中间  $K$  值的结果也不会与这些极端情形有显著差别。由于一般  $K$  的详细分析涉及相当冗长的计算和复杂数值程序, 我们将限制在  $K \rightarrow \infty$  极限中; 在该极限下, 计算可利用类似 (12.8) 的渐近结果。

像奇偶树情形一样进行, 但把 (12.3) 替换为 (12.4), 并对重叠使用复本与位点对称 ansatz, 可得 quenched 熵表达式的能量部分

$$G_E = \ln 2 \int \prod_k D t_k \left[ \text{Tr}_{\{\tau_k\}} \theta \left( \frac{1}{\sqrt{K}} \sum_k \tau_k \right) \prod_k H \left( \frac{\sqrt{R} t_k \tau_k}{\sqrt{1-R}} \right) \right]^n. \quad (12.37)$$

方括号中的表达式可再次利用  $\theta$  函数的著名积分表示 (A1.19) 加以简化:

$$\begin{aligned} [\cdots] &= \text{Tr}_{\{\tau_k\}} \theta \left( \frac{1}{\sqrt{K}} \sum_k \tau_k \right) \prod_k H \left( \frac{\sqrt{R} t_k \tau_k}{\sqrt{1-R}} \right) \\ &= \int_0^\infty \frac{d\Lambda}{2\pi} \int d\hat{\Lambda} e^{i\hat{\Lambda}\Lambda} \text{Tr}_{\{\tau_k\}} \exp \left( -\frac{i\hat{\Lambda}}{\sqrt{K}} \sum_k \tau_k \right) \prod_k H \left( \frac{\sqrt{R} t_k \tau_k}{\sqrt{1-R}} \right) \\ &= \int_0^\infty \frac{d\Lambda}{2\pi} \int d\hat{\Lambda} e^{i\hat{\Lambda}\Lambda} \prod_k \left[ \text{Tr}_{\tau} \exp \left( -\frac{i\hat{\Lambda}}{\sqrt{K}} \tau \right) H \left( \frac{\sqrt{R} t_k \tau}{\sqrt{1-R}} \right) \right]. \end{aligned}$$

对  $1/\sqrt{K}$  展开到二阶, 对内部表示取迹, 并使用缩写

$$H_k = H \left( \frac{\sqrt{R} t_k}{\sqrt{1-R}} \right),$$

再重新指数化, 可得  $1/K$  阶

$$[\cdots] = \int_0^\infty \frac{d\Lambda}{2\pi} \int d\hat{\Lambda} \exp \left[ i\hat{\Lambda}\Lambda + i\hat{\Lambda} \frac{1}{\sqrt{K}} \sum_k (1 - 2H_k) - \frac{\hat{\Lambda}^2}{2} \left( 1 - \frac{1}{K} \sum_k (1 - 2H_k)^2 \right) \right].$$

因此, (12.37) 中的被积函数不依赖于所有单独积分变量  $t_k$ , 而只依赖于组合  $\sum_k (1 - 2H_k)$ 。由中心极限定理,

$$\frac{1}{\sqrt{K}} \sum_k (1 - 2H_k)$$

是均值为零、方差为

$$\int Dt \left[ 1 - 2H \left( \frac{\sqrt{R}t}{\sqrt{1-R}} \right) \right]^2 = \frac{2}{\pi} \arcsin R =: R_{\text{eff}} \quad (12.38)$$

的 Gaussian 随机变量。因此可用替换

$$\int \prod_k Dt_k f \left( \frac{1}{\sqrt{K}} \sum_k (1 - 2H_k), \frac{1}{K} \sum_k (1 - 2H_k)^2 \right) = \int Dt f(\sqrt{R_{\text{eff}}}t, R_{\text{eff}})$$

并得到

$$\begin{aligned} G_E &= \ln 2 \int Dt \left[ \int_0^\infty \frac{d\Lambda}{2\pi} \int d\hat{\Lambda} \exp \left( i\hat{\Lambda}(\Lambda + \sqrt{R_{\text{eff}}}t) - \frac{1 - R_{\text{eff}}}{2} \hat{\Lambda}^2 \right) \right]^n \\ &= \ln 2 \int Dt H^n \left( \frac{\sqrt{R_{\text{eff}}}t}{\sqrt{1 - R_{\text{eff}}}} \right). \end{aligned} \quad (12.39)$$

这个表达式在作替换  $R \mapsto R_{\text{eff}}$  后, 完全等价于简单感知机的相应量。因此最后可得 quenched 熵

$$s(\alpha) = \text{extr}_R \left[ \frac{1}{2} \ln(1 - R) + \frac{R}{2} + 2\alpha \int Dt H \left( \frac{\sqrt{R_{\text{eff}}}t}{\sqrt{1 - R_{\text{eff}}}} \right) \ln H \left( \frac{\sqrt{R_{\text{eff}}}t}{\sqrt{1 - R_{\text{eff}}}} \right) \right]. \quad (12.40)$$

由 (12.40) 的数值极值化和  $\epsilon = \arccos(R_{\text{eff}})/\pi$  (比较 (12.8)) 得到的泛化误差如图 12.7 所示; 图中还包括  $K = 3$  和  $K \rightarrow \infty$  的 annealed 近似, 以及对应于  $K = 1$  的感知机结果。可以清楚看出,  $K = 1$  和  $K \rightarrow \infty$  的委员会树泛化行为在定性上相当相似, 因此可预期一般  $K$  的结果不会显著不同于这些极端情形。特别地, 这里没有像奇偶树那样的不连续转变,  $\epsilon$  的渐近衰减是代数的。事实上, 由 (12.40) 可得

$$\epsilon \sim 2 \frac{\sqrt{2}}{\alpha \int Dt e^{-t^2/2} [H(t)]^{-1}} \sim \frac{1.25}{\alpha}, \quad (12.41)$$

这恰好是感知机泛化误差渐近值的两倍 (比较 (2.50))。

注意, (12.41) 是先取  $K \rightarrow \infty$  极限再取  $\alpha \rightarrow \infty$  极限得到的。事实上, 该结果只在  $\alpha \lesssim \sqrt{K}$  时正确。对  $\alpha > \sqrt{K}$ ,  $\epsilon(\alpha)$  的渐近行为与  $K$  无关, 因此与 (2.50) 中给出的感知机行为相同; 习题 12.10 澄清了这一显著结果的来源。

与感知机相比, 大委员会树中泛化误差随训练集大小的初始衰减更慢。这与如下事实一致: 在前一种情形中, 存储容量以及 VC 维数都显著更大。不过, 与奇偶树不同, 这里没有延迟学习, 而且看起来不可能从学习曲线  $\epsilon(\alpha, K)$  中提取结果 (12.28)。因此, 与感知机一样, “泛化在记忆结束处开始” 这一简单规则并没有以直接方式出现在委员会机的学习行为中。这与输出和隐单元之间存在正相关有关 (比较习题 12.11)。




图 12.7: 树结构委员会机的泛化误差随训练集大小的变化, 取无限多隐单元极限  $K \rightarrow \infty$  (实线)。图中还给出 annealed 近似在  $K \rightarrow \infty$  时的结果 (长虚线)、 $K = 3$  时的结果 (虚线), 以及对应于  $K = 1$  的感知机结果 (点划线)。细线是渐近结果 (12.41)。

## 12.6 全连接委员会机

作为全连接多层网络学习的一个例子, 本节考虑可实现场景: 具有  $K \rightarrow \infty$  个隐单元的全连接委员会机, 学习由同结构教师网络给出的分类。由于详细计算相当冗长, 我们只简要讨论在这种情况下出现的额外特征。对这一重要情形的完整而非常清楚的分析见 [205]。

全连接结构学习中定性上新的主要方面, 是隐单元之间的置换对称性, 以及该对称性可能由于教师与学生的特定隐单元之间的相关而自发破缺。隐单元的这种可能专门化, 造成了树结构与全连接委员会机泛化行为之间的主要差异。

如同存储问题中一样, 这种可能性在计算中表现为形式 (12.30) 的额外序参量出现。对泛化问题, 最重要的一族序参量为

$$R_{kl}^a = \frac{1}{N} \mathbf{T}_k \mathbf{J}_l^a, \quad (12.42)$$

它描述教师与学生不同子感知机之间的重叠。一个适合这些序参量、并允许进一步解析推进的 ansatz, 把复本对称性 (同样可证明成立) 与部分委员会对称假设结合起来, 其形式为

$$R_{kl}^a = R + \Delta R \delta(k, l), \quad (12.43)$$

其中 Kronecker 符号  $\delta(k, l)$  定义于 (A1.13)。

这个 ansatz 把用于存储容量分析的位点对称假设推广到泛化问题。对  $\Delta R = 0$ , 它描述一个置换对称态, 其中学生每个隐单元与教师所有隐单元有相同对齐。另一方面, 若  $\Delta R > 0$ , 则学生每个隐单元都与教师的一个隐单元相关, 并出现前述隐单元专门化。注意, 更一般的情形当然是可以设想的, 例如两个学生隐单元试图模仿教师的同一个隐单元; 不过, 上述 ansatz 是能够显示专门化的最简单选择, 并已被证明给出与数值模拟相符的结果。

以类似方式处理描述学生自重叠的其余序参量后，分析可像委员会树那样完成。最终得到五个序参量的鞍点方程，需要数值求解。

把  $\alpha$  定义为  $\alpha = p/(NK)$ ，即样例数与网络中可调耦合数之比，可得到以下结果 [205]。对小训练集大小  $\alpha = O(1/K)$ ，以  $\Delta R = 0$  表征的置换对称态稳定，隐单元不发生专门化。在这个区域中，泛化误差从初始值 0.5 下降到一个中间平台值

$$\epsilon_{\text{pl}} = \frac{1}{\pi} \arccos \frac{2}{\pi} \simeq 0.28. \quad (12.44)$$

趋近  $\epsilon_{\text{pl}}$  的方式是代数的， $(\epsilon - \epsilon_{\text{pl}}) \sim \text{const}/\alpha$ 。尽管泛化误差最初下降，在这一相中完美学习仍不可能。这一失败与学生隐单元之间的对称性有关，表明它们之间的分工效率不足。训练集中的样例数为输入维数  $N$  的量级，恰好足以让各个子感知机的耦合各自适应任务，却还不足以优化它们之间的相互作用。

当  $\alpha$  增大到 1 阶，使样例数可与网络中的自适应耦合数相比时，置换对称态仍是鞍点方程的一个解。然而，在  $\alpha = \alpha_d \simeq 7.65$  处，会发生到  $\Delta R > 0$  的专门化状态的不连续转变，随后泛化误差代数衰减到零。若教师的不同子感知机彼此正交，则详细渐近行为由委员会树中得到的 (12.41) 给出。

因此，全连接多层网络中的泛化行为由三个阶段组成。最初，不同子感知机各自适应任务。由于由相同输入馈入，它们平均实现相同构型。在这一阶段中，泛化误差连续下降并达到平台值。接下来，泛化误差发生不连续下降，这与从置换对称态转变到隐单元专门承担教师某个特定隐单元任务的状态有关。由于该转变与学生隐单元之间置换对称性的自发破缺相关，它对应于学习过程中离散自由度的适应；其不连续性与我们在第 七 章获得的经验一致。最后，学生耦合向教师值的精细调节导致泛化误差第二阶段连续下降，并渐近达到可实现问题特征性的  $\epsilon = 0$ 。

## 12.7 小结

多层神经网络是强大的信息处理装置。即使只有一个中间层，只要含有足够多隐单元，也能实现输入与输出之间的任意 Boolean 函数。然而，在统计力学框架内作详细分析，只对非常受限的结构才可能。因此，允许以合理数学工作量粗略刻画多层网络能力的近似方法特别重要。

隐单元数  $K$  远小于输入维数  $N$  的多层网络，可以进行细致的统计力学分析，因为隐单元处的输入场是 Gaussian 随机变量。特别地，如果假设树结构，其中隐单元由输入的不交子集馈入，并且内部表示与输出之间有固定 Boolean 函数  $F$ ，计算就可以有效建立在感知机结果之上。本章主要处理了奇偶机和委员会机，但若干结果可推广到一般置换对称 Boolean 函数，如习题 12.9–12.11 所示。尽管这些特殊结构相当“感知机式”，它们在存储和泛化行为上仍表现出有趣的新特征。

在存储问题中，主要复杂性在于很可能发生复本对称性破缺；其原因是不同内部表示可能给出相同输出，从而导致解空间不连通。这与第 七 章中已经讨论过的反楔形感知机非常类似。当隐单元数  $K$  很大（但仍  $K \ll N$ ）时，存储容量可随  $K$  发散，这也意味着 VC 维数变得显著大于输入空间维数  $N$ 。

泛化行为的初始阶段关键取决于隐单元与输出之间的相关（比较习题 12.11）。如果 Boolean 函数  $F$  要求多数隐单元显示某一特定符号才能实现正输出（如委员会机情形），那么只要  $\alpha > 0$ ，泛化误差就会立即从初始值 0.5 下降。这是合理的，因为输出处关于教师分类的信息在一定程度上直接传递给了隐单元。另一方面，如果 Boolean 函数不在隐单元取值与输出之间产生相关（如奇偶

机情形), 泛化误差会在某个  $\alpha$  区间内保持 0.5, 系统表现出延迟学习。

对大的训练集大小  $\alpha$ , 泛化误差呈现与感知机相同的代数衰减。考虑隐单元数很大的情形时, 必须记住  $K \rightarrow \infty$  与  $\alpha \rightarrow \infty$  两个极限并不对易。

全连接结构中出现了学习行为的新特征。由于所有隐单元现在都连接到完全相同的输入, 隐层中具有完全置换对称性。学习现在分两个不同阶段进行。如果样例数仅为输入维数的量级, 所有子感知机各自适应, 系统落入一个置换对称态, 其中教师与学生所有隐单元对之间的重叠都相同。泛化误差在这一相中接近中间平台值  $\epsilon_{pl} > 0$ 。进一步进展只有在隐单元之间更有效分工时才可能。这要求样例数达到  $KN$  的量级, 即系统中可自适应参数的数目。它导致置换对称性破缺, 使学生隐单元专门化到教师隐单元。在这个对称性破缺转变处, 泛化误差发生不连续下降; 随后  $\epsilon$  向零的最终衰减再次是代数的。

由于内部表示充当离散自由度, 多层网络的显式学习算法必须处理第 7.4 节中对 Ising 感知机已经讨论过的同类困难。事实上, 对具有不可微传递函数的多层网络, 目前没有快速、可靠而通用的学习算法。不同启发式方法 (例如见 [195, 191]) 在某些设置中工作得相当好, 在另一些设置中却会失败。这个问题在下一章将讨论的在线学习框架内要轻得多。

最后再次汇集若干基本参考文献。从统计力学角度对多层网络存储问题进行的第一个完整分析见 [197], 处理的是奇偶树。委员会机的存储性质在 [198, 199] 中讨论; 大  $K$  极限下存储容量的渐近结果最早由 [184] 使用内部表示空间的多重分形分析得到。具有  $K = 2$  个隐单元的奇偶树泛化行为在 [206] 中讨论; 一般  $K$  的完整分析见 [193]。  $K \rightarrow \infty$  的委员会树泛化性质最早见 [207], 全连接委员会机情形由 [205] 作了详尽分析。全连接结构中间平台的存在也由 [208, 209] 基于 annealed 近似讨论过。树结构多层网络在隐单元与输出之间具有一般置换不变 Boolean 函数时的泛化性质, 由 [210] 阐明。一个简单的过可实现场景见 [211]。多层网络中最优学习的若干方面在 [212] 中考虑。

## 12.8 习题

**12.1** 使用第 10 章的结果证明, 感知机至多能实现  $e^{N^2}$  量级个输入与输出之间的不同 Boolean 函数。

**12.2** 考虑把所有具有二元分量  $\xi_i = \pm 1, i = 1, \dots, N$  的向量  $\xi$  作为输入样例。证明通过引入“祖母细胞”, 即隐层中只被一个输入样例激活的节点, 多层网络可以实现这些样例的任意分类, 也就是  $N$  个变量的任意 Boolean 函数 [213]。

**12.3** 考虑具有单个输入  $\xi$  和线性输出节点的前馈网络。用几何论证证明, 只要隐层中有足够多节点, 该网络可以以任意期望精度逼近任意函数  $\sigma_T(\xi)$ 。

(提示: 考虑两个隐节点, 并证明  $g(J_1 x - \theta_1) - g(J_2 x - \theta_2)$  会对输出贡献一个局域脉冲。通过叠加这类脉冲, 可重构任意函数。)

**12.4** 考虑两个结构相同的委员会机的教师-学生场景。对非常大的隐单元数  $K$  (但仍  $K \ll N$ ), 预期同一机器中不同隐单元之间只有很弱相关。由于每一对教师-学生隐单元以概率  $1 - \epsilon_r$  一致、以概率  $\epsilon_r$  不一致, 教师和学生输出处的局域场成为均值为零、方差为一、相关为  $1 - 2\epsilon_r$  的 Gaussian 分布变量。记输入层与隐层之间对应教师和学生子感知机的重叠为  $R$ , 证明

$$\epsilon_{K \rightarrow \infty}^{\text{COM}} = \frac{1}{\pi} \arccos \left( \frac{2}{\pi} \arcsin R \right), \quad (12.45)$$

从而验证 (12.8)。

- 12.5** 使用 annealed 近似证明 Ising 奇偶树，即耦合  $J_i = \pm 1$  的奇偶树，其存储容量  $\alpha_c$  必须小于或等于 1。然后证明对所有  $K > 1$ ，这个界确实被饱和。
- 12.6** 验证奇偶树存储容量  $\alpha_c$  的复本对称表达式 (12.21) 与 (12.22)，并证明渐近地  $\alpha_c^{\text{RS}} \sim K^2$ ，这违反 Mitchison–Durbin 界 (12.11)。
- 12.7** 考虑全连接奇偶机的存储问题，并使用下面这个在学习过程中添加隐单元的学习算法 [214]。该算法从带有可调阈值的感知机开始。当通过调整该感知机的耦合和阈值已不可能实现所有期望输入-输出映射时，加入第二个同类型、由相同输入馈入的感知机，并把总体输出取为两个感知机输出的乘积。第二个感知机通过对第一个感知机分类正确的所有输入给出 +1、对其分类错误的输入给出 -1，来修正第一个感知机的错误。因此，第二个感知机的输出带有偏置。当这个  $K = 2$  奇偶机的存储容量达到时，再加入第三个隐单元，如此继续。使用习题 6.9 的结果证明，该特殊学习算法达到的存储容量渐近表现为  $\alpha_c \sim K \ln K$ ，从而饱和 Mitchison–Durbin 界 (12.12)。
- 12.8** 将 (12.39) 与 Ising 耦合的熵部分结合（比较 (7.8)），证明耦合  $J_i = \pm 1$ 、且  $K \rightarrow \infty$  的委员会树从同结构教师学习时，在  $\alpha_d \simeq 1.07$  处发生到完美泛化的不连续转变。把这与第 7.2 节中讨论的 Ising 感知机相应结果作比较。
- 12.9** 考虑树结构的两个两层神经网络之间的可实现教师-学生场景，其中隐单元与输出之间有一般置换不变 Boolean 函数  $F(\tau_1, \dots, \tau_K)$  [210]。定义

$$\text{Tr}_{\{\tau_k|\sigma\}} \cdots \quad (12.46)$$

为对所有产生输出  $\sigma$  的内部表示  $\{\tau_k\}$  的受限迹。证明泛化误差和 quenched 熵分别为

$$\epsilon = \frac{1}{2K} \text{Tr}_\sigma \text{Tr}_{\{\tau_k^T|\sigma\}} \text{Tr}_{\{\tau_k^J|-\sigma\}} \prod_k \left[ 1 - \frac{1}{\pi} \arccos(\tau_k^J \tau_k^T R) \right], \quad (12.47)$$

以及

$$\begin{aligned} s = \text{extr}_R & \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} + \alpha \int \prod_k D t_k \text{Tr}_\sigma \right. \\ & \times \left( \text{Tr}_{\{\tau_k|\sigma\}} \prod_k H \left( \sqrt{\frac{R}{1-R}} \tau_k t_k \right) \right) \\ & \left. \times \ln \left( \text{Tr}_{\{\tau_k|\sigma\}} \prod_k H \left( \sqrt{\frac{R}{1-R}} \tau_k t_k \right) \right) \right], \end{aligned} \quad (12.48)$$

其中  $R$  表示教师和学生对应子感知机之间的重叠。

- 12.10** 考虑上一题设置的大  $\alpha$  行为。证明当  $R \rightarrow 1$  时，由 (12.47) 和 (12.48) 得到

$$\epsilon \sim \frac{N_{\text{db}}}{2K} \frac{1}{\pi} \sqrt{2(1-R)}, \quad (12.49)$$

以及

$$s \sim \text{extr}_R \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} + \alpha \frac{N_{\text{db}}}{2K} \sqrt{1-R} \sqrt{\frac{2}{\pi}} \int dt H(t) \ln H(t) \right], \quad (12.50)$$



其中  $N_{\text{db}}$  表示  $F$  的决策边界上的内部表示数, 即那些翻转单个  $\tau_k$  可能导致输出不同的构型  $\{\tau_k\}$  的数目。对  $R$  作极值化, 证明泛化误差随  $\alpha$  的渐近衰减与  $F(\tau_1, \dots, \tau_K)$  无关, 并由

$$\epsilon \sim \frac{1}{\sqrt{\pi} \left| \int dt H(t) \ln H(t) \right|} \frac{1}{\alpha} \quad (12.51)$$

给出, 这与感知机结果 (2.50) 一致。

- 12.11** 现在考虑习题 12.9 设置在小  $\alpha$  下、具有一般置换不变 Boolean 解码函数的泛化行为。证明在此极限中, 由 (12.47) 和 (12.48) 得到

$$\epsilon \sim 2c_0(1 - c_0) - \frac{4K}{\pi} c_1^2 R + \dots \quad (12.52)$$

以及

$$s \sim \text{extr}_R \left[ -\frac{R^2}{4} + \alpha c_0 \ln c_0 + \alpha c_1 \ln c_1 + \frac{\alpha K}{\pi} \frac{c_1^2}{c_0(1 - c_0)} R + \dots \right], \quad (12.53)$$

其中

$$c_0 = \frac{1}{2^K} \text{Tr}_{\{\tau_k|+\}} = 1 - \frac{1}{2^K} \text{Tr}_{\{\tau_k|-\}}, \quad (12.54)$$

以及

$$c_1 = \frac{1}{2^K} \text{Tr}_{\{\tau_k|+\}} \tau_l = -\frac{1}{2^K} \text{Tr}_{\{\tau_k|-\}} \tau_l \quad (12.55)$$

是存储问题中定义的相关系数 (12.29) 的推广。对  $R$  作极值化, 证明当  $c_1 \neq 0$  时, 泛化误差在  $\alpha > 0$  后立即下降; 而当  $c_1 = 0$  时, 出现延迟学习。

- 12.12** 考虑一个感知机向具有无限多个隐单元 ( $K \rightarrow \infty$ ) 且子感知机正交的全连接委员会机学习, 其中  $\mathbf{T}_k \mathbf{T}_l = N \delta_{kl}$ 。假设当  $\alpha \rightarrow \infty$  时, 学生向量将趋近于教师向量  $\mathbf{T}_k$  的质心, 证明泛化误差将收敛到

$$\epsilon_r = \frac{1}{\pi} \arccos \sqrt{\frac{2}{\pi}}. \quad (12.56)$$

(提示: 使用如下事实:

$$\frac{\mathbf{J}\boldsymbol{\xi}}{\sqrt{N}} \quad \text{and} \quad \frac{1}{\sqrt{K}} \sum_k \text{sgn} \left( \frac{\mathbf{T}_k \boldsymbol{\xi}}{\sqrt{N}} \right) \quad (12.57)$$

是相关 Gaussian 变量。)

# 第十三章 多层网络中的在线学习

多层网络的在线学习在应用中使用广泛，因此对它进行理论研究具有首要重要性。尽管关于网络结构细节和训练规则的选择已经有许多特设处方，更深层的理解仍然不足。我们将从上一章引入的简化多层结构开始，即奇偶树和委员会机。我们将看到，它们与感知机共享若干特征，但同时也出现了多层结构所特有的差异。对于具有符号传递函数的一般多层机器，理论会变得相当复杂。因此，一个令人愉快的意外是：对具有光滑激活函数的全连接多层网络，可以导出显式的演化方程。这使人能够研究并更深入理解前面提到的若干重要问题，例如平台的起源。

## 13.1 委员会树

我们从一个较简单的情形开始详细讨论多层网络中的在线学习：一个树结构学生委员会机，有  $K$  个隐单元，由突触向量集合  $\mathbf{J}_k$  表征；它从同样结构的教师机器学习，教师突触向量为  $\mathbf{T}_k$ ， $k = 1, \dots, K$ 。由于计算与  $K = 1$  对应的感知机情形非常相似，我们可以省略细节，并把第 9.1 节作为参照。样例  $\xi^\mu$  由随机且相互独立的子片段  $\xi_k^\mu$  构成，它们随后被呈现给具有突触向量  $\mathbf{J}_k^\mu$  的隐单元；该向量由  $\mu$  之前的样例构造。回忆  $\xi_k^\mu$  与  $\mathbf{J}_k^\mu$  都是维数为  $N/K$  的向量，在线学习规则具有形式

$$\mathbf{J}_k^{\mu+1} = \mathbf{J}_k^\mu + \frac{1}{\sqrt{N/K}} F_k^\mu \xi_k^\mu. \quad (13.1)$$

学习幅度  $F_k^\mu$  原则上可以依赖所有可得信息，包括例如其他学生单元  $k' \neq k$  的状态。

仿照对感知机在线学习的处理，引入序参量

$$\rho_k^\mu = \frac{\mathbf{J}_k^\mu \mathbf{T}_k}{N/K}, \quad Q_k^\mu = \frac{(\mathbf{J}_k^\mu)^2}{N/K}. \quad (13.2)$$

在热力学极限中，这些量成为  $\alpha = p/N$  的自平均函数，并服从演化方程

$$\frac{d\rho_k}{d\alpha} = K \langle F_k u_k \rangle, \quad (13.3)$$

$$\frac{dQ_k}{d\alpha} = K \langle F_k (F_k + 2t_k) \rangle. \quad (13.4)$$

这些方程在形式上与感知机方程 (9.9) 和 (9.11) 相同，只是训练集大小  $\alpha$  被替换为  $K\alpha = p/(N/K)$ 。平均是对随机选取的样例  $\xi_k$  取的，其中

$$u_k = \frac{\mathbf{T}_k \xi_k}{\sqrt{N/K}} \quad (13.5)$$

是教师的局域场，而

$$t_k = \frac{\mathbf{J}_k \xi_k}{\sqrt{N/K}} \quad (13.6)$$

是一个新样例  $\xi_k$  对向量  $\mathbf{J}_k$  的局域场；这里  $\mathbf{J}_k$  是基于先前样例构造的。演化方程 (13.3)–(13.4) 必须补充学习幅度  $F_k$  的具体形式。随后，对样例的平均可容易地完成，因为  $u_k$  与  $t_k/\sqrt{Q_k}$  组成相

关 Gaussian 随机变量对, 并满足

$$\begin{aligned}\langle u_k \rangle &= \left\langle \frac{t_k}{\sqrt{Q_k}} \right\rangle = 0, \\ \langle u_k u_l \rangle &= \left\langle \frac{t_k}{\sqrt{Q_k}} \frac{t_l}{\sqrt{Q_l}} \right\rangle = \delta(k, l), \\ \left\langle u_k \frac{t_l}{\sqrt{Q_l}} \right\rangle &= \frac{\rho_k}{\sqrt{Q_k}} \delta(k, l) = R_k \delta(k, l).\end{aligned}\tag{13.7}$$

其中  $\delta(k, l)$  在 (A1.13) 中定义。由适当归一化的重叠  $R_k = \rho_k / \sqrt{Q_k}$ , 相应隐单元的泛化误差为  $\epsilon_k = (\arccos R_k) / \pi$ ; 若对所有  $k$  都有  $\epsilon_k = \epsilon_\tau$ , 则委员会机的泛化误差可由 (12.7) 得到。

作为上述公式的第一个应用, 考虑简单的 Hebb 学习, 对应于选择

$$F_k = \eta \sigma_T = \eta \operatorname{sgn} \left( \sum_{k'=1}^K \operatorname{sgn} u_{k'} \right).\tag{13.8}$$

(13.3)–(13.4) 中的多重 Gaussian 积分很容易计算, 只要注意非零贡献只来自如下情形: 除了  $k$  之外的隐单元处于平局, 即  $\sum_{k' \neq k} \operatorname{sgn} u_{k'} = 0$ 。于是有

$$\begin{aligned}\left\langle u_k \operatorname{sgn} \left( \sum_{k'=1}^K \operatorname{sgn} u_{k'} \right) \right\rangle &= \frac{1}{2^{K-1}} \binom{K-1}{(K-1)/2} \sqrt{\frac{2}{\pi}}, \\ \left\langle t_k \operatorname{sgn} \left( \sum_{k'=1}^K \operatorname{sgn} u_{k'} \right) \right\rangle &= \frac{1}{2^{K-1}} \binom{K-1}{(K-1)/2} \rho_k \sqrt{\frac{2}{\pi}}.\end{aligned}\tag{13.9}$$

对  $\rho_k$  与  $Q_k$  的方程积分, 并取初始条件  $\rho_k(0) = Q_k(0) = 0$ , 得到

$$R_k(\alpha) = \left[ 1 + \frac{2^{2K-3} \pi}{K \alpha \binom{K-1}{(K-1)/2}^2} \right]^{-1/2}.\tag{13.10}$$

特别地, 对  $K = 3$  有

$$R_k(\alpha) = \left( 1 + \frac{2\pi}{3\alpha} \right)^{-1/2}.\tag{13.11}$$

泛化误差  $\epsilon$  由 (12.7) 给出。当  $\alpha \rightarrow 0$  (且所有初始重叠均为零) 时, 可得  $\epsilon(\alpha) \approx 1/2 - \sqrt{17\alpha/32\pi^3}$ , 而渐近衰减为  $\epsilon(\alpha) \sim \sqrt{3/(2\pi\alpha)}$ 。其他有限  $K$  也给出类似的渐近行为。转向  $K \rightarrow \infty$  极限时, 可得到如下显式结果 (比较习题 13.2):

$$\epsilon(\alpha) = \frac{1}{\pi} \arccos \left[ \frac{2}{\pi} \arcsin \left( 1 + \frac{\pi^2}{4\alpha} \right)^{-1/2} \right],\tag{13.12}$$

它意味着当  $\alpha \rightarrow 0$  时  $\epsilon(\alpha) \approx 1/2 - 4\sqrt{\alpha}/\pi^3$ , 而当  $\alpha \rightarrow \infty$  时  $\epsilon(\alpha) \sim \sqrt{2}/(\pi\alpha^{1/4})$ 。注意, 与离线学习一样, 极限  $\alpha \rightarrow \infty$  与  $K \rightarrow \infty$  不可交换。为了了解 Hebb 学习下委员会树泛化能力随  $K$  的劣化, 我们在图 13.1 中给出了  $K = 1$ 、 $K = 3$  和  $K = \infty$  情形的泛化误差。

为了把 Hebb 结果放在合适的视角下, 现在转向最优情形。计算仍然与  $K = 1$  情形非常相似, 但代数更加繁琐。这里仅复现计算中的主要步骤。由于  $\epsilon$  是重叠  $R_k = \rho_k / \sqrt{Q_k}$  的单调函数, 我们希望最大化  $dR_k/d\alpha$ 。由 (13.3)–(13.4) 可知, 最优学习幅度为

$$F_{k,\text{opt}} = -t_k + \frac{Q_k}{\rho_k} \langle u_k \rangle_{|(t_1, \dots, t_K), \sigma_T},\tag{13.13}$$




图 13.1: 从同结构教师学习的  $K = 3$  学生树结构委员会机的泛化误差。下方实线为最优学习规则结果, 见 (13.16); 上方实线为 Hebb 规则结果, 见 (13.11)。作为比较, 图中还给出通常  $K = 1$  感知机的对应结果 (虚线) 以及 Hebb  $K = \infty$  结果 (点线), 见 (13.12)。

可与 (9.28) 比较。这里的平均是对未知自由度取的, 即在给定教师分类以及学生隐状态条件下, 对教师单元状态  $u_k$  平均。对最简单的非平凡情形  $K = 3$  计算 Gaussian 积分, 得到

$$F_{k,\text{opt}} = \frac{\sigma_T}{\sqrt{2\pi}} \frac{\sqrt{Q_k(1-R_k^2)}}{R_k} \exp\left(-\frac{R_k^2}{2(1-R_k^2)} \frac{t_k^2}{Q_k}\right) v_k(x_1, x_2, x_3), \quad (13.14)$$

其中变量  $x_k$ ,  $k = 1, 2, 3$ , 定义为

$$x_k = \frac{R_k}{\sqrt{1-R_k^2}} \frac{\sigma_T t_k}{\sqrt{Q_k}}. \quad (13.15)$$

此外

$$v_1(x_1, x_2, x_3) = \frac{H(-x_2)H(x_3) + H(x_2)H(-x_3)}{H(-x_2)H(-x_3) + H(-x_1)[H(-x_2)H(x_3) + H(x_2)H(-x_3)]},$$

$k = 2, 3$  的结果由指标置换得到。这个结果与  $K = 1$  结果 (9.33) 有些相似, 但有一个重要差别: 最优幅度  $F_{k,\text{opt}}$  现在依赖来自其他学生隐单元  $k' \neq k$  的交叉信息。事实上, 也可以构造一种只使用局域信息的优化算法, 即要求  $F_{k,\text{opt}}$  不依赖  $t_{k'}$ ,  $k' \neq k$ 。结果表明, 这个问题等价于带输出噪声的通常感知机问题, 见习题 13.4。

将 (13.14) 代入 (13.3)–(13.4), 可发现  $R_k$  的方程与长度  $Q_k$  的方程解耦, 并得到

$$\frac{dR_k}{d\alpha} = \frac{3}{4\pi} \frac{1-R_k^2}{R_k} \int \prod_{k'=1}^3 \text{D}y_{k'} e^{-y_{k'}^2} w_k(y_1, y_2, y_3), \quad (13.16)$$

其中

$$w_1(y_1, y_2, y_3) = \prod_{k'=1}^3 \left( \frac{\sqrt{1-R_{k'}^2}}{R_{k'}} e^{y_{k'}^2 - y_{k'}^2/(2R_{k'}^2)} \right) \frac{[H(-y_2)H(y_3) + H(y_2)H(-y_3)]^2}{r_1(y_1, y_2, y_3) [1 - r_1(y_1, y_2, y_3)]} \quad (13.17)$$

并且

$$r_1(y_1, y_2, y_3) = H(y_2)H(y_3) + H(y_1)[H(-y_2)H(y_3) + H(y_2)H(-y_3)]. \quad (13.18)$$

$k = 2, 3$  的结果再次由指标置换得到。与感知机一样，突触向量长度的方程和重叠方程有简单关系

$$\frac{1}{\sqrt{Q_k}} \frac{d\sqrt{Q_k}}{d\alpha} = \frac{1}{R_k} \frac{dR_k}{d\alpha}, \quad (13.19)$$

因此可由观测到的长度直接测量重叠（比较习题 9.8）。




图 13.2: 缩放后的最优学习幅度  $F_{1,\text{opt}}\sigma_T/\sqrt{Q_1}$  作为  $t_1\sigma_T/\sqrt{Q_1}$  的函数；这里  $t_2\sigma_T/\sqrt{Q_2} = -3$ 、 $t_3\sigma_T/\sqrt{Q_3} = 3$ ，重叠  $R_1 = R_2 = R_3$  分别等于 0.1, 0.5, 0.9（自上而下）。

由 (13.16) 的解与 (12.7) 结合，可得到相应泛化误差。结果与 Hebb 学习结果一起示于图 13.1。对于  $\alpha \rightarrow 0$ ，最优学习与 Hebb 学习如预期那样相同。然而，在  $\epsilon$  渐近趋零时，对最优学习而言，无论  $K = 1$  还是  $K = 3$ ，都得到常见的  $1/\alpha$  衰减。更令人惊讶的是，比例因子也完全相同。因此，渐近学习对树结构并不比对简单感知机更困难。这个结论相当一般：它对所有  $K$  成立，在有输出噪声时仍保持 [215]，而且对奇偶树机器也成立，如下文所见。

上面的计算和最优学习结果看起来与感知机相当相似。不过，当关注学习幅度的形式时，可观察到多层网络的一个独特特征，如图 13.2 所示。考虑所有  $R_k$  相等的最简单情形，可以看到，作为  $t_1\sigma_T/\sqrt{Q_1}$  的函数，缩放幅度  $F_{1,\text{opt}}\sigma_T/\sqrt{Q_1}$  在  $t_1\sigma_T/\sqrt{Q_1}$  取很大的负值时表现出与感知机截然不同的行为。这种情形对应于这样一些样例：所考察的学生隐单元以“很大确信度”给出了与教师输出不一致的分类。在简单感知机中，这会导致对学生的大幅修正；而在这里，修正实际上非常小。用拟人化语言说，学生的这个隐单元把正确分类的责任转移给委员会中的另外两个成员，并决定不担心自己的分类。因此它的突触向量不被修正。正如预期的那样，随着学生获得更多经验，即随着  $R_k$  接近 1，这种自动劳动分工会更加明显。

## 13.2 奇偶树

学生奇偶机从教师奇偶机学习的场景，可与委员会机同样讨论。方程 (13.1)–(13.7) 完全适用。主要差别在于学习算法的选择：它必须适应这样的事实：输出现在是隐单元输出的乘积。例如，Hebb 规则作为奇偶机的学习算法完全失效（比较习题 13.5）。因此，我们考虑另一种受感知机学习规则

启发的算法，即所谓最小作用量算法 [195]。在这条规则中，当奇偶机出错时，按感知机规则修正局域场绝对值最小的那个单元的  $\mathbf{J}$  向量。“最小作用量”指的是：把修正的“劳动”分配给对自身分类确信度最低的单元。为简单起见，我们把讨论限于  $K = 2$ 。这导致如下学习幅度选择：比较 (9.19)，其中  $\text{sgn}(u)$  被  $-\text{sgn}(t)$  取代，因为教师隐单元的输出不可得：

$$F_k = -\theta(-u_1 u_2 t_1 t_2) \theta(|t_j| - |t_k|) \text{sgn}(t_k), \quad (13.20)$$

其中  $j \neq k$ 。把这个表达式代入 (13.3) 和 (13.4)，即可得到重叠参数的演化方程。由于积分不能显式计算，我们关注极限区域，并且仍为简单起见，将讨论限制到对称情形  $Q = Q_1 = Q_2$ 、 $\rho = \rho_1 = \rho_2$ 。先考察  $Q$  和  $R = \rho/\sqrt{Q}$  都很小的低性能区域。可得

$$\frac{dR}{d\alpha} \approx -\left(\frac{1}{4} - \frac{2}{\pi^{3/2}}\sqrt{Q}\right) \frac{R}{Q}, \quad (13.21)$$

$$\frac{dQ}{d\alpha} \approx \frac{1}{2} - 2\frac{\sqrt{2}-1}{\sqrt{\pi}}\sqrt{Q}. \quad (13.22)$$

这些方程给出如下结论。首先，如果在  $\alpha = 0$  时  $R = 0$ ，则对所有  $\alpha$  都有  $R = 0$ ，即从零开始学习是不可能的。泛化需要最低限度的先验知识，对应于大于零的初始  $R$ 。如前所述，这个结果严格地说只在系统的热力学极限中成立。有限尺寸导致的涨落允许系统逃离  $R = 0$  不动点，但这需要很长时间，并会在学习曲线  $\epsilon(\alpha)$  中产生一个初始平台。更令人惊讶的是，学生只有在其向量长度达到临界值  $Q_c = \pi^3/64$  后才会开始泛化。对于较小长度，有  $dR/d\alpha < 0$ ，导致重叠衰减。为避免这个问题，算法应在学习的初始阶段补充一个退火方案，即从足够小的学习幅度开始，比较习题 13.6。

转向高性能区域  $R \approx 1$ ，可得

$$\frac{dR}{d\alpha} \approx -\frac{1}{Q} \left( \frac{\sqrt{2}}{\pi} \sqrt{1-R} - \frac{4}{\sqrt{2\pi}} (1-R) \sqrt{Q} \right), \quad (13.23)$$

$$\frac{dQ}{d\alpha} \approx \frac{2\sqrt{2}}{\pi} \sqrt{1-R} - \frac{4}{\sqrt{2\pi}} (1-R) \sqrt{Q}, \quad (13.24)$$

这意味着渐近行为  $R \sim 0.24 \alpha^{-2/3}$ ，泛化误差  $\epsilon \sim 0.44 \alpha^{-1/3}$ 。这个结果与感知机的结果相似，比较 (9.22)。

现在讨论最优学习策略。由于计算再次类似于前面为感知机和委员会机回顾的计算，我们只给出结果，并引用 [216] 中的更多细节。我们将看到，最小作用量算法的若干独特特征在最优策略中并不存在。

和离线情形一样，奇偶机在技术上比委员会机简单，而且可对所有  $K$  完成计算，最终结果为

$$\begin{aligned} \frac{dR_k}{d\alpha} = & \frac{K}{2\pi} \frac{1-R_k^2}{R_k} \int \prod_{i=1}^K D u_i \exp\left(-\frac{u_k^2 R_k^2}{1-R_k^2}\right) \\ & \times \frac{\prod_{l \neq k} \left[ H\left(-\frac{u_l R_l}{\sqrt{1-R_l^2}}\right) - H\left(\frac{u_l R_l}{\sqrt{1-R_l^2}}\right) \right]^2}{\sum_{\{b_i = \pm 1\}} \delta\left(\prod_i b_i, 1\right) \prod_{j=1}^K H\left(-b_j \frac{u_j R_j}{\sqrt{1-R_j^2}}\right)}. \end{aligned} \quad (13.25)$$

在低性能区域得到简单结果

$$\frac{dR_k}{d\alpha} \approx \frac{K}{2} \left(\frac{2}{\pi}\right)^K \frac{\prod_{l \neq k} R_l^2}{R_k}. \quad (13.26)$$



由此可见,任意两个或更多分支满足  $R_k = 0$  都是动力学的不动点,这反映了在线学习的内在限制。它与离线场景中出现的延迟学习有关。如前所述,这是由该网络结构中的一个对称性导致的,即如果反转偶数个突触向量的符号,输出保持不变。注意,这样的平台不会出现在委员会机中,因为该结构没有反演对称性。考虑从不动点出发的偏离,初始条件  $R_k = R$  小但大于零;可以看到,当  $K = 2$  时偏离是指数的,而  $K > 2$  时则是慢得多的幂律。这一区分让人想起离线情形中也观察到的定性差异,比较第 12.4 节。虽然初始  $R = 0$  平台在最小作用量算法中也出现且无法避免,但与后者这种非优化算法不同,最优算法不需要用于学习的最小长度  $Q_c$ 。这并不真正令人意外,因为最优算法包含对学习率的最优退火。

转向  $\alpha \rightarrow \infty$  且  $R_k \rightarrow R \rightarrow 1$  的区域,得到如下演化方程:

$$\frac{dR}{d\alpha} \sim \frac{K}{2\pi} [2(1-R)]^{3/2} \int Dx \frac{e^{-x^2/2}}{H(x)}. \quad (13.27)$$

注意,所有感知机分支以同一速率学习。若重新缩放  $\alpha_K = K\alpha$ ,即用单个分支中的耦合数来归一化样例数,则这个速率与  $K$  无关。由  $\epsilon_k = \arccos R_k/\pi$  以及奇偶机本身泛化误差的公式 (12.5),可导出渐近结果

$$\epsilon \sim \sum_k \epsilon_k \sim \frac{2}{\alpha} \left( \int Dx \frac{e^{-x^2/2}}{H(x)} \right)^{-1}. \quad (13.28)$$

注意,即使在这个极限中机器的泛化误差是各个误差之和,若我们用  $\alpha$  而不是  $K\alpha$  适当地度量训练集大小,整个机器实际上以与隐单元相同的速率学习。 $1/\alpha$  衰减是唯一与这一特殊性质相容的规律。此外,比例系数与简单感知机中的系数完全相同,见 (9.36)。因此,对树结构的委员会机和奇偶机,最优渐近趋近都与感知机相同。这个结论在存在输出噪声时仍然有效,比较习题 13.7。

### 13.3 软委员会机

对具有符号传递函数的全连接机器的分析看起来极其复杂,这里不再继续讨论。相反,我们转向一个隐单元具有光滑传递函数  $g$  的委员会机。为简单起见,考虑一个线性输出单元。网络通过对二次输出误差作梯度下降来训练。正如我们已经在简单感知机中注意到的(比较第 9.4 节),只要巧妙选择传递函数,所有积分都能显式完成,从而极大简化序参量演化方程的分析。

学生与教师委员会机分别由  $N$  维突触向量集合  $\{\mathbf{J}_k, k = 1, \dots, K\}$  和  $\{\mathbf{T}_m, m = 1, \dots, M\}$  表征,其中  $K$  与  $M$  分别为学生和教师的隐单元数。我们将后续分析限制到可学习场景  $K = M$ ,并取各向同性教师,其权重向量彼此正交且位于  $N$  球面上,即  $\mathbf{T}_m \mathbf{T}_n = N\delta(m, n)$ 。不过,我们也会提及过可实现的  $K > M$  情形、不可实现的  $K < M$  情形,以及具有某些主导权重向量比其他权重更大的分级教师情形。我们用二次输出误差的在线梯度下降训练

$$V(\mathbf{J}_1, \dots, \mathbf{J}_K) = \frac{1}{2} \left[ \sum_{k=1}^K g(t_k^\mu) - \sum_{m=1}^M g(u_m^\mu) \right]^2, \quad (13.29)$$

其中

$$t_k^\mu = \frac{\mathbf{J}_k \boldsymbol{\xi}^\mu}{\sqrt{N}} \quad (13.30)$$

以及

$$u_m^\mu = \frac{\mathbf{T}_m \boldsymbol{\xi}^\mu}{\sqrt{N}}. \quad (13.31)$$

呈现一个新的训练样例  $\xi^\mu$  会使学生向量作在线更新

$$\mathbf{J}_k^{\mu+1} = \mathbf{J}_k^\mu + \frac{1}{\sqrt{N}} F_k^\mu \xi^\mu, \quad (13.32)$$

其中

$$F_k^\mu = -\eta \left[ \sum_{k'=1}^K g(t_{k'}^\mu) - \sum_{m'=1}^M g(u_{m'}^\mu) \right] g'(t_k^\mu). \quad (13.33)$$

由此得到的重叠演化方程涉及

$$R_{km} = \frac{\mathbf{J}_k \mathbf{T}_m}{\sqrt{N} Q_{kk}}, \quad Q_{kl} = \frac{\mathbf{J}_k \mathbf{J}_l}{N}. \quad (13.34)$$

利用变量  $t_k$  与  $u_m$  的 Gaussian 性质，可以显式计算这些方程。代数与  $K=1$  的情形相似，但相当冗长。特别选取误差函数作为传递函数  $g(x) = 1 - 2H(x)$ ，可使所有这些平均显式算出。显式结果见文献 [134, 217, 218]。

得到的耦合一阶方程组可以数值积分，从而为机器的学习过程提供有价值的理解。如果关注若干特殊情形，也可以进行详细解析研究。例如，学习率的作用、由隐单元置换对称性诱导的平台的存在、这些单元的专门化出现，以及到完美泛化的指数渐近收敛，都是可以详细记录的关键要素。

为说明具体做法，我们把自己限制到如下小  $\eta$  子空间的分析；它表示第 12.6 节中引入的部分委员会对称性：

$$Q_{kl} = Q\delta(k, l) + C[1 - \delta(k, l)], \quad R_{kl} = R\delta(k, l) + S[1 - \delta(k, l)]. \quad (13.35)$$

使用缩放  $\alpha' = \alpha\eta$ ，得到如下演化方程 [218]：

$$\begin{aligned} \frac{dR}{d\alpha'} = \frac{2}{\pi} \frac{1}{1+Q} & \left[ \frac{1+Q-R^2}{\sqrt{2(1+Q)-R^2}} - \frac{RS(K-1)}{\sqrt{2(1+Q)-S^2}} \right. \\ & \left. - \frac{R}{\sqrt{1+2Q}} - \frac{(1+Q)S(K-1)-RC(K-1)}{\sqrt{(1+Q)^2-C^2}} \right], \end{aligned} \quad (13.36)$$

$$\begin{aligned} \frac{dS}{d\alpha'} = \frac{2}{\pi} \frac{1}{1+Q} & \left[ \frac{1+Q-S^2(K-1)}{\sqrt{2(1+Q)-S^2}} - \frac{RS}{\sqrt{2(1+Q)-R^2}} - \frac{S}{\sqrt{1+2Q}} \right. \\ & \left. - \frac{(1+Q)[R+S(K-2)]-SC(K-1)}{\sqrt{(1+Q)^2-C^2}} \right], \end{aligned} \quad (13.37)$$

$$\frac{dQ}{d\alpha'} = \frac{4}{\pi} \frac{1}{1+Q} \left[ \frac{R}{\sqrt{2(1+Q)-R^2}} + \frac{S(K-1)}{\sqrt{2(1+Q)-S^2}} - \frac{Q}{\sqrt{1+2Q}} - \frac{C(K-1)}{\sqrt{(1+Q)^2-C^2}} \right], \quad (13.38)$$

$$\begin{aligned} \frac{dC}{d\alpha'} = \frac{4}{\pi} \frac{1}{1+Q} & \left[ \frac{(1+Q)S-RC}{\sqrt{2(1+Q)-R^2}} + \frac{(1+Q)[R+S(K-2)]-SC(K-1)}{\sqrt{2(1+Q)-S^2}} \right. \\ & \left. - \frac{C}{\sqrt{1+2Q}} - \frac{(1+Q)[Q+C(K-2)]-C^2(K-1)}{\sqrt{(1+Q)^2-C^2}} \right]. \end{aligned} \quad (13.39)$$

泛化误差定义为对随机新样例的平均二次输出误差，它由 [218] 给出：

$$\begin{aligned} \epsilon = \frac{K}{\pi} & \left[ \frac{\pi}{6} + \arcsin\left(\frac{Q}{1+Q}\right) + (K-1) \arcsin\left(\frac{C}{1+Q}\right) \right. \\ & \left. - 2 \arcsin\left(\frac{R}{\sqrt{2(1+Q)}}\right) - 2(K-1) \arcsin\left(\frac{S}{\sqrt{2(1+Q)}}\right) \right]. \end{aligned} \quad (13.40)$$

作为上述显式演化方程组的第一个应用，研究对称相的性质。该相以学生隐单元之间没有区分为特征。特别地，不存在某个学生单元与某个教师向量之间的优先重叠。因此，对称子空间由条件 (13.35) 以及额外约束  $R = S$  定义。注意，以概率 1 出现在热力学极限中的“自然”初始条件，即随机初始选择长度平方相等为  $NQ$  的学生权重向量，对应  $R = S = C = 0$ ，属于这个对称子空间。此外，人们立即验证，当  $R = S$  时， $R$  与  $S$  的方程重合，因此这种初始条件会随时间保持。演化方程数因此减少为三个。

定态解可如下得到。把由  $dQ/d\alpha' = 0$  得到的  $R$  解代入条件  $dC/d\alpha' = 0$ ，可验证稳态下  $Q^2 = C^2$ 。舍去非物理解  $Q = -C$ ，可由 (13.36)–(13.39) 以及  $R = S$  得到唯一不动点解

$$Q_{\text{pl}} = C_{\text{pl}} = \frac{1}{2K-1}, \quad (13.41)$$

$$R_{\text{pl}} = S_{\text{pl}} = \frac{1}{\sqrt{K(2K-1)}}. \quad (13.42)$$

对应的泛化误差为

$$\epsilon_{\text{pl}} = \frac{K}{\pi} \left[ \frac{\pi}{6} - K \arcsin \left( \frac{1}{2K} \right) \right]. \quad (13.43)$$

数值分析表明，这个不动点在对称子空间内部是全局稳定的。看起来不存在逃逸解或极限环。




图 13.3: 泛化误差作为  $\alpha' = \alpha\eta$  的函数。曲线由 (13.36)–(13.39) 与 (13.40) 结合得到，初始条件分别为  $(R, S, Q, C) = (0, 0, 0.5, 0)$  (点线)、 $(0.1, 0.1, 0.5, 0)$  (虚线) 以及  $(10^{-6}, 0, 0.5, 0)$  (实线)。插图展示小  $\alpha'$  下的行为。小  $\alpha'$  时，点线几乎与实线重合；大  $\alpha'$  时，它几乎与虚线重合。

图 13.3 中的虚线展示了泛化误差的典型演化：泛化误差单调收敛到其最终非零值 (13.43)。这不同于第 9.6 节讨论的具有对称性的感知机问题；在那里，如果从对称相开始，就完全没有学习发生。这里观察到一个初始学习阶段，它在一个非平凡平台上饱和，相当类似于第 12.6 节中讨论的全连接结构中的离线学习。不过，与感知机情形一样，上述不动点在对称子空间之外是不稳定的。因此，非对称初始化会把参数带离这个子空间，隐单元专门化随之开始。

为研究专门化的初生阶段，必须区分一个给定学生单元与相应教师单元之间的主导重叠  $R$ ，以及它与其他教师单元之间的次级重叠  $S \neq R$ 。从对称子空间逃离最容易通过对  $r = R - R_{\text{pl}}$ 、

$s = S - S_{\text{pl}}$ 、 $q = Q - Q_{\text{pl}}$ 、 $c = C - C_{\text{pl}}$  作线性稳定性分析来研究。结果表明，对称相的不稳定性在最低阶上由  $R$  与  $S$  的分化标志。只有一个本征值严格为正，相应本征向量分量为  $((K-1), -1, 0, 0)$ 。由突触向量长度恒定时隐含的关系  $s = -r/(K-1)$  可知，离开对称子空间只是学生向量朝它正试图实现的特定教师向量旋转。这个同时进行的过程，即增强与某一特定教师单元的相关、同时与其余单元去相关，是各向同性教师的特征；图 13.3 给出了说明。对于分级教师，专门化通过一连串逃离对称子空间的过程发生，次序遵循与教师单元重叠的递减顺序 [218]。

最后转向对完美解  $S = C = 0$ 、 $R = Q = 1$  的渐近趋近。在子空间

$$R_{kl} = R\delta(k, l), \quad Q_{kl} = Q\delta(k, l) \quad (13.44)$$

中研究对这个不动点的趋近。在此区域，泛化误差为

$$\epsilon = \frac{K}{\pi} \left[ \frac{\pi}{6} + \arcsin \left( \frac{Q}{1+Q} \right) - 2 \arcsin \left( \frac{R}{\sqrt{2(1+Q)}} \right) \right]. \quad (13.45)$$

对  $r = 1 - R$  和  $q = 1 - Q$  线性化，并取  $C = S = 0$ ，由 (13.36)–(13.39) 得到

$$\frac{d}{d\alpha} \begin{pmatrix} r \\ q \end{pmatrix} = \frac{2\sqrt{3}}{\pi} \frac{\eta}{9} \begin{pmatrix} -4 & 3/2 \\ 4 - 2\eta\mu & -3 + \eta\mu \end{pmatrix} \begin{pmatrix} r \\ q \end{pmatrix}, \quad (13.46)$$

其中

$$\mu = \sqrt{3} \frac{2}{\pi} \left( K - 1 + \frac{3}{\sqrt{5}} \right).$$

注意，这里也已经包含  $\eta$  中的非线性项，细节见 [218]。完美解的稳定性要求 (13.46) 中矩阵的本征值为负。立即得到：只有在  $0 < \eta < \eta_{\text{max}}$  时，到完美泛化的指数收敛才得到保证，其中

$$\eta_{\text{max}} = \frac{\pi\sqrt{3}}{K - 1 + 3/\sqrt{5}}. \quad (13.47)$$

由于在小学习率  $\eta$  下本征值虽为负却同样很小，系统会在对称子空间中被困很长时间。增大  $\eta$  可显著缩短平台区域。事实上，把  $r$  和  $q$  的结果代入泛化误差，可确定给出最快渐近衰减的学习率  $\eta_{\text{opt}}$ 。可得  $\eta_{\text{opt}} = 2\eta_{\text{max}}/3$ 。若  $\eta > \eta_{\text{max}}$ ，则达到零误差解的能力丧失。

上面的分析限于子空间 (13.35)。完整图像要丰富得多 [219]。特别是，对方程组的数值分析显示，存在许多不动点，它们具有不同的泛化误差值和不同程度的对称性。例如，当  $K = M = 3$ 、 $\eta = 1$  时，可找到 13 个不动点。此外，学习率  $\eta$  作为控制参数时，不动点会发生分岔。它们的性质通过在泛化误差中产生一连串平台来影响学习动力学，甚至会把学生困在稳定的次优不动点上。

本节最后简要讨论不可实现的  $K < M$  情形和过可实现的  $K > M$  情形。在过可实现情形中，学习过程会自动剪除不必要的隐单元。相应单元的长度  $Q_{kk}$  趋于零。其他单元经历与  $K = M$  情形类似的演化：先逃离对称相，然后发生专门化。非必要单元的剪除让人想起第 10.3 节末尾提到的 Occam 剃刀。在不可实现情形中，学生单元在逃离对称子空间后以级联方式专门化，分别对应越来越不主导的教师节点，同时保留与被舍弃教师单元的一定重叠。当然，即使在渐近极限中，泛化误差仍然非零。

## 13.4 反向传播

现在更进一步，考虑可能含有若干隐层的多层网络，其中所有突触向量，包括馈入输出单元的突触向量，都可以被调节。反向传播算法是目前最流行的做法 [220]。至少可以列举它成功的四个

主要原因。第一，如前所述，只要在隐层中加入足够多的单元，这样的网络就能以任意期望精度逼近输入变量  $\xi$  的任意函数  $f(\xi)$ 。第二，反向传播训练规则虽然实际上只是一个梯度下降算法，却具有一个极好的性质：修正只需要局域信息，见下文。第三，应用方便。网络结构和训练算法都很简单，除了训练集以外不需要加入额外信息。第四，这类网络尽管简单且一般，却在非常不同的问题中以近似于更专门化方法的水平取得了令人惊异的成功。

可以把上一节的计算推广到这样的反向传播网络：输出权重也在学习过程中适应，例如见 [221]。由于计算和主要图像与较简单机器中的情形相似，我们不讨论这些结果。不过，鉴于反向传播的实际重要性，我们将更详细地解释它如何工作。考虑第一章中引入的多层前馈网络，见图 1.1c；其中单元具有连续而非二值的激活函数。特别地，单元  $k$  的输出  $\sigma_k$  由位于前一层的一组其他单元  $l$  提供输入，并给出为

$$\sigma_k = g\left(\sum_l J_{lk}\sigma_l\right), \quad (13.48)$$

其中激活或传递函数  $g$  通常选为 sigmoid 形式，从  $-1$ （双极形式）或  $0$ （二值形式）到  $+1$ 。一个常用选择是  $g(x) = \tanh(\beta x)$ ，因为它可在  $\beta \rightarrow 0$  的线性感知机和  $\beta \rightarrow \infty$  的阈值敏感感知机之间调节，而且其导数可方便地用自身取值表示为  $g' = \beta(1 - g^2)$ 。

反向传播算法的目的，是对一组训练样例  $\xi^\mu$ ， $\mu = 1, \dots, p$ ，最小化总二次误差  $E$ ：

$$E = \sum_\mu (\sigma_T^\mu - \sigma_o^\mu)^2, \quad (13.49)$$

其中  $\sigma_o^\mu$  是呈现样例  $\xi^\mu$  时输出节点的值，而  $\sigma_T^\mu$  是所要求的教师输出。为简单起见，我们考虑单输出系统。多输出可完全类似处理。

显然，误差  $E$  通过所得输出值  $\sigma_o^\mu$  依赖于所有突触向量的当前选择  $\mathbf{J} = \{J_{lk}\}$ ，即  $E = E(\mathbf{J})$ 。为了降低误差，注意通过 Taylor 展开，突触强度  $\{J_{lk}\}$  的改变  $\delta J_{lk}$  在最低阶会导致如下形式的误差改变：

$$\delta E = \sum_{[l,k]} \delta J_{lk} \frac{\partial E}{\partial J_{lk}}, \quad (13.50)$$

其中求和遍历所有连接节点对  $[l, k]$ 。梯度下降对应于选择

$$\delta J_{lk} = -\eta \frac{\partial E}{\partial J_{lk}} \quad \text{for all } [l, k], \quad (13.51)$$

这显然保证  $E$  降低。乍看之下，应用 (13.51) 似乎需要相当复杂的计算，以求出除输出节点以外所有相关导数。但事实并非如此。首先注意，误差  $E$  只通过受该权重馈入的节点输出  $\sigma_k$  依赖于  $J_{lk}$ 。因此

$$\frac{\partial E}{\partial J_{lk}} = \frac{\partial E}{\partial \sigma_k} \frac{\partial \sigma_k}{\partial J_{lk}}. \quad (13.52)$$

此外，由 (13.48) 有

$$\frac{\partial \sigma_k}{\partial J_{lk}} = \sigma_l g' = \beta \sigma_l (1 - \sigma_k^2), \quad (13.53)$$

其中撇号表示对自变量求导。因此，(13.53) 只需利用局域信息即可计算。量

$$\frac{\partial E}{\partial \sigma_k} = \delta_k \quad (13.54)$$

称为节点  $k$  贡献的误差。反向传播的本质是观察到这个因子也可以局域计算。对硬件实现而言，这是一个关键优点，因为不需要长程布线。为了说明这种误差如何计算，假设某个特定节点  $l$  所馈入



的那一层节点的误差  $\delta_k$  已知。则  $\delta_l$  可计算为

$$\delta_l = \frac{\partial E}{\partial \sigma_l} = \sum_k \frac{\partial E}{\partial \sigma_k} \frac{\partial \sigma_k}{\partial \sigma_l} = \sum_k \delta_k J_{lk} \beta(1 - \sigma_k^2), \quad (13.55)$$

其中使用了  $E$  只通过由  $l$  馈入的节点输出  $\sigma_k$  依赖于  $\sigma_l$  这一事实。由 (13.55) 可知，误差可以被反向传播：某一给定节点上的误差值，是它所馈入的节点误差的加权和。

## 13.5 贝叶斯在线学习

本章最后讨论一种相当一般、且不局限于热力学极限的在线处方。它基于学习过程的贝叶斯表述；我们先作简要回顾，另见第 3.6 节和第 8.3 节。假设生成数据集  $\xi^\mu$ 、 $\mu = 1, \dots, p$  的概率分布  $P(\xi^\mu | \mathbf{T})$  已知，但它依赖一组未知参数  $\mathbf{T}$ 。用神经网络语言说，数据集除了样例以外还可以包含相应分类，而参数  $\mathbf{T}$  是教师权重集合。此外，先验信念或可信度由先验分布  $P_0(\mathbf{J})$  表示，它给出选择  $\mathbf{J}$  先验上与教师一致的概率。换言之，教师被认为是从该分布抽样得到的。利用 Bayes 定理 [116]，可计算后验分布

$$P(\mathbf{J} | \xi^\mu) \sim P(\xi^\mu | \mathbf{J}) P_0(\mathbf{J}), \quad (13.56)$$

即  $\mathbf{J}$  与教师一致的后验概率，其中已经考虑了观测样例。比例常数由归一化确定。

现在可以作若干具体选择。可以选择最大后验预测  $\mathbf{J}_{\text{MAP}} = \arg \max_{\mathbf{J}} P(\mathbf{J} | \xi^\mu)$ ，它最大化后验，因此是最可能的参数值。最大似然预测  $\mathbf{J}_{\text{ML}} = \arg \max_{\mathbf{J}} P(\xi^\mu | \mathbf{J})$  最大化样例似然；在均匀先验下，它与最大后验选择一致。最后可以作质心预测  $\mathbf{J} = \int d\mathbf{J}' \mathbf{J}' P(\mathbf{J} | \xi^\mu)$ ，即后验平均。正如第 3.6 节解释的，这种选择在估计向量与真实向量之间的平均重叠最大这一意义下是 Bayes 最优的。顺便指出，一般并不能实现统一的最优性，即对所有实现和所有判据都最优。例如，平均意义下的最优通常不同于最坏情形意义下的最优预测，后者对应于所谓 minimax 选择；更多细节见 [222]。

后验 (13.56) 的估计涉及所有训练样例  $\xi^\mu$ ，因此本质上是离线的。不过，可以通过使用一个足够合适的后验近似形式来构造在线版本；这个近似形式由在线更新的参数值表征。我们将讨论两种不同的后验选择。首先，在光滑分布的情况下，已知在相当一般的条件下，当独立样例数  $p$  趋于无穷时，后验会收敛到一个多维 Gaussian [222]。因此，为至少捕捉正确的渐近形式，自然可以假设如下 Gaussian 后验分布 [147]：

$$P(\mathbf{J} | \xi^\mu) \sim \exp \left[ -\frac{1}{2} \sum_{i,j} (J_i - m_i) C_{i,j}^{-1} (J_j - m_j) \right], \quad (13.57)$$

它由平均  $\mathbf{m} = \langle \mathbf{J} \rangle$  和相关矩阵  $\mathbf{C} = \langle (\mathbf{J} - \mathbf{m})(\mathbf{J} - \mathbf{m}) \rangle$  决定；两者都是样例数  $p$  的函数， $\mathbf{m} = \mathbf{m}(p)$ 、 $\mathbf{C} = \mathbf{C}(p)$ 。当呈现一个新样例时，用近似后验 (13.57) 代替精确后验 (13.56)，通过 Bayes 定理计算新的后验。随后用该后验确定参数的新取值  $\mathbf{m}(p+1)$  和  $\mathbf{C}(p+1)$ ；把它们代入 (13.57)，就得到  $p+1$  个样例之后的后验新近似。应用于光滑的可实现规则时，可以证明这一过程达到渐近最优的错误率，与第 9.6 节中优化在线学习得到的早先结果一致。

对于非光滑问题，Gaussian 近似预期会相当差。为说明类似思想仍可如何应用，转向二值权重教师的在线学习。在这种情况下，很自然地使用如下二值近似后验形式 [223]：

$$P(\mathbf{J} | \xi^\mu) = \prod_i \left[ \frac{1 + m_i(p)}{2} \delta(J_i - 1) + \frac{1 - m_i(p)}{2} \delta(J_i + 1) \right], \quad (13.58)$$



它由平均偏置  $\mathbf{m} = \langle \mathbf{J} \rangle$  表征。随后过程的其余部分与光滑网络相同。呈现一个新样例时，使用 (13.58) 作为  $p$  个样例之后的后验来计算新的后验，并由此计算参数的新值  $\mathbf{m}(p+1)$ 。在二值权重的感知机学生从二值权重感知机教师学习的应用中，该算法工作得相当好 [224]，从而克服了第 9.8 节末尾指出的简单更新规则（如 (9.1)）的限制。

## 13.6 讨论

在多层网络章节的末尾，我们不能不注意到，这些结构极其丰富而复杂，目前的理论分析仅仅触及表面。不过，除了教学和智识价值之外，现有理论工具也允许人们系统地研究特定问题或检验新思想，而不是靠试错。此外，正如我们在从感知机到多层网络的过渡中看到的，许多特征相当稳健；我们预期，在玩具多层网络中观察到的性质会在更现实的场景中继续存在。

让我们简要回顾本章记录的一些新特征。我们称为劳动分工的现象相当引人注目。使用最优算法时，学生的不同单元参与一场比赛博弈，以复现教师的答案。另一方面，非最优算法可能严重降低性能：它们会引入寄生相变的出现，甚至更糟，即完全无法学习一个本来可学习的问题。与感知机学习一样，我们也遇到了平台问题，但现在平台源于网络结构内禀的对称性：奇偶机中的反演对称性，以及全连接结构中的置换对称性。此外，平台是在泛化误差快速下降之后到达的，并由序参量的非平凡取值表征。

就文献而言，我们已经提到关于奇偶树机器 [225, 216] 和委员会树机器 [226, 227] 的在线学习、具有光滑传递函数的全连接机器 [217, 218, 221] 以及 Bayesian 在线方法 [147, 224] 的工作。另见 [228] 中关于鲁棒性图的研究，该研究考察错误估计教师输出噪声的情形；[219] 中对学习率和初始条件影响的进一步研究；[229] 中固定时间窗口上的优化在线学习；以及 [230, 231] 中的在线 Gibbs 算法。更近的研究考察了受限训练的情形。对已见过样例的重新抽样会破坏  $u$  和  $t$  分布的 Gaussian 性质，并使情形变得复杂得多。例如，后一分布将不再由有限个序参量（如  $R$  和  $Q$ ）描述 [232, 233]。

## 13.7 习题

- 13.1 考虑 Hebb 规则中的  $\alpha$ -依赖学习率，比较 (13.8)，即  $\eta = \eta(\alpha)$ 。证明，使泛化误差最低的函数选择事实上是常数  $\eta(\alpha)$ 。换言之，引入退火方案不能改进 Hebb 规则的性能。
- 13.2 将结果 (13.10) 与习题 12.4 结合，证明当  $K \rightarrow \infty$  时，Hebb 训练下委员会机的泛化误差由 (13.12) 给出。
- 13.3 考虑委员会树机器场景中的查询学习，其中问题与学生向量正交。证明，对学习幅度作最优选择时，该策略导致泛化误差的渐近衰减形式为

$$\epsilon(\alpha) \sim \frac{2}{\pi^{3/2}} \exp\left(-\frac{\alpha}{\pi^2}\right). \quad (13.59)$$

- 13.4 考虑委员会树机器场景中的最优学习，但加上限制： $F_{k,\text{opt}}$  不依赖其他隐单元的状态。因此 (13.13) 被替换为

$$F_{k,\text{opt}} = -t_k + \frac{Q_k}{\rho_k} \langle u_k \rangle_{|t_k, \sigma_T}. \quad (13.60)$$

证明学生某个隐单元的泛化误差  $\epsilon_k$ ，与从具有输出噪声水平

$$a = \frac{1}{2^{K-1}} \binom{K-1}{(K-1)/2} \quad (13.61)$$

的教师学习的感知机完全相同，其中  $a$  用于 (5.4)。换言之，由于其他教师隐单元的干扰，学生隐单元感受到的教师输出分类等同于一个被输出噪声污染的教师隐单元。借助这一等价性， $K$ -委员会树机器在这种情况下可对所有  $K$  显式求解；更多细节见 [227]。

13.5 考虑树结构奇偶机场景。由 (13.1)–(13.7) 证明：若用 Hebb 规则 (13.8) 训练学生机器，并把其中的和替换为乘积，则它无法从教师奇偶机学习。

13.6 用与步长  $\eta$  成正比的学习幅度，重复导致 (13.21) 和 (13.22) 的计算。证明，通过取  $\eta \sim \sqrt{Q}$  且比例因子小于  $8/\pi^{3/2}$ ，可修正小长度下重叠下降的问题。

13.7 重复第 13.2 节中最小作用量算法训练的  $K=2$  奇偶机计算，但现在教师分类存在输出噪声。证明存在一个临界噪声水平：高于它时， $\alpha \rightarrow \infty$  下泛化误差不再衰减到零 [225]。换言之，使用该算法时，问题变得不可学习。再用最优算法重复计算，证明泛化误差的  $1/\alpha$  渐近衰减在所有噪声水平下保持，且比例因子与感知机中的完全相同（细节见 [216]）。

13.8 训练一个前馈反向传播网络来学习 XOR 问题；该网络有两个输入节点、两个隐节点和一个输出节点。网络是否总是收敛？

13.9 考虑标准反向传播算法在某一时刻  $t$  的修正：

$$\delta J_{lk}(t) = -\eta S_{lk}(t), \quad (13.62)$$

其中  $S_{lk}(t)$  是时刻  $t$  的梯度：

$$S_{lk}(t) = \frac{\partial E}{\partial J_{lk}}. \quad (13.63)$$

现在假设  $E$  对  $J_{lk}$  的依赖具有形式

$$E = a + bJ_{lk} + cJ_{lk}^2. \quad (13.64)$$

证明，所谓 quick-prop 选择 [234]

$$\delta J_{lk}(t) = \delta J_{lk}(t-1) \frac{S_{lk}(t)}{S_{lk}(t-1) - S_{lk}(t)} \quad (13.65)$$

可实现最小误差。用这种方法求解 XOR 问题。证明这种冒险算法通常比标准反向传播收敛得更快，但有时完全不收敛。

13.10 根据 Ruelle 和 Takens 的一个一般定理 [235]，分形维数为  $d$  的混沌吸引子的动力学可由时间离散映射  $x(t+1) = F(x(t), \dots, x(t-m))$  精确复现，其中  $m$  位于  $d$  与  $2d+1$  之间。基于此，你能否提出一个前馈反向传播网络，使它成为学习混沌时间序列的良好候选？更多细节见 [236]。

## 第十四章 还有什么？

在本书中，我们讨论了如何利用无序系统统计力学发展出的概念和技术，来量化人工神经网络学习的不同方面。这些方法最初源于人们想理解无序磁体某些奇异低温性质的愿望；然而，它们对于另一类完全不同的复杂系统分析所表现出的有效性，也凸显了统计力学原理的普遍性与力量。

在最后这一章中，我们收集若干非物理复杂系统的补充例子。对这些系统，使用类似于研究神经网络时所采用的统计力学方法，已经产生了一些新的而有趣的结果。与前面各章相比，本章的讨论会稍微浅一些：我们主要指出这些问题与前文已阐明问题之间的定性类比，而不再完整展开所有后果。此外，我们考虑的一些问题与信息处理和人工神经网络密切相关，另一些则并非如此。在所有情形中，冻结随机变量都被用来表示那些细节未知的复杂相互作用，而在适当定义的热力学极限中，典型行为尤其令人感兴趣。

### 14.1 支持向量机

感知机之所以不能成为解决许多现实学习问题的严肃候选者，主要原因在于它只能实现线性可分的 Boolean 函数。在第 12 章和第 13 章中，我们已经看到，这一限制可以通过引入形式神经元的隐层来克服。这类多层网络中的输入-输出映射可以看作一个两步过程。首先，输入被映射为内部表示。由于隐单元的 sigmoidal 激活函数，这是从输入空间到某个抽象中间表示的非线性变换。其次，从隐层到输出层的映射对这些内部表示执行线性可分的分类。因此，从输入层到隐层的映射承担了一种预处理任务，把一个非线性可分的问题变换为线性可分的问题。

从不一定与人工神经网络相关的一般学习机器观点出发，这一策略可以按如下方式推广。输入  $\mathbf{S}$  仍取为  $N$  维实向量，并通过一个一般的非线性变换映射到中间的特征空间。随后，输出由该特征空间中的一个感知机执行线性可分分类来确定。

直观上似乎相当清楚：只要把输入映射到足够高维特征空间的函数足够复杂，就应当能够把输入空间中的任意分类展开为特征空间中的线性可分函数。然而，我们关心的是能够从样例中学习的系统：乍看之下，由特征空间的高维、甚至无限维所造成的巨大可变性，似乎无论在原则上还是实践上都会阻碍有效学习。

不过，有两个非平凡观察克服了这些困难，并把上述设想转变为机器学习实际问题中最有希望的方法之一。

第一个观察是：如果用第 3.5 节讨论过的最大稳定感知机在特征空间中执行分类，那么机器的 VC 维会显著降低 [155]。再次考虑一个训练集  $\{\xi^\mu, \sigma_T^\mu\}$ ，其中包含  $p$  个输入  $\xi^\mu$  及其目标输出  $\sigma_T^\mu$ 。特征空间中最大稳定感知机的耦合向量  $\mathbf{J}$  可以写成（比较 (3.11)）

$$\mathbf{J} \sim \sum_{\mu} x^\mu \sigma_T^\mu \Phi(\xi^\mu). \quad (14.1)$$

只有一部分嵌入强度  $x^\mu$  非零。在最大稳定感知机的情形中，满足  $x^\mu \neq 0$  的输入被称为活跃样例；在当前更一般的框架中，它们称为支持向量。在学习过程中，只有这些支持向量的嵌入强度的显式

值需要确定。因此,对泛化误差给出界限时,关键量不是特征空间维数,而是支持向量数目与样例总数之间的比值 [155]。此外,如第 3.5 节所述,最大稳定感知机耦合向量的显式确定可以通过凸优化的强有力方法有效完成 [46]。综合起来,这保证了即使在极高维特征空间中,原则上也可以从样例进行有意义的学习。

第二个要点涉及一个更实际的问题:怎样为所考察的具体问题显式构造合适的非线性映射  $\Phi(\mathbf{S})$ 。颇为令人惊讶的是,完整的  $\Phi(\mathbf{S})$  形式根本不需要知道 [237, 238]。相反,只需知道两个输入  $\mathbf{S}$  和  $\mathbf{S}'$  对应的特征向量  $\Phi(\mathbf{S})$  与  $\Phi(\mathbf{S}')$  的标量积;它由所谓核函数指定:

$$K(\mathbf{S}, \mathbf{S}') = \Phi(\mathbf{S})\Phi(\mathbf{S}') = \sum_i \Phi_i(\mathbf{S})\Phi_i(\mathbf{S}'). \quad (14.2)$$

原因在于,在学习过程中(比较 (3.24)),确定耦合向量  $\mathbf{J}$  只需要知道相关矩阵

$$C_{\mu\nu} = \Phi(\xi^\mu)\Phi(\xi^\nu)\sigma_T^\mu\sigma_T^\nu, \quad (14.3)$$

利用 (14.2) 可将其写成

$$C_{\mu\nu} = K(\xi^\mu, \xi^\nu)\sigma_T^\mu\sigma_T^\nu. \quad (14.4)$$

此外,学习完成后,为了确定一个新样例  $\mathbf{S}$  的分类,需要计算  $\text{sgn}(\mathbf{J}\Phi(\mathbf{S}))$ 。借助 (14.1),它变成

$$\text{sgn}(\mathbf{J}\Phi(\mathbf{S})) = \text{sgn}\left(\sum_\mu x^\mu K(\xi^\mu, \mathbf{S})\sigma_T^\mu\right), \quad (14.5)$$

因此同样完全由核函数  $K$  决定。于是没有必要处理完整映射  $\Phi$  的所有复杂性。更方便的做法是选取一个合适的核函数  $K(\mathbf{S}, \mathbf{S}')$ , 例如代表输入空间中的多项式判决曲面,然后直接使用方程 (14.4) 和 (14.5)。当然,并非任意函数  $K(\mathbf{S}, \mathbf{S}')$  都能写成 (14.2) 的形式;不过,保证这种分解存在的数学条件是熟知的(Mercer 定理,见如 [239])。通过这种方式,即使是无限维特征空间,也可以在所需工作量上几乎不超过最大稳定感知机的情形。一个简单例子由所谓径向基函数网络给出,见如 [240],其定义为

$$K(\mathbf{S}, \mathbf{S}') = \exp\left(-\frac{|\mathbf{S} - \mathbf{S}'|^2}{2}\right), \quad (14.6)$$

对应于以无限维 Hilbert 空间作为特征空间。

支持向量机的统计力学分析建立在它与最优稳定感知机的紧密联系之上。所需的耦合  $\mathbf{J}$  在特征空间中以最大间隔执行线性可分分类,因此它在约束  $\mathbf{J}\Phi(\xi^\mu)\sigma_T^\mu > 1$  下使范数  $\mathbf{J}^2$  最小。于是我们引入配分函数

$$Z = \int d\mu(\mathbf{J}) e^{-\beta\mathbf{J}^2/2} \prod_\mu \theta(\mathbf{J}\Phi(\xi^\mu)\sigma_T^\mu - 1) \quad (14.7)$$

并考察自由能  $f = -\langle \ln Z \rangle / \beta$  的零温极限  $\beta \rightarrow \infty$ 。目标标签  $\sigma_T^\mu$  由一个教师支持向量机给出;该教师具有相同的函数  $\Phi$ , 并含有一个未知的耦合向量  $\mathbf{T}$ , 在特征空间中执行分类。

文献 [241] 针对如下形式的多项式核完成了这一方案:

$$K(\mathbf{S}, \mathbf{S}') = g\left(\frac{\mathbf{S}\mathbf{S}'}{N}\right) \quad (14.8)$$

其中

$$g(x) = \sum_l a_l x^l. \quad (14.9)$$

所得泛化误差行为显示出一系列平台层级,对应于训练集大小  $p$  与输入空间维数  $N$  的不同比例区间  $p \sim N^l$ 。这类似于第 12.6 节中对全连接委员会机的讨论。对于含有高阶相互作用的感知机,例

如在输出局域场表达式中包含  $J_{ij}S_iS_j$  型项的模型,也发现了类似行为 [242]。粗略地说,当  $p \sim N$  时,样例只足以学习 (14.9) 的线性成分;当  $p \sim N^2$  时,二次部分被调节;依此类推。不过,这不应按字面理解,因为从分解 (14.1) 可以清楚看出,对于  $p$  的所有标度区间,  $\Phi$  的非线性特征也会对  $\mathbf{J}$  作出贡献。

与感知机情形一样,统计力学分析允许在热力学极限中精确计算若干有趣量。由此,它对支持向量机性能的定量刻画作出了关键贡献。例如在 [241] 中,不仅计算了学习曲线  $\epsilon(\alpha)$ ,还计算了支持向量的平均数目。此外,文中还表明,具有二次核的支持向量网络在线性可分任务上表现相当好,验证了虽然容量较大,其泛化能力仍然非常高。存储问题也被加以讨论,并重新导出了 Cover 关于多项式判决曲面的结果 [72]。

支持向量机的概念由 V. N. Vapnik 及其合作者在 1990 年代发展起来 [171, 243]。文献 [244] 给出了教学性的介绍。在学习的统计力学中,支持向量机同样构成了一个现代而有前景的领域。

## 14.2 复杂优化

组合优化问题在日常工程实践中大量出现,例如物流、调度和设计,以及 IC 芯片布局和布线。相当一般地,这些问题可以表述为:在许多参数以及大量  $N$  个变量之下最小化某个代价函数。参数的不同选择对应于问题的不同实例。

著名例子包括旅行商问题、数划分问题和背包问题。在旅行商问题中,给定  $N$  个城市的列表以及任意两城之间的旅行代价,要求找到一条旅行商路线,使其恰好经过每个城市一次,回到起点,并使总代价最小。在数划分问题中,给定  $2N$  个实数,要求把它们划分为两个子集,使两个子集中数字和的差尽可能小。在背包问题中,给定  $N$  个具有不同“效用”和“负载”的物品,要求找出一个效用最大的物品子集,同时不超过给定负载上限。<sup>1</sup> 与本书主题相关的一个问题,是具有离散自由度的神经网络学习(见第 7.4 节)。

实践经验表明,其中一些问题容易求解,另一些则出了名地困难;还有一些问题的某些实例很难,而其他实例容易。算法复杂性理论 [245, 246] 的目标,是把这些松散说法严格化为数学定理。为此,关键在于研究算法求解一个问题所需时间  $t$  如何依赖问题规模  $N$ 。

如果对某个问题存在一种算法,使该时间仅按  $N$  的幂增长,即  $t \sim N^\gamma$ ,那么该问题称为多项式问题,属于类 P。注意,求解任意组合优化问题都有一个普适而显然的算法,即穷举搜索:计算所有可能构型的代价函数并选出最小值。这种算法的时间标度至少随  $N$  指数增长。因此,知道一个多项式算法的存在,意味着对该问题具有更深入的理解,并且这种理解被用于得到有效得多的解法。

然而,对于许多相关问题,目前并不知道多项式算法;因此存在一些实例,使得求解所需时间随  $N$  指数增长,从而即使对相当小的规模,精确求解也会变得不实际。这种指数标度的一个显然但也相当无趣的原因,可能是对  $N$  个变量的某个具体构型计算代价函数本身就非常昂贵。更有挑战性的情形,是那些代价函数本身容易计算的问题,也就是说,其计算复杂度关于系统大小是多项式的。此时,解所需时间的指数标度才真正来自问题的内在困难。因此,人们仍然可以希望改进对问题的理解并找到更有效的算法。这类问题称为非确定性多项式问题,组成类 NP。

在所有 NP 问题中,有一些问题尤为突出,因为任意一个 NP 问题的任意实例,都可以在多项

<sup>1</sup> 亲自尝试求解这些问题的随机生成实例很有启发性,系统大小可取中等的  $N$ ,例如 10 到 50。



式时间内映射为这些问题的某个实例。这个 NP 问题子类称为 NP-完全问题，并构成所有 NP 问题的核心。第一个被证明为 NP-完全的问题是可满足性问题，它询问是否能为  $N$  个逻辑变量赋值，使一个涉及这些变量及其否定的长逻辑表达式为真 [247]；另见 [248] 中的教学性介绍。

计算复杂性理论中的基本问题之一，是类 P 与 NP 是否确实不同。根据上述定义，这等价于询问是否存在一种算法，能够在多项式时间内求解至少一个 NP-完全问题。尽管人们普遍相信这样的算法不存在，但迄今尚无证明。

由于优化问题涉及代价函数的最小化，乍看之下它们很容易与统计力学技术联系起来。例如考虑数划分问题，可以引入二值变量  $S_i = \pm 1$ ,  $i = 1, \dots, 2N$ ，用以指定第  $i$  个数  $a_i$  属于哪个子集；这样，问题的解对应于具有能量

$$H(\mathbf{S}) = \sum_{i,j} a_i a_j S_i S_j \quad (14.10)$$

的 Ising 自旋系统的基态。具有效用  $a_i$  和负载  $b_i$  的背包问题也可类似表述：引入变量  $c_i$ ，其取值为 1（把物品  $i$  放入背包）或 0（不包括该物品），并寻找能量函数

$$H(\mathbf{c}) = - \sum_i a_i c_i \quad (14.11)$$

在约束  $\sum_i b_i c_i < B$  下的最小值。该约束可以通过 Lagrange 乘子纳入能量中，而这个乘子起到化学势的作用。类似地，旅行商问题 [17] 和可满足性问题 [249] 也可以映射为确定适当 Ising 自旋系统基态的问题。

然而，尽管存在这些形式相似性，算法复杂性与复杂优化理论中的关注点仍然与统计力学相当不同。在前者中，一个实例的所有细节都是已知的，并且需要完整的微观解。相反，在统计力学中，人们只掌握系统的部分信息，并寻求平均的宏观特征。不过，如果考虑复杂优化问题随机生成实例系综的统计力学，这种联系仍然可能变得富有成果。正如本书所讨论的学习情形一样，刻画优化问题的许多有趣量，例如旅行商问题中的最短巡回长度，都是自平均的，因此对几乎所有实例都相同。因此，统计力学再次试图刻画典型性质，从而与算法复杂性理论互补；后者集中于最坏情形，即最困难实例。对实际目的而言，优化问题的典型困难度常常可能比过度悲观的最坏情形结果更相关。事实上，已知对某些 NP-完全问题，大多数实例可以容易求解，只有极少数实现真的需要对所有可能构型作完整枚举 [250, 251]。

统计力学的结果可以以几种方式对优化任务有用。首先，对代价函数典型最小值的估计显然可作为求解某个具体实例的指南，因为它允许判断一个中间结果离真正最优值可能还有多远。此外，典型基态代价的界，例如来自退火近似的界，在显式求解问题时所用的分支定界算法中可能极为有用。除此之外，基态熵以及更一般地说基态附近的态密度，分别给出最优解和近最优解的典型数目。借助这些信息，人们可以比较寻找真正最优解与寻找几乎最优解所需的努力。在实际情形中，与其坚持寻找难以得到且只带来微小额外改进的真正最优解，不如满足于一个容易确定的近最优解，这也许更为可取。此外，可用低能构型之间的重叠参数来刻画优化问题近最优解之间的相互关系 [252]。这使人们能够形成关于解空间拓扑的印象，而这种印象对于设计合适算法可能非常有用。特别地，一族称为模拟退火的算法已经被提出，它源自统计力学中使用的标准 Monte Carlo 方法 [98]。这类算法的效率关键取决于可能的动力学相变的位置与性质，而后者又与解空间的组织有关。最后还要提到，有限尺寸标度技术是统计力学中数值研究相变的标准工具；它已被发现对定量研究可满足性问题算法复杂性的突变转变极有价值 [253]。

因此，在无序系统理论中发展起来的统计力学技术，可以用于分析复杂优化问题；相应结果往往与数学和理论计算机科学中得到的结果互为补充。一个具体计算例子见 [17]，其中包括对旅行商



问题的讨论。背包问题已在统计力学框架中通过利用与第 6.3 节所讨论 Ising 感知机的类比而得到分析 [254, 255]。对于可满足性问题, [249, 256] 基于统计力学 [257] 与计算机科学 [253] 中的先前的工作, 使用与神经网络学习问题中引入的方法相当类似的技术, 进行了非常详细的统计力学分析。关于数划分问题若干令人惊讶方面的漂亮而简洁讨论, 见 [258, 259]。

### 14.3 纠错码

自 Shannon 关于信息论的奠基性工作 [260, 261] 以来, 编码与消息传输研究已经发展成为一个独立学科。Shannon 的伟大成就之一, 是证明有噪传输信道实际上能够以某个最大速率无误差地传输信息, 这个最大速率称为信道容量。作为例子, 考虑有噪二元信道, 其中一个 bit 在传输过程中以概率  $(1-a)/2$  被翻转。这样一个有噪 bit 所包含的信息为

$$\frac{1}{\alpha_c} = 1 - \left( -\frac{1-a}{2} \log_2 \frac{1-a}{2} - \frac{1+a}{2} \log_2 \frac{1+a}{2} \right). \quad (14.12)$$

括号中的项表示由有噪翻转造成的信息损失。根据 Shannon 定理, 使用合适的纠错码, 可以从一条长度为  $\alpha_c N$  的有噪传输消息中无误差地恢复一条  $N$  bit 的消息 (在  $N \rightarrow \infty$  极限中) [164]。

最近, Sourlas 提出了一族新的编码 [262], 其中消息被编码为自旋模型的最低能态或基态。类似于自旋玻璃理论和神经网络中所用的方法, 可以用统计力学方法分析这些编码的效率, 并探索和构造新的编码方式。

基本思想如下。消息由一个  $N$  维二值向量  $\xi$  构成。并不直接发送该信号, 而是传输如下形式的二值耦合向量构成的编码消息:

$$J_{i_1 i_2 \dots i_K}^0 = \xi_{i_1} \xi_{i_2} \cdots \xi_{i_K}, \quad (14.13)$$

也就是信号  $\xi$  中指标为  $i_1, i_2, \dots, i_K$  的  $K$  个分量的乘积。用  $J_{i_1 i_2 \dots i_K}$  表示二值变量  $J_{i_1 i_2 \dots i_K}^0$  的传输版本。目标是把原消息恢复为如下能量函数的最低态; 该能量函数具有由  $\mathbf{J}$ -耦合描述的  $K$ -自旋相互作用:

$$H(\mathbf{S}) = - \sum_K \sum_{(i_1 i_2 \dots i_K)} c_{i_1 i_2 \dots i_K} J_{i_1 i_2 \dots i_K} S_{i_1} S_{i_2} \cdots S_{i_K}. \quad (14.14)$$

这里  $\mathbf{S}$  是一个  $N$  维自旋变量; 内层求和对给定连通度  $K$  下所有  $\binom{N}{K}$  种不同指标选择求和;  $c$  是连通矩阵, 如果相应的  $K$ -自旋相互作用存在, 则其元素取值 1, 否则为 0。为理解这一构造的动机, 先考虑完全连通  $c \equiv 1$  且信道无噪声的情形。此时显然, 能量  $H$  的最小值在  $\mathbf{S} = \xi$  处达到。不过, 这并不是一个很高效的过程, 因为被传输的 bit 数, 也就是所有耦合分量的数目, 远大于  $N$ 。然而, 由于关于信号的信息以冗余且“分布式”的方式存储, 人们预期当信道变得有噪时, 并且更重要地, 当通过随机稀释自旋之间的连接来删除冗余信息时, 正确的基态仍可保留下来。具体做法是把连通矩阵  $c$  中相应元素置零。与此同时, 只有那些对应于非零元素的耦合分量需要被传输。根据 Shannon 界, 在  $N \rightarrow \infty$  极限中, 有可能把它们的数目降到  $\alpha_c N$ 。

为了详细研究这一问题, 需要考虑从 Boltzmann 分布中抽取自旋态  $\mathbf{S}$ :

$$\text{Prob}(\mathbf{S}) = \frac{1}{Z} e^{-\beta H(\mathbf{S})}. \quad (14.15)$$

相应自由能定义为

$$f(\beta) = -\frac{1}{\beta} \lim_{N \rightarrow \infty} \frac{1}{N} \langle \ln Z \rangle, \quad (14.16)$$

其中平均是对稀释的随机选择、突触向量的随机翻转以及随机选择的消息取的。现在可以通过取零温极限  $\beta \rightarrow \infty$  来研究基态性质。在用复本技巧计算  $f$  的过程中, 会遇到如下自平均序参量:

$$R(\beta) = \frac{1}{N} \sum_{i=1}^N S_i \xi_i. \quad (14.17)$$

如果该重叠在  $\beta \rightarrow \infty$  极限中趋于 1, 那么信号确实被无误差地恢复; 更准确地说, 错误数不是广延的。为了用自旋系统语言重新表述同一问题, 我们先注意到, 可以不失一般性地选择<sup>1</sup>信号所有分量都等于 1。于是, 需要值的基本量是磁化强度

$$m(\beta) = \frac{1}{N} \sum_{i=1}^N S_i, \quad (14.18)$$

信号的完全恢复对应于铁磁基态。

上述问题已经在若干场景中得到研究, 这些场景的主要区别在于自旋连接如何被稀释, 也就是连通矩阵  $c$  的选择。Sourlas [262] 考虑了只允许对  $K$  求和中的一项出现、但连通度很高的问题, 即每个自旋的连接数正比于  $\binom{N-1}{K-1}$ 。当  $K = 2$  时, 它可映射到 Sherrington–Kirkpatrick 模型 [264]; 而当  $K \rightarrow \infty$  时, 则得到随机能量模型 [79]。在后一种情形中, 发现 Shannon 界确实达到饱和。稀疏连通情形, 即每个自旋的连接数为 1 的量级, 在 [265] 中得到研究, 并且在一个极限情形中再次恢复 Shannon 界。受奇偶校验码思想的启发, 人们还考虑过这样一种情形: 能量函数由对配位数  $K$  的求和构成, 其中  $K$  从 1 到某个最大值  $N^\alpha$ , 并且每个配位阶数  $K$  只有一个随机选择的自旋相互作用 [266]。

有趣的是, 可以在 Bayesian 框架中证明, Sourlas 基态最大化后验概率, 也就是它是消息最可能的选择。然而, 正如从有噪教师学习在零温下并非最优一样, 见第 5 章, 零温解码并不一定给出最低错误率。事实上, Ruján [267] 建议把有限温度下自旋系统中观察到的截断磁化, 作为消息的最佳近似; 这个有限温度就是所谓 Nishimori 温度  $T_N$ , 其满足

$$\frac{1}{T_N} = \frac{1}{2} \ln \frac{1+a}{1-a}. \quad (14.19)$$

随后有人证明 [268], 在这种情况下错误率总是不高于基态的错误率。同一类思想也被应用于图像恢复 [269]。它与纠错码的主要差别在于, 图像恢复中通常并没有收到额外的冗余信息, 但可以利用关于图像的先验知识来去除噪声。

需要强调的是, 不同纠错码方案的实际实现通常远非直接。对于使用自旋系统映射的编码, 例如会观察到精度与基态吸引盆之间的权衡; 这里精度指最终磁化强度。如果后者相当小, 那么该编码在实践上毫无用处, 尽管理论上它仍可能使 Shannon 界饱和。关于这一困境可能解决方案的想法, 见 [270]。

最后, 我们转向另一种编码, 即由本书研究过的一个神经网络模型所启发的编码。我们曾提到, 当考虑特定楔宽  $\gamma = \gamma_c = \sqrt{2 \ln 2}$  时, 从相似教师学习的 Ising 反楔形感知机在泛化上达到信息论界, 见第 7.3 节。因此, 原则上可以基于随机选择样例  $\xi^\mu$ ,  $\mu = 1, \dots, p = \alpha N$ , 的分类  $\sigma_T^\mu = g_{\text{RW}}(\mathbf{T} \xi^\mu / \sqrt{N})$ , 在  $\alpha = 1$  时重构  $N$  维二值教师向量  $\mathbf{T}$ 。这里  $g_{\text{RW}}(\lambda) = \text{sgn}(\lambda - \gamma) \text{sgn}(\lambda) \text{sgn}(\lambda + \gamma)$  是反楔传递函数。如果这些分类经过有噪信道传输, 问题就等价于从具有输出噪声的教师学习,  $\sigma_T'^\mu = \eta^\mu \sigma_T^\mu$ , 比较第 5 章; 其中  $\eta^\mu$  根据该信道是否出错而取  $-1$  或  $+1$ 。为了在这种情况下重构教师, 我们定义能量函数  $H(\mathbf{J})$ , 它计数学生  $\mathbf{J}$  在有噪分类上的错误数:

$$H(\mathbf{J}) = \sum_{\mu=1}^p \theta \left( -g_{\text{RW}} \left( \frac{\mathbf{J} \xi^\mu}{\sqrt{N}} \right) g_{\text{RW}} \left( \frac{\mathbf{T} \xi^\mu}{\sqrt{N}} \right) \eta^\mu \right). \quad (14.20)$$

<sup>1</sup>这可通过切换到新自旋变量  $\tilde{S}_i = \xi_i S_i$  以及纯铁磁相互作用  $J^0$  来实现, 正如自旋玻璃的 Mattis 模型 [263] 中那样。

基于我们对有限温学习的经验, 将从 Boltzmann 系综中抽样  $\mathbf{J}$ :

$$\text{Prob}(\mathbf{J}) = \frac{1}{Z} e^{-\beta H(\mathbf{J})}. \quad (14.21)$$

所用温度是逆 Nishimori 温度的类似物, 即  $\beta = \beta_N = \ln \frac{1+a}{1-a}$ , 比较 (5.32)。在该温度下, 被选中的学生相对于有噪分类  $\sigma_T^\mu$  犯错的数目, 与教师一样多。这恢复了学生与教师之间的对称性, 从而在复本技巧中允许作  $n \rightarrow 1$  而不是  $n \rightarrow 0$  的计算, 并伴随有对称性质  $q = R$ 。对特定楔宽  $\gamma = \gamma_c$  执行这些计算, 还发现当  $\alpha \leq \alpha_c$  时  $q = R = 0$ , 其中  $\alpha_c$  由 (14.12) 定义, 并且退火近似变为精确。特别地, 当  $\alpha \leq \alpha_c$  时, 熵为

$$s(\alpha) = \ln 2 \left( 1 - \frac{\alpha}{\alpha_c} \right). \quad (14.22)$$

在  $\alpha = \alpha_c$  处, 熵变为零, 并发生到完美泛化  $R = 1$  的一阶转变。因此, 原则上可以从  $p = \alpha_c N$  个有噪分类中重构教师。反楔编码由此使 Shannon 界饱和。

## 14.4 博弈论

博弈论的目标, 是用数学语言为通常出现在经济学、社会学或政治学中的决策问题建模。虽然以此为目标的最早尝试看起来已相当古老, 但只有在 John von Neumann 的开创性工作被收录进影响深远的著作 [271] 之后, 博弈论才成为一个成熟的数学领域。此后, 随着若干有趣结果的获得, 包括均衡的刻画 [272] 与合作的涌现 [273], 博弈论已经发展成一个繁荣的数学领域, 并且对经济学研究产生越来越大的影响。<sup>1</sup>

一般的博弈论设置由一组参与者  $\{X, Y, \dots\}$  表征, 他们在不同策略  $\{X_i\}$ 、 $\{Y_j\}$ 、 $\dots$  之间作选择。博弈结果由每个参与者将得到的收益  $P_X(X_i, Y_j, \dots)$ 、 $P_Y(X_i, Y_j, \dots)$ 、 $\dots$  指定。博弈重复许多次, 每个参与者都努力最大化自己的累积收益。关键点在于, 每个个体参与者的收益依赖于整组策略, 包括所有其他参与者所选择的策略。因此, 为最大化自己的收益, 每个参与者必须在无法控制其他参与者行动的情况下优化自己的策略。

人们已经研究过这一基本场景的若干实现; 通常这些实现只涉及少数参与者, 且每个参与者可用的策略也只有少数几个 (见如 [271, 274])。与当前语境相关的方面在于, 可能策略的数目常常很大, 并且收益对策略的依赖一般非常复杂, 涉及许多参数。于是, 一个自然问题是: 收益能否由随机函数来建模, 以及能否识别出刻画博弈典型性质的有趣自平均量。

最近已表明, 这一思路对于矩阵博弈 [275] 以及双矩阵博弈的一些方面 [276, 277] 是有成果的。矩阵博弈是两个参与者之间零和博弈的一种经典而简单的实现形式, 也构成了 von Neumann 早期研究的基础。两个参与者  $X$  与  $Y$  可以分别在  $N$  个策略  $X_i$  和  $M$  个策略  $Y_j$  之间选择; 收益  $P_X(X_i, Y_j) =: c_{ij}$  与  $P_Y(X_i, Y_j) =: -c_{ij}$  总是相加为零, 并被编码在收益矩阵  $c_{ij}$  中。因此, 一个参与者所得总是另一个参与者所失, 两个参与者的目标完全冲突。

为了对情形有一些直观感受, 考虑一个简单例子。令收益矩阵为

$$c_{ij} = \begin{pmatrix} -8 & 2 & -4 & -11 \\ 6 & 4 & 2 & 17 \\ 12 & 7 & 1 & 3 \end{pmatrix}. \quad (14.23)$$

对参与者  $X$  而言, 如下做法是合理的: 如果他采用策略  $i$ , 至少会得到收益  $\min_j c_{ij}$ 。在这个例子中, 选择策略 1、2 或 3 分别保证收益  $-11$ 、2 和 1。因此最好选择这些值中的最大者, 并采用满

<sup>1</sup>1994 年诺贝尔经济学奖授予 J. C. Harsanyi、J. S. Nash 和 R. Selten, 以表彰他们在博弈论方面的工作。

足  $\min_j c_{i^*j} = \max_i \min_j c_{ij}$  的策略  $i^*$ 。在此例中, 这就是策略 2。类似地, 参与者  $Y$  为了最大化自己的收益, 首先考察采用某个给定策略时可能遇到的最大损失, 也就是对所有  $j$  确定  $\max_i c_{ij}$ 。在这个例子中, 采用策略 1、2、3 和 4 时, 他可能分别损失 12、7、2 和 17。因此他选择满足  $\max_i c_{ij^*} = \min_j \max_i c_{ij}$  的策略  $j^*$ , 使最大可能损失最小。在此例中, 参与者  $Y$  的最佳选择因而是策略 3。由 (14.23) 指定的矩阵博弈因此代表一个相当简单的情形。参与者  $X$  应始终采用他的第二个策略, 而参与者  $Y$  应始终采用他的第三个策略。如果其中一方偏离这一处方而另一方保持不变, 则偏离者的收益会下降。这是 Nash 均衡最基本的例子 [272, 274]。

不难证明, 对给定矩阵  $c_{ij}$ , 总有

$$\max_i \min_j c_{ij} \leq \min_j \max_i c_{ij}. \quad (14.24)$$

只有当矩阵  $c$  有鞍点时等号才成立, 也就是说, 若存在一对  $i^*, j^*$ , 使

$$\max_i \min_j c_{ij} = c_{i^*j^*} = \min_j \max_i c_{ij}, \quad (14.25)$$

就如例 (14.23) 中那样。对于没有鞍点的收益矩阵, 情形更有趣。由不等式 (14.24) 可知, 参与者  $X$  能够保证的收益小于参与者  $Y$  所预期的损失。直观上很清楚, 两个参与者应试图进入由上述悲观推理留下的这一间隙。然而, 若以可被对手预见的方式偏离各自策略, 可能导致巨大损失。von Neumann 的一个关键思想是, 参与者可以通过随机混合策略来提高收益。这允许他们以对另一参与者不可预测的方式, 使用所有策略, 包括那些可能带来高收益、但也承担同样高损失风险的策略。

因此, 给出采用不同策略  $X_1, \dots, X_N$  的概率向量  $\mathbf{x} = \{x_1, \dots, x_N\}$ , 称为参与者  $X$  的混合策略。由于这些向量是概率, 它们当然必须满足归一化条件

$$\sum_i x_i = 1. \quad (14.26)$$

von Neumann 著名的极大极小定理断言, 对于所有收益矩阵  $c_{ij}$ , 都存在混合策略的鞍点; 也就是说, 存在最优混合策略  $\mathbf{x}^*$  和  $\mathbf{y}^*$ , 使得 (比较 (14.25))

$$\max_{\mathbf{x}} \min_{\mathbf{y}} \sum_{i,j} c_{ij} x_i y_j = \sum_{i,j} c_{ij} x_i^* y_j^* = \min_{\mathbf{y}} \max_{\mathbf{x}} \sum_{i,j} c_{ij} x_i y_j. \quad (14.27)$$

最优混合策略下的期望收益

$$\nu_c := \sum_{i,j} c_{ij} x_i^* y_j^* \quad (14.28)$$

称为博弈的值。对于具有鞍点的博弈, 最优策略作为纯策略实现, 其形式为  $x_i = \delta(i, m)$ 、 $y_j = \delta(j, n)$ , 其中 Kronecker 符号由 (A1.13) 定义, 而博弈的值正是收益矩阵的相应元素  $c_{mn}$ 。

除了最优混合策略的存在性之外, 人们对它们知之甚少。如果参与者可用策略数  $N$  和  $M$  很大, 可以通过在热力学极限  $N, M \rightarrow \infty$  中考虑随机生成的收益矩阵, 来获得某些一般洞见。如果收益矩阵中不同元素  $c_{ij}$  是独立随机变量, 不难证明, 纯策略鞍点的概率随矩阵大小指数衰减。因此, 最优混合策略以概率 1 是非平凡的。为了继续分析, 下面这个简单结果非常有用: 参与者  $X$  的混合策略  $\mathbf{x}^*$  是最优的充要条件为

$$\sum_i c_{ij} x_i^* \geq \nu_c \quad \text{for all } j. \quad (14.29)$$

必要性在于, 如果对某个  $j$  它被违反, 参与者  $Y$  就可以通过始终采用  $j$  来提高自己的收益。充分性在于, 将该式乘以  $y_j$  并对  $j$  求和, 可知参与者  $X$  采用  $\mathbf{x}^*$  时的收益绝不会小于  $\nu_c$ 。

利用这一条件, 可以为最优混合策略引入指示函数

$$\chi(\mathbf{x}) = \prod_{j=1}^M \theta \left( \sum_i c_{ij} x_i - \nu_c \right). \quad (14.30)$$

如果 (14.29) 至少对一个  $j$  被违反, 则该函数为 0, 否则为 1。把这个函数放在对所有满足归一化条件 (14.26) 的可能混合策略  $\mathbf{x}$  的积分之下, 就会投影出参与者  $X$  的全部最优策略。不过, 以 (14.30) 的形式, 指示函数还没有多大帮助, 因为  $\nu_c$  是收益矩阵的一个复杂函数, 事先未知。然而, 受最优稳定神经网络经验的指引 (比较第 4.1 节和第 6.1 节), 我们可以引入冻结熵

$$s(\nu) = \lim_{N \rightarrow \infty} \frac{1}{N} \left\langle \ln \int_0^1 \prod_{i=1}^N dx_i \delta \left( \sum_i x_i - 1 \right) \right. \\ \left. \times \prod_{j=1}^M \theta \left( \sum_i c_{ij} x_i - \nu \right) \right\rangle. \quad (14.31)$$

它描述了满足 (14.29) 但把  $\nu_c$  替换为一般阈值  $\nu$  的策略的典型可变性。这里的平均是对收益矩阵元素的分布取的。根据期望收益  $\nu_c$  的定义 (14.28), 我们预期当  $\nu \rightarrow \nu_c$  时  $s(\nu) \rightarrow -\infty$ , 因为随着  $\nu$  增大, 可用混合策略的数目减少, 直到  $\nu = \nu_c$  时只剩最优混合策略  $\mathbf{x}^*$  (也比较图 4.1)。因此, 计算冻结熵 (14.31) 并取与  $s(\nu) \rightarrow -\infty$  对应的适当序参量极限, 就可以刻画随机博弈的典型值以及最优稳定性的典型性质。显式计算 [275] 与第 6.1 节中球形感知机存储问题的计算相当类似; 一个显著差别是, 感知机耦合的球面约束 (2.1) 必须替换为概率  $x_i$  的单纯形约束 (14.26)。

作为一个有趣例子, 文献 [275] 计算了最优策略中零分量的比例。结果表明, 在参与者  $X$  可用的  $N$  个策略中, 有一个广延比例在最优策略中完全不会被采用, 也就是说, 它们满足  $x_i^* = 0$ 。这一比例对两个参与者先验可变性之比  $M/N$  的依赖, 是统计力学可以给出的非平凡结果, 并且对博弈论很有意义。

矩阵博弈属于博弈论中最简单的系统, 许多有趣的博弈方面超出了这一基本设置。不过, 只要复杂关系能够由随机参数建模, 并且在适当定义的热力学极限中有趣量表现为自平均, 统计力学方法在研究更高级情形时仍可能具有价值。分析更复杂博弈论问题的第一步, 是对双矩阵博弈的分析; 其 Nash 均衡的典型数目已在 [276] 和 [277] 中计算。关于统计力学技术在相关系统中的应用, 另见 [278, 279]、[280] 和 [281]。



# 附录 1 基础数学

本附录的目的，是汇集本书中使用的一些基本数学工具。更多细节可参见标准教材 [282, 283]。

## A1.1 Gaussian 积分

令  $\mathbf{t}$  和  $\mathbf{b}$  为  $N$  维实向量， $A$  为  $N \times N$  正定矩阵。则

$$\begin{aligned} \int d\mathbf{t} e^{-\frac{1}{2}\mathbf{t}A\mathbf{t}+\mathbf{t}\mathbf{b}} &= \int_{-\infty}^{\infty} dt_1 \cdots \int_{-\infty}^{\infty} dt_N \exp\left(-\frac{1}{2} \sum_{i,j=1}^N t_i A_{ij} t_j + \sum_{i=1}^N t_i b_i\right) \\ &= \frac{(2\pi)^{N/2}}{\sqrt{\det A}} \exp\left(\frac{1}{2} \sum_{i,j=1}^N b_i (A^{-1})_{ij} b_j\right) \\ &= \frac{(2\pi)^{N/2}}{\sqrt{\det A}} e^{\frac{1}{2}\mathbf{b}A^{-1}\mathbf{b}}, \end{aligned} \quad (\text{A1.1})$$

其中  $A^{-1}$  表示  $A$  的逆矩阵。这类积分在神经网络统计力学中非常频繁地出现。因此，人们习惯引入 Gaussian 测度的缩写

$$Dt := \frac{dt}{\sqrt{2\pi}} \exp(-t^2/2), \quad (\text{A1.2})$$

借助它，(A1.1) 中对应于  $N = 1$  的最简单情形可写成

$$\int Dt e^{bt} = e^{b^2/2}. \quad (\text{A1.3})$$

从右向左使用这个方程，通常称为 Hubbard-Stratonovich 变换。它允许把指数中含有  $b^2$  的表达式，改写为指数中只线性含有  $b$  的表达式；代价是引入一个辅助变量  $t$  的额外积分。当  $b$  是多个积分变量之和时，这对积分因子化尤其有用。

另一个经常出现的构造，是对 Gaussian 测度 (A1.2) 的不完全积分，记为

$$H(x) := \int_x^\infty Dt = \int_x^\infty \frac{dt}{\sqrt{2\pi}} \exp(-t^2/2). \quad (\text{A1.4})$$

这样定义的函数  $H(x)$  与互补误差函数  $\text{erfc}(x)$  的关系为

$$H(x) = \frac{1}{2} \text{erfc}\left(\frac{x}{\sqrt{2}}\right) = \frac{1}{2} \left(1 - \text{erf}\left(\frac{x}{\sqrt{2}}\right)\right). \quad (\text{A1.5})$$

特别重要的是  $H(x)$  在小参数和大参数下的渐近形式：

$$H(x) \sim \begin{cases} \frac{1}{2} - \frac{1}{\sqrt{2\pi}} \left(x - \frac{x^3}{6} + \cdots\right), & x \rightarrow 0, \\ \frac{1}{\sqrt{2\pi}x} \exp\left(-\frac{x^2}{2}\right) \left(1 - \frac{1}{x^2} + \frac{3}{x^4} + \cdots\right), & x \rightarrow \infty. \end{cases} \quad (\text{A1.6})$$



我们还列出一些涉及 Gaussian 测度与  $H$ -函数的有用积分，其中  $a$  表示实参数：

$$\begin{aligned}\int Dt H(at) &= \frac{1}{2}, \\ \int Dt t H(at) &= -\frac{a}{\sqrt{2\pi(1+a^2)}}, \\ \int Dt t^2 H(at) &= \frac{1}{2}, \\ \int_0^\infty Dt H(at) &= \frac{1}{2\pi} \operatorname{arccot}(a), \\ \int_0^\infty Dt t H(at) &= \frac{1}{2\sqrt{2\pi}} \left(1 - \frac{a}{\sqrt{1+a^2}}\right), \\ \int_0^\infty Dt t^2 H(at) &= \frac{1}{2\pi} \operatorname{arccot}(a) - \frac{a}{2\pi(1+a^2)}.\end{aligned}$$

## A1.2 Jensen 不等式

对于一个凸函数  $f(x)$ ，也就是对所有  $x$  都有  $f''(x) \geq 0$ ，不等式

$$f(x) \geq f(x_0) + (x - x_0)f'(x_0) \quad (\text{A1.7})$$

对所有  $x$  和  $x_0$  成立。现在考虑随机变量  $x$  的情形。对  $x$  取平均并选择  $x_0 = \langle x \rangle$ ，得到

$$\langle f(x) \rangle \geq f(\langle x \rangle). \quad (\text{A1.8})$$

对于凹函数，不等式方向正好相反。这个不等式的重要应用包括  $\langle x \rangle \langle 1/x \rangle \geq 1$  以及

$$\langle \ln x \rangle \leq \ln \langle x \rangle. \quad (\text{A1.9})$$

## A1.3 $\delta$ -函数与 $\theta$ -函数

$\delta$ -函数由 P. A. M. Dirac 在量子力学背景下引入。由于其精确数学定义需要一些更高级的概念，这里我们满足于直观理解它，并按如下方式“定义”：

$$\delta(x) = \begin{cases} 0, & x \neq 0, \\ \infty, & x = 0, \end{cases} \quad (\text{A1.10})$$

同时要求  $\int dx \delta(x) = 1$ 。因此， $\delta$ -函数表示位于  $x = 0$  的一个“极尖锐峰”。由这一描述推出的主要性质是

$$\int dx f(x) \delta(x - x_0) = f(x_0) \quad (\text{A1.11})$$

对任意足够光滑的函数  $f(x)$  成立。一些有用推论为

$$\begin{aligned}f(x)\delta(x - x_0) &= f(x_0)\delta(x - x_0), \\ x\delta(x) &= 0, \\ \delta(ax) &= \frac{1}{|a|}\delta(x).\end{aligned}$$

特别有意义的是  $\delta$ -函数的积分表示，其形式为

$$\delta(x) = \int \frac{d\hat{x}}{2\pi} e^{i\hat{x}x}. \quad (\text{A1.12})$$

离散变量中一个相关函数是 Kronecker  $\delta$ -符号，它定义为

$$\delta(m, n) = \begin{cases} 0, & n \neq m, \\ 1, & n = m, \end{cases} \quad (\text{A1.13})$$

其中  $n$  和  $m$  是整数。(A1.11) 的离散对应物显然为

$$\sum_n a_n \delta(m, n) = a_m. \quad (\text{A1.14})$$

与 Dirac  $\delta$ -函数类似，Kronecker 符号也具有积分表示：

$$\delta(m, n) = \int_{-\pi}^{\pi} \frac{d\hat{x}}{2\pi} e^{i\hat{x}(n-m)}. \quad (\text{A1.15})$$

为了展示涉及  $\delta$ -函数的操作的有用性，我们考虑一个简单例子。假设需要计算如下形式的积分：

$$\int \prod_{i=1}^N dx_i \prod_{i=1}^N g(x_i) f\left(\sum_{i=1}^N x_i\right). \quad (\text{A1.16})$$

显然，各个单独积分通过  $f$  对所有  $x_i$  之和的依赖而彼此耦合。然而，利用 (A1.11) 和 (A1.12)，可以进行如下变换：

$$\begin{aligned} & \int \prod_{i=1}^N dx_i \prod_{i=1}^N g(x_i) f\left(\sum_{i=1}^N x_i\right) \\ &= \int dy \delta\left(y - \sum_i x_i\right) \int \prod_{i=1}^N dx_i \prod_{i=1}^N g(x_i) f(y) \\ &= \int \frac{dy d\hat{y}}{2\pi} e^{i\hat{y}y} f(y) \int \prod_{i=1}^N dx_i \prod_{i=1}^N g(x_i) e^{-i\hat{y} \sum_i x_i} \\ &= \int \frac{dy d\hat{y}}{2\pi} e^{i\hat{y}y} f(y) \left[ \int dx g(x) e^{-i\hat{y}x} \right]^N. \end{aligned}$$

$\delta$ -函数的引入由此给出了一种简单方法来因子化  $x_i$ -积分。对于大  $N$  这特别有用，而大  $N$  又是统计力学计算的特征。

$\theta$ -函数定义为

$$\theta(x) = \begin{cases} 0, & x \leq 0, \\ 1, & x > 0. \end{cases} \quad (\text{A1.17})$$

它也常称为 Heaviside 函数或阶跃函数。 $\theta$ -函数很适合用来纳入不等式约束，比较 (2.13)。由它与  $\delta$ -函数之间的显然关系

$$\theta(x - x_0) = \int_{x_0}^{\infty} dy \delta(x - y) \quad (\text{A1.18})$$

可推出  $\theta$ -函数的积分表示：

$$\theta(x - x_0) = \int_{x_0}^{\infty} dy \int \frac{d\hat{y}}{2\pi} e^{i\hat{y}(x-y)}. \quad (\text{A1.19})$$

## A1.4 鞍点法

由于统计力学计算严重依赖热力学极限，人们经常面临如下问题：在  $N \rightarrow \infty$  极限中提取形如

$$I = \int_{x_1}^{x_2} dx g(x) e^{Nf(x)} \quad (\text{A1.20})$$

的积分的渐近行为。一个可追溯到 Laplace 的方法，建立在如下观察之上：当  $N$  很大时，积分中贡献最大的区域，是函数  $f$  取得最大值的区域。事实上，如果  $f$  的最大值  $f(x_0)$  位于积分区间内部，也就是  $x_1 < x_0 < x_2$ ，那么在  $x_0$  附近对  $f$  和  $g$  作 Taylor 展开，把积分区间延拓到整条实轴，并使用 (A1.1)，可得

$$\begin{aligned} I &\simeq \int_{x_1}^{x_2} dx (g(x_0) + g'(x_0)(x - x_0) + \cdots) \\ &\quad \times \exp \left( N \left[ f(x_0) + \frac{1}{2} f''(x_0)(x - x_0)^2 + \cdots \right] \right) \\ &\simeq g(x_0) e^{Nf(x_0)} \sqrt{\frac{2\pi}{N|f''(x_0)|}}, \end{aligned}$$

其中撇号表示微分。使用更精细的方法，确实可以证明这一论证给出正确的渐近形式

$$\begin{aligned} \ln \int_{x_1}^{x_2} dx g(x) e^{Nf(x)} &= Nf(x_0) - \frac{1}{2} \ln N + \frac{1}{2} \ln \frac{2\pi}{|f''(x_0)|} \\ &\quad + \ln g(x_0) + O\left(\frac{1}{\sqrt{N}}\right). \end{aligned} \quad (\text{A1.21})$$

在许多情形中，只有与  $N$  成正比的主导项是我们关心的。因此，积分计算可化为寻找函数  $f$  在积分区间中的最大值。假设所有出现的函数都是可微的，这需要确定方程  $f'(x) = 0$  的所有解  $x_0^{(1)}, \dots, x_0^{(k)}$ ，并比较相应的函数值  $f(x_0^{(i)})$  以及边界处的函数值  $f(x_1)$  和  $f(x_2)$ 。后者是必要的，因为  $f$  的最大值完全可能出现在某个边界值处，而边界点通常并不是  $f'(x) = 0$  的解。

作为例子，考虑  $N > 0$  时 gamma 函数  $\Gamma(N+1)$  的积分表示：

$$\Gamma(N+1) = \int_0^\infty dx e^{-x} x^N. \quad (\text{A1.22})$$

被积函数在积分区间边界处为零，并在  $x_0 = N$  处取得最大值。这启发我们引入积分变量  $y = x/N - 1$ ，并把积分写成

$$\Gamma(N+1) = N e^{-N+N \ln N} \int_{-1}^\infty dy e^{N[-y+\ln(1+y)]}. \quad (\text{A1.23})$$

指数中的函数在  $y = y_0 = 0$  处最大，由此得到

$$\ln \Gamma(N+1) = \ln N! \sim N \ln N - N + \frac{1}{2} \ln N + \frac{1}{2} \ln(2\pi), \quad (\text{A1.24})$$

这正是描述  $\Gamma$ -函数渐近行为的著名 Stirling 公式。这个简单例子也表明，一般而言，最好试着找到一种积分表示，使最大值位置  $x_0$  与  $N$  无关，以便追踪  $N$  的不同幂次。

上述方法可以容易地推广到多变量函数。不过，从 (A1.1) 中行列式的出现可以看出，积分变量的数目不应随  $N$  发散。

把 Laplace 方法推广到复平面中沿积分路径  $C$  对复变量  $z$  作积分的情形，通常也很方便，即考察

$$\int_C dz g(z) e^{Nf(z)}. \quad (\text{A1.25})$$

为理解这种情形中出现的新特征，先关注复函数  $f(z)$  在一个实变量函数极值点的类似物附近的行  
为：这个类似物是满足  $f'(z_0) = 0$  的解析点  $z_0$ 。Taylor 展开的前几项为

$$f(z) = f(z_0) + \frac{1}{2}(z - z_0)^2 f''(z_0) + \cdots \quad (\text{A1.26})$$

一个简单计算表明，两个变量  $x = \operatorname{Re} z$  和  $y = \operatorname{Im} z$  的函数  $u(x, y) = \operatorname{Re} f(z)$  与  $v(x, y) = \operatorname{Im} f(z)$ ，  
在  $z_0$  附近实际上都具有鞍形形状，且各自的轴相差  $\pi/4$  的旋转。因此， $z_0$  称为函数  $f(z)$  的鞍点。

为了求积分 (A1.25) 的渐近行为，把积分轮廓  $C$  形变为经过鞍点  $z_0$  的  $C'$ ，同时不穿过  $f(z)$   
的奇点。于是，为使积分

$$\int_{C'} dz g(z) e^{Nu(z) + iNv(z)} \quad (\text{A1.27})$$

由  $z_0$  附近主导，必须满足两个条件。第一，沿  $C'$  穿过  $z_0$  时， $u(z)$  必须经过一个最大值。这类似  
于实值函数的情形。此外，由 (A1.21) 可知，如果  $C'$  沿着  $u(z)$  的最速下降方向，近似将最佳。第  
二， $v(z)$  必须保持常数，以避免被积函数发生剧烈振荡；这种振荡会造成抵消，使得即便  $u(z)$  在  
 $z_0$  处最大，积分贡献仍然很小。仿佛奇迹一般，后一条件等价于要求  $C'$  沿着  $u(z)$  的最速下降方  
向。

为简单起见，考虑  $z_0 = f(z_0) = 0$  且  $f''(z_0) = 1$  的情形；这总可以通过坐标系的平移、旋转  
和重标度来实现。于是  $u = (x^2 - y^2)/2$ ，而  $v = xy$ 。虚部沿  $x$ -轴和  $y$ -轴都是常数。不过，只有沿  
 $y$ -轴， $u$  才真正经过最大值。因此，积分轮廓在  $z_0$  附近必须沿  $y$ -轴。

因此，若积分路径  $C$  可在不穿过  $f$  的奇点的情况下变形，使它经过鞍点  $z_0$ ，其中  $z_0$  是  
 $f'(z_0) = 0$  的解，并且局域上沿  $f$  的实部的最速下降方向，同时保证  $f$  的实部在完整积分路径上  
的绝对最大值位于  $z_0$ ，则可用鞍点法计算 (A1.25) 型积分的渐近行为。所得结果与 (A1.21) 形式  
类似。

如果函数  $f(z)$  依赖某个参数  $a$ ，则可能出现这样的情形：给定的形变轮廓  $C'$  的处方在  $a < a_c$   
时有效，但在  $a > a_c$  时失效；原因是当  $a > a_c$  时，它选取了虚部为常数的“错误方向”，沿该方  
向实部达到最小而不是最大。这时称鞍点在  $a = a_c$  处变得不稳定。

## 附录 2 Gardner 分析

在本附录中，我们对冻结熵

$$S = \langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}} \quad (\text{A2.1})$$

作详细计算。这里考虑的是一个具有  $N$  个输入的球形感知机  $\mathbf{J}$ ，它由随机样例  $\boldsymbol{\xi}^\mu$ ， $\mu = 1, \dots, p = \alpha N$ ，训练；这些样例由一个随机球形教师感知机分类，教师耦合向量为  $\mathbf{T}$ 。我们将考虑样例分量的概率分布

$$P_{\boldsymbol{\xi}}(\boldsymbol{\xi}^\mu) = \prod_i \left[ \frac{1}{2} \delta(\xi_i^\mu + 1) + \frac{1}{2} \delta(\xi_i^\mu - 1) \right] \quad (\text{A2.2})$$

以及教师耦合向量  $\mathbf{T}$  的概率分布

$$P_T(\mathbf{T}) = (2\pi e)^{-N/2} \delta(\mathbf{T}^2 - N). \quad (\text{A2.3})$$

因此， $\boldsymbol{\xi}^\mu$  的分量以相等概率取  $\pm 1$ ，而  $\mathbf{T}$  均匀分布在  $N$ -球面上。

利用复本技巧，我们通过

$$\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle = \lim_{n \rightarrow 0} \frac{\langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}} - 1}{n} \quad (\text{A2.4})$$

把  $\langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}}$  同  $\langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}}$  联系起来。因此，需要计算的关键量是

$$\begin{aligned} \Omega^{(n)} &:= \langle \Omega^n(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}} \\ &= \left\langle \left\langle \int \prod_{a=1}^n d\mu(\mathbf{J}^a) \prod_{a,\mu} \theta \left( \frac{\mathbf{T} \boldsymbol{\xi}^\mu \mathbf{J}^a \boldsymbol{\xi}^\mu}{\sqrt{N} \sqrt{N}} \right) \right\rangle \right\rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}}, \end{aligned} \quad (\text{A2.5})$$

其中

$$d\mu(\mathbf{J}) := \prod_{i=1}^N \frac{dJ_i}{\sqrt{2\pi e}} \delta \left( \sum_{i=1}^N J_i^2 - N \right) \quad (\text{A2.6})$$

表示 (2.11) 中定义的球面测度。

为了计算  $\Omega^{(n)}$ ，我们首先通过  $\delta$ -函数引入变量

$$\lambda_\mu^a = \frac{\mathbf{J}^a \boldsymbol{\xi}^\mu}{\sqrt{N}}, \quad u_\mu = \frac{\mathbf{T} \boldsymbol{\xi}^\mu}{\sqrt{N}}, \quad (\text{A2.7})$$

得到

$$\begin{aligned} \Omega^{(n)} &= \int \prod_a d\mu(\mathbf{J}^a) \int \prod_{a,\mu} d\lambda_\mu^a \int \prod_\mu du_\mu \prod_{a,\mu} \theta(u_\mu \lambda_\mu^a) \\ &\times \left\langle \left\langle \delta \left( \lambda_\mu^a - \frac{\mathbf{J}^a \boldsymbol{\xi}^\mu}{\sqrt{N}} \right) \delta \left( u_\mu - \frac{\mathbf{T} \boldsymbol{\xi}^\mu}{\sqrt{N}} \right) \right\rangle \right\rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}}. \end{aligned} \quad (\text{A2.8})$$

然后使用 (A1.12) 给出的  $\delta$ -函数积分表示, 可得

$$\begin{aligned}\Omega^{(n)} &= \int \prod_a d\mu(\mathbf{J}^a) \int \prod_{a,\mu} \frac{d\lambda_\mu^a d\hat{\lambda}_\mu^a}{2\pi} \int \prod_\mu \frac{du_\mu d\hat{u}_\mu}{2\pi} \\ &\quad \times \prod_{a,\mu} \theta(u_\mu \lambda_\mu^a) \exp \left( i \sum_{\mu,a} \lambda_\mu^a \hat{\lambda}_\mu^a + i \sum_\mu u_\mu \hat{u}_\mu \right) \\ &\quad \times \left\langle \left\langle \exp \left( -\frac{i}{\sqrt{N}} \sum_{a,\mu} \hat{\lambda}_\mu^a \mathbf{J}^a \boldsymbol{\xi}^\mu - \frac{i}{\sqrt{N}} \sum_\mu \hat{u}_\mu \mathbf{T} \boldsymbol{\xi}^\mu \right) \right\rangle \right\rangle_{\boldsymbol{\xi}^\mu, \mathbf{T}}.\end{aligned}\quad (\text{A2.9})$$

借助 (A2.2), 由于分量  $\xi_i^\mu$  的统计独立性, 这一表达式中的平均为

$$\begin{aligned}&\left\langle \prod_{i,\mu} \left\langle \exp \left[ -\frac{i}{\sqrt{N}} \left( \sum_a \hat{\lambda}_\mu^a J_i^a + \hat{u}_\mu T_i \right) \xi_i^\mu \right] \right\rangle_{\xi^\mu} \right\rangle_T \\ &= \left\langle \prod_{i,\mu} \cos \left[ \frac{1}{\sqrt{N}} \left( \sum_a \hat{\lambda}_\mu^a J_i^a + \hat{u}_\mu T_i \right) \right] \right\rangle_T \\ &= \left\langle \exp \left\{ \sum_{i,\mu} \ln \cos \left[ \frac{1}{\sqrt{N}} \left( \sum_a \hat{\lambda}_\mu^a J_i^a + \hat{u}_\mu T_i \right) \right] \right\} \right\rangle_T.\end{aligned}\quad (\text{A2.10})$$

对大  $N$ , 这一表达式的渐近行为为<sup>1</sup>

$$\begin{aligned}&\left\langle \exp \left\{ \sum_{i,\mu} \ln \left[ 1 - \frac{1}{2N} \left( \sum_a \hat{\lambda}_\mu^a J_i^a + \hat{u}_\mu T_i \right)^2 \right] \right\} \right\rangle_T \\ &= \left\langle \exp \left( -\frac{1}{2} \sum_\mu \sum_{a,b} \hat{\lambda}_\mu^a \hat{\lambda}_\mu^b \frac{1}{N} \sum_i J_i^a J_i^b - \sum_\mu \sum_a \hat{\lambda}_\mu^a \hat{u}_\mu \frac{1}{N} \sum_i J_i^a T_i - \frac{1}{2} \sum_\mu \hat{u}_\mu^2 \frac{1}{N} \sum_i T_i^2 \right) \right\rangle_T.\end{aligned}\quad (\text{A2.11})$$

显然, 对大  $N$ , 只要样例分布具有前两阶矩

$$\langle \xi_i^\mu \rangle = 0, \quad \langle \xi_i^\mu \xi_j^\nu \rangle = \delta(\mu, \nu) \delta(i, j), \quad (\text{A2.12})$$

主导项就与具体样例分布无关。利用  $\mathbf{J}^2 = \mathbf{T}^2 = N$ , 并将 (A2.11) 代回 (A2.9), 得到

$$\begin{aligned}\Omega^{(n)} &= \int \prod_a d\mu(\mathbf{J}^a) \int \prod_{a,\mu} \frac{d\lambda_\mu^a d\hat{\lambda}_\mu^a}{2\pi} \int \prod_\mu \frac{du_\mu d\hat{u}_\mu}{2\pi} \prod_{a,\mu} \theta(u_\mu \lambda_\mu^a) \\ &\quad \times \left\langle \exp \left( i \sum_{\mu,a} \lambda_\mu^a \hat{\lambda}_\mu^a + i \sum_\mu u_\mu \hat{u}_\mu - \frac{1}{2} \sum_{\mu,a} (\hat{\lambda}_\mu^a)^2 \right. \right. \\ &\quad \left. \left. - \frac{1}{2} \sum_\mu \sum_{(a,b)} \hat{\lambda}_\mu^a \hat{\lambda}_\mu^b \frac{1}{N} \sum_i J_i^a J_i^b - \frac{1}{2} \sum_\mu \hat{u}_\mu^2 - \sum_{\mu,a} \hat{\lambda}_\mu^a \hat{u}_\mu \frac{1}{N} \sum_i J_i^a T_i \right) \right\rangle_T.\end{aligned}\quad (\text{A2.13})$$

这里  $\sum_{(a,b)}$  表示对所有  $a \neq b$  的项求和。为了进一步推进, 引入辅助变量

$$q^{ab} = \frac{1}{N} \sum_i J_i^a J_i^b, \quad R^a = \frac{1}{N} \sum_i T_i J_i^a, \quad (\text{A2.14})$$

<sup>1</sup>注意, 对所有积分变量  $\hat{\lambda}_\mu^a$ 、 $\hat{u}_\mu$ 、 $J_i^a$  和  $T_i$  的取值, 这一展开并非都能得到证明。然而, 在  $N \rightarrow \infty$  时, 来自满足  $(\hat{\lambda}_\mu^a J_i^a + \hat{u}_\mu T_i) = O(\sqrt{N})$  的区域对  $\Omega^{(n)}$  的贡献可以忽略。



从而把  $\mathbf{J}$ -积分与  $\lambda$ - $u$ -积分解耦。于是有

$$\begin{aligned}
\Omega^{(n)} &= \int \prod_{a < b} N dq^{ab} \int \prod_a N dR^a \\
&\times \int \prod_a d\mu(\mathbf{J}^a) \left\langle \prod_a \delta(\mathbf{J}^a \mathbf{T} - N R^a) \right\rangle \prod_{T a < b} \delta(\mathbf{J}^a \mathbf{J}^b - N q^{ab}) \\
&\times \int \prod_{a, \mu} \frac{d\lambda_\mu^a d\hat{\lambda}_\mu^a}{2\pi} \int \prod_\mu \frac{du_\mu d\hat{u}_\mu}{2\pi} \prod_{a, \mu} \theta(u_\mu \lambda_\mu^a) \\
&\times \exp \left( i \sum_{\mu, a} \lambda_\mu^a \hat{\lambda}_\mu^a + i \sum_\mu u_\mu \hat{u}_\mu - \frac{1}{2} \sum_{\mu, a} (\hat{\lambda}_\mu^a)^2 \right. \\
&\quad \left. - \frac{1}{2} \sum_\mu \sum_{(a, b)} \hat{\lambda}_\mu^a \hat{\lambda}_\mu^b q^{ab} - \sum_{\mu, a} \hat{\lambda}_\mu^a \hat{u}_\mu R^a - \frac{1}{2} \sum_\mu \hat{u}_\mu^2 \right). \tag{A2.15}
\end{aligned}$$

剩下的  $\mathbf{T}$  平均是平凡的，因为对几乎所有  $\mathbf{T}$  的选择，关于  $\mathbf{J}^a$  的积分给出同一个结果。在已经对样例取平均后，由于样例分布的各向同性，教师平均因而是冗余的。

最后，我们对 (A2.15) 中剩余的  $\delta$ -函数引入积分表示，包括积分测度  $d\mu(\mathbf{J}^a)$  中所含的那些，并执行 Gaussian  $\hat{u}_\mu$ -积分。这样得到

$$\begin{aligned}
\Omega^{(n)} &= \int \prod_a \frac{d\hat{k}^a}{4\pi} \int \prod_{a < b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \int \prod_a \frac{dR^a d\hat{R}^a}{2\pi/N} \\
&\times \exp \left( i \frac{N}{2} \sum_a \hat{k}^a + iN \sum_{a < b} q^{ab} \hat{q}^{ab} + iN \sum_a R^a \hat{R}^a \right) \\
&\times \int \prod_{i, a} \frac{dJ_i^a}{\sqrt{2\pi e}} \exp \left( -\frac{i}{2} \sum_a \hat{k}^a \sum_i (J_i^a)^2 - i \sum_{a < b} \hat{q}^{ab} \sum_i J_i^a J_i^b - i \sum_a \hat{R}^a \sum_i J_i^a \right) \\
&\times \int \prod_\mu Du_\mu \int \prod_{\mu, a} d\lambda_\mu^a \int \prod_{\mu, a} \frac{d\hat{\lambda}_\mu^a}{2\pi} \prod_{a, \mu} \theta(u_\mu \lambda_\mu^a) \\
&\times \exp \left( -\frac{1}{2} \sum_a (1 - (R^a)^2) \sum_\mu (\hat{\lambda}_\mu^a)^2 \right. \\
&\quad \left. - \frac{1}{2} \sum_\mu \sum_{(a, b)} \hat{\lambda}_\mu^a \hat{\lambda}_\mu^b (q^{ab} - R^a R^b) + i \sum_{\mu, a} \lambda_\mu^a \hat{\lambda}_\mu^a - i \sum_\mu u_\mu \sum_a \hat{\lambda}_\mu^a R^a \right). \tag{A2.16}
\end{aligned}$$

现在  $J_i^a$ -积分在  $i$  上因子化，也就是说，它们给出单个  $J^a$ -积分的  $N$  次方。类似地， $u_\mu$ - $\lambda_\mu^a$ - $\hat{\lambda}_\mu^a$ -积分在  $\mu$  上因子化，因此可化为单个  $u$ - $\lambda^a$ - $\hat{\lambda}^a$ -积分的  $p = \alpha N$  次方。合并后得到

$$\begin{aligned}
\Omega^{(n)} &= \int \prod_a \frac{d\hat{k}^a}{4\pi} \int \prod_{a < b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \int \prod_a \frac{dR^a d\hat{R}^a}{2\pi/N} \\
&\times \exp N \left[ \frac{i}{2} \sum_a \hat{k}^a + i \sum_{a < b} q^{ab} \hat{q}^{ab} + i \sum_a R^a \hat{R}^a + G_S(\hat{k}^a, \hat{q}^{ab}, \hat{R}^a) + \alpha G_E(q^{ab}, R^a) \right], \tag{A2.17}
\end{aligned}$$

其中

$$\begin{aligned}
G_S(\hat{k}^a, \hat{q}^{ab}, \hat{R}^a) &= \ln \int \prod_a \frac{dJ^a}{\sqrt{2\pi e}} \exp \left( -\frac{i}{2} \sum_a \hat{k}^a (J^a)^2 \right. \\
&\quad \left. - i \sum_{a < b} \hat{q}^{ab} J^a J^b - i \sum_a \hat{R}^a J^a \right) \tag{A2.18}
\end{aligned}$$

而

$$G_E(q^{ab}, R^a) = \ln \int \frac{du}{\sqrt{2\pi}} \int \prod_a d\lambda^a \int \prod_a \frac{d\hat{\lambda}^a}{2\pi} \prod_a \theta(u\lambda^a) \\ \times \exp \left( -\frac{u^2}{2} - \frac{1}{2} \sum_a (1 - (R^a)^2)(\hat{\lambda}^a)^2 \right. \\ \left. - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b (q^{ab} - R^a R^b) + i \sum_a \lambda^a \hat{\lambda}^a - iu \sum_a \hat{\lambda}^a R^a \right). \quad (\text{A2.19})$$

$G_S$  称为熵部分，因为它只度量有多少个球形耦合向量  $\mathbf{J}$  满足约束 (A2.14)。另一方面， $G_E$  称为能量部分，因为它依赖于所使用的代价函数或学习规则（比较第 四 章）。

现在我们用第 A1.4 节讨论的鞍点法，求  $N \rightarrow \infty$  时关于辅助参数  $q^{ab}$ 、 $\hat{q}^{ab}$ 、 $R^a$ 、 $\hat{R}^a$  和  $\hat{k}^a$  的积分的渐近行为。

由于  $J^a$ -积分是 Gaussian 型，关于  $\hat{k}^a$ 、 $\hat{q}^{ab}$  和  $\hat{R}^a$  的极值可以闭合求出。引入  $n \times n$  矩阵  $A$  和  $B$ ：

$$A_{ab} = i\hat{k}^a \delta(a, b) + i\hat{q}^{ab}(1 - \delta(a, b)), \\ B_{ab} = \delta(a, b) + q^{ab}(1 - \delta(a, b)), \quad (\text{A2.20})$$

则熵部分中的  $J^a$ -积分可以执行，得到<sup>1</sup>

$$G_S(\hat{k}^a, \hat{q}^{ab}, \hat{R}^a) = -\frac{n}{2} - \frac{1}{2} \ln(\det A) - \frac{1}{2} \sum_{a,b} \hat{R}^a (A^{-1})_{ab} \hat{R}^b. \quad (\text{A2.21})$$

利用  $\ln \det A = \text{Tr} \ln A$ ，(A2.17) 的指数中依赖  $\hat{k}^a$ 、 $\hat{q}^{ab}$  和  $\hat{R}^a$  的部分可写为

$$-\frac{n}{2} - \frac{1}{2} \text{Tr} \ln A - \frac{1}{2} \sum_{a,b} \hat{R}^a (A^{-1})_{ab} \hat{R}^b + \frac{1}{2} \text{Tr} AB + i \sum_a R^a \hat{R}^a. \quad (\text{A2.22})$$

为寻找关于  $\hat{R}^a$  和  $A$  元素的极值，令这一表达式分别对  $\hat{R}^c$  和  $A_{cd}$  的导数为零：

$$0 = -\sum_a (A^{-1})_{ac} \hat{R}^a + iR^c \quad (\text{A2.23})$$

以及

$$0 = -\frac{1}{2} (A^{-1})_{cd} + \frac{1}{2} \sum_{a,b} \hat{R}^a (A^{-1})_{ac} (A^{-1})_{bd} \hat{R}^b + \frac{1}{2} B_{cd}. \quad (\text{A2.24})$$

由此得到

$$\hat{R}^a = i \sum_b A_{ab} R^b \quad (\text{A2.25})$$

和

$$(A^{-1})_{cd} = B_{cd} - R^c R^d =: C_{cd}. \quad (\text{A2.26})$$

利用这些结果可知，(A2.22) 在鞍点处简单地等于  $\frac{1}{2} \text{Tr} \ln C$ 。因此，(A2.17) 化简为

$$\Omega^{(n)} \sim \exp \left( N \underset{q^{ab}, R^a}{\text{extr}} \left[ \frac{1}{2} \text{Tr} \ln C + \alpha G_E(q^{ab}, R^a) \right] \right). \quad (\text{A2.27})$$

确定关于  $q^{ab}$  和  $R^a$  的剩余极值并不直接，尤其是考虑到最后还要执行解析延拓  $n \rightarrow 0$ 。一般情形中的微妙之处在 [17] 中有详细讨论。在我们的情形中，极值处  $q^{ab}$  和  $R^a$  的值是复本对称的，即它们满足

$$q^{ab} = q, \quad R^a = R, \quad (\text{A2.28})$$

<sup>1</sup>变换  $\hat{k}^a \rightarrow \hat{k}^a - i\epsilon$  使积分对所有  $\epsilon > 0$  收敛，并且不改变渐近行为，因为关于  $\hat{k}^a$  的极值位于负虚轴上。

这使后续分析大大简化。

首先注意, 在这种情况下, 由 (A2.26) 定义的矩阵  $C$  具有一个  $(n-1)$  重简并本征值  $(1-q)$ , 以及另一个本征值  $(1-q) + n(q-R^2)$ 。因此

$$\frac{1}{2} \text{Tr} \ln C = \frac{n}{2} \ln(1-q) + \frac{1}{2} \ln \left( 1 + n \frac{q-R^2}{1-q} \right). \quad (\text{A2.29})$$

接着使用 (A2.19) 中的  $\theta$ -函数来限制  $u$  和  $\lambda^a$  的积分范围, 并用 Hubbard-Stratonovich 变换 (A1.3) 化简能量部分。采用 (A1.2) 的简记, 得到

$$\begin{aligned} G_E &= \ln 2 \int Dt \int_0^\infty Du \int_0^\infty \prod_a d\lambda^a \int \prod_a \frac{d\hat{\lambda}^a}{2\pi} \\ &\quad \times \exp \left( -\frac{1-q}{2} \sum_a (\hat{\lambda}^a)^2 + i \sum_a \hat{\lambda}^a \left( \lambda^a - uR - \sqrt{q-R^2} t \right) \right) \\ &= \ln 2 \int Dt \int_0^\infty Du \left[ \int_0^\infty \frac{d\lambda}{\sqrt{2\pi(1-q)}} \exp \left( -\frac{(\lambda - uR - \sqrt{q-R^2} t)^2}{2(1-q)} \right) \right]^n \\ &= \ln 2 \int Dt \int_0^\infty Du H^n \left( -\frac{\sqrt{q-R^2} t + Ru}{\sqrt{1-q}} \right). \end{aligned} \quad (\text{A2.30})$$

把积分变量移位为  $t \rightarrow (\sqrt{q-R^2} t + uR)/\sqrt{q}$  后, 可以执行  $u$ -积分, 从而得到

$$G_E = \ln 2 \int Dt H \left( -\frac{Rt}{\sqrt{q-R^2}} \right) H^n \left( -\sqrt{\frac{q}{1-q}} t \right). \quad (\text{A2.31})$$

现在从 (A2.29) 和 (A2.31) 中提取  $n \rightarrow 0$  时的主导项是简单的, 得到

$$\Omega^{(n)} \sim \exp \left\{ N n \text{extr}_{q,R} \left[ \frac{1}{2} \ln(1-q) + \frac{q-R^2}{2(1-q)} + 2\alpha \int Dt H \left( -\frac{Rt}{\sqrt{q-R^2}} \right) \ln H \left( -\sqrt{\frac{q}{1-q}} t \right) \right] \right\}. \quad (\text{A2.32})$$

利用 (A2.4), 最终得到

$$\begin{aligned} \frac{1}{N} \langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle &= \text{extr}_{q,R} \left[ \frac{1}{2} \ln(1-q) + \frac{q-R^2}{2(1-q)} \right. \\ &\quad \left. + 2\alpha \int Dt H \left( -\frac{Rt}{\sqrt{q-R^2}} \right) \ln H \left( -\sqrt{\frac{q}{1-q}} t \right) \right]. \end{aligned} \quad (\text{A2.33})$$

令这一表达式右端分别关于  $q$  和  $R$  的导数为零, 并作若干分部积分后得到

$$\frac{q-R^2}{1-q} = \frac{\alpha}{\pi} \int Dt H \left( -\frac{Rt}{\sqrt{q-R^2}} \right) \frac{\exp \left( -\frac{q}{1-q} t^2 \right)}{H^2 \left( -\sqrt{\frac{q}{1-q}} t \right)} \quad (\text{A2.34})$$

以及

$$\frac{R\sqrt{q-R^2}}{\sqrt{q}\sqrt{1-q}} = \frac{\alpha}{\pi} \int Dt \frac{\exp \left[ -\frac{t^2}{2} \left( \frac{R^2}{q-R^2} + \frac{q}{1-q} \right) \right]}{H \left( -\sqrt{\frac{q}{1-q}} t \right)}. \quad (\text{A2.35})$$

当  $q=R$  时, 这两个方程重合。其直观原因已在第 2.3 节中讨论。因此, 总有一个由

$$q=R = \frac{\alpha}{\pi} \sqrt{1-R} \int Dt \frac{\exp(-Rt^2/2)}{H(\sqrt{R}t)} \quad (\text{A2.36})$$

确定的解。由 (A2.33)，对  $q = R$  的情形，熵为

$$\begin{aligned} \frac{1}{N} \langle \ln \Omega(\boldsymbol{\xi}^\mu, \mathbf{T}) \rangle &= \text{extr}_R \left[ \frac{1}{2} \ln(1-R) + \frac{R}{2} \right. \\ &\quad \left. + 2\alpha \int Dt H \left( -\sqrt{\frac{R}{1-R}} t \right) \ln H \left( -\sqrt{\frac{R}{1-R}} t \right) \right]. \end{aligned} \quad (\text{A2.37})$$

最后两个方程分别与 (2.42) 和 (2.41) 相同。

## 附录 3 感知机规则的收敛性

本附录的目的是证明：如果存在一个向量  $\mathbf{J}^*$ ，它能够以至少为  $\kappa$  的稳定性正确完成所有分类，也就是说满足

$$\frac{1}{\sqrt{N}} \mathbf{J}^* \boldsymbol{\xi}^\mu \sigma_T^\mu \geq \kappa > 0 \quad \text{对所有 } \mu = 1, \dots, p, \quad (\text{A3.1})$$

那么感知机规则将会收敛。不失一般性，我们假定  $\mathbf{J}^*$  满足通常的归一化条件  $|\mathbf{J}^*|^2 = N$ 。现在考虑从  $\mathbf{J} = 0$  出发、在总共  $X$  次更新之后由感知机规则得到的向量  $\mathbf{J}_X$ 。参见式 (3.11)，它具有形式

$$\mathbf{J}_X = \frac{1}{\sqrt{N}} \sum_{\mu} x^\mu \boldsymbol{\xi}^\mu \sigma_T^\mu, \quad (\text{A3.2})$$

其中嵌入强度  $x^\mu$  等于在样例  $\mu$  被呈现时所执行更新的次数。按照定义，有

$$\sum_{\mu} x^\mu = X. \quad (\text{A3.3})$$

把所有式 (A3.1) 乘以  $x^\mu$ ，再对  $\mu$  求和并将两边平方，于是得到

$$X^2 \kappa^2 \leq \left( \frac{1}{\sqrt{N}} \sum_{\mu} x^\mu \mathbf{J}^* \boldsymbol{\xi}^\mu \sigma_T^\mu \right)^2 = (\mathbf{J}^* \mathbf{J}_X)^2 \leq |\mathbf{J}^*|^2 |\mathbf{J}_X|^2 = N |\mathbf{J}_X|^2, \quad (\text{A3.4})$$

其中使用了 Schwarz 不等式。现在关注最后一次被更新的样例，设其标号为  $\nu$ 。由于感知机规则只在出现错误时执行更新，显然有  $\mathbf{J}_{X-1} \boldsymbol{\xi}^\nu \sigma_T^\nu < \kappa \sqrt{N}$ 。因此可以写成

$$\begin{aligned} |\mathbf{J}_X|^2 &= \left| \mathbf{J}_{X-1} + \frac{1}{\sqrt{N}} \boldsymbol{\xi}^\nu \sigma_T^\nu \right|^2 \\ &= |\mathbf{J}_{X-1}|^2 + 2 \frac{1}{\sqrt{N}} \mathbf{J}_{X-1} \boldsymbol{\xi}^\nu \sigma_T^\nu + \frac{1}{N} |\boldsymbol{\xi}^\nu|^2 \\ &\leq |\mathbf{J}_{X-1}|^2 + 2\kappa + 1. \end{aligned} \quad (\text{A3.5})$$

所以，向量长度平方的最大增量为  $2\kappa + 1$ 。由式 (A3.4) 和式 (A3.5) 可知

$$X^2 \kappa^2 \leq N |\mathbf{J}_X|^2 \leq NX(2\kappa + 1), \quad (\text{A3.6})$$

从而更新次数满足

$$X \leq \left( \frac{2}{\kappa} + \frac{1}{\kappa^2} \right) N, \quad (\text{A3.7})$$

因而必定是有限的。

## 附录 4 复本对称鞍点的稳定性

本附录汇总考察复本对称 (RS) 鞍点稳定性所需的计算。正如第 2.3 节所说明的, 鞍点稳定性检验是任何复本计算中的重要环节。作为示例, 我们使用第 6.3 节讨论的 Ising 感知机存储问题, 并主要沿用文献 [25] 的处理。

我们从式 (6.22) 中平均复本相空间体积的鞍点表达式出发:

$$\langle\langle\Omega^n\rangle\rangle = \int \prod_{a<b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \exp(NG(q^{ab}, \hat{q}^{ab})), \quad (\text{A4.1})$$

其中

$$G(q^{ab}, \hat{q}^{ab}) = i \sum_{a<b} q^{ab} \hat{q}^{ab} + G_S(\hat{q}^{ab}) + \alpha G_E(q^{ab}), \quad (\text{A4.2})$$

并且

$$G_S(\hat{q}^{ab}) = \ln \sum_{\{J^a=\pm 1\}} \exp\left(-i \sum_{a<b} \hat{q}^{ab} J^a J^b\right) \quad (\text{A4.3})$$

以及

$$G_E(q^{ab}) = \ln \int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} \exp\left(i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab}\right). \quad (\text{A4.4})$$

在极限  $N \rightarrow \infty$  中, 式 (A4.1) 的积分由鞍点法计算, 这要求找到  $G(q^{ab}, \hat{q}^{ab})$  的最大值。RS 假设认为, 在这一最大值处, 对所有复本对  $a < b$ , 都有  $q^{ab} = q$  和  $-i\hat{q}^{ab} = \hat{q}$ , 从而得到 RS 鞍点方程

$$q = \int Dz \tanh^2(\sqrt{q} z),$$

$$\hat{q} = \frac{\alpha}{2\pi(1-q)} \int Dt \frac{\exp\left[-\frac{(\kappa - \sqrt{q} t)^2}{1-q}\right]}{H^2\left(\frac{\kappa - \sqrt{q} t}{\sqrt{1-q}}\right)}, \quad (\text{A4.5})$$

它们把  $q$  和  $\hat{q}$  确定为  $\alpha$  的函数。

为了检查式 (A4.5) 的解是否确实是  $G(q^{ab}, \hat{q}^{ab})$  的最大值, 我们令

$$q^{ab} = q + \delta q^{ab}, \quad \hat{q}^{ab} = i\hat{q} + i\delta\hat{q}^{ab}, \quad (\text{A4.6})$$

并围绕  $q, \hat{q}$  对  $\delta q^{ab}, \delta\hat{q}^{ab}$  展开  $G$ 。把  $q^{ab}$  与  $\hat{q}^{ab}$  两者的涨落组成一个  $n(n-1)$  维向量  $(\delta q^{ab}, \delta\hat{q}^{ab})$ , 则到二阶为止有

$$G(q + \delta q^{ab}, \hat{q} + \delta\hat{q}^{ab}) = G(q, \hat{q}) + \frac{1}{2} \sum_{a<b, c<d} (\delta q^{ab}, \delta\hat{q}^{ab}) M^{ab, cd} (\delta q^{cd}, \delta\hat{q}^{cd}). \quad (\text{A4.7})$$

注意,  $\delta q^{ab}, \delta\hat{q}^{ab}$  的线性项必须消失, 因为  $q$  和  $\hat{q}$  被选为满足  $\partial G/\partial q = \partial G/\partial \hat{q} = 0$  (见式 (A4.5))。为了使  $(q, \hat{q})$  成为  $G$  的局域最大值, Hessian 矩阵  $M^{ab, cd}$  必须负定, 也就是它的所有本征值都必须为负。



确定  $M^{ab,cd}$  这类矩阵的谱并非平凡任务；要做到这一点，我们必须利用它在复本指标置换下的对称性。由式 (A4.2) 中  $G(q^{ab}, \hat{q}^{ab})$  的形式可知， $M^{ab,cd}$  是一个块矩阵，由四个  $n(n-1)/2 \times n(n-1)/2$  矩阵组成，形式为

$$M = \begin{pmatrix} \alpha A & I \\ I & B \end{pmatrix}, \quad (\text{A4.8})$$

其中  $I$  表示单位矩阵，并且

$$A^{ab,cd} = \frac{\partial^2 G_E}{\partial q^{ab} \partial q^{cd}}, \quad (\text{A4.9})$$

以及

$$B^{ab,cd} = \frac{\partial^2 G_S}{\partial \hat{q}^{ab} \partial \hat{q}^{cd}}, \quad (\text{A4.10})$$

导数均在 RS 鞍点  $q^{ab} = q, \hat{q}^{ab} = i\hat{q}$  处计算。

### 第一步

我们从  $A$  的元素开始。引入某个函数  $g(\lambda^c)$  的平均  $\langle g(\lambda^c) \rangle$ ，可将公式写得最为紧凑：

$$\langle g(\lambda^c) \rangle := \frac{\int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} \exp\left(i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab}\right) g(\lambda^c)}{\int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} \exp\left(i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab}\right)} \Bigg|_{q^{ab}=q}.$$

于是由式 (A4.4) 得到

$$\frac{\partial^2 G_E}{\partial q^{cd} \partial q^{ef}} \Bigg|_{q^{ab}=q} = \langle \hat{\lambda}^c \hat{\lambda}^d \hat{\lambda}^e \hat{\lambda}^f \rangle - \langle \hat{\lambda}^c \hat{\lambda}^d \rangle \langle \hat{\lambda}^e \hat{\lambda}^f \rangle. \quad (\text{A4.11})$$

在 RS 鞍点，所有复本指标等价；又因为  $c < d$  且  $e < f$ ，这个二阶导数只可能三个不同取值：

$$P := \langle (\hat{\lambda}^c)^2 (\hat{\lambda}^d)^2 \rangle - \langle \hat{\lambda}^c \hat{\lambda}^d \rangle^2, \quad (\text{A4.12})$$

对应  $c = e$  且  $d = f$ ；

$$Q := \langle (\hat{\lambda}^c)^2 \hat{\lambda}^d \hat{\lambda}^f \rangle - \langle \hat{\lambda}^c \hat{\lambda}^d \rangle \langle \hat{\lambda}^c \hat{\lambda}^f \rangle = \langle (\hat{\lambda}^c)^2 \hat{\lambda}^d \hat{\lambda}^f \rangle - \langle \hat{\lambda}^c \hat{\lambda}^d \rangle^2, \quad (\text{A4.13})$$

对应正好两个指标相同的情形；以及

$$R := \langle \hat{\lambda}^c \hat{\lambda}^d \hat{\lambda}^e \hat{\lambda}^f \rangle - \langle \hat{\lambda}^c \hat{\lambda}^d \rangle \langle \hat{\lambda}^e \hat{\lambda}^f \rangle = \langle \hat{\lambda}^c \hat{\lambda}^d \hat{\lambda}^e \hat{\lambda}^f \rangle - \langle \hat{\lambda}^c \hat{\lambda}^d \rangle^2, \quad (\text{A4.14})$$

对应四个指标彼此均不同的情形。

让我们显式计算  $P$  中的第一项:

$$\begin{aligned}
& \langle (\hat{\lambda}^c)^2 (\hat{\lambda}^d)^2 \rangle \\
&= \frac{\int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} e^{i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab}} (\hat{\lambda}^c)^2 (\hat{\lambda}^d)^2}{\int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} e^{i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab}}} \Big|_{q^{ab}=q} \\
&= \frac{\int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} e^{i \sum_a \lambda^a \hat{\lambda}^a - \frac{1-q}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{q}{2} (\sum_a \hat{\lambda}^a)^2} (\hat{\lambda}^c)^2 (\hat{\lambda}^d)^2}{\int_{\kappa}^{\infty} d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} e^{i \sum_a \lambda^a \hat{\lambda}^a - \frac{1-q}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{q}{2} (\sum_a \hat{\lambda}^a)^2}} \\
&= \frac{\int Dt H^{n-2} \left( \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}} \right) \left[ \int_{\kappa}^{\infty} d\lambda \int \frac{d\hat{\lambda}}{2\pi} e^{i \hat{\lambda}(\lambda - \sqrt{q} t) - \frac{1-q}{2} \hat{\lambda}^2 \lambda^2} \right]^2}{\int Dt H^n \left( \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}} \right)} \\
&= \frac{\int Dt H^{n-2} \left( \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}} \right) \left[ \int_{\kappa}^{\infty} \frac{d\lambda}{\sqrt{2\pi(1-q)}} e^{-\frac{(\lambda - \sqrt{q} t)^2}{2(1-q)}} \frac{1}{1-q} \left( 1 - \frac{(\lambda - \sqrt{q} t)^2}{1-q} \right) \right]^2}{\int Dt H^n \left( \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}} \right)} \\
&= \frac{1}{(1-q)^2} \frac{\int Dt H^{n-2}(\kappa') \left[ \int_{\kappa'}^{\infty} D\lambda' (1 - \lambda'^2) \right]^2}{\int Dt H^n(\kappa')},
\end{aligned} \tag{A4.15}$$

其中

$$\kappa' = \frac{\kappa - \sqrt{q} t}{\sqrt{1-q}}, \quad \lambda' = \frac{\lambda - \sqrt{q} t}{\sqrt{1-q}}. \tag{A4.16}$$

最后取极限  $n \rightarrow 0$ , 得到

$$\langle (\hat{\lambda}^c)^2 (\hat{\lambda}^d)^2 \rangle = \frac{1}{(1-q)^2} \int Dt \frac{\left[ \int_{\kappa'}^{\infty} D\lambda' (1 - \lambda'^2) \right]^2}{H^2(\kappa')}. \tag{A4.17}$$

以完全类似的方式可得

$$\begin{aligned}
\langle \hat{\lambda}^c \hat{\lambda}^d \rangle &= \frac{1}{1-q} \int Dt \frac{\left[ \int_{\kappa'}^{\infty} D\lambda' i\lambda' \right]^2}{H^2(\kappa')}, \\
\langle (\hat{\lambda}^c)^2 \hat{\lambda}^d \hat{\lambda}^f \rangle &= \frac{1}{(1-q)^2} \int Dt \frac{\int_{\kappa'}^{\infty} D\lambda' (1 - \lambda'^2) \left[ \int_{\kappa'}^{\infty} D\lambda' i\lambda' \right]^2}{H^3(\kappa')},
\end{aligned} \tag{A4.18}$$

以及

$$\langle \hat{\lambda}^c \hat{\lambda}^d \hat{\lambda}^e \hat{\lambda}^f \rangle = \frac{1}{(1-q)^2} \int Dt \frac{\left[ \int_{\kappa'}^{\infty} D\lambda' i\lambda' \right]^4}{H^4(\kappa')}, \tag{A4.19}$$

由此可以确定  $P, Q, R$ .

$\mathbf{B}$  的元素可按类似方式得到。引入缩写

$$\langle g(J^c) \rangle := \frac{\sum_{\{J^a\}} \exp(-i \sum_{a < b} \hat{q}^{ab} J^a J^b) g(J^c)}{\sum_{\{J^a\}} \exp(-i \sum_{a < b} \hat{q}^{ab} J^a J^b)} \Big|_{\hat{q}^{ab}=i\hat{q}}, \tag{A4.20}$$

可得

$$-\frac{\partial^2 G_S}{\partial \hat{q}^{cd} \partial \hat{q}^{ef}} = \langle J^c J^d J^e J^f \rangle - \langle J^c J^d \rangle \langle J^e J^f \rangle. \tag{A4.21}$$

这里同样只有三个不同取值：

$$\begin{aligned} -P' &:= \langle (J^c)^2 (J^d)^2 \rangle - \langle J^c J^d \rangle^2, \\ -Q' &:= \langle (J^c)^2 J^d J^f \rangle - \langle J^c J^d \rangle^2, \\ -R' &:= \langle J^c J^d J^e J^f \rangle - \langle J^c J^d \rangle^2, \end{aligned} \quad (\text{A4.22})$$

其中不同的复本指标都被假定表示 1 到  $n$  之间不同的自然数。显式地，例如有

$$\begin{aligned} \langle J^c J^d \rangle &= \frac{\sum_{\{J^a\}} \exp(-i \sum_{a < b} \hat{q}^{ab} J^a J^b) J^c J^d}{\sum_{\{J^a\}} \exp(-i \sum_{a < b} \hat{q}^{ab} J^a J^b)} \Big|_{\hat{q}^{ab} = i\hat{q}} \\ &= \frac{\sum_{\{J^a\}} \exp\left[\frac{\hat{q}}{2} (\sum_a J^a)^2 - \frac{n\hat{q}}{2}\right] J^c J^d}{\sum_{\{J^a\}} \exp\left[\frac{\hat{q}}{2} (\sum_a J^a)^2 - \frac{n\hat{q}}{2}\right]} \\ &= \frac{\int Dz \sum_{\{J^a\}} \exp(\sqrt{\hat{q}} z \sum_a J^a) J^c J^d}{\int Dz \sum_{\{J^a\}} \exp(\sqrt{\hat{q}} z \sum_a J^a)} \\ &= \frac{\int Dz [2 \cosh(\sqrt{\hat{q}} z)]^{n-2} [2 \sinh(\sqrt{\hat{q}} z)]^2}{\int Dz [2 \cosh(\sqrt{\hat{q}} z)]^n}, \end{aligned} \quad (\text{A4.23})$$

并且在  $n \rightarrow 0$  时，

$$\langle J^c J^d \rangle = \int Dz \tanh^2(\sqrt{\hat{q}} z) = q, \quad (\text{A4.24})$$

其中最后一步使用了式 (A4.5)。通过类似代数最后得到

$$\begin{aligned} P' &= q^2 - 1, \\ Q' &= q^2 - q, \\ R' &= q^2 - \int Dz \tanh^4(\sqrt{\hat{q}} z), \end{aligned} \quad (\text{A4.25})$$

这就完成了矩阵  $A$  和  $B$  元素计算的第一步。

## 第二步

现在计算矩阵  $A$  和  $B$  的本征值及相应本征向量。de Almeida 和 Thouless 在一篇重要论文 [284] 中指出，这些对象几乎完全由矩阵元素在复本置换下的性质决定。考虑一个  $n(n-1)/2 \times n(n-1)/2$  矩阵  $C^{ab,cd}$ ，其中  $a, b, c, d = 1, \dots, n$ ， $a < b, c < d$ ，且其结构与  $A$  和  $B$  类似；也就是说，根据下列情形，只有三个不同元素  $P, Q, R$ ：

$$\begin{aligned} C^{ab,cd} &= P \quad \text{若 } a = c, b = d, \\ C^{ab,cd} &= Q \quad \text{若正好两个指标相同,} \\ C^{ab,cd} &= R \quad \text{若所有指标彼此不同.} \end{aligned} \quad (\text{A4.26})$$

我们通过显式构造本征向量来确定本征值。首先注意， $C^{ab,cd}$  每一行中各元素之和对所有行都是相同的：

$$\sum_{c < d} C^{ab,cd} = P + (2n-4)Q + \frac{(n-2)(n-3)}{2}R. \quad (\text{A4.27})$$

因此由

$$\zeta_1^{ab} = \zeta \quad \text{对所有 } a < b \quad (\text{A4.28})$$

定义的向量  $\zeta_1$  是  $C^{ab,cd}$  的本征向量，本征值为

$$\lambda_1 = P + (2n - 4)Q + \frac{(n - 2)(n - 3)}{2}R. \quad (\text{A4.29})$$

这个本征向量本身就是复本对称的，因为所有复本都被同等对待。

接着考虑有一个特殊复本指标  $l$  的向量  $\zeta_2$ ：

$$\zeta_2^{ab} = \begin{cases} \zeta, & a = l \text{ 或 } b = l, \\ \varepsilon, & \text{其他情形.} \end{cases} \quad (\text{A4.30})$$

这类向量张成所有本征向量所在的  $n(n - 1)/2$  维空间中的一个  $n$  维子空间。该子空间包含  $\zeta_1$ （当  $\zeta = \varepsilon$  时）。不过，若选择  $\zeta = (1 - n/2)\varepsilon$ ，所有 (A4.30) 类型的向量都与  $\zeta_1$  正交。于是得到

$$\sum_{c < d} C^{ab,cd} \zeta_2^{cd} = (P + (n - 4)Q - (n - 3)R) \zeta_2^{ab}, \quad (\text{A4.31})$$

这意味着存在一个  $(n - 1)$  重简并的本征值

$$\lambda_2 = P + (n - 4)Q - (n - 3)R. \quad (\text{A4.32})$$

继续考虑有两个特殊复本指标  $k < l$  的向量  $\zeta_3$ ：

$$\zeta_3^{ab} = \begin{cases} \zeta, & a = k, b = l, \\ \varepsilon, & |\{a, b\} \cap \{k, l\}| = 1, \\ \varnothing, & \text{其他情形.} \end{cases} \quad (\text{A4.33})$$

这些向量张成整个  $n(n - 1)/2$  维空间。在 (A4.33) 中取  $\zeta = (2 - n)\varepsilon$  且  $\varepsilon = (3 - n)\vartheta/2$ ，即可保证它们与  $\zeta_1$  以及所有  $\zeta_2$  正交。经过同样的代数运算可得

$$\sum_{c < d} C^{ab,cd} \zeta_3^{cd} = (P - 2Q + R) \zeta_3^{ab}, \quad (\text{A4.34})$$

因此有第三个本征值

$$\lambda_3 = P - 2Q + R, \quad (\text{A4.35})$$

其简并度为  $n(n - 3)/2$ 。

这样便得到一个本征向量  $\zeta_1$ 、 $(n - 1)$  个本征向量  $\zeta_2$ ，以及  $n(n - 3)/2$  个本征向量  $\zeta_3$ ，总数为  $n(n - 1)/2$  个线性无关本征向量，因而问题已经解决。

因此，我们能够确定矩阵  $A$  和  $B$  的本征值。注意，相应本征向量完全不依赖矩阵中的元素  $P, Q, R$ ，所以  $A$  与  $B$  具有平行的本征向量，它们完全由复本结构决定。此外，对  $A$  和  $B$  而言， $\zeta_1$  都描述所谓纵向涨落；这些涨落位于复本对称子空间内。因此，它们只是在检验复本对称鞍点方程是否被正确求解，并不能指示 RS 假设本身的破缺。能够做到这一点的，只能是  $\zeta_2$  与  $\zeta_3$  所描述的横向涨落。然而在极限  $n \rightarrow 0$  中， $\lambda_2$  与  $\lambda_1$  变得简并。因此，可能变号并由此指示 RS 鞍点局域不稳定性的，是由式 (A4.35) 给出的所谓 replicon 本征值  $\lambda_3$ 。

### 第三步

现在假设  $\varphi$  同时是  $A$  与  $B$  的本征向量，相应本征值分别为  $\lambda_A$  与  $\lambda_B$ 。构造两个  $n(n-1)$  维向量  $\phi = (\varphi, \varphi)$  与  $\bar{\phi} = (\varphi, -\varphi)$ ，并寻找  $M$  的本征值  $\Lambda$ ，其本征向量形如  $a\phi + b\bar{\phi}$ ：

$$\begin{aligned} 0 &= (M - \Lambda I)(a\phi + b\bar{\phi}) \\ &= \begin{pmatrix} \alpha A - \Lambda I & -I \\ -I & B - \Lambda I \end{pmatrix} \begin{pmatrix} (a+b)\varphi \\ (a-b)\varphi \end{pmatrix} \\ &= \begin{pmatrix} [(\alpha\lambda_A - \Lambda)(a+b) - (a-b)]\varphi \\ [-a-b + (\lambda_B - \Lambda)(a-b)]\varphi \end{pmatrix} \\ &= \begin{pmatrix} [(\alpha\lambda_A - \Lambda - 1)a + (\alpha\lambda_A - \Lambda + 1)b]\varphi \\ [(\lambda_B - \Lambda - 1)a - (\lambda_B - \Lambda + 1)b]\varphi \end{pmatrix}. \end{aligned}$$

对于  $a$  和  $b$  存在非平凡解，需要

$$\begin{vmatrix} \alpha\lambda_A - \Lambda & \Lambda \\ \Lambda & \lambda_B - \Lambda \end{vmatrix} = 0, \quad (\text{A4.36})$$

或等价地

$$\Lambda^2 - (\alpha\lambda_A + \lambda_B)\Lambda + \alpha\lambda_A\lambda_B - 1 = 0. \quad (\text{A4.37})$$

为了阐明 RS 鞍点的稳定性，考虑两个本征值的乘积是方便的：

$$\Lambda_1\Lambda_2 = \alpha\lambda_A\lambda_B - 1. \quad (\text{A4.38})$$

当  $\alpha = 0$  时有  $\Lambda_1\Lambda_2 = -1 < 0$ 。但这在最大值处是不可能的！另一方面，对于这种情形， $\langle\Omega^n\rangle$  的计算是平凡的，RS 应当稳定。这个“错误”符号的原因在于，式 (A4.1) 中对  $\hat{q}^{ab}$  的积分沿实轴进行，而假设 (A4.6) 引入的是  $\hat{q}^{ab}$  的虚涨落。由于解析函数的熟知性质， $G$  的实部沿实的  $\hat{q}^{ab}$  轴与虚的  $\hat{q}^{ab}$  轴的二阶导数只差一个符号，因此结果并无矛盾。

从  $\alpha = 0$  时的  $\Lambda_1\Lambda_2 < 0$  出发，RS 鞍点的不稳定性将表现为  $\Lambda_1\Lambda_2 \geq 0$ ，或等价地表现为

$$\alpha\lambda_A\lambda_B \geq 1. \quad (\text{A4.39})$$

代入式 (A4.35) 中的 replicon 本征值  $P - 2Q + R$  与  $P' - 2Q' + R'$ ，最终得到确定 de Almeida-Thouless 值  $\alpha_{\text{AT}}$  的方程；当  $\alpha$  超过该值时，RS 变得不稳定：

$$\frac{1}{\alpha_{\text{AT}}} = \frac{1}{(1-q)^2} \int Dt H^{-4}(\kappa') \left[ H(\kappa') \int_{\kappa'}^{\infty} D\lambda (1-\lambda^2) + \left( \int_{\kappa'}^{\infty} D\lambda \lambda \right)^2 \right]^2 \int Dz \left( 1 - \tanh^2(\sqrt{\hat{q}}z) \right)^2 \quad (\text{A4.40})$$

其中仍有

$$\kappa' = \frac{\kappa - \sqrt{\hat{q}}t}{\sqrt{1-q}}. \quad (\text{A4.41})$$

为了数值求解  $\alpha_{\text{AT}}$ ，需要对  $\alpha$  的每个试探值，由式 (A4.5) 确定  $q$  与  $\hat{q}$ 。计算得到  $\alpha_{\text{AT}} \sim 1.015$ ，此时  $q \sim 0.721$ ， $\hat{q} \sim 7.366$ 。

通过类似考虑，也可以研究具有一步或多步复本对称破缺的解的局域稳定性，只是代数复杂度会随之增加。后来，这些关键步骤已经在一定程度上被形式化 [285]，相应数学工具也已建立 [286]，有助于使计算更加透明。

最后指出复本技巧的另一个奇特特征。对于自然数  $n \geq 1$ ，若要把鞍点法正确用于式 (A4.1) 给出的解空间体积计算，就必须找到  $G(q^{ab}, \hat{q}^{ab})$  的最大值。这个最大值由相应 Hessian 矩阵  $M^{ab,cd}$

的所有本征值均为负来识别。在  $n \rightarrow 0$  极限中，我们仍保留这一关于本征值符号的要求，作为 RS 鞍点稳定性的相关判据；这确实是正确步骤 [17]。不过，函数  $G$  依赖于  $n(n-1)$  个变量，而当  $n < 1$  时，这个数变为负数！结果表明，在这个区域中，Hessian 的负本征值对应的是  $G$  的极小值而不是极大值。这就是为什么 RS 鞍点方程的解  $q$  会最小化淬火熵的 RS 表达式。



## 附录 5 一步复本对称破缺

本附录在一步复本对称破缺 (one-step RSB) 的框架内研究  $\kappa = 0$  的 Ising 感知机存储问题。出发点仍是式 (6.22) 给出的复本解体积的一般表达式：

$$\langle\langle \Omega^n \rangle\rangle = \int \prod_{a < b} \frac{dq^{ab} d\hat{q}^{ab}}{2\pi/N} \exp \left[ N \left( i \sum_{a < b} q^{ab} \hat{q}^{ab} + G_S(\hat{q}^{ab}) + \alpha G_E(q^{ab}) \right) \right]. \quad (\text{A5.1})$$

对于足够小的存储比  $\alpha$ ，解空间是连通的，并且可以由复本对称假设  $q^{ab} = q, -i\hat{q}^{ab} = \hat{q}$  正确描述。然而，对于足够大的  $\alpha$ ，这一假设已知会失效。正如第 6.3 节所讨论的，要描述由若干彼此分离的斑块构成的非连通解空间，合适的假设至少必须包含两个重叠参数。一个记为  $q_1$ ，指定属于同一斑块的不同解之间的重叠；另一个记为  $q_0 \leq q_1$ ，刻画属于不同斑块的两个解之间的重叠。

具体地，称为一步 RSB 的假设定义为 [86, 17]

$$q^{ab} = \begin{cases} q_1, & 0 < |a - b| < m, \\ q_0, & \text{其他情形}, \end{cases} \quad (\text{A5.2})$$

类似地，

$$-i\hat{q}^{ab} = \begin{cases} \hat{q}_1, & 0 < |a - b| < m, \\ \hat{q}_0, & \text{其他情形}. \end{cases} \quad (\text{A5.3})$$

在这一阶段，参数  $m$  是  $n$  的一个整数因子，称为块大小。它的物理解释只有在取极限  $n \rightarrow 0$  后才会变得清楚，下面会讨论这一点。作为例子，当  $n = 6$  且  $m = 2$  时， $q^{ab}$  的形式为

$$\begin{pmatrix} 0 & q_1 & q_0 & q_0 & q_0 & q_0 \\ q_1 & 0 & q_0 & q_0 & q_0 & q_0 \\ q_0 & q_0 & 0 & q_1 & q_0 & q_0 \\ q_0 & q_0 & q_1 & 0 & q_0 & q_0 \\ q_0 & q_0 & q_0 & q_0 & 0 & q_1 \\ q_0 & q_0 & q_0 & q_0 & q_1 & 0 \end{pmatrix}. \quad (\text{A5.4})$$

注意，当  $q_1 = q_0$  且  $\hat{q}_1 = \hat{q}_0$ ，或当  $m = n$  时，我们恢复复本对称假设。

现在看这一假设如何简化式 (A5.1) 中的复本解体积。很容易看出

$$i \sum_{a < b} q^{ab} \hat{q}^{ab} = -\frac{n}{2}(m-1)q_1\hat{q}_1 - \frac{n}{2}(n-m)q_0\hat{q}_0. \quad (\text{A5.5})$$

为了简化  $G_S(\hat{q}^{ab})$  和  $G_E(q^{ab})$ ，方便起见把复本指标改写成  $a = Am + \alpha$ ，其中  $A = 1, \dots, n/m$

给出  $a$  所属块的编号, 而  $\alpha = 1, \dots, m$  指定块内位置。<sup>1</sup> 于是得到

$$\begin{aligned}
G_S &= \ln \sum_{\{J^a\}} \exp \left( -\frac{i}{2} \sum_{(a,b)} \hat{q}^{ab} J^a J^b \right) \\
&= \ln \sum_{\{J^a\}} \exp \left[ \frac{\hat{q}_0}{2} \sum_{A,B} \sum_{\alpha,\beta} J^{Am+\alpha} J^{Bm+\beta} + \frac{\hat{q}_1 - \hat{q}_0}{2} \sum_A \sum_{\alpha,\beta} J^{Am+\alpha} J^{Am+\beta} - \frac{\hat{q}_1}{2} \sum_A \sum_{\alpha} (J^{Am+\alpha})^2 \right] \\
&= \ln \sum_{\{J^a\}} \exp \left[ \frac{\hat{q}_0}{2} \left( \sum_A \sum_{\alpha} J^{Am+\alpha} \right)^2 + \frac{\hat{q}_1 - \hat{q}_0}{2} \sum_A \left( \sum_{\alpha} J^{Am+\alpha} \right)^2 - n \frac{\hat{q}_1}{2} \right].
\end{aligned} \tag{A5.6}$$

使用适当的 Hubbard-Stratonovich 变换, 可得

$$\begin{aligned}
G_S &= -n \frac{\hat{q}_1}{2} + \ln \int Dz_0 \int \prod_A Dz_A \sum_{\{J^a\}} \exp \left( \sqrt{\hat{q}_0} z_0 \sum_A \sum_{\alpha} J^{Am+\alpha} + \sqrt{\hat{q}_1 - \hat{q}_0} \sum_A z_A \sum_{\alpha} J^{Am+\alpha} \right) \\
&= -n \frac{\hat{q}_1}{2} + \ln \int Dz_0 \int \prod_A Dz_A \prod_A \sum_{\{J^{Am+\alpha}\}} \prod_A \exp \left[ \left( \sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_A \right) \sum_{\alpha} J^{Am+\alpha} \right],
\end{aligned} \tag{A5.7}$$

其中  $\sum_{\{J^{Am+\alpha}\}}$  表示在固定  $A$  时, 对所有  $2^m$  个满足  $J^{Am+\alpha} = \pm 1$ 、 $\alpha = 1, \dots, m$  的构型求和。计算这个求和后最终得到

$$\begin{aligned}
G_S &= -n \frac{\hat{q}_1}{2} + \ln \int Dz_0 \left[ \int Dz_1 \sum_{\{J^{\alpha}\}} \exp \left( \left( \sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1 \right) \sum_{\alpha} J^{\alpha} \right) \right]^{n/m} \\
&= -n \frac{\hat{q}_1}{2} + \ln \int Dz_0 \left[ \int Dz_1 \left[ 2 \cosh \left( \sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1 \right) \right]^m \right]^{n/m} \\
&= -n \frac{\hat{q}_1}{2} + \frac{n}{m} \int Dz_0 \ln \int Dz_1 \left[ 2 \cosh \left( \sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1 \right) \right]^m + O(n^2).
\end{aligned} \tag{A5.8}$$

<sup>1</sup>这个位置指标  $\alpha$  不应与存储比  $\alpha$  混淆。

以类似方式可以简化  $G_E(q^{ab})$  的表达式:

$$\begin{aligned}
G_E &= \ln \int_0^\infty d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} \exp \left( i \sum_a \lambda^a \hat{\lambda}^a - \frac{1}{2} \sum_a (\hat{\lambda}^a)^2 - \frac{1}{2} \sum_{(a,b)} \hat{\lambda}^a \hat{\lambda}^b q^{ab} \right) \\
&= \ln \int_0^\infty d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} \exp \left[ i \sum_{A,\alpha} \lambda^{Am+\alpha} \hat{\lambda}^{Am+\alpha} - \frac{q_0}{2} \sum_{A,B} \sum_{\alpha,\beta} \hat{\lambda}^{Am+\alpha} \hat{\lambda}^{Bm+\beta} \right. \\
&\quad \left. - \frac{q_1 - q_0}{2} \sum_A \sum_{\alpha,\beta} \hat{\lambda}^{Am+\alpha} \hat{\lambda}^{Am+\beta} - \frac{1 - q_1}{2} \sum_A \sum_{\alpha} (\hat{\lambda}^{Am+\alpha})^2 \right] \\
&= \ln \int Dt_0 \int \prod_A Dt_A \int_0^\infty d\lambda^a \int \frac{d\hat{\lambda}^a}{2\pi} \exp \left[ i \sum_{A,\alpha} \lambda^{Am+\alpha} \hat{\lambda}^{Am+\alpha} - i\sqrt{q_0} t_0 \sum_{A,\alpha} \hat{\lambda}^{Am+\alpha} \right. \\
&\quad \left. - i\sqrt{q_1 - q_0} \sum_A t_A \sum_{\alpha} \hat{\lambda}^{Am+\alpha} - \frac{1 - q_1}{2} \sum_{A,\alpha} (\hat{\lambda}^{Am+\alpha})^2 \right] \\
&= \ln \int Dt_0 \left[ \int Dt_1 \int_0^\infty d\lambda^\alpha \int \frac{d\hat{\lambda}^\alpha}{2\pi} \exp \left( i \sum_{\alpha} \lambda^\alpha \hat{\lambda}^\alpha - i\sqrt{q_0} t_0 \sum_{\alpha} \hat{\lambda}^\alpha \right. \right. \\
&\quad \left. \left. - i\sqrt{q_1 - q_0} t_1 \sum_{\alpha} \hat{\lambda}^\alpha - \frac{1 - q_1}{2} \sum_{\alpha} (\hat{\lambda}^\alpha)^2 \right) \right]^{n/m} \\
&= \ln \int Dt_0 \left[ \int Dt_1 H^m \left( -\frac{\sqrt{q_0} t_0 + \sqrt{q_1 - q_0} t_1}{\sqrt{1 - q_1}} \right) \right]^{n/m} \\
&= \frac{n}{m} \int Dt_0 \ln \int Dt_1 H^m \left( -\frac{\sqrt{q_0} t_0 + \sqrt{q_1 - q_0} t_1}{\sqrt{1 - q_1}} \right) + O(n^2).
\end{aligned} \tag{A5.9}$$

最后还必须取极限  $n \rightarrow 0$ 。在这一极限中如何处理  $m$  并不显然。作为假设的一部分，人们假定  $m$  会从整数  $n$  情形中介于 1 与  $n$  之间的整数，变为介于 0 ( $n$  所趋近的值) 和 1 (取极限前  $m$  的最小值) 之间的实数 [86]。它的具体值必须由鞍点方程自洽确定。随后可以证明， $m$  给出从解空间中随机选取的两个耦合向量属于不同斑块的概率。鉴于式 (A5.2)，这并不完全出人意料。<sup>1</sup>

令  $n \rightarrow 0$  后，最终得到

$$\begin{aligned}
\frac{1}{N} \langle \ln \Omega \rangle &= \text{extr}_{q_0, q_1, \hat{q}_0, \hat{q}_1, m} \left\{ \frac{m}{2} (q_0 \hat{q}_0 - q_1 \hat{q}_1) - \frac{\hat{q}_1}{2} (1 - q_1) \right. \\
&\quad \left. + \frac{1}{m} \int Dz_0 \ln \int Dz_1 \left[ 2 \cosh \left( \sqrt{\hat{q}_0} z_0 + \sqrt{\hat{q}_1 - \hat{q}_0} z_1 \right) \right]^m \right. \\
&\quad \left. + \frac{\alpha}{m} \int Dt_0 \ln \int Dt_1 H^m \left( -\frac{\sqrt{q_0} t_0 + \sqrt{q_1 - q_0} t_1}{\sqrt{1 - q_1}} \right) \right\}.
\end{aligned} \tag{A5.10}$$

这个表达式通过求解序参量  $q_0, q_1, \hat{q}_0, \hat{q}_1$  和  $m$  的鞍点方程来计算。

<sup>1</sup>关于 RSB 假设的许多假定及其物理解释，更完整的说明见 [17]。

## 附录 6 空腔方法

本书中大多数统计力学计算都使用复本方法来处理淬火随机变量问题。复本方法紧凑且相当直接；另一方面，由于它相当形式化，人们往往不容易把握所做变换的直观含义，有时甚至不容易理解所得结果本身。空腔方法将在本附录以最简单版本描述：它是在无序系统理论中发展出来的互补方法，强调计算的物理内容，并赋予所引入量以直观意义。空腔推导通常不如复本计算直接；由于它依赖自洽论证，往往需要对最终结果可能是什么有相当清楚的预期。另一方面，它常常能更深入地揭示复本方法形式操作背后的机制，并便于解释结果。

空腔方法的核心工具，是分析在加入一个单独自由度时宏观系统的反应。对于一个由  $N \gg 1$  个自旋组成的系统，这例如涉及加入另一个自旋及其相应耦合后局域场的重组。由于热力学极限存在，这种反应预期很小，因此可用微扰方式处理。在非常简单的系统中，例如铁磁体，这种反应完全可以忽略。然而，Onsager 在计算晶体中的电极化时首先认识到 [287]，在稍复杂的情形中，恰当处理由新自由度存在所诱导的关联是很重要的。在具有淬火无序的系统中这一点尤其关键 [288]；对这类系统而言，空腔方法如今已成为平均场理论的一种相当成熟而有力的版本 [17]。核心思想是首先确定所谓空腔场，也就是忽略这些关联时新自旋的局域场。由于没有关联，这个空腔场通常具有简单的概率性质；在平均场模型中，它往往由中心极限定理给出为高斯量。随后，把系统对新自旋的反应纳入考虑，便可确定真正的局域场。

在神经网络模型学习问题的框架中，空腔方法通常研究的是向训练集加入一个新样例  $\xi^p$  后耦合向量的重组。为简单起见，我们将按照文献 [289] 的分析，针对一个从无结构输入中学习的无监督感知机这一简单情形，说明该方法的基本思想。<sup>1</sup> 这将使我们能够把结果同第 8.2 节中用复本方法得到的结果进行比较。

在学习问题中，空腔场的角色由新样例在学习前的对齐场  $t$  扮演，也就是在把耦合向量  $\mathbf{J}$  调整到这个样例之前的对齐场。由于新样例通常假定与先前样例不相关， $t$  由中心极限定理可知是高斯随机变量。通过确定新模式被纳入训练集时突触向量的微小修正，可以计算新样例学习后的稳定性  $\lambda$ 。这一方法的主要思想是：对于给定训练集大小， $\lambda$  是空腔场  $t$  的一个普适、自平均函数；它可以自洽确定，并决定描述学习过程的序参量。

首先考虑向量  $\mathbf{J}$ ，它在归一化约束下最小化给定代价函数

$$E(\mathbf{J}) = \sum_{\mu=1}^{p-1} V(\lambda^\mu), \quad (\text{A6.1})$$

这个代价函数指定学习规则。归一化约束为

$$\mathbf{J}^2 - N = 0. \quad (\text{A6.2})$$

样例  $\xi^\mu$  随机取自  $N$ -球面，稳定性

$$\lambda^\mu = \frac{\mathbf{J} \xi^\mu}{\sqrt{N}} \quad (\text{A6.3})$$

按式 (8.5) 定义。

<sup>1</sup>关于神经网络语境中略有不同的空腔方法版本，见 [290] 和 [291]。

通过最小化  $E(\mathbf{J}) - (\mathbf{J}^2 - N)/(2\Gamma)$ , 可知  $\mathbf{J}$  满足方程

$$\mathbf{J} = \frac{\Gamma}{\sqrt{N}} \sum_{\mu=1}^{p-1} V'(\lambda^\mu) \boldsymbol{\xi}^\mu, \quad (\text{A6.4})$$

其中撇号表示对自变量求导。拉格朗日乘子  $\Gamma$  由归一化条件 (A6.2) 确定。

现在考虑加入一个新样例  $\boldsymbol{\xi}^p$ 。空腔场是对齐场

$$t^p = \frac{\mathbf{J} \boldsymbol{\xi}^p}{\sqrt{N}}, \quad (\text{A6.5})$$

其中  $\mathbf{J}$  向量是在没有这个样例时构造的。由  $\boldsymbol{\xi}^p$  与  $\mathbf{J}$  的统计独立性可知,  $t^p$  是均值为零、方差为一的高斯随机变量。

当  $\boldsymbol{\xi}^p$  被纳入训练集后,  $\mathbf{J}$  向量会从  $\mathbf{J}$  轻微调整为  $\mathbf{J}_+$ , 并满足

$$\mathbf{J}_+ = \frac{\Gamma_+}{\sqrt{N}} \sum_{\mu=1}^p V'(\lambda_+^\mu) \boldsymbol{\xi}^\mu. \quad (\text{A6.6})$$

随着  $\mathbf{J}$  的移动, 拉格朗日乘子也会修正, 此前已经学过的样例的稳定性也从  $\lambda^\mu$  改变为  $\lambda_+^\mu$ 。

对  $\mathbf{J}$  和  $\mathbf{J}_+$  同时强制球面归一化条件, 可以证明  $|\Gamma - \Gamma_+| = O(1/\sqrt{N})$ 。因此, 在下面的变换中, 可以忽略拉格朗日乘子的变化。此外, 此前学过的样例的稳定性修正  $\lambda_+^\mu - \lambda^\mu$  同样是  $1/\sqrt{N}$  阶, 于是可以围绕  $\lambda^\mu$  展开  $V'(\lambda_+^\mu)$ 。这给出

$$\mathbf{J}_+ - \mathbf{J} = \frac{\Gamma}{\sqrt{N}} V'(\lambda_+^p) \boldsymbol{\xi}^p + \frac{\Gamma}{\sqrt{N}} \sum_{\mu=1}^{p-1} V''(\lambda^\mu) (\lambda_+^\mu - \lambda^\mu) \boldsymbol{\xi}^\mu. \quad (\text{A6.7})$$

第一项来自把新样例纳入训练集的直接代价; 第二项描述先前样例发生轻微重新对齐所产生的间接贡献。<sup>1</sup> 将式 (A6.7) 乘以  $\boldsymbol{\xi}^p/\sqrt{N}$ , 并使用定义 (A6.3) 与 (A6.5), 得到

$$\lambda_+^p - t^p = \Gamma V'(\lambda_+^p) + \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda^\mu) (\lambda_+^\mu - \lambda^\mu) \boldsymbol{\xi}^\mu \boldsymbol{\xi}^p. \quad (\text{A6.8})$$

因此, 我们得到了一个方程: 新样例学习前后的对齐场差异, 可以表示为所有其他模式的稳定性位移的函数。

如同所有平均场理论一样, 我们通过注意到第  $p$  个模式并无特殊之处, 将这一关系转化为自治方程。因此, 训练集中每个其他样例的稳定性和空腔场之间也必须满足等价关系。更准确地说, 我们将假定存在一个普适、自平均函数; 为与正文保持一致, 记为  $\lambda_0(t, \alpha)$ 。它把  $p = \alpha N$  个样例之一在学习前的对齐场  $t$ , 映射到学习后的稳定性  $\lambda$ 。

借助这一假设, 可以如下简化式 (A6.8) 中的反应项。记  $\mathbf{J}^{\setminus \mu}$  与  $\mathbf{J}_+^{\setminus \mu}$  为从相应训练集中删除样例  $\boldsymbol{\xi}^\mu$  后构造的耦合向量, 并引入

$$t_+^\mu = \frac{\mathbf{J}_+^{\setminus \mu} \boldsymbol{\xi}^\mu}{\sqrt{N}}, \quad t^\mu = \frac{\mathbf{J}^{\setminus \mu} \boldsymbol{\xi}^\mu}{\sqrt{N}}, \quad (\text{A6.9})$$

分别作为样例  $\boldsymbol{\xi}^\mu$  在包含和不包含样例  $\boldsymbol{\xi}^p$  时的空腔场。由于  $\lambda_+^\mu - \lambda^\mu = O(1/\sqrt{N})$ , 对普适函数  $\lambda_0(t, \alpha)$  在两个变量上作 Taylor 展开, 得到

$$\lambda_+^\mu - \lambda^\mu = \lambda_0\left(t_+^\mu, \alpha + \frac{1}{N}\right) - \lambda_0(t^\mu, \alpha), \quad (\text{A6.10})$$

<sup>1</sup> 顺便指出, 这里考虑的离线学习场景与第 九 章讨论的在线学习之间的主要差别, 恰恰在于在线学习中不存在这些后续调整。

以及

$$\lambda_+^\mu - \lambda^\mu = \lambda_0'(t^\mu, \alpha)(t_+^\mu - t^\mu) + O(1/N), \quad (\text{A6.11})$$

其中撇号表示对第一个自变量求导。利用这些表达式，式 (A6.8) 中的反应项可写成

$$\begin{aligned} & \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda^\mu) \lambda_0'(t^\mu, \alpha) \sum_{i,j} \frac{J_{+i}^\mu - J_i^\mu}{\sqrt{N}} \xi_i^\mu \xi_j^\mu \xi_j^p \\ &= \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda^\mu) \lambda_0'(t^\mu, \alpha) \left[ \sum_i \frac{J_{+i}^\mu - J_i^\mu}{\sqrt{N}} \xi_i^p + \sum_{i \neq j} \frac{J_{+i}^\mu - J_i^\mu}{\sqrt{N}} \xi_i^\mu \xi_j^\mu \xi_j^p \right]. \end{aligned}$$

现在利用在没有输入  $\mu$  时与式 (A6.7) 类似的关系，可以验证，方括号中分别来自  $i, j$  求和的对角部分和非对角部分的两项都是 1 阶。然而，由于  $\xi_i^\mu \xi_j^\mu$  对  $\mu$  的随机依赖，并且  $\mathbf{J}^\mu$  不依赖于  $\boldsymbol{\xi}^\mu$ ，第二项在对  $\mu$  求和后的贡献可以忽略。最后，在所需阶数上，可在第一项中把  $(J_{+i}^\mu - J_i^\mu)$  替换为  $(J_{+i} - J_i)$ ，从而得到

$$\lambda_+^p - t^p = \Gamma V'(\lambda_+^p) + (\lambda_+^p - t^p) \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda^\mu) \lambda_0'(t^\mu, \alpha). \quad (\text{A6.12})$$

于是，不出意料地，反应项正比于其原因，即  $(\lambda_+^p - t^p)$ 。引入辅助量

$$x = \frac{\Gamma}{1 - \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda_0(t_\mu)) \lambda_0'(t_\mu)}, \quad (\text{A6.13})$$

便可由式 (A6.12) 得到

$$\lambda_0(t, \alpha) - t = x V'(\lambda_0), \quad (\text{A6.14})$$

这等价于式 (8.18) 中关于  $\lambda$  的极值条件，其中  $\lambda_0$  对  $\alpha$  的依赖由  $x$  参数化。

最后，为了推导决定  $x$  作为  $\alpha$  函数的方程，回忆空腔场  $t^\mu$  是均值为零、方差为一的彼此不相关高斯变量。这意味着当  $N$  很大时，

$$\frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda_0(t^\mu)) \lambda_0'(t^\mu) = \Gamma \alpha \int Dt V''(\lambda_0(t)) \lambda_0'(t), \quad (\text{A6.15})$$

并且

$$\Gamma \alpha \int Dt V''(\lambda_0(t)) \lambda_0'(t) = \frac{\Gamma \alpha}{x} \int Dt (\lambda_0'(t) - 1), \quad (\text{A6.16})$$

其中最后一个等式来自对式 (A6.14) 求导。把这一结果与  $x$  的定义 (A6.13) 结合，得到

$$x = \Gamma \left( 1 + \alpha \int Dt (\lambda_0'(t) - 1) \right). \quad (\text{A6.17})$$

$\Gamma$  的值由归一化条件给出。将式 (A6.4) 乘以  $\mathbf{J}/N$ ，得到

$$1 = \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V'(\lambda^\mu) \frac{\mathbf{J} \boldsymbol{\xi}^\mu}{\sqrt{N}}, \quad (\text{A6.18})$$

$$1 = \Gamma \alpha \int Dt V'(\lambda_0(t)) \lambda_0(t), \quad (\text{A6.19})$$

以及

$$1 = \frac{\Gamma \alpha}{x} \int Dt (\lambda_0(t) - t) \lambda_0(t), \quad (\text{A6.20})$$



其中再次使用了式 (A6.14)。代入  $x$  的表达式 (A6.17) 后, 拉格朗日乘子  $\Gamma$  消去, 最后通过分部积分得到

$$\alpha \int Dt (\lambda_0(t) - t)^2 = 1, \quad (\text{A6.21})$$

这与对应于式 (8.18) 的鞍点方程相同。

使用类似论证, 还可以得到一个关于上述一般推理的自洽性判据。空腔方法的核心假设是, 新样例所诱导的耦合向量修正  $(\mathbf{J}_+ - \mathbf{J})$  很小。把式 (A6.7) 乘以  $(\mathbf{J}_+ - \mathbf{J})$ , 并采用与导出式 (A6.12) 时类似的论证, 得到

$$(\mathbf{J}_+ - \mathbf{J})^2 = \frac{\Gamma V'(\lambda_+^p)(\lambda_+^p - t^p)}{1 - \frac{\Gamma}{N} \sum_{\mu=1}^{p-1} V''(\lambda_0(t_\mu)) (\lambda_0'(t_\mu, \alpha))^2}. \quad (\text{A6.22})$$

利用式 (A6.14) 及其对  $t$  的导数, 可将其写成

$$(\mathbf{J}_+ - \mathbf{J})^2 = \frac{(\lambda_+^p - t^p)^2}{1 - \alpha \int Dt (\lambda_0'(t) - 1)^2}, \quad (\text{A6.23})$$

它在  $\alpha \rightarrow \alpha_{\text{AT}}$  时发散, 其中 de Almeida-Thouless 阈值由

$$\frac{1}{\alpha_{\text{AT}}} = \int Dt (\lambda_0'(t) - 1)^2 \quad (\text{A6.24})$$

给出。因此, 当  $\alpha$  接近  $\alpha_{\text{AT}}$  时, 单个新增样例所诱导的  $\mathbf{J}$  修正会变成宏观量, 空腔方法的推理随之失效。对于当前问题, 结果 (A6.24) 等价于习题 4.13 中推导的复本对称鞍点的局域稳定性条件。关于它与复本形式主义之间联系的更多细节, 可参见 [292] 和 [17]。

## 附录 7 VC 定理

统计学中的许多结果都建立在概率分布不等式之上，而这些不等式不依赖某个未知参数的具体取值。第 10.3 节引入的 Vapnik–Chervonenkis 界，正是这一思想的一个漂亮而成功的例证。证明这个重要定理的第一步，是消去对测试函数未知泛化误差的依赖。为此，我们首先把概率 (10.3) 改写为

$$\begin{aligned}\text{Prob}\left(\sup_{f \in \mathcal{F}} |\nu_f^p - \varepsilon_f| > \delta\right) &= \left\langle \theta\left(\sup_{f \in \mathcal{F}} |\nu_f^p - \varepsilon_f| - \delta\right) \right\rangle \\ &= \left\langle \sup_{f \in \mathcal{F}} \theta(|\nu_f^p - \varepsilon_f| - \delta) \right\rangle \\ &= \left\langle \sup_{f \in \mathcal{F}} \left[ \theta(\nu_f^p - \varepsilon_f - \delta) + \theta(\varepsilon_f - \nu_f^p - \delta) \right] \right\rangle,\end{aligned}\tag{A7.1}$$

其中  $\theta(x)$  仍表示式 (A1.17) 中定义的阶跃函数。括号  $\langle \dots \rangle$  表示对决定  $\nu_f^p$  取值的  $p$  个样例的选择求平均。证明该定理的主要步骤之一，是构造一个不等式，使得均值中的  $\varepsilon_f$  依赖可以被消去。为此，引入一个含  $p'$  个样例的新训练集，对它而言函数  $f$  给出的错误频率为  $\nu_f^{p'}$ 。由于  $\theta(x)\theta(x') \leq \theta(x+x')$ ，可得

$$\theta(\nu_f^p - \varepsilon_f - \delta) \theta\left(\varepsilon_f - \nu_f^{p'} + \frac{1}{p'}\right) \leq \theta\left[\nu_f^p - \nu_f^{p'} - \left(\delta - \frac{1}{p'}\right)\right].$$

这个不等式对  $\nu_f^{p'}$  的任意取值都成立，因此也对  $p'$  个新的独立样例的选择平均  $\langle \dots \rangle'$  成立，即

$$\theta(\nu_f^p - \varepsilon_f - \delta) \left\langle \theta\left(\varepsilon_f - \nu_f^{p'} + \frac{1}{p'}\right) \right\rangle' \leq \left\langle \theta\left[\nu_f^p - \nu_f^{p'} - \left(\delta - \frac{1}{p'}\right)\right] \right\rangle'.\tag{A7.2}$$

回忆  $p'\nu_f^{p'}$  是一个服从二项分布的随机变量，其均值为  $p'\varepsilon_f$ ，可以证明 [155]

$$\left\langle \theta\left(\varepsilon_f - \nu_f^{p'} + \frac{1}{p'}\right) \right\rangle' = \text{Prob}\left[0 \leq \nu_f^{p'} < \varepsilon_f + \frac{1}{p'}\right] \geq \frac{1}{2}.$$

这与式 (A7.2) 合起来给出

$$\theta(\nu_f^p - \varepsilon_f - \delta) \leq 2 \left\langle \theta\left[\nu_f^p - \nu_f^{p'} - \left(\delta - \frac{1}{p'}\right)\right] \right\rangle'.\tag{A7.3}$$

以类似方式也容易证明

$$\theta(\varepsilon_f - \nu_f^p - \delta) \leq 2 \left\langle \theta\left[\nu_f^{p'} - \nu_f^p - \left(\delta - \frac{1}{p'}\right)\right] \right\rangle'.\tag{A7.4}$$

最后，把式 (A7.1)、(A7.3) 与 (A7.4) 合并，得到

$$\text{Prob}\left(\sup_{f \in \mathcal{F}} |\nu_f^p - \varepsilon_f| > \delta\right) \leq 2 \left\langle \left\langle \sup_{f \in \mathcal{F}} \theta\left[\nu_f^p - \nu_f^{p'} - \left(\delta - \frac{1}{p'}\right)\right] \right\rangle' \right\rangle,$$

或者

$$\text{Prob}\left(\sup_{f \in \mathcal{F}} |\nu_f^p - \varepsilon_f| > \delta\right) \leq 2 \text{Prob}\left[\sup_{f \in \mathcal{F}} |\nu_f^p - \nu_f^{p'}| > \left(\delta - \frac{1}{p'}\right)\right].\tag{A7.5}$$

Vapnik 和 Chervonenkis 将这一结果称为基本引理 [168]。这里的推导沿用 [160]。

现在可以引入函数类  $\mathcal{F}$  的分类多样性：对于这些样例的一次给定选择，函数  $f \in \mathcal{F}$  可以分成等价类  $\hat{f}$ ，使得给定等价类  $\hat{f}$  中所有函数对  $p + p'$  个样例给出的分类完全相同。由于  $\mathcal{F}$  中的函数对任意  $p + p'$  个训练样例至多诱导  $\Delta(p + p')$  种不同分类，对任意样例选择，等价类总数都被  $\Delta(p + p')$  所界定。由于同一类  $\hat{f}$  中所有元素在样例上的输出相同，因而观测到的错误频率也相同，可以写成

$$\left\langle \left\langle \sup_{f \in \mathcal{F}} \theta \left[ |\nu_f^p - \nu_f^{p'}| - \left( \delta - \frac{1}{p'} \right) \right] \right\rangle' \right\rangle \leq \left\langle \left\langle \sum_{\hat{f}} \theta \left[ |\nu_{\hat{f}}^p - \nu_{\hat{f}}^{p'}| - \left( \delta - \frac{1}{p'} \right) \right] \right\rangle' \right\rangle,$$

其中右边的求和遍历所有等价类。注意，这些等价类依赖于样例的选择，但不依赖它们在总样本中出现的顺序。另一方面，总平均值在  $p + p'$  个样例的置换下也是不变的。因此可以写成

$$\begin{aligned} & \left\langle \left\langle \sum_{\hat{f}} \theta \left[ |\nu_{\hat{f}}^p - \nu_{\hat{f}}^{p'}| - \left( \delta - \frac{1}{p'} \right) \right] \right\rangle' \right\rangle \\ &= \left\langle \left\langle \sum_{\hat{f}} \frac{1}{(p + p')!} \sum_{\sigma} \theta \left[ |\sigma(\nu_{\hat{f}}^p) - \sigma(\nu_{\hat{f}}^{p'})| - \left( \delta - \frac{1}{p'} \right) \right] \right\rangle' \right\rangle, \end{aligned}$$

其中求和遍历  $p + p'$  个样例的所有可能置换  $\sigma$ ，而  $\sigma(\nu_{\hat{f}}^p)$  和  $\sigma(\nu_{\hat{f}}^{p'})$  是对整个样本的样例作置换后，在所考虑的两个子样本中得到的频率。注意，每个子样本的组成可以由置换改变。

结果表明，对所有可能输出，量

$$\Gamma_{\delta} = \frac{1}{(p + p')!} \sum_{\sigma} \theta \left[ |\sigma(\nu_{\hat{f}}^p) - \sigma(\nu_{\hat{f}}^{p'})| - \delta \right]$$

都可以被界定。我们考虑  $\Gamma_{\delta}$  的两个不同界。第一个界在  $p = p'$  时成立，可见于 [155]：

$$\Gamma_{\delta} < 3e^{-p\delta^2}. \quad (\text{A7.6})$$

第二个界由 [154] 与 [159] 推得，在特殊情形  $p = p'$  下较弱，但当  $p' \gg p$  时给出更强结果。它为

$$\Gamma_{\delta} \leq 2 \exp \left[ -2p \left( \frac{p'}{p + p'} \delta \right)^2 \right]. \quad (\text{A7.7})$$

最后，把式 (A7.5) 与界 (A7.6) 结合，立即得到式 (10.9)。通过调节  $p$  与  $p'$  的选取并结合 (A7.7)，可以得到更尖锐的界，特别是第 10 章中提到的更尖锐精度阈值。

# 参考文献

- [1] W. S. McCulloch and W. Pitts. A logical calculus of ideas immanent in nervous activity. *Bull. Math. Biophys.*, 5:115–133, 1943.
- [2] D. J. Amit. *Modelling Brain Function*. Cambridge University Press, Cambridge, 1989.
- [3] J. A. Hertz, A. Krogh, and R. G. Palmer. *Introduction to the Theory of Neural Computation*. Addison-Wesley, Redwood City, 1991.
- [4] B. Müller and J. Reinhard. *Neural Networks – An Introduction*. Springer, Berlin, 1991.
- [5] P. Peretto. *An Introduction to the Modeling of Neural Networks*. Cambridge University Press, Cambridge, 1992.
- [6] F. Rosenblatt. *Principles of Neurodynamics*. Spartan, New York, 1962.
- [7] M. L. Minsky and S. A. Papert. *Perceptrons*. MIT Press, Cambridge, MA, 1969.
- [8] Patarnello and P. Carnevali. Exhaustive thermodynamical analysis of Boolean learning networks. *Europhys. Lett.*, 4:503, 1987.
- [9] T. J. Sejnowski and C. R. Rosenberg. Parallel networks that learn to pronounce english text. *Complex Systems*, 1:145, 1987.
- [10] D. E. Rumelhart and J. E. McClelland, editors. *Parallel Distributed Processing*. MIT Press, Cambridge MA, 1986.
- [11] E. Levin, N. Tishby, and S. Solla. A statistical approach to learning and generalization in layered neural networks. In R. Rivest, D. Haussler, and M. K. Warmuth, editors. *Proceedings of the 2nd Workshop on Computational Learning Theory*, page 245. Morgan Kaufmann, San Mateo, 1989.
- [12] M. Oppor and W. Kinzel. Statistical mechanics of generalization. In E. Domany, J. L. van Hemmen, and K. Schulten, editors. *Models of Neural Networks III*, pages 151–209. Springer, New York, 1996.
- [13] L. G. Valiant. A theory of the learnable. *Commun. ACM*, 27:1134, 1984.
- [14] E. W. Montroll and M. F. Shlesinger. Maximum entropy formalism, fractals, scaling phenomena, and  $1/f$  noise: a tale of tails. *J. Stat. Phys.*, 32:209, 1983.
- [15] M. Talagrand. Self averaging and the space of interactions in neural networks. *Random Struct. Alg.*, 14:199, 1999.
- [16] K. Binder and A. P. Young. Spin glasses: experimental facts, theoretical concepts, and open questions. *Rev. Mod. Phys.*, 58:801, 1986.
- [17] M. Mézard, G. Parisi, and M. A. Virasoro. *Spin Glass Theory and Beyond*. World Scientific, Singapore, 1987.
- [18] M. Kac. On certain Toeplitz-like matrices and their relation to the problem of lattice vibrations. *Ark. Det. Fys. Seminar i Trondheim*, 11:1–21, 1968.
- [19] S. F. Edwards. Statistical mechanics of polymerized materials. In R. W. Douglass and B. Ellis, editors. *Proc. Third Int. Conf. on the Physics of Non-crystalline Solids*, pages 279–300. Wiley, New York, 1972.
- [20] S. F. Edwards and P. W. Anderson. Theory of spin glasses. *J. Phys. F*, 5:965, 1975.

- [21] M. S. Seung, H. Sompolinsky, and N. Tishby. Statistical mechanics of learning from examples. *Phys. Rev. A*, 45:6056, 1992.
- [22] B. Schwartz, V. K. Samalam, S. A. Solla, and J. S. Denker. Exhaustive learning. *Neural Computation*, 2:371, 1990.
- [23] C. Van den Broeck and R. Kawai. Learning in feedforward Boolean networks. *Phys. Rev. A*, 42:6210, 1990.
- [24] E. Gardner. The space of interactions in neural network models. *J. Phys. A*, 21:257, 1988.
- [25] E. Gardner and B. Derrida. Optimal storage properties of neural network models. *J. Phys. A*, 21:271, 1988.
- [26] E. Gardner. Optimal basins of attraction in randomly sparse neural network models. *J. Phys. A*, 22:1969, 1989.
- [27] E. Gardner and B. Derrida. Three unfinished works on the optimal storage capacity of networks. *J. Phys. A*, 22:1983, 1989.
- [28] P. Del Giudice, S. Franz, and M. A. Virasoro. Perceptron beyond the limit of capacity. *J. Physique*, 50:121, 1989.
- [29] F. Vallet. The Hebb rule for learning linearly separable Boolean functions: learning and generalization. *Europhys. Lett.*, 8:747, 1989.
- [30] G. Györgyi and N. Tishby. Statistical theory of learning a rule. In K. Theumann and W. K. Koeberle, editors. *Workshop on Neural Networks and Spin Glasses*, pages 3–36. World Scientific, Singapore, 1990.
- [31] M. Bouten and C. Van den Broeck. Nearest-neighbour classifier for the perceptron. *Europhys. Lett.*, 26:69, 1994.
- [32] D. O. Hebb. *The Organization of Behavior*. Wiley, New York, 1949.
- [33] R. Meir and J. F. Fontanari. Calculation of learning curves for inconsistent algorithms. *Phys. Rev. A*, 45:8874, 1992.
- [34] J. Berg and A. Engel. A multifractal phase-space analysis of perceptrons with biased patterns. *J. Phys. A*, 31:2509, 1998.
- [35] S. Seung, M. Oppen, and H. Sompolinsky. Query by committee. In *Vth Annual Workshop on Computational Learning Theory (COLT92)*, page 287, San Mateo, 1992.
- [36] P. Ruján. Playing billiards in version space. *Neural Computation*, 9:99, 1995.
- [37] T. L. H. Watkin. Optimal learning with a neural network. *Europhys. Lett*, 21:871, 1993.
- [38] T. Kohonen. Analysis of a simple self-organizing process. *Biol. Cyb.*, 44:135, 1982.
- [39] L. Personnaz, I. Guyon, and G. Dreyfus. Information storage and retrieval in spin-glass like neural networks. *J. Phys. Lett.*, 46:4217, 1985.
- [40] B. Widrow and M. E. Hoff. Adaptive switching circuits. *WESCON convention report*, (4):96, 1960.
- [41] M. Oppen. Learning in neural networks: solvable dynamics. *Europhys. Lett.*, 8:389, 1989.
- [42] S. Diederich and M. Oppen. Learning of correlated patterns in spin-glass networks by local learning rules. *Phys. Rev. Lett.*, 58:949, 1987.
- [43] W. Krauth and M. Mézard. Learning algorithms with optimal stability in neural networks. *J. Phys. A*, 20:L745, 1987.
- [44] M. Oppen. Learning times of neural networks: exact solution for a perceptron algorithm. *Phys. Rev. A*, 38:3824, 1988.

- [45] J. F. Fontanari and A. Theumann. Learning times of a perceptron that learns from examples. *J. Phys. A*, 27:379, 1994.
- [46] R. Fletcher. *Practical Methods of Optimization*. John Wiley and Sons, New York, 1996.
- [47] J. K. Anlauf and M. Biehl. The adatron: an adaptive perceptron algorithm. *Europhys. Lett.*, 10:687, 1989.
- [48] P. Ruján. A fast method for calculating the perceptron with maximal stability. *J. Physique I*, 3:277, 1993.
- [49] J. Imhoff. A polynomial training algorithm for calculating perceptrons of optimal stability. *J. Phys. A*, 28:2173, 1995.
- [50] D. Haussler, M. Kearns, and R.E. Schapire. Bounds on the sample complexity of Bayesian learning using information theory and the VC dimension. In *Machine Learning*, volume 14, page 83, 1994.
- [51] J. A. Anderson and E. Rosenfeld. *Neurocomputing: Foundations of Research*. MIT Press, Cambridge, MA, 1988.
- [52] W. Kinzel and G. Reents. *Physics by Computer*. Springer, Berlin, 1998.
- [53] S. Solla. A Bayesian approach to learning in neural networks. *Intl. J. of Neural Systems*, 6:161, 1995.
- [54] M. Bouten, J. Schietse, and C. Van den Broeck. Gradient descent learning in perceptrons: a review of its possibilities. *Phys. Rev. E*, 52:1958, 1995.
- [55] O. Kinouchi and N. Caticha. Learning algorithm that gives the Bayes generalization limit for perceptrons. *Phys. Rev. E*, 54:R54, 1996.
- [56] A. Buhot, J.-M. T. Moreno, and M. B. Gordon. Finite size scaling of the Bayesian perceptron. *Phys. Rev. E*, 55:7434, 1997.
- [57] N. Caticha and O. Kinouchi. Time ordering in the evolution of information processing and modulation systems. *Phil. Mag. B*, 77:1565, 1998.
- [58] M. Oppen, W. Kinzel, J. Kleinz, and R. Nehl. On the ability of the optimal perceptron to generalize. *J. Phys. A*, 23:581, 1990.
- [59] M. Oppen and D. Haussler. Generalization performance of Bayes optimal classification algorithm for learning a perceptron. *Phys. Rev. Lett.*, 66:2677, 1991.
- [60] J. M. Parrondo and C. Van den Broeck. Error vs. rejection curve for the perceptron. *Europhys. Lett.*, 22:319, 1993.
- [61] I. Derényi, T. Gészti, and G. Györgyi. Generalization in the programmed teaching of a perceptron. *Phys. Rev. E*, 50:3192, 1994.
- [62] P. Majer, A. Engel, and A. Zippelius. Perceptrons above saturation. *J. Phys. A*, 26:7405, 1993.
- [63] T. L. H. Watkin and A. Rau. Learning unlearnable problems with perceptrons. *Phys. Rev. A*, 45:4102, 1992.
- [64] P. Kuhlmann and K.-R. Müller. On the generalization ability of diluted perceptrons. *J. Phys. A*, 27:3759, 1994.
- [65] D. Nabutovsky and E. Domany. Learning the unlearnable. *Neural Comp.*, 3:604, 1991.
- [66] G. Györgyi. Inference of a rule by a neural network with thermal noise. *Phys. Rev. Lett.*, 64:2957, 1990.
- [67] D. Hansel and H. Sompolinsky. Learning from examples in a single-layer neural network. *Europhys. Lett.*, 11:687, 1990.

- [68] G. Parisi. A memory which forgets. *J. Phys. A*, 19:L617, 1986.
- [69] J. L. van Hemmen, G. Keller, and R. Kühn. Forgetful memories. *Europhys. Lett.*, 5:663, 1988.
- [70] M. Mézard, J. P. Nadal, and G. Toulouse. Solvable models of working memories. *J. Physique*, 47:1457, 1986.
- [71] J. P. Nadal, G. Toulouse, J. P. Changeux, and S. Dehaene. Networks of formal neurons and memory palimpsests. *Europhys. Lett.*, 1:535, 1986.
- [72] T. M. Cover. Geometrical and statistical properties of systems of linear inequalities with applications in pattern recognition. *IEEE Trans. Electron. Comput.*, EC-14:326, 1965.
- [73] J. G. Wendel. A problem in geometric probability. *Math. Scand.*, 11:109, 1962.
- [74] L. Schläfli. Theorie der vielfachen Kontinuität. In Steiner-Schläfli-Komitee Basel, editor. *Gesammelte Mathematische Abhandlungen*. Birkhäuser, Basel, 1852.
- [75] M. Bouten. Replica symmetry instability in perceptron models. *J. Phys. A*, 27:6021, 1994.
- [76] D. J. Gross and M. Mézard. The simplest spin glass. *Nucl. Phys. B*, 240:431, 1984.
- [77] W. Krauth and M. Oppen. Critical storage capacity of the  $j = \pm 1$  neural network. *J. Phys. A*, 22:L519, 1989.
- [78] B. Derrida, R. B. Griffith, and A. Prügel-Bennett. Finite-size effects and bounds for perceptron models. *J. Phys. A*, 24:4907, 1991.
- [79] B. Derrida. Random-energy model: an exactly solvable model of disordered systems. *Phys. Rev. B*, 24:2613, 1981.
- [80] M. Bouten, A. Komoda, and R. Serneels. Storage capacity of a diluted neural network with Ising couplings. *J. Phys. A*, 23:2605, 1990.
- [81] T. B. Kepler and L. F. Abbott. Domains of attraction in neural networks. *J. Physique*, 49:1657, 1988.
- [82] L. Ein-Dor and I. Kanter. Confidence in prediction by neural networks. *Phys. Rev. E*, 60:799, 1999.
- [83] W. Whyte and D. Sherrington. Replica-symmetry breaking in perceptrons. *J. Phys. A*, 29:3063, 1996.
- [84] M. Griniasty and H. Gutfreund. Learning and retrieval in attractor neural networks above saturation. *J. Phys. A*, 24:715, 1991.
- [85] R. Erichsen and W. K. Theumann. Optimal storage of a neural network model: a replica symmetry-breaking solution. *J. Phys. A*, 26:L61, 1993.
- [86] G. Parisi. The order parameter for spin glasses: A function on the interval 0–1. *J. Phys. A*, 13:L115, 1101 and 1887, 1980.
- [87] G. Györgyi and P. Reimann. Parisi phase in a neuron. *Phys. Rev. Lett.*, 79:2746, 1997.
- [88] G. Györgyi and P. Reimann. Beyond storage capacity in a single model neuron: Continuous replica symmetry breaking. *Journ. Stat. Phys.*, 101:673, 2000.
- [89] G. Györgyi. Techniques of replica symmetry breaking and the storage problem of the McCulloch–Pitts neuron. *Phys. Rep.*, to appear, 2001.
- [90] D. J. Amit, K. Y. M. Wong, and C. Campbell. Perceptron learning with sign-constrained weights. *J. Phys. A*, 22:2039, 1989.
- [91] D. J. Amit, C. Campbell, and K. Y. M. Wong. The interaction space of neural networks with sign-constrained synapses. *J. Phys. A*, 22:4687, 1989.



- [92] C. Campbell and A. Robinson. On the storage capacity of neural networks with sign-constrained weights. *J. Phys. A*, 24:L93, 1991.
- [93] I. Kanter and E. Eisenstein. On the capacity per synapse. *J. Phys. A*, 23:L935, 1990.
- [94] H. Gutfreund and Y. Stein. Capacity of neural networks with discrete synaptic couplings. *J. Phys. A*, 23:2613, 1990.
- [95] B. López and W. Kinzel. Learning by dilution in a neural network. *J. Phys. A*, 30:7753, 1997.
- [96] R. Meir and J. F. Fontanari. Learning from examples in weight-constrained neural networks. *J. Phys. A*, 25:1149, 1992.
- [97] D. M. L. Barbato and J. F. Fontanari. The effects of lesions on the generalization ability of a perceptron. *J. Phys. A*, 26:1847, 1993.
- [98] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220:671, 1983.
- [99] H. Horner. Dynamics of learning for the binary perceptron problem. *Z. Phys. B*, 86:291, 1992.
- [100] S. Mertens. Exhaustive search for low-autocorrelation binary sequences. *J. Phys. A*, 29:L199, 1996.
- [101] L. Pitt and L. G. Valiant. Computational limitations on learning from examples. *J. Assoc. Comput. Machinery*, 35:965, 1988.
- [102] R. W. Penney and D. Sherrington. The weight-space of the binary perceptron. *J. Phys. A*, 26:6173, 1993.
- [103] L. Reimers, M. Bouten, and B. Van Rompaey. Learning strategy for the binary perceptron. *J. Phys. A*, 29:6247, 1996.
- [104] R. E. Mayer. *Thinking and Problem Solving: An Introduction to Human Cognition and Learning*. Scott, Foresman and Company, Glenview, 1977.
- [105] G. Györgyi. First-order transition to perfect generalization in a neutral network with binary synapses. *Phys. Rev. A*, 41:7097, 1990.
- [106] G. Boffetta, R. Monasson, and R. Zecchina. Symmetry breaking in nonmonotonic neural networks. *J. Phys. A*, 26:L507, 1993.
- [107] A. Engel and L. Reimers. Reliability of replica symmetry for the generalization problem in a toy multilayer neural network. *Europhys. Lett.*, 28:531, 1994.
- [108] G. J. Bex, R. Serneels, and C. Van den Broeck. Storage capacity and generalization error for the reversed-wedge Ising perceptron. *Phys. Rev. E*, 51:6309, 1995.
- [109] J. Schietse, M. Bouten, and C. Van den Broeck. Training binary perceptrons by clipping. *Europhys. Lett.*, 32:279, 1995.
- [110] R. O. Duda and P. E. Hart. *Pattern Classification and Scene Analysis*. Wiley, New York, 1973.
- [111] E. Oja. A simplified neuron model as a principal component analyser. *J. Math. Biology*, 15:267, 1992.
- [112] M. Biehl and A. Mietzner. Statistical mechanics of unsupervised learning. *Europhys. Lett.*, 24:421, 1993.
- [113] R. Linsker. Towards an organizing principle for perception: the role of Hebbian synapses in the emergence of feature-analyzing function. In 1987 IEEE Conference on Neural Information Processing Systems – Natural and Synthetic. IEEE, Denver, page 10, 1987.
- [114] P. Reimann, C. Van den Broeck, and G. J. Bex. A Gaussian scenario for unsupervised learning. *J. Phys. A*, 29:3521, 1996.

- [115] F. Spitzer. Principles of a Random Walk. Van Nostrand, Princeton, New Jersey, 1964.
- [116] W. Feller. An Introduction to Probability Theory and its Applications, volume 1. John Wiley and Sons, New York, 1950.
- [117] M. Biehl and A. Mietzner. Statistical mechanics of unsupervised structure recognition. J. Phys. A, 27:1885, 1994.
- [118] T. L. H. Watkin and J-P. Nadal. Optimal unsupervised learning. J. Phys. A, 27:1899, 1994.
- [119] A. Buhaut, J.-M. T. Moreno, and M. Gordon. Finite size scaling of the Bayesian perceptron. Phys. Rev. E, 55:7434, 1997.
- [120] E. Lootens and C. Van den Broeck. Analysing cluster formation by replica method. Europhys. Lett., 30:381, 1995.
- [121] P. R. Krishnaiah and L. N. Kanal. Classification, Pattern Recognition, and Reduction of Dimensionality, volume 2. North Holland, Amsterdam, 1982.
- [122] S. Grossberg. Studies of the Mind and Brain. Reidel, Boston, 1982.
- [123] K. Rose, E. Gurewitz, and G. C. Fox. Statistical mechanics and phase transitions in clustering. Phys. Rev. Lett., 65:945, 1990.
- [124] N. Barkai and H. Sompolinsky. Statistical mechanics of the maximum-likelihood density estimation. Phys. Rev. E, 50:1766, 1994.
- [125] M. Blatt, S. Wiseman, and E. Domany. Superparamagnetic clustering of data. Phys. Rev. Lett., 76:3251, 1996.
- [126] N. Barkai, H. S. Seung, and H. Sompolinsky. Scaling laws in learning of classification tasks. Phys. Rev. Lett., 70:3167, 1993.
- [127] P. Reimann and C. Van den Broeck. Learning by examples from a nonuniform distribution. Phys. Rev. E, 53:3989, 1996.
- [128] C. Marangi, M. Biehl, and S. A. Solla. Supervised learning from clustered input examples. Europhys. Lett., 30:117, 1995.
- [129] D. Herschkowitz and M. Oppen. Retarded learning: rigorous results from statistical mechanics. Phys. Rev. Lett., to appear, 2001.
- [130] P. Reimann. Unsupervised learning of distributions. Europhys. Lett, 40:251, 1997.
- [131] G. Reents and R. Urbanczik. Self-averaging and on-line learning. Phys. Rev. Lett, 80:5445, 1998.
- [132] E. B. Baum. The perceptron algorithm is fast for nonmalicious distributions. Neural Comp., 2:248, 1990.
- [133] D. Saad, editor. On-line Learning in Neural Networks. Cambridge University Press, Cambridge, 1998.
- [134] M. Biehl and H. Schwarze. Learning by on-line gradient descent. J. Phys. A, 28:643, 1995.
- [135] W. Kinzel and P. Ruján. Improving a network generalization ability by selecting examples. Europhys. Lett., 13:473, 1990.
- [136] T. Heskes and B. Kappen. Learning processes in neural networks. Phys. Rev. A, 44:2718, 1990.
- [137] S. Amari and S. C. Douglas. Why natural gradient? In Proceedings of the 1998 IEEE International Conference on Acoustics, Speech and Signal Processing, page 1213, 1998.
- [138] O. Kinouchi and N. Caticha. Lower bounds on generalization errors for drifting rules. J. Phys. A, 26:2878, 1992.
- [139] M. Biehl and P. Riegler. On-line learning with a perceptron. Europhys. Lett., 28:525, 1994.

- [140] N. Barkai, H. S. Seung, and H. Sompolinsky. Local and global convergence of on-line learning. *Phys. Rev. Lett.*, 75:1415, 1995.
- [141] M. Biehl and H. Schwarze. Learning drifting concepts with neural networks. *J. Phys. A*, 26:2651, 1993.
- [142] O. Kinouchi and N. Caticha. Lower bounds on generalization errors for drifting rules. *J. Phys. A*, 26:6161, 1993.
- [143] O. Kinouchi. Biased learning in Boolean perceptrons. *Physica A*, 185:411, 1992.
- [144] T. L. H. Watkin and A. Rau. Selecting examples for perceptrons. *J. Phys. A*, 25:113, 1992.
- [145] J.-I. Inoue, H. Nishimori, and Y. Kabashima. On-line learning of non-monotonic rules by simple perceptron. *J. Phys. A*, 30:3795, 1997.
- [146] C. Van den Broeck and P. Reimann. Unsupervised learning by examples: on-line versus off-line. *Phys. Rev. Lett.*, 76:2188, 1996.
- [147] M. Oppen. On-line versus off-line learning from random examples: general results. *Phys. Rev. Lett.*, 77:4671, 1996.
- [148] M. Rattray, D. Saad, and S. Amari. Natural gradient descent for on-line learning. *Phys. Rev. Lett.*, 81:5461, 1998.
- [149] C. W. H. Mace and A. C. C. Coolen. Statistical mechanical analysis of the dynamics of learning in perceptrons. *Statistics and Computing*, 8:55, 1998.
- [150] J. W. Kim and H. Sompolinsky. On-line Gibbs learning. *Phys. Rev. Lett.*, 76:3021, 1996.
- [151] W. Kinzel and R. Urbanczik. On-line learning in a discrete state space. *J. Phys. A*, 31:L27, 1998.
- [152] P. Riegler, M. Biehl, S. A. Solla, and C. Marangi. In M. Marinaro and R. Tagliaferri, editors. On-line learning from clustered input examples. *Proc. 7th Italian Workshop on Neural Networks*. World Scientific, Singapore, 1996.
- [153] W. Hoeffding. On the distribution of the number of successes in independent trials. *Ann. Math. Statist.*, 27:713, 1956.
- [154] G. R. Shorak and J. A. Wellner. *Empirical Processes with Applications to Statistics*. Wiley, New York, 1986.
- [155] V. N. Vapnik. *Estimation of Dependences Based on Empirical Data*. Springer, Berlin, 1982.
- [156] N. Sauer. On the density of families of sets. *J. Comb. Th. A*, 13:145, 1972.
- [157] M. Anthony and N. Biggs. *Computational Learning Theory*. CUP, Cambridge, 1992.
- [158] E. Baum and D. Haussler. What size net gives valid generalization? *Neur. Comput.*, 1:151, 1989.
- [159] L. Devroye. Bounds for the uniform deviation of empirical measures. *J. Multivariate Anal.*, 12:72–79, 1982.
- [160] J. M. Parrondo and C. Van den Broeck. Vapnik–Chervonenkis bounds for generalization. *J. Phys. A*, 26:2211, 1993.
- [161] A. Engel and C. Van den Broeck. Replica calculation of the Vapnik–Chervonenkis bound for the perceptron. *Physica A*, 200:636–643, 1993.
- [162] A. Engel and C. Van den Broeck. Systems that can learn from examples: replica calculation of uniform convergence bounds for perceptrons. *Phys. Rev. Lett.*, 71:1772, 1993.
- [163] D. Haussler, M. Kearns, and R. Schapire. Bounds on the sample complexity of Bayesian learning using information theory and the VC dimension. In *Proceedings of the Fourth Annual Workshop on Computational Learning Theory*, page 61. Morgan Kaufmann, San Mateo, 1991.

- [164] T. Cover and J. Thomas. Elements of Information Theory. Wiley, New York, 1991.
- [165] A. Engel and W. Fink. Statistical mechanics calculation of Vapnik–Chervonenkis bounds for perceptrons. *J. Phys. A*, 26:6893, 1993.
- [166] A. Blumer, A. Ehrenfeucht, D. Haussler, and M. K. Warmuth. Learnability and the Vapnik–Chervonenkis dimension. *J. Assoc. Comput. Machinery*, 36:929, 1989.
- [167] Y. S. Abu-Mostafa. The Vapnik–Chervonenkis dimension: information versus complexity in learning. *Neur. Comput.*, 1:312–317, 1989.
- [168] V. N. Vapnik and A. Y. Chervonenkis. Theory of uniform convergence of frequency of appearance, attributes to their probabilities and problems of defining optimal solution by empiric data. *Avtomatika i Telemekhanika*, 2:42, 1971.
- [169] M. Biehl and M. Oppel. Perceptron learning: the largest version space. In J.-H. Oh, C. Kwon, and S. Cho, editors. *Neural Networks: The Statistical Mechanics Perspective*, page 59. World Scientific, Singapore, 1995.
- [170] M. Anthony and P. L. Bartlett. *Neural Network Learning: Theoretical Foundations*. Cambridge University Press, Cambridge, 1999.
- [171] V. N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, 1995.
- [172] J. Feder. *Fractals*. Plenum, New York, 1988.
- [173] T. Tél. Fractals, multifractals, and thermodynamics. *Z. Naturforsch.*, 43a:1154, 1988.
- [174] A. Engel and M. Weigt. Multifractal analysis of the coupling space of feedforward neural networks. *Phys. Rev. E*, 53:R2064, 1996.
- [175] U. Frisch and G. Parisi. Fully developed turbulence and intermittency. In M. Ghil, R. Benzi, and G. Parisi, editors. *Turbulence and Predictability in Geophysical Fluid Dynamics and Climate Dynamics*. North-Holland, 1985.
- [176] T. C. Halsey, M. H. Jensen, L. P. Kadanoff, I. Procaccia, and B. I. Shraiman. Fractal measures and their singularities: the characterization of strange sets. *Phys. Rev. A*, 33:1141, 1986.
- [177] R. Monasson and D. O’Kane. Domains of solutions and replica symmetry breaking in multilayer neural networks. *Europhys. Lett.*, 27:85, 1994.
- [178] M. Weigt. Multifractal analysis of perceptron learning with errors. *Phys. Rev. E*, 57:955, 1998.
- [179] M. Weigt and A. Engel. Multifractality and percolation in the phase space of neural networks. *Phys. Rev. E*, 55:4552, 1997.
- [180] P. Riegler and H. S. Seung. Vapnik–Chervonenkis entropy of the spherical perceptron. *Phys. Rev. E*, 55:3283, 1997.
- [181] C. Van den Broeck and G. J. Bex. Multifractal a-priori probability distribution for the perceptron. *Phys. Rev. E*, 57:3660–3663, 1998.
- [182] L. Reimers and A. Engel. Weight space structure and generalization in the reversed-wedge-perceptron. *J. Phys. A*, 29:3923, 1996.
- [183] G. J. Bex and C. Van den Broeck. Domain sizes of the Gardner volume for the Ising reversed wedge perceptron. *Phys. Rev. E*, 56:870, 1997.
- [184] R. Monasson and R. Zecchina. Weight space structure and internal representations: a direct approach to learning and generalization in multilayer neural networks. *Phys. Rev. Lett.*, 75:2432, 1995.
- [185] R. Monasson and R. Zecchina. Learning and generalization theories of large committee-machines. *Mod. Phys. Lett. B*, 9:1887, 1996.

- [186] S. Cocco, R. Monasson, and R. Zecchina. Analytical and numerical study of internal representations in multilayer neural networks with binary weights. *Phys. Rev. E*, 54:717, 1996.
- [187] M. Oppen, P. Kuhlmann, and A. Mietzner. Convexity, internal representations and the statistical mechanics of neural networks. *Europhys. Lett.*, 37:31, 1997.
- [188] J. S. Denker, D. Schwartz, B. Wittner, S. Solla, R. Howard, L. Jackel, and J. Hopfield. Large automatic learning, rule extraction, and generalization. *Complex Systems*, 1:877, 1987.
- [189] G. Cybenko. Approximation by superpositions of a sigmoidal function. *Math. Contr. Sign. Syst.*, 2:303, 1989.
- [190] A. N. Kolmogorov. On the representation of continuous functions of many variables by superposition of continuous functions of one variable and addition. *Dokl. Akad. Nauk SSSR*, 114:953, 1957.
- [191] A. Priel, M. Blatt, T. Grossmann, E. Domany, and I. Kanter. Computational capabilities of restricted two-layered perceptrons. *Phys. Rev. E*, 50:577, 1994.
- [192] N. J. Nilson. *Learning Machines*. McGraw-Hill, New York, 1965.
- [193] M. Oppen. Learning and generalization in a two-layer neural network: the role of the Vapnik–Chervonenkis dimension. *Phys. Rev. Lett.*, 72:2113, 1994.
- [194] G. Mato and N. Parga. Generalization properties of multilayered neural networks. *J. Phys. A*, 25:5047, 1992.
- [195] G. J. Mitchison and R. M. Durbin. Bounds on the learning capacity of some multi-layer networks. *Biol. Cybern.*, 60:345, 1989.
- [196] M. Oppen. Statistical-physics estimates for the complexity of feedforward neural networks. *Phys. Rev. E*, 51:3613, 1995.
- [197] E. Barkai, D. Hansel, and I. Kanter. Statistical mechanics of a multilayered neural network. *Phys. Rev. Lett.*, 65:2312, 1990.
- [198] E. Barkai, D. Hansel, and H. Sompolinsky. Broken symmetries in multilayered perceptrons. *Phys. Rev. A*, 45:4146, 1992.
- [199] A. Engel, H. M. Köhler, F. Tschepe, H. Vollmayr, and A. Zippelius. Storage capacity and learning algorithm for two-layer perceptrons. *Phys. Rev. A*, 45:7590, 1992.
- [200] A. Engel. Correlation of internal representations in feed-forward neural networks. *J. Phys. A*, 29:L323, 1996.
- [201] D. Malzahn and A. Engel. Correlations between hidden units in multilayer neural networks and replica symmetry breaking. *Phys. Rev. E*, 60:2097, 1999.
- [202] D. Malzahn, A. Engel, and I. Kanter. Storage capacity of correlated perceptrons. *Phys. Rev. E*, 55:7369, 1997.
- [203] R. Urbanczik. Storage capacity of the fully-connected committee machine. *J. Phys. A*, 30:L387, 1997.
- [204] Y. S. Xiong, C. Kwon, and J.-H. Oh. Storage capacity of a fully-connected parity machine with continuous weights. *J. Phys. A*, 31:7043, 1998.
- [205] H. Schwarze. Learning a rule in a multilayer neural network. *J. Phys. A*, 26:5781, 1993.
- [206] D. Hansel, G. Mato, and C. Meunier. Memorization without generalization in a multilayered neural network. *Europhys. Lett.*, 20:471, 1992.
- [207] H. Schwarze and J. Hertz. Generalization in a large committee machine. *Europhys. Lett.*, 20:375, 1992.

- [208] H. Schwarze and J. Hertz. Learning from examples in fully connected committee machines. *J. Phys. A*, 26:4919, 1993.
- [209] K. Kang, J.-H. Oh, C. Kwon, and Y. Park. Generalization in a two-layer neural network. *Phys. Rev. E*, 48:4805, 1993.
- [210] B. Schottky. Phase transitions in the generalization behaviour of multilayer neural networks. *J. Phys. A*, 28:4515, 1995.
- [211] H. Schwarze, M. Oppen, and W. Kinzel. Generalization in a two-layer neural network. *Phys. Rev. A*, 46:R6185, 1992.
- [212] O. Winther, B. Lautrup, and J.-B. Zhang. Optimal learning in multilayer neural networks. *Phys. Rev. E*, 55:836, 1997.
- [213] R. De Figueviedo. *J. Math. Anal.*, 38:1227, 1980.
- [214] M. Biehl and M. Oppen. Tiling-like learning in the parity machine. *Phys. Rev. A*, 44:6888, 1991.
- [215] M. Copelli and N. Caticha. Universal asymptotics in committee machines with tree architecture. In D. Saad, editor. *On-line Learning in Neural Networks*, page 165. Cambridge University Press, Cambridge, 1998.
- [216] R. Simonetti and N. Caticha. On-line learning in parity machines. *J. Phys. A*, 29:4859, 1996.
- [217] S. Saad and S. Solla. Exact solution for on-line learning in multilayer neural networks. *Phys. Rev. Lett.*, 74:4337, 1995.
- [218] D. Saad and S. Solla. On-line learning in soft committee machines. *Phys. Rev. E*, 52:4225, 1995.
- [219] M. Biehl, P. Riegler, and C. Wohler. Transient dynamics of on-line learning in two-layered neural networks. *J. Phys. A*, 29:4769, 1996.
- [220] Y. Chauvin and D. E. Rumelhart, editors. *Backpropagation: Theory, Architectures, and Applications*. Erlbaum, Hillsdale, NJ, 1995.
- [221] P. Riegler and M. Biehl. On-line backpropagation in two-layered neural networks. *J. Phys. A*, 28:L507, 1995.
- [222] M. J. Shervish. *Theory of Statistics*. Springer, New York, 1995.
- [223] O. Winther and S. Solla. Optimal Bayesian on-line learning. In K. Y. M. Wong, I. King, and D.-Y. Yeung, editors. *Theoretical Aspects of Neural Computation*, page 61. Springer, Berlin, 1997.
- [224] S. Solla and O. Winther. Optimal perceptron learning: an on-line Bayesian approach. In D. Saad, editor. *On-line Learning in Neural Networks*, page 379. Cambridge University Press, Cambridge, 1998.
- [225] Y. Kabashima. Perfect loss of generalization due to noise in  $K = 2$  parity machines. *J. Phys. A*, 27:1917, 1994.
- [226] M. Copelli and N. Caticha. On-line learning in the committee machine. *J. Phys. A*, 28:1615, 1995.
- [227] M. Copelli, O. Kinouchi, and N. Caticha. Equivalence between learning in noisy perceptrons and tree committee machines. *Phys. Rev. E*, 53:1615, 1996.
- [228] M. Copelli, R. Eichorn, O. Kinouchi, M. Biehl, R. Simonetti, P. Riegler, and N. Caticha. Noise robustness in multilayer neural networks. *Europhys. Lett.*, 37:427, 1997.
- [229] D. Saad and M. Rattray. Optimal on-line learning in multilayer neural networks. In D. Saad, editor. *On-line Learning in Neural Networks*, page 135. Cambridge University Press, Cambridge, 1998.
- [230] H. Sompolinsky and J. W. Kim. On-line Gibbs learning. i. general theory. *Phys. Rev. E*, 58:2335, 1998.

- [231] J. W. Kim and H. Sompolinsky. On-line Gibbs learning. ii. application to perceptron and multilayer networks. *Phys. Rev.*, (58):2348, 1998.
- [232] H. C. Rae, P. Sollich, and A. C. C. Coolen. On-line learning with restricted training sets: an exactly solvable case. *J. Phys. A*, 32:3321, 1999.
- [233] A. C. C. Coolen and D. Saad. Dynamics of supervised learning with restricted training sets. In D. Saad, editor. *On-line Learning in Neural Networks*, page 303. Cambridge University Press, Cambridge, 1998.
- [234] S. E. Fahlman. Fast-learning variations on back-propagation: an empirical study. In *Proceedings of the 1988 Connectionist Models Summer School*, page 38. Morgan Kaufmann, San Mateo, CA, 1988.
- [235] D. Ruelle and F. Takens. On the nature of turbulence. *Comm. Math. Phys.*, 20:167, 1971.
- [236] A. Lapides and R. Farber. How neural nets work. In D. Anderson, editor. *Neural Information Processing Systems*, page 442. American Institute of Physics, New York, 1988.
- [237] M. A. Aizerman, E. M. Braverman, and L. I. Rozonoer. Theoretical foundations of the potential function method in pattern recognition learning. *Automation and Remote Control*, 25:821, 1964.
- [238] B. E. Boser, I. Guyon, and V. N. Vapnik. A training algorithm for optimal margin classifiers. In *Proceedings of the 5th Workshop on Computational Learning Theory*, page 144, Pittsburgh, 1992. ACM.
- [239] R. Courant and D. Hilbert. *Methoden der mathematischen Physik*. Springer, Berlin, 1993.
- [240] C. M. Bishop. *Neural Networks for Pattern Recognition*. Cambridge University Press, Cambridge, 1995.
- [241] R. Dietrich, M. Oppen, and H. Sompolinsky. Statistical mechanics of support vector networks. *Phys. Rev. Lett.*, 82:2975, 99.
- [242] H. Yoon and J.-H. Oh. Learning of higher-order perceptrons with tunable complexities. *J. Phys. A*, 31:7771, 1998.
- [243] V. N. Vapnik. *Statistical Learning Theory*. John Wiley and Sons, New York, 1997.
- [244] N. Christianini and J. Shawe-Taylor. *An Introduction to Support Vector Machines*. Cambridge University Press, Cambridge, 2000.
- [245] A. R. Garey and D. S. Johnson. *Computers and Intractability: A Guide to the Theory of NP-completeness*. Freeman, San Francisco, 1979.
- [246] C. H. Papadimitriou. *Computational Complexity*. Addison-Wesley, Reading, MA, 1994.
- [247] S. A. Cook. The complexity of theorem-proving procedures. In *Proceedings of the 3rd Annual ACM Symposium on Theory of Computing*, page 151, 1971.
- [248] B. Hayes. Can't get no satisfaction. *American Scientist*, 85:108, 1997.
- [249] R. Monasson and R. Zecchina. Entropy of the K-satisfiability problem. *Phys. Rev. Lett.*, 76:3881, 1996.
- [250] K.-H. Borgwardt. Some distribution-independent results about the asymptotic order of the average number of pivot steps of the simplex method. *Math. Oper. Res.*, 7(3):441–462, 1982.
- [251] K.-H. Borgwardt. *The Simplex Method*. Springer, Berlin, 1987.
- [252] S. Kirkpatrick and G. Toulouse. Configuration space analysis of travelling salesman problems. *J. Physique*, 46:1277, 1985.
- [253] S. Kirkpatrick and B. Selman. Critical behavior in the satisfiability of random Boolean expressions. *Science*, 264:1297, 1994.



- [254] E. Korutcheva, M. Oppen, and B. López. Statistical mechanics of the knapsack problem. *J. Phys. A*, 27:L645, 1994.
- [255] J. Inoue. Statistical mechanics of the multi-constraint continuous knapsack problem. *J. Phys. A*, 30:1047, 1997.
- [256] R. Monasson and R. Zecchina. Statistical mechanics of the random K-satisfiability model. *Phys. Rev. E*, 56:1357, 1997.
- [257] S. Kirkpatrick, G. Györgyi, N. Tishby, and L. Troyansky. The statistical mechanics of k-satisfaction. In J. Cowan, G. Tesauro, and L. Troyansky, editors. *Advances in Neural Information Processing Systems*, volume 6, page 439. Morgan Kaufmann, San Mateo, 1994.
- [258] S. Mertens. Phase transition in the number partitioning problem. *Phys. Rev. Lett.*, 81:4281, 1998.
- [259] S. Mertens. Random costs in combinatorial optimization. *Phys. Rev. Lett.*, 84:1347, 2000.
- [260] C. E. Shannon. A mathematical theory of communication: I. *Bell. Sys. Tech. J.*, 27:379, 1948.
- [261] C. E. Shannon. A mathematical theory of communication: II. *Bell. Sys. Tech. J.*, 27:623, 1948.
- [262] N. Surlas. Spin-glass models as error-correcting codes. *Nature*, 339:693, 1989.
- [263] D. C. Mattis. Solvable spin systems with random interactions. *Phys. Lett.*, 56A:421, 1976.
- [264] D. Sherrington and S. Kirkpatrick. Solvable model of a spin glass. *Phys. Rev. Lett.*, 35:1792, 1975.
- [265] Y. Kabashima and D. Saad. Statistical mechanics of error-correcting codes. *Europhys. Lett.*, 45:97, 1999.
- [266] N. Surlas. Spin glasses, error-correcting codes and finite-temperature decoding. *Europhys. Lett.*, 25:159, 1994.
- [267] P. Ruján. Finite temperature error-correcting codes. *Phys. Rev. Lett.*, 70:2968, 1993.
- [268] H. Nishimori. Optimum decoding temperature for error-correcting codes. *J. Phys. Soc. Jpn.*, 62:2973, 1993.
- [269] H. Nishimori and K. Y. M. Wong. Statistical mechanics of image restoration and error-correcting codes. *Phys. Rev. E*, 60:132, 1999.
- [270] I. Kanter and D. Saad. Error-correcting codes that nearly saturate Shannon's bound. *Phys. Rev. Lett.*, 83:2660, 2000.
- [271] J. von Neumann and O. Morgenstern. *Theory of Games and Economic Behavior*. Princeton Press, Princeton, 1953.
- [272] J. F. Nash. Non-cooperative games. *Annals of Mathematics*, 54(2):286–95, 1951.
- [273] R. Axelrod. *The Evolution of Cooperation*. Basic Books, New York, 1984.
- [274] W. Jianhua. *The Theory of Games*. Oxford University Press, Oxford, 1988.
- [275] J. Berg and A. Engel. Matrix games, mixed strategies, and statistical mechanics. *Phys. Rev. Lett.*, 81:4999, 1998.
- [276] J. Berg and M. Weigt. Entropy and typical properties of Nash equilibria in two-player games. *Europhys. Lett.*, 48:129, 1999.
- [277] J. Berg. Statistical mechanics of random two-player games. *Phys. Rev. E*, 61:2327, 2000.
- [278] S. Diederich and M. Oppen. Replicators with random interactions: a solvable model. *Phys. Rev. A*, 39:4333, 1989.
- [279] M. Oppen and S. Diederich. Phase transition and  $1/f$  noise in a game dynamical model. *Phys. Rev. Lett.*, 69:1616, 1992.

- [280] V. Peter. Minimax games, spin glasses, and the polynomial-time hierarchy of complexity classes. *Phys. Rev. E*, 57:6487, 1998.
- [281] D. Challet, M. Marsili, and R. Zecchina. Statistical mechanics of systems with heterogeneous agents: minority games. *Phys. Rev. Lett.*, 84:1824, 2000.
- [282] J. Mathews and R. L. Walker. *Mathematical Methods of Physics*. Addison-Wesley, Redwood City, 1970.
- [283] C. M. Bender and S. A. Orszag. *Advanced Mathematical Methods for Scientists and Engineers*. McGraw-Hill, Auckland, 1978.
- [284] J. R. L. de Almeida and D. Thouless. Stability of the Sherrington–Kirkpatrick solution of a spin glass model. *J. Phys. A*, 11:983, 1978.
- [285] T. Temesvári, C. De Dominicis, and I. Kondor. Block diagonalizing ultrametric matrices. *J. Phys. A*, 27:7569, 1994.
- [286] C. De Dominicis, M. Carlucci, and T. Temesvári. Replica fourier transforms on ultrametric trees, and block-diagonalizing multi-replica matrices. *J. Physique I*, 7:105, 1997.
- [287] L. Onsager. Electric moments of molecules in liquids. *J. Am. Chem. Soc.*, 58:1486–1493, 1936.
- [288] D. J. Thouless, P. W. Anderson, and R. G. Palmer. Solution of 'solvable model of a spin glass'. *Phil. Mag.*, 35:593, 1977.
- [289] K. Y. M. Wong. Microscopic equations and stability conditions in optimal neural networks. *Europhys. Lett.*, 30:245, 1995.
- [290] M. Mézard. The space of interactions in neural networks: Gardner's computation with the cavity method. *J. Phys. A*, 22:2181, 1989.
- [291] M. Griniasty. 'Cavity-approach' analysis of the neural-network learning problem. *Phys. Rev. E*, 47:4496, 1993.
- [292] T. Plefka. Convergence condition of the TAP equation for the infinite-ranged Ising spin glass model. *J. Phys. A*, 15:1971, 1982.

# 索引

- adaline rule, 39, 60
- adatron rule, 41, 61
  - on-line, 154, 172
- aligning field, 34, 126, 150
- annealed approximation, 18, 28, 65
  - for the Ising parity tree, 233
  - for the Ising perceptron, 95, 106, 122
  - for the Ising reversed wedge perceptron, 117, 123
  - for multilayer networks, 216
- annealed entropy, 20
- annealing of the learning rate, 154
- attractor neural networks, 2, 85
- back-propagation, 39, 159, 251
- basin of attraction, 89
- batch learning, 149
- Bayes rule, 42, 62, 63, 147, 168
  - on-line, 253
- cavity method, 147, 304
- clipping, 119, 123
- clustering, 137, 142
- combinatorial optimization, 263
- committee machine, 211
- committee tree, 225, 237
- competitive learning, 137
- correlated perceptrons, 222
- cost function, 49, 56, 62, 152
  - in optimization problems, 263
- Cover method, 89, 199, 208, 214
- Cramér–Rao bound, 176, 186, 192
- cumulative Gibbs error, 185
- de Almeida–Thouless threshold, 68, 298, 309
- delta rule, 39
- dichotomy, 89, 105, 190
- discontinuous learning, 109
  - dynamics of, 118
  - in the Ising perceptron, 112
  - in multilayer networks, 230
  - in the reversed wedge perceptron, 116
- Dvoretzky–Kiefer–Wolfowitz theorem, 191
- embedding strength, 36, 41, 260
- energetic part, 21, 110, 216, 286
- entropic part, 21, 110, 216, 286
  - for Ising couplings, 111
- error-correcting codes, 266
- error-versus-rejection, 66, 102
- exhaustive search, 263
- feature space, 260
- feed-forward neural networks, 3, 209
- first order phase transition, 112, 121
- Fisher information, 186, 192
- Fisher matrix, 169, 187
- formal neurons, 1, 209
- free energy, 54
- fully connected architecture, 212, 228
- game theory, 270
- Gardner method, 22, 87, 199, 282
- Gaussian measure, 275
- general position of examples, 90, 105, 215

- generalization error, 10, 15, 176
- Gibbs rule, 16, 37, 45, 52, 59
  - unsupervised, 134
- grandmother cells, 232
- growth function, 178
- Hebb rule, 33, 59, 149
  - clipped, 120
  - for the committee tree, 239
  - unsupervised, 127, 129, 147
  - using queries, 162
- high–low game, 13, 47, 173, 191
- high-temperature learning, 56, 65, 218
- Hoeffding inequality, 177, 180
- Hubbard–Stratonovich transformation, 275
- hypothesis space, 177
- infomax principle, 127
- information gain, 27, 31, 160, 185
- input noise, 70, 77
- instability of a saddle point, 281
- internal representation, 259
  - in multilayer networks, 210
  - in the reversed wedge perceptron, 114
  - multifractal characterization of, 203
- Ising committee tree, 234
- Ising perceptron, 110, 111, 201
  - one-step replica symmetry breaking, 300
  - stability of replica symmetry, 291
  - storage problem, 93
- Jensen’s inequality, 276
- K-means algorithm, 139
- kernel, 261
- knapsack problem, 263
- Kuhn–Tucker conditions, 41
- learning amplitude, 149, 165
  - optimal, 156, 166, 240
- learning by dilution, 106
- learning error, 56
- learning rate, 39, 41, 152, 160, 170
  - critical, 160
  - optimal, 160, 172
- learning rule, 9, 61, 62
- least action algorithm, 243, 257
- linearly separable classification, 14, 90, 209, 260
- matrix game, 270
- maximal variance competitive learning, 148
- maximally stable rule, 40, 49, 260
- maximum likelihood prediction, 254
- minover algorithm, 40
- Mitchison–Durbin bound, 216
- mixed strategy, 272
- multifractal spectrum, 195, 207
- multifractal technique, 193, 198, 201
  - for multilayer networks, 220
  - for the reversed wedge perceptron, 205
- multilayer networks, 4, 113, 171, 209
- Nash equilibrium, 271
- natural gradient, 169
- nearest neighbour classifier, 32
- Nishimori temperature, 268
- noisy teacher, 69
- non-overlapping receptive fields, 212
- NP-complete problem, 119, 264
- number partitioning problem, 263
- Occam’s razor, 182, 251
- off-line learning, 149
- Oja’s rule, 127

- on-line learning, 149, 209
  - in multilayer networks, 237
  - unsupervised, 165
- optimal learning, 63
  - on-line, 154, 155
  - unsupervised, 135
- output noise, 70, 81, 147, 257
- over-fitting, 51, 75, 76, 78, 79, 81, 82
- over-realizable learning problem, 212, 232, 246
- overlapping receptive fields, 212
- PAC learning, 11
- palimpsest, 84
- parity machine, 211
- parity tree, 222, 243
- partial committee symmetry, 229
- partition function, 54
- payoff matrix, 271
- perceptron rule, 36, 59, 153, 154, 172
  - convergence proof, 289
- perfect generalization, 112, 117, 122
- permutation symmetry of hidden units, 222
- plateaus in the learning curve, 167, 170
  - of multilayer networks, 229, 244, 251
  - of support vector machines, 262
- posterior probability distribution, 134, 254
- prediction error, 70
- principal component analysis, 127
- projection rule, 38
- pseudo-inverse rule, 37, 40, 47, 49, 61, 66
- quenched entropy, 22
- queries, 160
  - in the committee tree, 256
- query by committee, 165
- quick-prop, 257
- radial basis function networks, 261
- random energy model, 98, 220, 268
- replica symmetry, 24, 197, 287
  - stability of, 68, 96, 103, 106, 291
- replica symmetry breaking,
  - full Parisi scheme, 104
  - in the Ising perceptron, 97, 112
  - in the multifractal technique, 200
  - one-step, 96, 115, 300
- replica trick, 23, 282
  - $n \rightarrow 1$  version, 25, 81, 122, 223
- residual error, 71
- retarded learning
  - in the parity tree, 216, 223, 245
  - in the reversed wedge perceptron, 116
  - in unsupervised learning, 129, 146
- reversed wedge perceptron, 114, 147, 174, 203, 269
- rule space, 177
- saddle point method, 279
- satisfiability problem, 264
- Sauer's lemma, 178, 190
- self-averaging, 12, 22, 28, 150, 189, 265, 305
- Shannon bound, 266
- spherical perceptron, 93
- sign-constrained couplings, 106
- simulated annealing, 119, 265
- smooth networks, 47, 109, 159
- soft committee machine, 246
- specialization of hidden units, 229, 249
- stability of a classification, 34
  - distribution of, 98, 107
- stability threshold, 86

- Stirling formula, 280
- stochastic gradient descent, 149
- storage capacity, 86, 88, 190
  - of the parity tree, 216
  - of the reversed wedge perceptron, 115, 123
- storage problem, 85
  - for multilayer networks, 218
- support vector machines, 259
- support vectors, 260
- teacher–student overlap, 15, 71
- thermodynamic limit, 11, 16, 22, 193
- training error, 10, 52
- training set, 9, 177
- travelling salesman problem, 263
- tree-structured architecture, 212
- unbiased estimator, 186
- unrealizable learning problem, 69, 82, 122, 212, 246
- unsupervised learning, 125
- Vapnik–Chervonenkis bound, 176, 180, 184, 310
- VC dimension, 179, 190
  - of the committee tree, 228
  - of the parity machine, 218
  - of the parity tree, 224
  - of support vector machines, 260
- version space, 15, 110, 181
- weight noise, 70, 77, 147
- winner takes all, 140
- worst case, 11, 28, 45, 178, 265
- worst compatible student, 182
- worst teacher, 192, 208
- zero-entropy criterion, 97, 113, 116, 208